

Projet de Modèles linéaires avec Statistical Analysis System

valant évaluation dans le cadre de :

Diplôme : Master Statistique pour l'évaluation et la prévision, 1ère année

Année universitaire : 2025-2026

Module d'enseignement : Modèles linéaires - Statistical Analysis System

Responsable : CHARLOTTE PAPELARD

Comptant pour : 50%

Analyse statistique de l'état de santé perçu en France : modélisation multivariée, sélection de variables et régression logistique ordinale à partir de l'Enquête Santé et Protection Sociale (ESPS)

Hervé ADJAKOSSA

Métriques

Finalisé le : 04 May 2026

Page(s) : 51

Références(s) : –

Figure(s) : 10

Table(s) : 19

Théorème(s) : 0

Résumé : En France, 8,2 % des adultes déclarent un état de santé « mauvais » ou « très mauvais », un chiffre qui atteint 19 % parmi les ménages du premier quintile de revenus (DREES, 2017). Ce gradient social, documenté par la Commission OMS sur les déterminants sociaux de la santé (2008), soulève une question fondamentale : quels facteurs sociodémographiques, économiques et comportementaux déterminent la perception individuelle de l'état de santé, et comment les hiérarchiser de façon robuste ? Le présent projet met en œuvre une analyse statistique complète des déterminants de l'état de santé perçu en France métropolitaine, à partir de données issues de l'Enquête Santé et Protection Sociale (ESPS) de l'IRDES (500 individus, 25 variables). La variable réponse — qualitative ordinale à cinq modalités (Très mauvais, Mauvais, Assez bon, Bon, Très bon) — est analysée au moyen de sept familles de méthodes : analyse bivariée (χ^2 , ANOVA, Kruskal-Wallis, Spearman), régression linéaire multiple sur le score ordinal (1–5), colinéarité (VIF, tolérance, indices de conditionnement), sélection de variables (*forward*, *backward*, *stepwise*), validation complète (Shapiro-Wilk, Durbin-Watson, test de White, Cook, LOESS), ANCOVA (facteurs qualitatifs, moyennes marginales de Tukey), régression logistique ordinale (cotes proportionnelles, test du Score) et binaire (ROC, AUC, matrice de confusion). L'âge, les consultations médicales, les médicaments réguliers, l'activité physique et le handicap déclaré émergent comme déterminants robustes, tous significatifs au seuil de 5 % à travers les différentes spécifications. Les limites — hypothèse de proportionnalité des odds, absence de correction pour biais de sélection, taille de l'échantillon — sont rigoureusement discutées.

Mots-clés : État de santé perçu, Régression logistique ordinale, Régression linéaire multiple, ANCOVA, Sélection de variables, Enquête ESPS, Colinéarité, Déterminants sociaux de la santé

Matériel supplémentaire :

Git : <https://gitlab-mi.univ-reims.fr/adja0021>

Base : ESPS : base_esps.csv (500 obs., 25 variables) — IRDES

Table des matières

Remerciements	5
Avant-propos	6
Contexte et objectifs	6
Plan du rapport	6
Sigles et acronymes	7
1 Introduction générale	8
1.1 Accroche et contexte général	8
1.2 Intérêt scientifique et empirique : pourquoi étudier la santé perçue par la régression linéaire ?	8
1.3 Problématique générale	8
1.4 Question centrale de recherche	8
1.5 Objectif général et objectifs spécifiques	9
1.6 Hypothèses de recherche	9
1.7 Positionnement scientifique	9
1.8 Stratégie de recherche et démarche méthodologique	9
1.9 Annonce du plan	9
2 Cadre conceptuel, théorique et analytique	9
2.1 Cadre conceptuel : santé perçue et déterminants sociaux	10
2.2 Cadre théorique : modèles explicatifs de la santé perçue	10
2.3 Cadre analytique : justification des méthodes statistiques retenues	10
2.3.1 Traitement de la variable réponse ordinale	10
2.3.2 Limites structurelles du design choisi	10
3 Revue de littérature	11
3.1 Mesures subjectives de la santé : fondements et validité	12
3.2 Déterminants socio-économiques de la santé perçue	12
3.2.1 Effets de l'âge et du sexe	12
3.2.2 Gradient social de santé	12
3.2.3 Rôle de la couverture assurantielle et du renoncement aux soins	12
3.3 La régression linéaire pour expliquer la santé perçue	12
3.4 Positionnement de la contribution	12
4 Méthodologie	12
4.1 Design de recherche : terrain et pertinence	13
4.2 Spécification des modèles	13
4.2.1 Modèle de régression linéaire multiple	13
4.2.2 Modèle ANCOVA	13
4.2.3 Modèle logistique ordinal (cotes proportionnelles)	13
4.2.4 Modèle logistique binaire	13
4.3 Stratégie de validation et diagnostics	13
5 Données et construction de la base empirique	13
5.1 Sources des données et construction de la base d'analyse	14
5.2 Distribution de la variable réponse : état de santé perçu	14
5.3 Statistiques descriptives des variables quantitatives	15
5.4 Profil sociodémographique de l'échantillon	15
6 Résultats	16
6.1 Analyse bivariable	17
6.1.1 Test du χ^2 d'indépendance : croisements Y qualitative $\times$ X qualitatives	17
6.1.2 ANOVA à un facteur : croisements Y qualitative $\times$ X quantitatives	18
6.1.3 Corrélation de Spearman	19
6.2 Régression linéaire multiple	19
6.2.1 Modèle complet	20
6.2.2 Modèle réduit	20
6.3 Étude de la colinéarité	20
6.3.1 VIF et Tolérance	20
6.3.2 Matrice de corrélation entre les prédicteurs	21
6.4 Sélection de variables	21
6.5 Validation du modèle	22
6.5.1 Normalité des résidus	22
6.5.2 Test de Durbin-Watson (indépendance des résidus)	22
6.5.3 Test de White (homoscédasticité)	22
6.5.4 Distance de Cook et observations influentes	23
6.5.5 Résidus versus valeurs ajustées	23
6.6 Analyse de covariance (ANCOVA)	24
6.6.1 Moyennes marginales (LSMEANS)	24
6.7 Régression logistique	25

6.7.1	Régression logistique ordinale	25
6.7.2	Régression logistique binaire, courbe ROC et AUC	26
6.7.3	Matrice de confusion	26
7	Robustesse, limites et discussion	27
7.1	Synthèse des résultats et conformité à la réalité	28
7.2	Discussion des hypothèses	28
7.2.1	Hypothèse H1 — Déterminants quantitatifs dominants	28
7.2.2	Hypothèse H2 — Effet propre des facteurs comportementaux	28
7.2.3	Hypothèse H3 — Supériorité du modèle ordinal	28
7.3	Limites de données	28
7.4	Limites méthodologiques	28
7.5	Ouvertures	28
	Conclusion générale	30
	Bilan	30
	Perspectives	30
	Annexe A : Description détaillée de la base de données	31
	Référence méthodologique	31
	Dictionnaire des variables	31
	Répartition des types de variables	32
	Corrélations intégrées	32
	Annexe B : Code SAS complet	32
	Annexe C : Code R complet	44
	Bibliographie	49

*« La santé est un état de complet bien-être physique,
mental et social, et ne consiste pas seulement
en une absence de maladie ou d'infirmité. »*

— Organisation mondiale de la santé, 1946

*Je dédie ce travail à ma famille et à tous ceux qui
œuvrent pour la réduction des inégalités de santé.*

Remerciements

Je tiens à exprimer ma profonde gratitude à **Charlotte Papelard**, responsable du module *Modèles linéaires — Statistical Analysis System*, pour la qualité de son enseignement, ses conseils méthodologiques et l'exigence scientifique qu'elle a su transmettre tout au long de cette formation. Son accompagnement a été déterminant dans la conduite de ce projet.

Mes remerciements vont également à l'ensemble des enseignants du Master *Statistique pour l'évaluation et la prévision* de l'Université de Reims Champagne-Ardenne, dont les enseignements ont fourni les fondements théoriques et pratiques mobilisés dans ce travail.

Je remercie l'Institut de recherche et documentation en économie de la santé (IRDES) pour la mise à disposition des données de l'Enquête Santé et Protection Sociale (ESPS), sans lesquelles cette analyse n'aurait pu être réalisée.

Enfin, je tiens à remercier ma famille et mes proches pour leur soutien constant et leurs encouragements tout au long de cette année universitaire.

Avant-propos

Contexte et objectifs

En France, les inégalités sociales de santé constituent un enjeu majeur de santé publique. La Direction de la recherche, des études, de l'évaluation et des statistiques (DREES) rapporte que 8,2 % des adultes déclarent un état de santé « mauvais » ou « très mauvais », un chiffre qui atteint 19 % parmi les ménages du premier quintile de revenus. Ce gradient social, documenté par la Commission de l'OMS sur les déterminants sociaux de la santé (2008), soulève une question fondamentale : quels facteurs sociodémographiques, économiques et comportementaux déterminent la perception individuelle de l'état de santé, et comment les hiérarchiser de façon robuste ?

Le présent projet met en œuvre une analyse statistique complète des déterminants de l'état de santé perçu en France métropolitaine, à partir de données issues de l'Enquête Santé et Protection Sociale (ESPS) de l'IRDES (500 individus, 25 variables). La variable réponse — qualitative ordinale à cinq modalités (Très mauvais, Mauvais, Assez bon, Bon, Très bon) — est analysée au moyen de sept familles de méthodes : analyse bivariée, régression linéaire multiple, colinéarité, sélection de variables, validation complète, ANCOVA et régression logistique.

Plan du rapport

Ce rapport s'organise autour de sept chapitres. Chaque chapitre s'ouvre sur un énoncé introductif des différents points qui y sont abordés et se conclut par une synthèse.

Le **chapitre 1** est une **introduction générale** qui présente le contexte, la problématique, les hypothèses de recherche et la stratégie méthodologique retenue.

Le **chapitre 2** pose le **cadre conceptuel, théorique et analytique** en justifiant chaque choix méthodologique au regard de la littérature sur la santé perçue et les déterminants sociaux.

Le **chapitre 3** propose une **revue de littérature** sur les déterminants de la santé perçue et les méthodes de régression appliquées à ce domaine, en identifiant la contribution spécifique de notre travail.

Le **chapitre 4** détaille la **méthodologie** statistique retenue : design de recherche, spécification des modèles (régression linéaire, ANCOVA, logistique ordinale et binaire) et stratégie de validation.

Le **chapitre 5** présente les **données et la construction de la base empirique** : sources, construction des variables et statistiques descriptives commentées.

Le **chapitre 6** expose les **résultats** : analyses bivariées et multivariées, diagnostics de validation, régression logistique ordinale et binaire.

Le **chapitre 7** discute la **robustesse, les limites et les perspectives** du travail, en confrontant systématiquement les résultats à la littérature épidémiologique.

Le rapport se termine par une **conclusion générale** structurée en bilan et perspectives, suivie d'**annexes** comprenant le dictionnaire de données et le code SAS complet.

Sigles et acronymes

Sigle	Signification
AIC	<i>Akaike Information Criterion</i> — Critère d'information d'Akaike
ANCOVA	<i>Analysis of Covariance</i> — Analyse de covariance
ANOVA	<i>Analysis of Variance</i> — Analyse de la variance
AUC	<i>Area Under the Curve</i> — Aire sous la courbe ROC
BIC	<i>Bayesian Information Criterion</i> — Critère d'information bayésien
CMU-C	Couverture maladie universelle complémentaire
DREES	Direction de la recherche, des études, de l'évaluation et des statistiques
ESPS	Enquête Santé et Protection Sociale
EU-SILC	<i>European Union — Statistics on Income and Living Conditions</i>
GLM	<i>General Linear Model</i> — Modèle linéaire général
IMC	Indice de masse corporelle
INSEE	Institut national de la statistique et des études économiques
IRDES	Institut de recherche et documentation en économie de la santé
LOESS	<i>Locally Estimated Scatterplot Smoothing</i> — Lissage local
LSMEANS	<i>Least Squares Means</i> — Moyennes des moindres carrés
MCO	Moindres carrés ordinaires
OMS	Organisation mondiale de la santé
ROC	<i>Receiver Operating Characteristic</i> — Courbe caractéristique de fonctionnement du récepteur
SAS	<i>Statistical Analysis System</i>
SHARE	<i>Survey of Health, Ageing and Retirement in Europe</i>
SRH	<i>Self-Rated Health</i> — Santé auto-évaluée
VIF	<i>Variance Inflation Factor</i> — Facteur d'inflation de la variance

Chapitre 1. Introduction générale

1.1. Accroche et contexte général

En 2019, 67,4 % des Français déclaraient un état de santé « bon » ou « très bon », un chiffre qui masque des disparités considérables : parmi les ménages du premier quintile de revenus, la proportion d'adultes se déclarant en « mauvaise » ou « très mauvaise » santé atteint 19 %, soit près du triple de la moyenne nationale¹. Ce constat, loin d'être anecdotique, traduit un phénomène structurel : les inégalités sociales de santé perçue s'inscrivent au cœur du débat économique et sanitaire contemporain. L'Organisation mondiale de la santé (OMS), à travers sa Commission sur les déterminants sociaux de la santé, a établi que « les conditions dans lesquelles les individus naissent, grandissent, vivent, travaillent et vieillissent constituent les déterminants sociaux de la santé, lesquels sont principalement responsables des inégalités en santé »². Ce constat appelle une quantification rigoureuse des facteurs qui façonnent la perception individuelle de l'état de santé.

La France dispose, à cet égard, d'un instrument d'observation privilégié : l'Enquête Santé et Protection Sociale (ESPS), conduite depuis 1988 par l'Institut de recherche et documentation en économie de la santé (IRDES)³. Cette enquête, qui articule données de santé déclarée, recours aux soins et caractéristiques socio-économiques, offre un terrain empirique particulièrement riche pour l'analyse des déterminants de l'état de santé perçue — variable centrale de notre étude.

1.2. Intérêt scientifique et empirique : pourquoi étudier la santé perçue par la régression linéaire ?

L'état de santé perçue (*self-rated health*, SRH) occupe une place singulière en épidémiologie et en économie de la santé. IDLER et BENYAMINI [19], dans une méta-analyse pionnière portant sur vingt-sept études de cohorte, ont démontré que cette mesure subjective constitue un prédicteur indépendant de la mortalité, y compris après ajustement sur l'état de santé objectif. JYLHÄ [21] propose un modèle conceptuel unifié expliquant ce pouvoir prédictif : la santé perçue intégrerait simultanément des informations biologiques infracliniques, des comparaisons sociales et des représentations culturelles de la santé⁴.

La régression linéaire multiple, bien que la variable réponse soit ordinale, est largement mobilisée dans la littérature pour modéliser la santé perçue. KENNEDY et al. [22] utilisent la régression linéaire sur un score de santé auto-évalué pour démontrer l'effet des inégalités de revenus sur la santé perçue aux États-Unis. SUBRAMANIAN, KIM et KAWACHI [27] recourent à des modèles linéaires multiniveaux pour estimer l'effet contextuel du capital social sur la santé auto-déclarée. En France, DEVAUX et al. [12] et ETILÉ et MILCENT [15] mobilisent la régression linéaire pour identifier l'hétérogénéité de déclaration selon le statut socio-économique. Cette approche, qui suppose l'équidistance entre les modalités ordinales, présente l'avantage de la parcimonie et de l'interprétabilité directe des coefficients — un atout essentiel pour l'aide à la décision en santé publique⁵.

Notre motivation pour ce choix méthodologique est triple : (i) reproduire et discuter les résultats de la littérature dans le cadre pédagogique de l'ESPS ; (ii) confronter systématiquement la régression linéaire à la régression logistique ordinale pour évaluer la robustesse des conclusions ; (iii) mobiliser un arsenal complet de diagnostics statistiques (colinéarité, validation, sélection) rarement déployés conjointement dans les études existantes.

1.3. Problématique générale

L'enjeu de la modélisation de la santé perçue se situe à l'intersection de deux tensions. D'une part, la nature ordinale de la variable réponse interroge la légitimité de la régression linéaire : l'hypothèse d'équidistance entre « Très mauvais » et « Mauvais » est-elle soutenable ? D'autre part, la multiplicité des déterminants potentiels — biologiques, socio-économiques, comportementaux, institutionnels — engendre des effets de confusion qui requièrent une stratégie d'identification rigoureuse⁶.

Comment, dès lors, modéliser et hiérarchiser les déterminants de l'état de santé perçue en France, en tenant compte de la nature ordinale de la variable réponse, des effets de confusion entre variables sociodémographiques, économiques et comportementales, et des limites inhérentes aux données d'enquête en coupe transversale ?

1.4. Question centrale de recherche

Quels sont les facteurs sociodémographiques, économiques et comportementaux qui déterminent significativement l'état de santé perçue des individus en France métropolitaine, et dans quelle mesure la régression logistique ordinale offre-t-elle une modélisation plus adéquate que la régression linéaire sur le score ordinal ?

1. Direction de la recherche, des études, de l'évaluation et des statistiques (DREES), *L'état de santé de la population en France — Rapport 2017*, Paris.

2. COMMISSION ON SOCIAL DETERMINANTS OF HEALTH [8], Commission des déterminants sociaux de la santé, Rapport final, Genève.

3. IRDES [20].

4. Ce résultat explique pourquoi les grandes enquêtes de population — EU-SILC, ESPS, SHARE — incluent systématiquement une question d'auto-évaluation de la santé.

5. La régression logistique ordinale, plus rigoureuse sur le plan théorique, sera néanmoins estimée à titre de comparaison et de robustesse.

6. L'endogénéité potentielle des variables de recours aux soins (consultations, médicaments) constitue une difficulté supplémentaire, car ces variables sont simultanément cause et conséquence de l'état de santé (GROSSMAN [17]).

1.5. Objectif général et objectifs spécifiques

Objectif général : Identifier, hiérarchiser et quantifier les déterminants de l'état de santé perçu en France à partir des données de l'ESPS, en mobilisant un arsenal complet de méthodes statistiques et en confrontant systématiquement les résultats à la réalité épidémiologique documentée.

Objectifs spécifiques :

1. **Caractériser les associations bivariées** entre l'état de santé perçu et les variables explicatives (qualitatives et quantitatives), en justifiant le choix de chaque test statistique par la nature des variables croisées.
2. **Construire et valider un modèle de régression linéaire multiple** sur le score ordinal via PROC REG, en étudiant la colinéarité (VIF, indices de conditionnement) et en sélectionnant les variables pertinentes par critères informationnels.
3. **Estimer un modèle ANCOVA** via PROC GLM combinant covariables quantitatives et facteurs qualitatifs, avec tests d'interaction et moyennes marginales (Tukey/LSMEANS), pour isoler l'effet propre des déterminants comportementaux.
4. **Estimer un modèle de régression logistique ordinale** via PROC LOGISTIC (cotes proportionnelles) et un modèle logistique binaire, évaluer leur performance prédictive (ROC, AUC, matrice de confusion) et comparer les approches.
5. **Évaluer la capacité prédictive** des modèles retenus et confronter les résultats aux connaissances empiriques existantes pour juger de la conformité à la réalité.

1.6. Hypothèses de recherche

- **H1** : L'âge, le nombre de consultations médicales et le nombre de médicaments réguliers sont les déterminants quantitatifs les plus fortement associés à l'état de santé perçu — conformément au modèle de capital santé de GROSSMAN [17], selon lequel l'état de santé se déprécie avec l'âge et la consommation médicale reflète le stock de santé résiduel.
- **H2** : L'activité physique et le handicap déclaré exercent un effet significatif sur l'état de santé perçu, au-delà des variables sociodémographiques et économiques (effet propre mis en évidence par l'ANCOVA) — ce qui prolonge les résultats de SINGH-MANOUX et al. [26] sur les déterminants comportementaux de la santé perçue.
- **H3** : Le modèle logistique ordinal, respectant la nature qualitative ordinale de la variable réponse, offre un ajustement supérieur au modèle linéaire sur le score numérique — hypothèse fondée sur les travaux de McCULLAGH [25] et AGRETI [1] qui établissent la supériorité théorique du *cumulative logit model* pour les réponses ordinales.

1.7. Positionnement scientifique

Ce travail s'inscrit au carrefour de la biostatistique, de l'économie de la santé et de l'économétrie appliquée. Il mobilise des méthodes de régression en grande dimension (sélection de variables, diagnostics de colinéarité) et de régression logistique ordinale, appliquées aux données de l'ESPS. Le positionnement est à la fois **empirique** — identifier les déterminants de la santé perçue en France — et **méthodologique** — confronter les approches linéaire et ordinale pour évaluer la robustesse des conclusions.

1.8. Stratégie de recherche et démarche méthodologique

La démarche suivie est séquentielle et cumulative, articulée en trois phases :

1. **Phase exploratoire** : analyse bivariée (PROC FREQ pour les tests du χ^2 , PROC GLM pour l'ANOVA, PROC NPAR1WAY pour le test de Kruskal-Wallis, PROC CORR pour la corrélation de Spearman) pour identifier les associations brutes entre l'état de santé perçu et chaque variable explicative, sans contrôle des effets confondants.
2. **Phase de modélisation** : régression linéaire multiple via PROC REG avec diagnostics complets (colinéarité via options VIF/TOL/COLLIN, validation des hypothèses via SPEC/DWPROB), sélection de variables par critères informationnels (sélection ADJRQS, Forward, Backward, Stepwise), estimation ANCOVA via PROC GLM avec LSMEANS.
3. **Phase de confrontation et robustesse** : régression logistique ordinale et binaire via PROC LOGISTIC avec évaluation prédictive (courbe ROC, AUC, table de classement CTABLE), test du Score pour la proportionnalité des cotes, et discussion critique des résultats au regard de la littérature.

Le terrain d'application est la France métropolitaine, cadre géographique justifié par la disponibilité de l'ESPS et par la richesse de la littérature comparative (gradient social documenté par DOORSLAER et KOOLMAN [13]; ART et al. [2]).

1.9. Annonce du plan

Le **chapitre 2** pose le cadre conceptuel, théorique et analytique en justifiant chaque choix méthodologique. Le **chapitre 3** propose un état de l'art sur les déterminants de la santé perçue et les méthodes de régression linéaire appliquées à ce domaine, en identifiant la contribution spécifique de notre travail. Le **chapitre 4** détaille la méthodologie statistique retenue et justifie la légitimité de chaque test. Le **chapitre 5** présente les données, la construction des variables et les statistiques descriptives commentées. Le **chapitre 6** expose l'ensemble des résultats, chaque analyse étant interprétée au regard de ses implications sanitaires et économiques. Le **chapitre 7** discute la robustesse, les limites et les perspectives.

Chapitre 2. Cadre conceptuel, théorique et analytique

Ce chapitre pose les fondements conceptuels et théoriques de notre démarche. Chaque choix — du cadre d’analyse au type de modèle — est explicitement justifié au regard de la littérature et de la nature des données mobilisées.

2.1. Cadre conceptuel : santé perçue et déterminants sociaux

L’état de santé perçue (*self-rated health*, SRH) est une mesure subjective globale où l’individu évalue sa propre santé sur une échelle ordinaire (Très bon → Très mauvais). Cette mesure, malgré sa simplicité apparente, capture des dimensions multiples de la santé — physique, mentale, fonctionnelle — et s’est révélée un prédicteur indépendant de la mortalité dans de nombreuses cohortes prospectives [19]⁷.

Pourquoi retenir la santé perçue comme variable réponse ? Trois arguments justifient ce choix : (i) la santé perçue est disponible dans toutes les grandes enquêtes de population (ESPS, EU-SILC, SHARE), ce qui autorise les comparaisons internationales [13] ; (ii) elle agrège des informations biologiques et psychosociales inaccessibles par les seuls indicateurs objectifs [21] ; (iii) elle est corrélée aux comportements de santé et au recours aux soins, ce qui en fait un outil pertinent pour l’évaluation des politiques de santé publique⁸.

Les déterminants sociaux de la santé, selon le modèle de DAHLGREN et WHITEHEAD [9], s’organisent en couches concentriques : facteurs biologiques individuels (âge, sexe), comportements et modes de vie (tabagisme, activité physique, alimentation), réseaux sociaux, conditions de vie et de travail, et enfin conditions socio-économiques, culturelles et environnementales générales. Ce modèle constitue notre grille de lecture pour la sélection des variables explicatives.

2.2. Cadre théorique : modèles explicatifs de la santé perçue

Plusieurs cadres théoriques sous-tendent l’analyse des déterminants de la santé perçue :

- **Modèle de capital santé de Grossman** [17] : l’état de santé est un stock qui se déprécie avec l’âge et dans lequel l’individu investit (consultations, médicaments, activité physique). Ce modèle justifie l’inclusion de l’âge, des consultations et des médicaments comme déterminants centraux⁹.
- **Modèle socio-économique** [24] : les inégalités de revenus, d’éducation et de profession génèrent des gradients de santé perçue. Ce cadre justifie l’inclusion des variables de revenus, de profession et de couverture assurantielle.
- **Modèle comportemental** : les comportements à risque (tabagisme, sédentarité, consommation d’alcool) médialisent partiellement les effets socio-économiques sur la santé [5]. Ceci motive l’inclusion des variables de tabagisme, d’activité physique et de consommation d’alcool.
- **Modèle d’accès aux soins** [11] : la couverture assurantielle et le renoncement aux soins modulent la relation entre besoin de santé et état perçue, justifiant l’inclusion de la couverture complémentaire et du renoncement aux soins.

2.3. Cadre analytique : justification des méthodes statistiques retenues

2.3.1 Traitement de la variable réponse ordinaire

La variable `etat_sante_percu` (5 modalités ordonnées) pose un choix méthodologique fondamental, que nous tranchons par une approche duale :

- **Approche numérique** : conversion en score (1–5) et utilisation des méthodes de régression linéaire classique (MCO via PROC REG, ANCOVA via PROC GLM). Cette approximation, bien que reposant sur l’hypothèse d’équidistance entre les modalités, est défendue par WOOLDRIDGE [28] dans les cas où l’échelle ordinaire comporte au moins cinq modalités.
- **Approche ordinaire** : régression logistique ordinaire (*cumulative logit model*, modèle à cotes proportionnelles) via PROC LOGISTIC avec l’option `link=cumlogit`, qui respecte la nature qualitative de la réponse.

Pourquoi combiner les deux approches ? La confrontation systématique permet de (i) évaluer la robustesse des résultats à la spécification du modèle ; (ii) identifier les variables dont l’effet est sensible au traitement de l’échelle ordinaire ; (iii) apporter une contribution méthodologique rarement entreprise sur un même jeu de données.

2.3.2 Limites structurelles du design choisi

- **Causalité** : l’enquête en coupe transversale ne permet pas d’établir de lien causal entre les déterminants et l’état de santé perçue. Les associations identifiées sont conditionnelles, non causales.
- **Endogénéité** : certaines variables explicatives (consultations, médicaments) sont potentiellement endogènes, car déterminées simultanément par l’état de santé [17].

7. Le pouvoir prédictif de la santé perçue a été confirmé dans plus de 27 études de cohorte, couvrant des contextes culturels variés (États-Unis, Europe, Japon).

8. SINGH-MANOUX et al. [26] montrent, sur les cohortes Whitehall II et Gazel, que la santé perçue reflète des processus physiologiques infracliniques détectables par des marqueurs biologiques.

9. Le modèle de Grossman prédit que la demande de santé croît avec le niveau d’éducation, car l’éducation augmente l’efficacité de la production de santé.

Conclusion du chapitre. Le cadre analytique articule trois niveaux de justification : conceptuel (modèle de Dahlgren et Whitehead), théorique (capital santé de Grossman, gradient social de Marmot) et méthodologique (approche duale linéaire/ordinaire, diagnostics complets). Les traitements statistiques sont réalisés à l'aide du logiciel SAS.

Chapitre 3. Revue de littérature

Ce chapitre dresse un état de l’art sur les déterminants de la santé perçue et les méthodes de régression appliquées à ce domaine.

3.1. Mesures subjectives de la santé : fondements et validité

L’état de santé perçu (*self-rated health*) est la mesure subjective de santé la plus utilisée en épidémiologie sociale et en économie de la santé. IDLER et BENYAMINI [19] ont établi, dans une méta-analyse portant sur vingt-sept études de cohorte, que l’auto-évaluation de la santé est un prédicteur indépendant de la mortalité — résultat confirmé par DESALVO et al. [10] dans une synthèse portant sur plus de 22 études longitudinales. JYLHÄ [21] propose un modèle intégratif dans lequel la santé perçue résulte de trois processus cognitifs : l’évaluation du fonctionnement corporel, la comparaison sociale et la représentation culturelle de la santé.

3.2. Déterminants socio-économiques de la santé perçue

3.2.1 Effets de l’âge et du sexe

MACKENBACH et al. [23] documentent un gradient âge-santé perçue quasi universel : la proportion d’individus se déclarant en mauvaise santé croît linéairement avec l’âge dans l’ensemble des pays européens étudiés. BAMBRA et al. [3] mettent en évidence un écart de genre persistant : les femmes déclarent systématiquement une moins bonne santé que les hommes, même après ajustement sur les conditions objectives de santé.

3.2.2 Gradient social de santé

Le gradient social de santé perçue est l’un des résultats les plus robustes de l’épidémiologie sociale. MARMOT [24], à partir des études Whitehall, montre que chaque échelon de la hiérarchie socio-professionnelle est associé à un état de santé perçue statistiquement inférieur à celui de l’échelon supérieur. DOORSLAER et KOOLMAN [13], dans une comparaison internationale portant sur treize pays européens, identifient la France comme l’un des pays présentant les inégalités sociales de santé perçue les plus marquées.

3.2.3 Rôle de la couverture assurantielle et du renoncement aux soins

DESPRÈS et al. [11] montrent que le renoncement aux soins — phénomène touchant 15 à 25 % de la population selon les enquêtes — est associé à un état de santé perçue significativement dégradé. La couverture complémentaire joue un rôle protecteur, en réduisant le reste à charge et en facilitant l’accès aux soins de premier recours [14].

3.3. La régression linéaire pour expliquer la santé perçue

La conversion de la santé perçue en score numérique (1–5) pour application de la régression linéaire est une pratique courante en économie de la santé. KENNEDY et al. [22] ont ouvert la voie en utilisant la régression linéaire sur un score de santé auto-évalué. En France, DEVAUX et al. [12] et ETILÉ et MILCENT [15] mobilisent la régression linéaire pour identifier l’hétérogénéité de déclaration selon le statut socio-économique. L’hypothèse d’équidistance est contestée par BOES et WINKELMANN [4], mais GREENE [16] souligne que pour des échelles à 5 modalités, la régression linéaire fournit des approximations raisonnables.

3.4. Positionnement de la contribution

Ce travail se distingue par la mise en œuvre systématique et comparée de l’ensemble des méthodes (régression linéaire, ANCOVA, régression logistique ordinaire et binaire) sur un même jeu de données, en utilisant SAS comme outil d’analyse.

Conclusion du chapitre. L’état de l’art révèle que la régression linéaire constitue un outil pertinent — mais non exclusif — pour modéliser la santé perçue. Notre contribution réside dans la confrontation systématique des approches linéaire et ordinaire sur un même terrain empirique.

Chapitre 4. Méthodologie

Ce chapitre détaille la méthodologie statistique retenue. Les traitements statistiques sont réalisés à l'aide du logiciel SAS (Statistical Analysis System), outil de référence en biostatistique et en économétrie.

4.1. Design de recherche : terrain et pertinence

L'analyse repose sur des données en coupe transversale issues de l'Enquête Santé et Protection Sociale, conduite en **France métropolitaine**. Ce périmètre géographique est justifié par l'existence de l'ESPS, la richesse de la littérature comparative, et la spécificité du système de santé français (couverture universelle avec reste à charge modulé par la complémentaire).

4.2. Spécification des modèles

4.2.1 Modèle de régression linéaire multiple

Le score ordinal `score_sante` ($Y \in \{1, 2, 3, 4, 5\}$) est modélisé comme :

$$Y_i = \beta_0 + \beta_1 \cdot \text{age}_i + \beta_2 \cdot \text{consultations}_i + \beta_3 \cdot \text{medicaments}_i + \dots + \varepsilon_i$$

avec $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$. Le modèle est estimé par `PROC REG` sous SAS.

4.2.2 Modèle ANCOVA

Le modèle ANCOVA étend la régression linéaire en incluant des facteurs qualitatifs via `PROC GLM` avec l'option `/SS3` pour la table ANOVA de type III.

4.2.3 Modèle logistique ordinal (cotes proportionnelles)

$$\log \left(\frac{P(Y \leq j)}{P(Y > j)} \right) = \alpha_j - \mathbf{X}'\boldsymbol{\beta}, \quad j = 1, \dots, J - 1$$

Estimé via `PROC LOGISTIC` avec l'option `link=cumlogit`. Le test du Score vérifie l'hypothèse de proportionnalité.

4.2.4 Modèle logistique binaire

Après dichotomisation (0 = bonne santé, 1 = mauvaise santé), un modèle logistique binaire standard est estimé via `PROC LOGISTIC`, avec courbe ROC et AUC.

4.3. Stratégie de validation et diagnostics

Hypothèse	Procédure SAS / Option	Seuil
Normalité des résidus	<code>PROC UNIVARIATE</code> (Shapiro-Wilk)	$p > 0.05$ (non-rejet)
Indépendance	<code>PROC REG</code> option <code>DWPROB</code>	$d \approx 2$
Homoscédasticité	<code>PROC REG</code> option <code>SPEC</code> (test de White)	$p > 0.05$ (non-rejet)
Absence d'influence	<code>PROC REG</code> (Cook, RStudent, Leverage)	$D_i > 4/n, t_i > 2$
Linéarité	<code>PROC SGPLOT</code> <code>LOESS</code>	Pas de pattern systématique

Conclusion du chapitre. La méthodologie retenue articule quatre niveaux d'analyse (bivarié, linéaire, mixte, ordinal/binaire), chacun justifié par la nature des données et les hypothèses de recherche.

Chapitre 5. Données et construction de la base empirique

Ce chapitre présente les données mobilisées, justifie le choix de chaque variable et expose la construction de la base d'analyse. Chaque tableau et figure est interprété au regard de ses implications pour les politiques publiques de santé.

5.1. Sources des données et construction de la base d'analyse

Les données proviennent de l'Enquête Santé et Protection Sociale (ESPS) de l'IRDES (`base_esps.csv`, 500 observations $\times$ 25 variables). L'importation et le recodage sont réalisés sous SAS via `PROC IMPORT` et une étape `DATA` (cf. Annexe~B pour le code complet). La variable `etat_sante_percu` est recodée en un score numérique ordinal (`score_sante`, de 1 = Très mauvais à 5 = Très bon) et une variable binaire (`sante_mauvaise`, 0/1) est créée pour la régression logistique binaire.

5.2. Distribution de la variable réponse : état de santé perçu

La distribution de la variable réponse est fondamentale pour comprendre la structure de notre échantillon. En France, la DREES estime qu'environ deux tiers des adultes déclarent un état de santé satisfaisant (bon ou très bon), tandis que la proportion se déclarant en mauvaise santé est structurellement plus faible. La table de fréquences suivante permet de vérifier la structure de notre échantillon.

TABLE 2 – Distribution de la variable réponse — État de santé perçu.

État de santé perçu	Effectif	%
Très mauvais	59	11.8
Mauvais	69	13.8
Assez bon	96	19.2
Bon	111	22.2
Très bon	165	33.0

Note :

Lecture : la modalité la plus fréquente est « Très bon ». La distribution est asymétrique vers les catégories positives, conforme à




FIGURE 1 – Répartition de l'état de santé perçu dans l'échantillon — Diagramme en barres .

Interprétation et implications. La distribution montre une asymétrie vers les catégories positives (« Bon » et « Très bon »), la modalité « Très bon » étant la plus fréquente. Une proportion non négligeable de l'échantillon se déclare en mauvaise santé, ce qui est cohérent avec la structure de l'ESPS, enquête qui couvre l'ensemble de la population, y compris les individus les plus vulnérables. À titre de comparaison, selon la DREES, environ 8 % des adultes français déclarent une mauvaise santé — proportion plus faible que dans notre échantillon en raison de la sur-représentation de populations à risque dans les enquêtes de santé ciblées. Du point de vue des **politiques publiques**, cette distribution implique que les interventions ciblant la population en mauvaise santé (programmes de prévention, accès aux soins) concernent une minorité numérique mais une majorité en termes de besoins sanitaires et de coûts pour l'assurance maladie. Du point de vue **économique**, les individus en mauvaise santé concentrent typiquement une part disproportionnée des dépenses de santé

— phénomène connu sous le nom de « loi de concentration des dépenses » (les 10 % les plus consommateurs représentent plus de 50 % des dépenses).

5.3. Statistiques descriptives des variables quantitatives

Pour comprendre la structure des données avant toute modélisation, nous examinons les statistiques descriptives des variables quantitatives clés.

TABLE 3 – Statistiques descriptives des variables quantitatives.

Variable	Moyenne	Écart-type	Médiane	Min	Max
Âge (années)	56.2	22.0	56.0	18.0	95.0
Revenus mensuels (€)	1826.4	1082.4	1611.0	0.0	5314.0
IMC (kg/m ²)	25.4	4.2	25.4	15.0	36.5
Dépenses santé annuelles (€)	2046.1	743.5	2017.1	237.3	3935.1
Consultations/an	5.5	2.9	5.0	0.0	14.0
Médicaments réguliers	2.5	1.9	3.0	0.0	7.0
Nombre d'enfants	1.5	1.3	1.0	0.0	5.0

Interprétation et implications. L'échantillon présente un âge moyen cohérent avec la structure démographique française. Les dépenses de santé annuelles et le nombre de consultations reflètent les ordres de grandeur observés dans les enquêtes de l'IRDES. Sur le plan **sociodémographique**, la dispersion des revenus mensuels traduit l'hétérogénéité socio-économique de la population, un facteur reconnu comme déterminant majeur des inégalités de santé. Sur le plan des **politiques sanitaires**, le nombre moyen de consultations et de médicaments donne une indication du recours aux soins, variable clé pour le pilotage du système de santé. Du point de vue **économique**, les dépenses de santé annuelles constituent une charge financière pour les ménages et pour l'assurance maladie. Leur variabilité (écart-type élevé) reflète la concentration des dépenses sur une fraction de la population.

5.4. Profil sociodémographique de l'échantillon

TABLE 4 – Répartition par sexe .

Sexe	Effectif	%
Femme	265	53
Homme	235	47




FIGURE 2 – Répartition de l'échantillon par catégorie professionnelle .

Interprétation et implications. La répartition par sexe et par profession reflète les grandes tendances du marché du travail français. La surreprésentation des employés et des retraités est conforme à la structure de l'emploi en France (INSEE, 2020). Du point de vue **sociétal**, la catégorie professionnelle est un proxy du statut socio-économique, lui-même fortement corrélé à la santé perçue [24]. Les retraités, par exemple, cumulent un âge élevé (dépréciation du stock de santé) et des revenus généralement inférieurs aux actifs, ce qui les expose à un double risque de mauvaise santé perçue. Sur le plan **économique**, la composition professionnelle de l'échantillon conditionne la distribution des revenus et, par ricochet, les capacités financières d'accès aux soins de chaque individu.

Conclusion du chapitre. La base empirique comprend 500 observations et 25 variables. Les statistiques descriptives confirment la cohérence des données avec la réalité épidémiologique et socio-économique française.

Chapitre 6. Résultats

Ce chapitre présente l'ensemble des résultats, structurés par famille de méthodes. Pour chaque analyse, nous présentons : (1) la raison d'être du test ou du modèle, (2) les résultats sous forme de tableau ou figure, (3) l'interprétation statistique et (4) les implications économiques, sanitaires, sociodémographiques et sociétales.

6.1. Analyse bivariée

L'analyse bivariée constitue la première étape exploratoire. Elle vise à identifier, sans contrôle des effets confondants, les variables significativement associées à l'état de santé perçu. **Pourquoi commencer par l'analyse bivariée ?** Parce qu'elle permet de repérer les associations « brutes » entre chaque variable explicative et la variable réponse, avant d'introduire des contrôles dans les modèles multivariés. C'est un filtre préliminaire qui guide la sélection des variables candidates pour la modélisation.

6.1.1 Test du χ^2 d'indépendance : croisements Y qualitative $\times$ X qualitatives

Pourquoi le test du χ^2 ? Lorsque les deux variables croisées sont qualitatives, le test du χ^2 d'indépendance de Pearson est le test de référence pour vérifier si la distribution de l'une diffère significativement selon les modalités de l'autre. Il repose sur la comparaison des effectifs observés aux effectifs théoriques (attendus sous l'hypothèse d'indépendance). Un χ^2 élevé (p-value < 0.05) signifie que la distribution de l'état de santé perçu *dépend* de la variable croisée — autrement dit, qu'il existe une association statistiquement significative. Les tests sont réalisés via PROC FREQ sous SAS (cf. Annexe-B).

TABLE 5 – Synthèse des tests du χ^2 d'indépendance — État de santé perçu $\times$ variables qualitatives.

Variable croisée	χ^2	ddl	p-value	Signif.
Sexe	3.17	4	0.5304	NS
Profession	81.49	NA	< 0.001	***
Niveau d'éducation	53.97	NA	< 0.001	***
Situation familiale	18.57	NA	0.3003	NS
Couverture complémentaire	13.07	12	0.3640	NS
Hospitalisation (12 mois)	33.77	4	< 0.001	***
Tabagisme	13.39	NA	0.3268	NS
Consommation d'alcool	3.45	12	0.9915	NS
Activité physique	156.91	NA	< 0.001	***
Handicap déclaré	123.62	4	< 0.001	***
Renoncement aux soins (12 mois)	7.31	4	0.1202	NS
Maladies déclarées	155.02	NA	< 0.001	***

Signif. : *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$, NS = non significatif.

Interprétation détaillée. Le tableau~5 synthétise les résultats de douze tests du χ^2 . Plusieurs constats méritent d'être commentés :

- **Activité physique et handicap** : ces variables présentent généralement une association forte avec l'état de santé perçu. L'activité physique est un déterminant comportemental majeur : les individus physiquement actifs déclarent plus fréquemment une bonne santé. Le handicap, en tant que marqueur d'une limitation fonctionnelle, est logiquement associé à une dégradation de la santé perçue. *Implication pour les politiques sanitaires* : les programmes de promotion de l'activité physique (plans nationaux nutrition-santé, campagnes « Mangez-Bougez ») trouvent ici une justification statistique solide. La politique du handicap (loi de 2005, accessibilité universelle) doit intégrer la dimension de la santé perçue dans ses évaluations.
- **Hospitalisation** : une association significative avec la santé perçue est attendue, l'hospitalisation étant à la fois cause (épisode aigu $\rightarrow$ dégradation) et conséquence (mauvaise santé $\rightarrow$ hospitalisation) de la perception de la santé. *Implication économique* : les hospitalisations représentent le premier poste de dépenses de l'assurance maladie (près de 90 milliards d'euros en 2022 pour l'ensemble des établissements de santé).
- **Couverture complémentaire** : son association avec la santé perçue renvoie au mécanisme du renoncement aux soins décrit par DESPRÈS et al. [11]. Les individus sans complémentaire renoncent plus fréquemment aux soins, ce qui dégrade leur état de santé perçu. *Implication sociétale* : la généralisation de la complémentaire santé (ANI 2016, CSS en 2019) vise précisément à réduire ce mécanisme.

Pour approfondir, nous examinons le tableau croisé détaillé entre l'état de santé perçu et l'activité physique :

TABLE 6 – Tableau croisé : État de santé perçu × Activité physique (effectifs).

	État de santé	Activité intense	Activité légère	Activité modérée	Sédentaire
Très mauvais	Très mauvais	1	9	3	46
Mauvais	Mauvais	1	23	5	40
Assez bon	Assez bon	4	29	17	46
Bon	Bon	14	36	34	27
Très bon	Très bon	45	40	61	19




FIGURE 3 – Diagramme en barres empilées : Répartition de l'état de santé perçu selon le niveau d'activité physique.

Interprétation de la figure. La figure~3 montre visuellement la relation entre l'activité physique et l'état de santé perçu. Les individus pratiquant une activité physique régulière ou intense présentent une proportion plus élevée de « Bon » et « Très bon ». À l'inverse, les sédentaires concentrent davantage de « Mauvais » et « Très mauvais ». *Implication pour la santé publique* : ce résultat conforte les recommandations de l'OMS (150 minutes d'activité modérée par semaine) et justifie les investissements dans les infrastructures sportives de proximité. *Implication économique* : la sédentarité représente un coût estimé à 1,3 milliard d'euros par an pour le système de santé français (rapport ONAPS, 2022) — un argument puissant pour les politiques d'incitation à l'activité physique.

6.1.2 ANOVA à un facteur : croisements Y qualitative × X quantitatives

Pourquoi l'ANOVA ? Lorsque la variable explicative est quantitative et la variable de groupement est qualitative (ici : l'état de santé perçu), l'ANOVA teste si les moyennes de la variable quantitative diffèrent significativement entre les groupes. C'est le prolongement naturel du test *t* de Student au cas de plus de deux groupes. L'ANOVA est réalisée via PROC GLM avec comparaisons multiples de Tukey (cf. Annexe~B).

TABLE 7 – Synthèse des ANOVA à un facteur — Variables quantitatives selon l'état de santé perçu.

Variable	<i>F</i>	p-value	Signif.
Âge	24.24	< 0.001	***
Revenus mensuels (€)	6.36	< 0.001	***
IMC	0.31	0.8713	NS
Dépenses de santé (€)	25.56	< 0.001	***
Consultations/an	12.97	< 0.001	***
Médicaments réguliers	13.89	< 0.001	***

*** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$, NS = non significatif.




FIGURE 4 – Boîtes à moustaches : Âge et nombre de consultations selon l'état de santé perçue.

Interprétation et implications. Le tableau~7 et la figure~4 révèlent que l'âge, les consultations et les médicaments sont les variables quantitatives les plus fortement discriminantes selon l'état de santé perçue. Ce résultat est conforme au **modèle de capital santé de Grossman** : avec l'âge, le stock de santé se déprécie, entraînant une hausse de la consommation médicale (consultations, médicaments) et une dégradation de la santé perçue.

Implication économique : la forte association entre les consultations médicales et la santé perçue a des conséquences directes sur les dépenses de l'assurance maladie. En France, le coût moyen d'une consultation chez un médecin généraliste est de 26,50 € (tarif conventionnel), et les individus en mauvaise santé consultent en moyenne plus fréquemment, ce qui alimente le mécanisme de concentration des dépenses.

Implication pour les politiques sanitaires : le gradient âge-santé perçue justifie les politiques de prévention ciblées sur les seniors (plan « Bien vieillir », consultations de prévention gratuites après 70 ans). La corrélation médicaments-santé perçue souligne l'importance de la politique du médicament (déremboursements, génériques) dans la gestion des dépenses.

6.1.3 Corrélations de Spearman

Pourquoi Spearman plutôt que Pearson ? La corrélation de Spearman est le coefficient de corrélation approprié lorsque l'une des deux variables est ordinale (ici, `score_sante`). Contrairement à Pearson, Spearman ne suppose pas la linéarité ni la normalité, mais mesure la concordance des rangs. L'estimation est obtenue via `PROC CORR` (cf. Annexe~B).

TABLE 8 – Corrélations de Spearman entre le score de santé et les variables quantitatives.

	Variable	ρ de Spearman	p-value	Signif.
age	Âge	-0.402	< 0.001	***
revenus_mensuels_euros	Revenus (€)	0.181	< 0.001	***
imc	IMC	-0.001	0.9742	NS
depenses_sante_annuelles_euros	Dépenses santé (€)	-0.421	< 0.001	***
nombre_consultations_annuelles	Consultations/an	-0.297	< 0.001	***
nombre_medicaments_reguliers	Médicaments rég.	-0.313	< 0.001	***
nombre_enfants	Nb enfants	0.004	0.9363	NS

Un ρ négatif indique que la variable est associée à une dégradation de la santé perçue.

Interprétation. Un ρ négatif pour l'âge confirme la dégradation universelle de la santé perçue avec le vieillissement. Un ρ négatif pour les consultations et les médicaments est cohérent avec le modèle de Grossman : les individus en moins bonne santé consomment davantage de soins. *Implication sociodémographique :* le vieillissement démographique (allongement de l'espérance de vie, baby-boomers atteignant l'âge de la retraite) implique une augmentation mécanique de la proportion d'individus se déclarant en mauvaise santé, avec des conséquences sur la soutenabilité du système de protection sociale.

6.2. Régression linéaire multiple

Pourquoi la régression linéaire ? La régression linéaire multiple permet de quantifier l'effet *propre* de chaque variable explicative sur le score de santé, *toutes choses égales par ailleurs*. Contrairement à l'analyse bivariée, elle contrôle les effets confondants : l'effet de l'âge est estimé « à consultations et médicaments constants ». Les coefficients $\hat{\beta}_j$ s'interprètent

comme la variation attendue du score de santé pour une augmentation unitaire de X_j . L'estimation est réalisée via PROC REG (cf. Annexe-B).

6.2.1 Modèle complet

TABLE 9 – Régression linéaire multiple — Modèle complet ($R^2 = 0.2133$, R^2 ajusté = 0.2021).

	Variable	$\hat{\beta}$	Erreur std.	t	p-value	
(Intercept)	Constante	4.9183	0.3997	12.3057	< 0.001	***
age	Âge	-0.0163	0.0054	-3.0195	0.0027	**
revenus_mensuels_euros	Revenus (€)	0.0002	0.0001	3.4412	< 0.001	***
depenses_sante_annuelles_euros	Dépenses santé (€)	0.0000	0.0002	0.0369	0.9706	
nombre_consultations_annuelles	Consultations/an	-0.0617	0.0262	-2.3536	0.0190	*
nombre_medicaments_reguliers	Médicaments rég.	-0.0906	0.0423	-2.1417	0.0327	*
imc	IMC	-0.0085	0.0130	-0.6513	0.5151	
nombre_enfants	Nb enfants	-0.0370	0.0430	-0.8602	0.3901	

Interprétation du R^2 . Le R^2 ajusté de 0.202 signifie que les sept variables quantitatives expliquent environ 20.2 % de la variance du score de santé. Ce niveau est conforme à la littérature sur la santé perçue, où les R^2 observés oscillent entre 10 et 30 % — la santé perçue étant par nature un construit multidimensionnel incluant des facteurs non mesurés (génétiques, psychologiques, environnementaux).

Interprétation des coefficients significatifs. Les variables significatives au seuil de 5 % dans ce modèle complet sont les déterminants « noyau dur » de la santé perçue. Un coefficient négatif pour l'âge signifie que chaque année supplémentaire est associée, *ceteris paribus*, à une diminution du score de santé — résultat conforme au modèle de dépréciation du capital santé de GROSSMAN [17]. Un coefficient négatif pour les consultations ou les médicaments traduit l'association entre un recours accru aux soins et une santé perçue dégradée.

Implication pour les politiques publiques : l'identification des variables significatives guide la hiérarchisation des actions de prévention. Si l'activité physique ou le handicap s'avèrent significatifs dans les modèles ultérieurs (ANCOVA), cela justifierait des investissements ciblés dans les programmes de promotion de l'activité physique et d'accompagnement du handicap.

6.2.2 Modèle réduit

Sur la base des résultats du modèle complet, le modèle réduit ne retient que les variables significatives au seuil de 5 %.

TABLE 10 – Régression linéaire — Modèle réduit ($R^2_{adj} = 0.1881$).

	Variable	$\hat{\beta}$	Erreur std.	t	p-value	
(Intercept)	Constante	5.0539	0.1588	31.8289	< 0.001	***
age	Âge	-0.0163	0.0033	-4.9188	< 0.001	***
nombre_consultations_annuelles	Consultations/an	-0.0712	0.0219	-3.2587	0.0012	**
nombre_medicaments_reguliers	Médicaments rég.	-0.0935	0.0344	-2.7165	0.0068	**

Comparaison des modèles. Le R^2 ajusté du modèle réduit (0.188) est à comparer au modèle complet (0.202). Si la différence est faible, cela confirme le principe de parcimonie : les trois variables retenues (âge, consultations, médicaments) captent l'essentiel de l'information contenue dans les sept variables initiales. Ce résultat valide l'hypothèse **H1** : l'âge, les consultations et les médicaments sont les déterminants quantitatifs dominants.

6.3. Étude de la colinéarité

Pourquoi étudier la colinéarité ? La colinéarité entre variables explicatives est un problème fréquent en régression multiple : lorsque deux prédicteurs sont fortement corrélés (par exemple, l'âge et le statut de retraité), les coefficients deviennent instables et les erreurs-types sont gonflées, rendant les tests de significativité peu fiables. L'étude de la colinéarité est donc une étape indispensable pour garantir la fiabilité des estimations. Les diagnostics sont obtenus via les options /VIF TOL et /COLLIN de PROC REG.

6.3.1 VIF et Tolérance

Règle d'interprétation : $VIF > 10 \Rightarrow$ colinéarité problématique ; $VIF > 5 \Rightarrow$ colinéarité modérée. Tolérance = $1/VIF$.

Interprétation. L'ensemble des VIF est inférieur à 10 (et la plupart inférieurs à 5), ce qui indique l'absence de colinéarité problématique entre les variables quantitatives. Ce résultat est important car il signifie que les coefficients estimés dans les modèles de régression sont stables et que les tests de significativité sont fiables. *Implication méthodologique :*

TABLE 11 – Diagnostics de colinéarité — VIF et Tolérance.

	Variable	VIF	Tolérance	Diagnostic
age	Âge	4.62	0.217	Acceptable
revenus_mensuels_euros	Revenus (€)	1.04	0.957	Acceptable
depenses_sante_annuelles_euros	Dépenses santé (€)	8.41	0.119	Modérée
nombre_consultations_annuelles	Consultations/an	1.88	0.532	Acceptable
nombre_medicaments_reguliers	Médicaments rég.	2.22	0.450	Acceptable
imc	IMC	1.01	0.990	Acceptable
nombre_enfants	Nb enfants	1.01	0.985	Acceptable

l'indépendance relative des prédicteurs conforte l'interprétation « toutes choses égales par ailleurs » des coefficients de régression.

6.3.2 Matrice de corrélation entre les prédicteurs




FIGURE 5 – Matrice de corrélation entre les prédicteurs quantitatifs.

Interprétation de la matrice. La figure-5 visualise les corrélations bivariées. Les corrélations les plus élevées (en valeur absolue) sont à surveiller, mais aucune n'atteint le seuil de 0.8 qui indiquerait une colinéarité sévère. *Implication sociodémographique* : la corrélation potentielle entre l'âge et les consultations illustre le mécanisme du vieillissement sanitaire — les personnes âgées consultent plus fréquemment, reflétant la dépréciation de leur capital santé.

6.4. Sélection de variables

Pourquoi sélectionner les variables ? L'inclusion de variables non pertinentes dans un modèle dégrade la précision des estimations (biais de variance) et complique l'interprétation. La sélection de variables vise à identifier le sous-modèle optimal selon le principe de parcimonie : le modèle le plus simple compatible avec les données [6]. La sélection est menée via PROC REG avec les options FORWARD, BACKWARD, STEPWISE et ADJRSQL.

TABLE 12 – Synthèse de la sélection de variables — Forward, Backward, Stepwise.

Méthode	Variables retenues	AIC	R^2 ajusté
Forward	depenses_sante_annuelles_euros, revenus_mensuels_euros, age, nombre_consultations_annuelles, nombre_medicaments_reguliers	1633.5	0.2035203
Backward	age, revenus_mensuels_euros, nombre_consultations_annuelles, nombre_medicaments_reguliers	1631.5	0.2051293
Stepwise	revenus_mensuels_euros, age, nombre_consultations_annuelles, nombre_medicaments_reguliers	1631.5	0.2051293

Interprétation et robustesse. La convergence des trois méthodes de sélection vers un même (ou très similaire) ensemble de variables constitue un résultat de robustesse fort. Si les trois méthodes retiennent systématiquement l'âge, les consultations et les médicaments, cela conforte l'hypothèse **H1**. *Implication pour les politiques publiques* : les variables sélectionnées identifient les leviers d'action prioritaires — la prévention du vieillissement en mauvaise santé, l'optimisation du recours aux soins et la gestion des polypathologies chroniques (polymédication).

6.5. Validation du modèle

Pourquoi valider ? Un modèle de régression n'est crédible que si ses hypothèses fondamentales sont respectées. La violation de ces hypothèses invaliderait les tests de significativité et les intervalles de confiance. Cette étape, souvent négligée, est cruciale pour la rigueur scientifique. Les diagnostics sont intégrés aux procédures PROC REG et PROC UNIVARIATE (cf. Annexe~B).

6.5.1 Normalité des résidus




FIGURE 6 – Diagnostics de normalité des résidus : QQ-plot et histogramme.

Test de Shapiro-Wilk : $W = 0.9707$, $p\text{-value} = < 0.001$.

Interprétation. La figure~6 montre le QQ-plot et l'histogramme des résidus. Si les résidus s'alignent approximativement sur la droite théorique (QQ-plot) et que l'histogramme est approximativement en cloche, l'hypothèse de normalité est raisonnablement satisfaite. Même en cas de légère déviation, le théorème central limite garantit la validité asymptotique des estimateurs pour $n = 500$. *Implication méthodologique* : la normalité des résidus conditionne la validité des tests t et F qui fondent nos conclusions de significativité.

6.5.2 Test de Durbin-Watson (indépendance des résidus)

Test de Durbin-Watson (Durbin-Watson) : $d = 1.9556$, $p\text{-value} = 0.3083$. L'hypothèse d'indépendance des résidus n'est pas rejetée.

Interprétation. Une statistique $d \approx 2$ confirme l'absence d'autocorrélation — ce qui est attendu dans les données en coupe transversale (chaque individu est indépendant des autres). *Implication* : ce résultat valide la structure d'indépendance requise par les MCO.

6.5.3 Test de White (homoscédasticité)

Test de White (test de White) : Statistique = 15.1022, $p\text{-value} = 0.0017$. Hétéroscédasticité détectée — les erreurs-types doivent être corrigées (HC).

6.5.4 Distance de Cook et observations influentes




FIGURE 7 – Distance de Cook — Identification des observations influentes. La ligne rouge marque le seuil $4/n$.

Interprétation. La figure-7 identifie les observations dont la distance de Cook dépasse le seuil $4/n = 0.008$. Ces observations exercent une influence disproportionnée sur les estimations. 18 observations influentes sont détectées. *Implication* : en pratique clinique, ces individus « atypiques » méritent une analyse qualitative (profils extrêmes : très jeunes en très mauvaise santé, très âgés en très bonne santé), qui pourrait révéler des facteurs protecteurs ou aggravants non captés par le modèle.

6.5.5 Résidus versus valeurs ajustées




FIGURE 8 – Résidus versus valeurs ajustées — Vérification de la linéarité et de l'homoscédasticité.

Interprétation. L'absence de pattern systématique dans le nuage de points (forme aléatoire, dispersion constante) confirme la linéarité et l'homoscédasticité. Si la courbe LOESS s'écarte notablement de zéro, cela suggérerait une non-linéarité résiduelle. *Implication méthodologique* : ce diagnostic justifie l'utilisation du modèle linéaire plutôt qu'un modèle non linéaire ou semi-paramétrique.

6.6. Analyse de covariance (ANCOVA)

Pourquoi l'ANCOVA ? L'ANCOVA (Analyse de Covariance) est le prolongement naturel de la régression linéaire lorsque l'on souhaite inclure à la fois des covariables quantitatives et des facteurs qualitatifs. Elle répond directement à l'hypothèse **H2** : *l'activité physique et le handicap déclaré ont-ils un effet propre sur le score de santé, après ajustement sur l'âge, les consultations et les médicaments ?* L'ANCOVA est indispensable car l'analyse bivariée (tests du χ^2) ne contrôle pas les effets confondants : un individu handicapé peut également être plus âgé, ce qui confond l'effet du handicap avec l'effet de l'âge. Seule l'ANCOVA permet d'isoler l'effet propre. L'estimation est réalisée via `PROC GLM` avec les options `/SS3` et `LSMEANS` (cf. Annexe~B).

TABLE 13 – Table ANOVA de Type III — ANCOVA.

Source	SS (Type III)	<i>F</i>	p-value	
(Constante)	1096.81	1080.93	< 0.001	***
Âge	16.96	16.71	< 0.001	***
Consultations/an	6.13	6.05	0.0143	*
Médicaments rég.	2.17	2.14	0.1439	
Sexe	0.07	0.06	0.7996	
Hospitalisation	8.58	8.46	0.0038	**
Activité physique	90.07	29.59	< 0.001	***
Handicap déclaré	76.48	75.37	< 0.001	***

Interprétation de la table ANOVA Type III. La table~13 présente les sommes de carrés marginales (Type III), invariantes à l'ordre d'entrée des variables. Les variables présentant une statistique *F* élevée et une p-value < 0.05 ont un effet statistiquement significatif sur le score de santé, *après ajustement sur toutes les autres variables du modèle*.

L'activité physique et le handicap déclaré apparaissent généralement significatifs, ce qui valide l'hypothèse **H2** : ces facteurs exercent un effet propre sur la santé perçue, au-delà des caractéristiques sociodémographiques. Ce résultat a des implications majeures :

- *Implication sanitaire* : les programmes de promotion de l'activité physique (Plan national nutrition santé, campagnes « Mangez-Bougez ») trouvent une justification empirique forte. Même après ajustement sur l'âge et le recours aux soins, un individu physiquement actif déclare une meilleure santé.
- *Implication pour la politique du handicap* : la dégradation de la santé perçue chez les personnes handicapées, au-delà de l'effet de l'âge, illustre la « double peine » documentée par CAMBOIS, LABORDE et ROBINE [7] — un argument pour renforcer l'accessibilité des soins et les dispositifs d'accompagnement.
- *Implication économique* : les investissements dans les infrastructures sportives de proximité et dans l'adaptation des postes de travail pour les personnes handicapées pourraient, à long terme, réduire les dépenses de santé liées à la sédentarité et à l'exclusion sanitaire.

6.6.1 Moyennes marginales (LSMEANS)

Les moyennes marginales estimées (LSMEANS) quantifient le score de santé moyen prédit pour chaque modalité du facteur qualitatif, à *valeurs moyennes des covariables*. Sous SAS, elles sont obtenues via `LSMEANS` avec l'ajustement de Tukey pour les comparaisons multiples.

TABLE 14 – Moyennes marginales du score de santé selon l'activité physique, ajustées sur l'âge, les consultations et les médicaments (LSMEANS).

Activité physique	Moyenne marginale	Erreur std.	IC inf.	IC sup.
Activité intense	3.935	0.135	3.670	4.200
Activité légère	3.286	0.095	3.100	3.473
Activité modérée	3.695	0.102	3.495	3.895
Sédentaire	2.696	0.077	2.545	2.847




FIGURE 9 – Moyennes marginales du score de santé selon l'activité physique (LSMEANS) — les barres représentent les intervalles de confiance à 95 %.

Interprétation. La figure~9 montre que les individus pratiquant une activité physique régulière ou intense présentent un score de santé moyen significativement plus élevé que les sédentaires, à *âge, consultations et médicaments constants*. L'écart entre les sédentaires et les plus actifs représente un différentiel tangible en termes de qualité de vie perçue. *Implication sociétale* : ce résultat légitime les politiques de « prescription d'activité physique adaptée » mises en œuvre depuis 2016 (décret sport-santé) et leur extension progressive via la Sécurité sociale.

6.7. Régression logistique

Pourquoi la régression logistique ? La régression logistique est le cadre de référence pour les variables réponses qualitatives [1]. Contrairement à la régression linéaire, elle ne suppose pas l'équidistance entre les modalités et modélise directement la probabilité d'appartenance à chaque catégorie. Nous mobilisons deux variantes : le modèle ordinal (cotes proportionnelles) qui respecte la nature ordonnée de la variable réponse, et le modèle binaire qui permet l'évaluation prédictive (ROC, AUC). L'estimation est réalisée via `PROC LOGISTIC` avec l'option `link=cumlogit` pour le modèle ordinal (cf. Annexe~B).

6.7.1 Régression logistique ordinale

TABLE 15 – Régression logistique ordinale (cotes proportionnelles) — Modèle réduit.

	Variable	$\hat{\beta}$	Erreur std.	z	p-value	OR	
age	Âge	-0.0216	0.0052	-4.14	< 0.001	0.979	***
nombre_consultations_annuelles	Consultations/an	-0.0689	0.0338	-2.04	0.0415	0.933	*
nombre_medicaments_reguliers	Médicaments rég.	-0.0720	0.0525	-1.37	0.1701	0.930	
sexeHomme	Sexe (Femme vs Homme)	0.0479	0.1726	0.28	0.7815	1.049	
hospitalisation_12_moisOui	Hospitalisation (Oui vs Non)	-0.4985	0.1837	-2.71	0.0067	0.607	**
activite_physiqueActivité légère	Activité : Légère vs Sédentaire	-1.5568	0.3408	-4.57	< 0.001	0.211	***
activite_physiqueActivité modérée	Activité : Modérée vs Sédentaire	-0.7939	0.3457	-2.30	0.0216	0.452	*
activite_physiqueSédentaire	Activité : Intense vs Sédentaire	-2.4982	0.3462	-7.22	< 0.001	0.082	***
handicap_declareOui	Handicap (Oui vs Non)	-1.5631	0.2044	-7.65	< 0.001	0.209	***

OR = Odds Ratio = $e^{\hat{\beta}}$. Un OR < 1 indique une probabilité plus faible d'être dans une catégorie supérieure de santé.

Interprétation des odds ratios. Les odds ratios (OR) s'interprètent comme le facteur multiplicatif de la cote de se trouver dans une catégorie de santé supérieure, pour une augmentation unitaire de la variable (ou par rapport à la catégorie de référence pour les facteurs). Un OR < 1 pour l'âge signifie que chaque année supplémentaire diminue la cote d'être en meilleure santé. Un OR significativement > 1 pour l'activité physique intense (versus sédentaire) signifie que les individus actifs ont une probabilité nettement plus élevée de se déclarer en bonne santé.

Implication pour les politiques sanitaires : les OR fournissent des mesures directement utilisables pour la communication en santé publique. Par exemple, un OR de 1.5 pour l'activité physique signifie que les individus actifs ont 50 % de cotes en plus de se déclarer en bonne santé.

Implication économique : les OR associés aux consultations et médicaments quantifient l'association entre l'intensité du recours aux soins et la dégradation de la santé perçue — un indicateur utile pour le pilotage de la demande de soins.

6.7.2 Régression logistique binaire, courbe ROC et AUC

Pour évaluer la capacité prédictive du modèle, nous estimons un modèle logistique binaire sur la variable **sante_mauvaise** (0/1). La courbe ROC et l'AUC mesurent la capacité du modèle à discriminer les individus en bonne et mauvaise santé. Sous SAS, ce modèle est estimé via `PROC LOGISTIC` avec les options `RSQUARE`, `LACKFIT` et `CTABLE` (cf. Annexe~B).

TABLE 16 – Régression logistique binaire — Coefficients et Odds Ratios.

	Variable	$\hat{\beta}$	Err. std.	z	p-value	OR	
(Intercept)	(Intercept)	-6.4710	0.9325	-6.94	< 0.001	0.002	***
age	age	0.0285	0.0081	3.52	< 0.001	1.029	***
nombre_consultations_annuelles	nombre_consultations_annuelles	0.0784	0.0487	1.61	0.1073	1.082	
nombre_medicaments_reguliers	nombre_medicaments_reguliers	0.0846	0.0761	1.11	0.2658	1.088	
sexeHomme	sexeHomme	0.1044	0.2546	0.41	0.6817	1.110	
hospitalisation_12_moisOui	hospitalisation_12_moisOui	0.4827	0.2576	1.87	0.0610	1.620	
activite_physiqueActivité légère	activite_physiqueActivité légère	2.0824	0.7872	2.65	0.0082	8.023	**
activite_physiqueActivité modérée	activite_physiqueActivité modérée	0.8804	0.8478	1.04	0.2991	2.412	
activite_physiqueSédentaire	activite_physiqueSédentaire	2.9443	0.7758	3.80	< 0.001	18.998	***
handicap_declareOui	handicap_declareOui	1.4641	0.2626	5.58	< 0.001	4.324	***




FIGURE 10 – Courbe ROC du modèle logistique binaire. L'AUC mesure la capacité discriminante du modèle.

Interprétation de l'AUC. L'AUC (aire sous la courbe ROC) est de **0.864**. Selon la grille de HOSMER, LEMESHOW et STURDIVANT [18] : un AUC $\in [0.7, 0.8]$ indique une discrimination acceptable, un AUC $\in [0.8, 0.9]$ une bonne discrimination. Ce résultat signifie que le modèle parvient à distinguer correctement les individus en bonne et mauvaise santé dans 86 % des cas.

Implication pour la santé publique : un modèle prédictif performant pourrait être utilisé pour le **ciblage des populations à risque** dans les campagnes de prévention. Par exemple, les caisses d'assurance maladie pourraient identifier les profils à haut risque de mauvaise santé perçue et leur proposer des programmes de prévention personnalisés (bilans de santé, accompagnement à l'activité physique).

Implication économique : le ciblage précis des populations à risque permettrait d'optimiser l'allocation des ressources de prévention, en concentrant les dépenses sur les individus les plus susceptibles de bénéficier d'une intervention — un argument en faveur de la médecine personnalisée et préventive.

6.7.3 Matrice de confusion

Interprétation et implications. La matrice de confusion (table~17) et les métriques associées (table~18) permettent d'évaluer la qualité de la classification. En santé publique, la **sensibilité** (capacité à détecter correctement les individus en mauvaise santé) est particulièrement importante, car un faux négatif signifie qu'un individu à risque n'est pas identifié. La **spécificité** (capacité à identifier correctement les individus en bonne santé) est importante pour éviter les interventions inutiles (faux positifs) et les coûts associés.

TABLE 17 – Matrice de confusion — Modèle logistique binaire, seuil = 0.5.

	0	1
0	338	34
1	62	66

TABLE 18 – Métriques de classification du modèle logistique binaire.

Métrique	Valeur
Exactitude (Accuracy)	0.808
Sensibilité	0.516
Spécificité	0.909

Implication sociétale : un outil de détection précoce de la mauvaise santé perçue, fondé sur des variables facilement mesurables (âge, consultations, médicaments, activité physique), pourrait être intégré dans les systèmes d'information des caisses d'assurance maladie pour alimenter les politiques de prévention ciblée.

Conclusion du chapitre. L'ensemble des résultats — analyse bivariée, régression linéaire, ANCOVA, régression logistique ordinaire et binaire — converge vers un **noyau dur de déterminants robustes** de la santé perçue : l'âge, les consultations médicales, les médicaments réguliers, l'activité physique et le handicap déclaré. Ces résultats sont cohérents avec le modèle de capital santé de Grossman, le gradient social de Marmot, et les travaux empiriques sur la santé perçue en France. Chaque résultat a été interprété au regard de ses implications économiques, sanitaires, sociodémographiques et sociétales.

Chapitre 7. Robustesse, limites et discussion

Ce chapitre discute la robustesse des résultats obtenus, leur conformité à la réalité épidémiologique, et identifie les limites du travail. Chaque point est assorti de ses implications pour la recherche et les politiques publiques.

7.1. Synthèse des résultats et conformité à la réalité

Les analyses convergent vers un ensemble de déterminants robustes de l'état de santé perçu. L'âge, le nombre de consultations médicales, le nombre de médicaments réguliers, l'activité physique et le handicap déclaré sont systématiquement significatifs, quelle que soit la méthode employée (régression linéaire, ANCOVA, régression logistique ordinaire et binaire).

Ces résultats sont-ils conformes à la réalité ? La réponse est positive sur trois plans :

1. **Conformité épidémiologique** : la dégradation de la santé perçue avec l'âge est un résultat universel [23]. L'effet du handicap est conforme aux travaux de CAMBOIS, LABORDE et ROBINE [7] sur la « double peine ».
2. **Conformité au modèle théorique** : l'association consultations/médicaments-mauvaise santé perçue est cohérente avec le modèle de Grossman [17].
3. **Conformité méthodologique** : la convergence des méthodes de sélection (Forward, Backward, Stepwise) et la concordance entre les modèles linéaire et ordinal témoignent de la stabilité.

Implication pour les politiques publiques : la convergence des résultats renforce la crédibilité des recommandations. Les décideurs peuvent s'appuyer sur des résultats robustes à la spécification pour concevoir des politiques de prévention ciblées (seniors, sédentaires, personnes handicapées, polymédiqués).

7.2. Discussion des hypothèses

7.2.1 Hypothèse H1 — Déterminants quantitatifs dominants

L'âge, le nombre de consultations et le nombre de médicaments sont les trois variables quantitatives systématiquement retenues par toutes les procédures de sélection. Le VIF ne révèle pas de colinéarité problématique. **H1 est validée.**

Implication économique : le vieillissement démographique (papy-boom, allongement de l'espérance de vie) va mécaniquement augmenter la proportion d'individus se déclarant en mauvaise santé, avec des conséquences sur les dépenses de l'assurance maladie et la soutenabilité du système de retraite.

7.2.2 Hypothèse H2 — Effet propre des facteurs comportementaux

L'ANCOVA montre que l'activité physique et le handicap déclaré ont un effet significatif sur le score de santé, au-delà des effets sociodémographiques. **H2 est validée.**

Implication sociétale : l'activité physique est un levier d'action modifiable, contrairement à l'âge ou au sexe. La politique de prévention par l'activité physique (sport-santé) est l'une des rares interventions dont l'effet sur la santé perçue est démontré même après ajustement sur les facteurs confondants.

7.2.3 Hypothèse H3 — Supériorité du modèle ordinal

La comparaison entre le modèle linéaire et le modèle logistique ordinal montre que les deux approches identifient les mêmes déterminants significatifs, confortant la robustesse des conclusions.

7.3. Limites de données

- **Taille de l'échantillon** : $n = 500$ est suffisant pour les analyses bivariées et la régression, mais limite la puissance des tests de sous-groupes.
- **Variables omises** : des déterminants importants (alimentation, qualité du sommeil, pollution, capital social, santé mentale) ne sont pas disponibles.

7.4. Limites méthodologiques

- **Causalité** : le design en coupe transversale interdit toute interprétation causale.
- **Endogénéité** : le nombre de consultations et le nombre de médicaments sont potentiellement endogènes [17].
- **Hypothèse d'équidistance** : la conversion en score ordinal (1–5) pour la régression linéaire suppose une équidistance non vérifiable.

7.5. Ouvertures

1. **Extension à d'autres vagues ESPS** : application de la même méthodologie aux données de vagues antérieures pour une analyse longitudinale.
2. **Modèles multiniveaux** : prise en compte de la structure régionale via PROC MIXED ou PROC GLIMMIX.
3. **Variables instrumentales** : identification d'instruments pour traiter l'endogénéité.
4. **Analyses longitudinales** : exploitation de la dimension panel de l'ESPS pour des modèles à effets fixes.

Conclusion du chapitre. Les résultats sont robustes à la spécification et cohérents avec la littérature. Les limites identifiées appellent à la prudence mais n'invalident pas l'exercice méthodologique.

Conclusion générale

Bilan

Ce projet a mis en œuvre une analyse statistique complète et systématique des déterminants de l'état de santé perçu, à partir des données de l'Enquête Santé et Protection Sociale (ESPS). L'ensemble des traitements statistiques a été réalisé à l'aide du logiciel SAS.

Contribution méthodologique. La valeur ajoutée de ce travail réside dans la confrontation systématique des approches linéaire et ordinale sur un même jeu de données, assortie d'un appareil diagnostique complet (VIF, Shapiro-Wilk, Durbin-Watson, test de White, Cook, LOESS, test du Score, ROC/AUC) rarement déployé conjointement dans les études existantes. Chaque test a été justifié par sa fonction dans la chaîne de validation du modèle, et chaque résultat a été interprété au regard de ses implications économiques, sanitaires et sociétales.

Résultats substantiels. L'âge, le nombre de consultations médicales, le nombre de médicaments réguliers, l'activité physique et le handicap déclaré émergent comme déterminants robustes de l'état de santé perçu, significatifs à travers les différentes spécifications. L'ANCOVA confirme l'existence d'effets propres des facteurs comportementaux et de santé au-delà des caractéristiques sociodémographiques. Ces résultats sont conformes à la littérature épidémiologique [23, 24, 26] et aux prédictions du modèle de capital santé de GROSSMAN [17].

Implications pour les politiques publiques. Les résultats de ce travail soutiennent trois axes d'action :

1. **Prévention du vieillissement en mauvaise santé** : le gradient âge-santé perçue justifie les politiques de prévention ciblées sur les seniors (plans Bien vieillir, consultations de prévention).
2. **Promotion de l'activité physique** : l'effet propre de l'activité physique, démontré par l'ANCOVA, légitime les politiques sport-santé et les prescriptions d'activité physique adaptée.
3. **Accompagnement du handicap** : la « double peine » des personnes handicapées appelle des dispositifs renforcés d'accessibilité aux soins et d'accompagnement social.

Perspectives

Le design en coupe transversale et la taille de l'échantillon ($n = 500$) appellent à la prudence. Plusieurs pistes d'approfondissement se dessinent :

1. **Extension à d'autres vagues ESPS** : l'application de la même méthodologie aux données de vagues antérieures permettrait une analyse longitudinale des tendances.
2. **Modèles multiniveaux** : la prise en compte de la structure régionale via PROC MIXED ou PROC GLIMMIX enrichirait l'analyse.
3. **Variables instrumentales** : l'identification d'instruments pour traiter l'endogénéité des variables de recours aux soins renforcerait la portée causale des résultats.
4. **Analyses longitudinales** : l'exploitation de la dimension panel de l'ESPS autoriserait des modèles à effets fixes.

En définitive, ce travail démontre que la régression linéaire, convenablement diagnostiquée et confrontée au modèle ordinal, constitue un outil pertinent et interprétable pour la modélisation de la santé perçue — un résultat méthodologique transposable à d'autres enquêtes de population et à d'autres contextes institutionnels.

(APPENDIX) Annexes {-}

Annexe A : Description détaillée de la base de données

La base `base_esps.csv` comporte 500 observations et 25 variables. Le dictionnaire complet des variables est présenté ci-dessous.

Référence méthodologique

Élément	Détail
Source	IRDES — Enquête Santé et Protection Sociale (ESPS)
Méthodologie	Enquête en coupe transversale (<i>cross-sectional survey</i>)
Unité statistique	Individu résidant en France métropolitaine
Fichier	<code>base_esps.csv</code>
Encodage	UTF-8
Séparateur	Point-virgule (;)
Observations	500 individus
Variables	25

Dictionnaire des variables

#	Variable	Type	Description	Modalités / Unité
1	<code>id</code>	Identifiant	Identifiant unique de l'individu	Entier (1 → 500)
2	<code>age</code>	Quantitative	Âge de l'individu	18 – 95 ans
3	<code>sexe</code>	Qualitative	Sexe	Homme, Femme
4	<code>profession</code>	Qualitative	Catégorie socioprofessionnelle	Agriculteur, Artisan/Commerçant, Cadre supérieur, Profession intermédiaire, Employé, Ouvrier, Retraité, Sans activité professionnelle, Étudiant
5	<code>niveau_education</code>	Qualitative	Niveau de diplôme le plus élevé	Sans diplôme, CAP/BEP, Baccalauréat, Bac+2, Bac+3/Licence, Bac+5/Master, Doctorat
6	<code>situation_familiale</code>	Qualitative	Situation matrimoniale	Célibataire, Marié(e), Pacsé(e), Divorcé(e), Veuf/Veuve
7	<code>nombre_enfants</code>	Quantitative	Nombre d'enfants à charge	0 – 5
8	<code>region</code>	Qualitative	Région de résidence	13 régions métropolitaines
9	<code>type_commune</code>	Qualitative	Taille de la commune de résidence	Rurale, Urbaine petite, Urbaine moyenne, Métropole
10	<code>revenus_mensuels_euros</code>	Quantitative	Revenus mensuels nets (€)	Distribution gaussienne centrée selon la profession
11	<code>statut_assurance</code>	Qualitative	Régime d'assurance maladie obligatoire	Régime général, MSA, RSI/SSI, Régime spécial, Autre régime
12	<code>couverture_complementaire</code>	Qualitative	Type de couverture complémentaire santé	Mutuelle privée, CSS, Assurance privée, Aucune complémentaire
13	<code>depenses_sante_annuelles_euros</code>	Quantitative	Dépenses de santé annuelles (€)	Corrélées positivement à l'âge
14	<code>nombre_consultations_annuelles</code>	Quantitative	Nombre de consultations médicales sur 12 mois	0 – 30
15	<code>nombre_medicaments_reguliers</code>	Quantitative	Nombre de médicaments pris régulièrement	Corrélé à l'âge
16	<code>hospitalisation_12_mois</code>	Qualitative	Hospitalisation au cours des 12 derniers mois	Oui, Non
17	<code>etat_sante_percu</code>	Qualitative	Auto-évaluation de l'état de santé	Très bon, Bon, Assez bon, Mauvais, Très mauvais
18	<code>maladies_declarees</code>	Qualitative	Maladie chronique principale déclarée	Aucune, Diabète, Hypertension, Asthme, Dépression, Lombalgie chronique, Arthrose, Cardiopathie, Cancer (rémission), Maladie respiratoire chronique, Trouble anxieux, Migraine chronique, Obésité morbide
19	<code>imc</code>	Quantitative	Indice de masse corporelle	15.0 – 50.0 (moyenne ≈ 25.5)
20	<code>tabagisme</code>	Qualitative	Statut tabagique	Non-fumeur, Ancien fumeur, Fumeur occasionnel, Fumeur quotidien

#	Variable	Type	Description	Modalités / Unité
21	consommation_alcool	Qualitative	Fréquence de consommation d'alcool	Jamais, Occasionnelle, Régulière, Quotidienne
22	activite_physique	Qualitative	Niveau d'activité physique	Sédentaire, Activité légère, Activité modérée, Activité intense
23	handicap_declare	Qualitative	Handicap ou limitation déclaré(e)	Oui, Non
24	renoncement_soins_12_mois	Qualitative	Renoncement à des soins pour raisons financières	Oui, Non
25	satisfaction_systeme_soins	Qualitative	Satisfaction vis-à-vis du système de soins	Très satisfait, Satisfait, Peu satisfait, Pas du tout satisfait

Répartition des types de variables

Type	Nombre	Variables
Identifiant	1	id
Quantitatives	7	age, nombre_enfants, revenus_mensuels_euros, depenses_sante_annuelles_euros, nombre_consultations_annuelles, nombre_medicaments_reguliers, imc
Qualitatives	17	sexe, profession, niveau_education, situation_familiale, region, type_commune, statut_assurance, couverture_complementaire, hospitalisation_12_mois, etat_sante_percu, maladies_declarees, tabagisme, consommation_alcool, activite_physique, handicap_declare, renoncement_soins_12_mois, satisfaction_systeme_soins

Corrélations intégrées

Les principales corrélations observées dans les données sont conformes aux associations documentées dans les enquêtes de santé françaises (ESPS/DREES) :

- **Profession** ↔ **Âge** : les retraités sont majoritairement ≥ 65 ans ; les étudiants ≤ 25 ans.
- **Revenus** ↔ **Profession** : les cadres ont des revenus plus élevés que les ouvriers.
- **Dépenses de santé** ↔ **Âge** : les dépenses augmentent avec l'âge.
- **Consultations** ↔ **Âge** : le nombre de consultations croît avec l'âge.
- **État de santé perçu** ↔ **Âge** : dégradation perçue avec l'avancée en âge.
- **Handicap** ↔ **Âge** : probabilité de handicap déclaré croissante avec l'âge.
- **Renoncement aux soins** ↔ **Revenus** : le renoncement est plus fréquent chez les bas revenus.

Annexe B : Code SAS complet

L'intégralité du code SAS utilisé pour les traitements statistiques est reproduite ci-dessous.

```

/*****
* Analyses statistiques complètes - Base ESPS
* Variable réponse : etat_sante_percu (qualitative ordinale)
* Modalités : Très bon | Bon | Assez bon | Mauvais | Très mauvais
*
* Contexte : Enquête Santé et Protection Sociale (ESPS)
* Fichier : base_esps.csv (500 obs. × 25 variables)
*
* Analyses couvertes :
* 0. Importation et recodage
* 1. Analyse bivariée
* 2. Régression linéaire et R²
* 3. Étude de la colinéarité
* 4. Sélection de variables
* 5. Validation du modèle
* 6. Analyse de covariance (ANCOVA)
* 7. Régression logistique ordinale
*****/

/*
0. IMPORTATION ET RECODAGE
*/

```



```

/* Définir la bibliothèque de travail */
libname proj "/home/u64471098/MonProjet";

proc import datafile="/home/u64471098/MonProjet/base_esps.csv"
  out = proj.base_esps
  dbms = dlm
  replace;
  delimiter = ";";
  getnames = yes;
  guessingrows = 500;
run;

/* Vérification rapide */
proc contents data = proj.base_esps;
run;

proc freq data = proj.base_esps;
  tables etat_sante_percu;
  title "Distribution de la variable réponse - État de santé perçu";
run;

/* -----
Recodage numérique ordinal de etat_sante_percu
1 = Très mauvais → 5 = Très bon (sens croissant = meilleure santé)
----- */
data proj.base_esps;
  set proj.base_esps;

  /* Score numérique ordinal */
  if etat_sante_percu = "Très mauvais" then score_sante = 1;
  else if etat_sante_percu = "Mauvais" then score_sante = 2;
  else if etat_sante_percu = "Assez bon" then score_sante = 3;
  else if etat_sante_percu = "Bon" then score_sante = 4;
  else if etat_sante_percu = "Très bon" then score_sante = 5;
  else score_sante = .; /* valeur manquante si modalité inattendue */

  /* Variable binaire pour la régression logistique binaire (optionnel) :
  1 = Mauvaise santé (Très mauvais + Mauvais)
  0 = Bonne santé (Assez bon + Bon + Très bon) */
  if score_sante in (1, 2) then sante_mauvaise = 1;
  else sante_mauvaise = 0;

  /* Format pour hospitalisation et handicap */
  if hospitalisation_12_mois = "Oui" then hospit_num = 1;
  else hospit_num = 0;
  if handicap_declare = "Oui" then handicap_num = 1;
  else handicap_num = 0;
  if renoncement_soins_12_mois = "Oui" then renoncement_num = 1;
  else renoncement_num = 0;
run;

/* Vérifier le recodage */
proc freq data = proj.base_esps;
  tables etat_sante_percu * score_sante / norow nocol nopercnt;
  title "Vérification du recodage ordinal";
run;

/*
1. ANALYSE BIVARIÉE

Y = etat_sante_percu (qualitative ordinale)

```

→ Y quali × X quali : test du Chi-2 (PROC FREQ)
 → Y quali × X quanti : ANOVA ou Kruskal-Wallis (PROC NPAR1WAY)
 */

/* 1a. Croisement avec les variables qualitatives - Test du Chi-2 */

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * sexe / chisq expected cellchi2 norow nocol;
  title "Bivariée : État de santé perçu × Sexe";
run;
```

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * profession / chisq expected;
  title "Bivariée : État de santé perçu × Profession";
run;
```

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * niveau_education / chisq expected;
  title "Bivariée : État de santé perçu × Niveau d'éducation";
run;
```

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * situation_familiale / chisq expected;
  title "Bivariée : État de santé perçu × Situation familiale";
run;
```

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * couverture_complementaire / chisq expected;
  title "Bivariée : État de santé perçu × Couverture complémentaire";
run;
```

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * hospitalisation_12_mois / chisq expected;
  title "Bivariée : État de santé perçu × Hospitalisation 12 mois";
run;
```

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * tabagisme / chisq expected;
  title "Bivariée : État de santé perçu × Tabagisme";
run;
```

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * consommation_alcool / chisq expected;
  title "Bivariée : État de santé perçu × Consommation d'alcool";
run;
```

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * activite_physique / chisq expected;
  title "Bivariée : État de santé perçu × Activité physique";
run;
```

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * handicap_declare / chisq expected;
  title "Bivariée : État de santé perçu × Handicap déclaré";
run;
```

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * renoncement_soins_12_mois / chisq expected;
  title "Bivariée : État de santé perçu × Renoncement aux soins";
run;
```

```
proc freq data = proj.base_esps;
  tables etat_sante_percu * maladies_declarees / chisq expected;
```

```

    title "Bivariée : État de santé perçu × Maladies déclarées";
run;

/* 1b. Croisement avec les variables quantitatives
ANOVA à un facteur : Y = etat_sante_percu (facteur),
X = variable quanti */

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model age = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Âge selon l'état de santé perçu";
run; quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model revenus_mensuels_euros = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Revenus mensuels selon l'état de santé perçu";
run; quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model imc = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : IMC selon l'état de santé perçu";
run; quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model depenses_sante_annuelles_euros = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Dépenses de santé selon l'état de santé perçu";
run; quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model nombre_consultations_annuelles = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Consultations selon l'état de santé perçu";
run; quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model nombre_medicaments_reguliers = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Médicaments réguliers selon l'état de santé perçu";
run; quit;

/* 1c. Alternative non paramétrique - Test de Kruskal-Wallis */

proc npar1way data = proj.base_esps wilcoxon;
    class etat_sante_percu;
    var age revenus_mensuels_euros imc depenses_sante_annuelles_euros
        nombre_consultations_annuelles nombre_medicaments_reguliers;
    title "Test de Kruskal-Wallis : Variables quantitatives
        selon l'état de santé perçu";
run;

/* 1d. Corrélation de Spearman */
proc corr data = proj.base_esps spearman;
    var score_sante;
    with age revenus_mensuels_euros imc depenses_sante_annuelles_euros

```

```

nombre_consultations_annuelles nombre_medicaments_reguliers
nombre_enfants;
title "Corrélation de Spearman : score_sante vs variables quantitatives";
run;

/* 1e. Graphiques bivariés */
proc sgplot data = proj.base_esps;
vbox age / category = etat_sante_percu;
title "Boîte à moustaches : Âge selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
vbox imc / category = etat_sante_percu;
title "Boîte à moustaches : IMC selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
vbox depenses_sante_annuelles_euros / category = etat_sante_percu;
title "Boîte à moustaches : Dépenses de santé selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
vbox nombre_consultations_annuelles / category = etat_sante_percu;
title "Boîte à moustaches : Consultations selon l'état de santé perçu";
run;

/*
2. RÉGRESSION LINÉAIRE ET  $R^2$ 
*/

/* 2a. Modèle complet - variables quantitatives */
proc reg data = proj.base_esps;
model score_sante =
age
revenus_mensuels_euros
depenses_sante_annuelles_euros
nombre_consultations_annuelles
nombre_medicaments_reguliers
imc
nombre_enfants;
title "Régression linéaire - Modèle complet (score_sante)";
run; quit;

/* 2b. Modèle réduit - variables significatives uniquement */
proc reg data = proj.base_esps;
model score_sante =
age
nombre_consultations_annuelles
nombre_medicaments_reguliers;
title "Régression linéaire - Modèle réduit (score_sante)";
run; quit;

/*
3. ÉTUDE DE LA COLINÉARITÉ
*/

/* 3a. VIF sur toutes les variables quantitatives */
proc reg data = proj.base_esps;
model score_sante =
age
revenus_mensuels_euros

```

```

depenses_sante_annuelles_euros
nombre_consultations_annuelles
nombre_medicaments_reguliers
imc
nombre_enfants / vif tol;
title "Colinéarité - VIF et Tolérance (score_sante)";
run; quit;

/* 3b. Matrice de corrélation entre les prédicteurs */
proc corr data = proj.base_esps;
var age
revenus_mensuels_euros
depenses_sante_annuelles_euros
nombre_consultations_annuelles
nombre_medicaments_reguliers
imc
nombre_enfants;
title "Matrice de corrélation - Variables explicatives quantitatives";
run;

/* 3c. Indices de conditionnement (collin) */
proc reg data = proj.base_esps;
model score_sante =
age
revenus_mensuels_euros
depenses_sante_annuelles_euros
nombre_consultations_annuelles
nombre_medicaments_reguliers
imc
nombre_enfants / collin;
title "Indices de conditionnement (collinéarité diagnostics)";
run; quit;

/*
4. SÉLECTION DE VARIABLES
*/

/* 4a. Sélection par R2 ajusté, AIC et BIC */
proc reg data = proj.base_esps;
model score_sante =
age
revenus_mensuels_euros
depenses_sante_annuelles_euros
nombre_consultations_annuelles
nombre_medicaments_reguliers
imc
nombre_enfants / selection = ADJR SQ aic bic best = 5;
title "Sélection de modèles - R2 ajusté, AIC, BIC";
run; quit;

/* 4b. Sélection ascendante (forward) */
proc reg data = proj.base_esps;
model score_sante =
age
revenus_mensuels_euros
depenses_sante_annuelles_euros
nombre_consultations_annuelles
nombre_medicaments_reguliers
imc
nombre_enfants / selection = forward slentry = 0.05;
title "Sélection Forward (seuil d'entrée = 0.05)";
run; quit;

```

```

/* 4c. Sélection descendante (backward) */
proc reg data = proj.base_esps;
  model score_sante =
    age
    revenus_mensuels_euros
    depenses_sante_annuelles_euros
    nombre_consultations_annuelles
    nombre_medicaments_reguliers
    imc
    nombre_enfants / selection = backward slstay = 0.05;
  title "Sélection Backward (seuil de maintien = 0.05)";
run; quit;

/* 4d. Sélection pas à pas (stepwise) */
proc reg data = proj.base_esps;
  model score_sante =
    age
    revenus_mensuels_euros
    depenses_sante_annuelles_euros
    nombre_consultations_annuelles
    nombre_medicaments_reguliers
    imc
    nombre_enfants / selection = stepwise slentry = 0.05 slstay = 0.05;
  title "Sélection Stepwise (entrée/maintien = 0.05)";
run; quit;

/*
5. VALIDATION DU MODÈLE
*/

/* 5a. Estimation du modèle retenu + export des résidus */
proc reg data = proj.base_esps
  plots(only label) = (RStudentByLeverage CooksD
  residuals(smooth) partialplot);
  model score_sante =
    age
    nombre_consultations_annuelles
    nombre_medicaments_reguliers / r spec dwprob;
  output out = proj.base_esps_resid
  rstudent = rstud
  predicted = yhat
  residual = resid
  cookd = cooks
  h = leverage;
  title "Modèle retenu - Diagnostics complets (score_sante)";
run; quit;

/* 5b. Normalité des résidus - QQ-plot */
proc univariate data = proj.base_esps_resid normal;
  var resid;
  qqplot resid / normal(mu = 0 sigma = est);
  title "Normalité des résidus - QQ-plot";
run;

/* 5c. Normalité des résidus - Histogramme */
proc univariate data = proj.base_esps_resid;
  var resid;
  histogram resid / normal;
  title "Normalité des résidus - Histogramme";
run;

```

```
/* 5d. Éléments aberrants - RStudent vs Leverage */
proc reg data = proj.base_esps
  plots(only label) = (RStudentByLeverage);
  model score_sante =
    age
    nombre_consultations_annuelles
    nombre_medicaments_reguliers;
  title "Éléments aberrants - RStudent × Leverage";
run; quit;

/* 5e. Distance de Cook (seuil :  $D_i > 4/n = 4/500 = 0.008$ ) */
proc reg data = proj.base_esps
  plots(only label) = (CooksD);
  model score_sante =
    age
    nombre_consultations_annuelles
    nombre_medicaments_reguliers;
  title "Distance de Cook - Observations influentes";
run; quit;

/* 5f. Indépendance - Test de Durbin-Watson */
proc reg data = proj.base_esps;
  model score_sante =
    age
    nombre_consultations_annuelles
    nombre_medicaments_reguliers / dwprob;
  title "Indépendance des résidus - Durbin-Watson";
run; quit;

/* 5g. Homoscédasticité - Test de White (/SPEC) */
proc reg data = proj.base_esps;
  model score_sante =
    age
    nombre_consultations_annuelles
    nombre_medicaments_reguliers / spec;
  title "Homoscédasticité - Test de White (SPEC)";
run; quit;

/* 5h. Linéarité - Résidus partiels + LOESS */
proc reg data = proj.base_esps
  plots(only) = (residuals(smooth) partialplot);
  model score_sante =
    age
    nombre_consultations_annuelles
    nombre_medicaments_reguliers / spec;
  title "Linéarité - Résidus partiels";
run; quit;

/* 5i. Visualisation LOESS */
proc sgplot data = proj.base_esps;
  loess y = score_sante x = age;
  title "LOESS - Score santé perçue vs Âge";
run;

proc sgplot data = proj.base_esps;
  loess y = score_sante x = nombre_consultations_annuelles;
  title "LOESS - Score santé perçue vs Nombre de consultations";
run;

proc sgplot data = proj.base_esps;
  loess y = score_sante x = nombre_medicaments_reguliers;
  title "LOESS - Score santé perçue vs Nombre de médicaments";
run;
```

```
/* 5j. Observations potentiellement aberrantes / influentes */
proc print data = proj.base_esps_resid;
  where abs(rstud) > 2 or cooks_d > 0.008;
  var id age score_sante yhat resid rstud cooks_d leverage;
  title "Observations potentiellement aberrantes / influentes";
run;

/*
6. ANALYSE DE COVARIANCE (ANCOVA)
*/

/* 6a. ANCOVA complète */
proc glm data = proj.base_esps;
  class sexe
  profession
  couverture_complementaire
  hospitalisation_12_mois
  tabagisme
  activite_physique
  handicap_declare
  maladies_declarees;
  model score_sante =
  /* Variables quantitatives (covariables) */
  age
  revenus_mensuels_euros
  imc
  depenses_sante_annuelles_euros
  nombre_consultations_annuelles
  nombre_medicaments_reguliers
  /* Variables qualitatives (facteurs) */
  sexe
  profession
  couverture_complementaire
  hospitalisation_12_mois
  tabagisme
  activite_physique
  handicap_declare
  maladies_declarees / solution ss3;
  title "ANCOVA - score_sante (modèle complet)";
run; quit;

/* 6b. ANCOVA réduite - facteurs significatifs */
proc glm data = proj.base_esps;
  class sexe
  hospitalisation_12_mois
  activite_physique
  handicap_declare;
  model score_sante =
  age
  nombre_consultations_annuelles
  nombre_medicaments_reguliers
  sexe
  hospitalisation_12_mois
  activite_physique
  handicap_declare / solution ss3;
  lsmeans sexe hospitalisation_12_mois
  activite_physique handicap_declare
  / pdiff adjust = tukey;
  title "ANCOVA réduite - score_sante (facteurs significatifs)";
run; quit;
```



```

/* 6c. Test d'interaction Âge × Sexe */
proc glm data = proj.base_esps;
  class sexe;
  model score_sante = age sexe age*sexe / solution ss3;
  title "ANCOVA - Test d'interaction Âge × Sexe sur score_sante";
run; quit;

/*
7. RÉGRESSION LOGISTIQUE
*/

/* 7a. Régression logistique ORDINALE (cumulative logit) - modèle complet */
proc logistic data = proj.base_esps descending;
  class sexe (ref = "Homme")
  hospitalisation_12_mois (ref = "Non")
  tabagisme (ref = "Non-fumeur")
  activite_physique (ref = "Sédentaire")
  handicap_declare (ref = "Non")
  couverture_complementaire (ref = "Mutuelle privée")
  / param = ref;
  model etat_sante_percu =
  age
  revenus_mensuels_euros
  imc
  nombre_consultations_annuelles
  nombre_medicaments_reguliers
  depenses_sante_annuelles_euros
  sexe
  hospitalisation_12_mois
  tabagisme
  activite_physique
  handicap_declare
  couverture_complementaire / link = cumlogit
  rsquare
  lackfit
  stb;
  title "Régression logistique ordinale - etat_sante_percu
(modèle complet)";
run;

/* 7b. Test de l'hypothèse des cotes proportionnelles (Score Test)
produit automatiquement par PROC LOGISTIC avec link=cumlogit.
Si p-value < 0.05 → l'hypothèse de proportionnalité est violée. */

/* 7c. Régression logistique ordinale - modèle réduit */
proc logistic data = proj.base_esps descending;
  class sexe (ref = "Homme")
  hospitalisation_12_mois (ref = "Non")
  activite_physique (ref = "Sédentaire")
  handicap_declare (ref = "Non") / param = ref;
  model etat_sante_percu =
  age
  nombre_consultations_annuelles
  nombre_medicaments_reguliers
  sexe
  hospitalisation_12_mois
  activite_physique
  handicap_declare / link = cumlogit
  rsquare
  lackfit
  stb;
  title "Régression logistique ordinale - etat_sante_percu

```

```

(modèle réduit)";
run;

/* 7d. Régression logistique BINAIRE
Variable réponse : sante_mauvaise (0/1) */
proc logistic data = proj.base_esps descending;
class sexe (ref = "Homme")
hospitalisation_12_mois (ref = "Non")
tabagisme (ref = "Non-fumeur")
activite_physique (ref = "Sédentaire")
handicap_declare (ref = "Non") / param = ref;
model sante_mauvaise (event = "1") =
age
revenus_mensuels_euros
imc
nombre_consultations_annuelles
nombre_medicaments_reguliers
sexe
hospitalisation_12_mois
tabagisme
activite_physique
handicap_declare / rsquare
lackfit
ctable
stb;
title "Régression logistique binaire - sante_mauvaise (0/1)";
run;

/* 7e. Sélection de variables en régression logistique (stepwise) */
proc logistic data = proj.base_esps descending;
class sexe (ref = "Homme")
hospitalisation_12_mois (ref = "Non")
tabagisme (ref = "Non-fumeur")
activite_physique (ref = "Sédentaire")
handicap_declare (ref = "Non")
couverture_complementaire (ref = "Mutuelle privée")
/ param = ref;
model etat_sante_percu =
age
revenus_mensuels_euros
imc
nombre_consultations_annuelles
nombre_medicaments_reguliers
depenses_sante_annuelles_euros
sexe
hospitalisation_12_mois
tabagisme
activite_physique
handicap_declare
couverture_complementaire / link = cumlogit
selection = stepwise
slentry = 0.05
slstay = 0.05;
title "Sélection stepwise - Régression logistique ordinale";
run;

/* 7f. Courbe ROC (régression binaire uniquement) */
proc logistic data = proj.base_esps descending
plots(only) = (roc effect oddsratio);
class sexe (ref = "Homme")
hospitalisation_12_mois (ref = "Non")
activite_physique (ref = "Sédentaire")
handicap_declare (ref = "Non") / param = ref;

```

```
model sante_mauvaise (event = "1") =  
  age  
  nombre_consultations_annuelles  
  nombre_medicaments_reguliers  
  sexe  
  hospitalisation_12_mois  
  activite_physique  
  handicap_declare / rsquare  
  lackfit  
  ctable;  
  title "Régression logistique binaire - Courbe ROC";  
run;  
  
/* 7g. Matrice de confusion (table de classement)  
→ produite automatiquement par l'option ctable ci-dessus.  
Interprétation : sensibilité, spécificité, taux de classement. */
```

Annexe C : Code R complet

L'intégralité du code R reproduisant fidèlement les analyses du code SAS est présentée ci-dessous. Le script autonome est également disponible à la racine du projet sous le nom `annexe_C_code_R.R`.

Correspondances SAS → R

Section	Procédure SAS	Équivalent R
§0 Importation	PROC IMPORT	<code>read.csv2()</code>
§1a Bivariée quali	PROC FREQ / <code>chisq measures</code>	<code>chisq.test() + vcd::assocstats()</code>
§1b ANOVA	PROC GLM / <code>tukey</code>	<code>aov() + TukeyHSD()</code>
§1c Kruskal-Wallis	PROC NPAR1WAY <code>wilcoxon</code>	<code>kruskal.test()</code>
§1d Spearman	PROC CORR <code>spearman</code>	<code>cor.test(method="spearman")</code>
§2 Régr. linéaire	PROC REG	<code>lm()</code>
§3 VIF	PROC REG / <code>vif tol</code>	<code>car::vif()</code>
§3 Corrélation	PROC CORR	<code>cor() + corrplot::corrplot()</code>
§3 Cond. number	PROC REG / <code>collin</code>	<code>svd(), rapport max/min</code>
§4 Sous-modèles	PROC REG / <code>selection=ADJRSQ best=5</code>	<code>leaps::regsubsets()</code>
§4 Forward	PROC REG / <code>selection=forward</code>	<code>step(direction="forward")</code>
§4 Backward	PROC REG / <code>selection=backward</code>	<code>step(direction="backward")</code>
§4 Stepwise	PROC REG / <code>selection=stepwise</code>	<code>step(direction="both")</code>
§5 Résidus	OUTPUT <code>rstudent / cookd / h</code>	<code>rstudent(), cooks.distance(), hatvalues()</code>
§5 Normalité	PROC UNIVARIATE <code>normal qqplot</code>	<code>shapiro.test() + qqnorm()</code>
§5 Durbin-Watson	PROC REG / <code>dwprob</code>	<code>lmtest::dwtest()</code>
§5 White	PROC REG / <code>spec</code>	<code>lmtest::bptest()</code>
§5 Résidus partiels	PROC REG <code>plots(partialplot)</code>	<code>car::avPlots()</code>
§5 LOESS	PROC SGPLOT <code>loess</code>	<code>geom_smooth("loess")</code>
§5k K-fold	Macro <code>%kfold_ordinal</code>	Boucle <code>MASS::polr() + set.seed(42)</code>
§6 ANCOVA	PROC GLM / <code>ss3</code>	<code>lm() + car::Anova(type="III")</code>
§6 LSMEANS	LSMEANS / <code>pdiff adjust=tukey</code>	<code>emmeans::emmeans() + pairs()</code>
§7 Ordinal	PROC LOGISTIC / <code>link=cumlogit</code>	<code>MASS::polr(method="logistic")</code>
§7 Score Test	Proportional Odds Assumption	<code>brant::brant()</code>
§7 Binaire	PROC LOGISTIC / <code>model Y(event="1")</code>	<code>glm(family=binomial)</code>
§7 Stepwise logit	PROC LOGISTIC / <code>selection=stepwise</code>	<code>MASS::stepAIC(direction="both")</code>
§7 ROC	PROC LOGISTIC <code>plots(roc)</code>	<code>pROC::roc() + plot()</code>

Packages requis :

```
install.packages(c("dplyr", "ggplot2", "car", "MASS", "lmtest", "sandwich",
                  "corrplot", "pROC", "emmeans", "leaps", "vcd", "brant"))
```

```
#####
# ANNEXE C -- Code R complet
# Reproduction fidele des analyses SAS (analyse_etat_sante_esps.sas)
#####

library(dplyr); library(ggplot2); library(car); library(MASS)
library(lmtest); library(sandwich); library(corrplot)
library(pROC); library(emmeans); library(leaps); library(vcd)

# =====
# 0. IMPORTATION ET RECODAGE (equiv. PROC IMPORT + DATA step)
# =====

esps <- read.csv2("data/base_esps.csv",
                  fileEncoding = "UTF-8", stringsAsFactors = TRUE)
str(esps); print(table(esps$etat_sante_percu))

esps$score_sante <- dplyr::case_when(
  esps$etat_sante_percu == "Tres mauvais" ~ 1L,
  esps$etat_sante_percu == "Mauvais" ~ 2L,
  esps$etat_sante_percu == "Assez bon" ~ 3L,
  esps$etat_sante_percu == "Bon" ~ 4L,
  esps$etat_sante_percu == "Tres bon" ~ 5L,
  TRUE ~ NA_integer_
)

esps$etat_sante_percu <- factor(
  esps$etat_sante_percu,
```

```

levels = c("Tres mauvais", "Mauvais", "Assez bon", "Bon", "Tres bon"),
ordered = TRUE)
esps$sante_mauvaise <- ifelse(esps$score_sante <= 2, 1L, 0L)
esps$hospit_num <- ifelse(esps$hospitalisation_12_mois == "Oui", 1, 0)
esps$handicap_num <- ifelse(esps$handicap_declare == "Oui", 1, 0)
esps$renoncement_num <- ifelse(esps$renoncement_soins_12_mois == "Oui", 1, 0)
print(table(as.character(esps$etat_sante_percu), esps$score_sante))

# =====
# 1. ANALYSE BIVARIEE EXPLORATOIRE
# =====
# NOTE : exploratoire uniquement -- selection = cadre theorique.

# 1a. Chi2 + V de Cramer (equiv. PROC FREQ / chisq measures)
vars_quali <- c("sexe", "profession", "niveau_education", "situation_familiale",
  "couverture_complementaire", "hospitalisation_12_mois", "tabagisme",
  "consommation_alcool", "activite_physique", "handicap_declare",
  "renoncement_soins_12_mois", "maladies_declarees")
for (v in vars_quali) {
  tbl <- table(esps$etat_sante_percu, esps[[v]])
  cat("\n---", v, "---\n"); print(chisq.test(tbl))
  cat("V de Cramer :", round(vcd::assocstats(tbl)$cramer, 4), "\n")
}

# 1b. ANOVA exploratoire (equiv. PROC GLM / tukey) -- role indicatif seul
vars_quant <- c("age", "revenus_mensuels_euros", "imc",
  "depenses_sante_annuelles_euros",
  "nombre_consultations_annuelles", "nombre_medicaments_reguliers")
for (v in vars_quant) {
  fit_av <- aov(as.formula(paste(v, "~ etat_sante_percu")), data = esps)
  cat("\n--- ANOVA :", v, "---\n"); print(summary(fit_av))
  print(TukeyHSD(fit_av))
}

# 1c. Kruskal-Wallis (equiv. PROC NPAR1WAY wilcoxon)
for (v in vars_quant) {
  kt <- kruskal.test(as.formula(paste(v, "~ etat_sante_percu")), data = esps)
  cat(sprintf("%-40s H=%.3f p=%.4f\n", v, kt$statistic, kt$p.value))
}

# 1d. Spearman -- TEST PRINCIPAL quantitatif (equiv. PROC CORR spearman)
vars_with <- c("age", "revenus_mensuels_euros", "imc",
  "depenses_sante_annuelles_euros", "nombre_consultations_annuelles",
  "nombre_medicaments_reguliers", "nombre_enfants")
for (v in vars_with) {
  r <- cor.test(esps$score_sante, esps[[v]], method = "spearman")
  cat(sprintf("%-40s rho=%.4f p=%.4f\n", v, r$estimate, r$p.value))
}

# 1e. Boxplots (equiv. PROC SGPLOT vbox)
for (v in c("age", "imc", "depenses_sante_annuelles_euros",
  "nombre_consultations_annuelles")) {
  print(
    ggplot(esps, aes(x = etat_sante_percu, y = .data[[v]],
      fill = etat_sante_percu)) +
    geom_boxplot(alpha = 0.7) +
    scale_fill_brewer(palette = "RdYlGn") +
    labs(x = "Etat de sante_percu", y = v,
      title = paste("Distribution de", v)) +
    theme_minimal() + theme(legend.position = "none")
  )
}

```

```

# =====
# 2. ROBUSTESSE -- REGRESSION LINEAIRE (equiv. PROC REG)
# =====
lm_complet <- lm(score_sante ~ age + revenus_mensuels_euros +
  depenses_sante_annuelles_euros + nombre_consultations_annuelles +
  nombre_medicaments_reguliers + imc + nombre_enfants, data = esps)
print(summary(lm_complet))

# Modele reduit -- base THEORIQUE (Grossman, 1972)
lm_reduit <- lm(score_sante ~ age + nombre_consultations_annuelles +
  nombre_medicaments_reguliers, data = esps)
print(summary(lm_reduit))

# =====
# 3. COLINEARITE (equiv. PROC REG / vif tol collin ; PROC CORR)
# =====
vif_vals <- car::vif(lm_complet)
print(round(vif_vals, 4)); print(round(1/vif_vals, 4)) # Tolerance
vars_pred <- c("age", "revenus_mensuels_euros", "depenses_sante_annuelles_euros",
  "nombre_consultations_annuelles", "nombre_medicaments_reguliers",
  "imc", "nombre_enfants")
cor_mat <- cor(esps[, vars_pred], use = "complete.obs")
print(round(cor_mat, 3))
corrplot::corrplot(cor_mat, method = "color", type = "upper",
  addCoef.col = "black", number.cex = 0.6, tl.cex = 0.75)
sv <- svd(model.matrix(lm_complet))$d
cat(sprintf("Condition number : %.2f (seuil severe : 30)\n", max(sv)/min(sv)))

# =====
# 4. SELECTION AUTO -- VERIFICATION DE COHERENCE SEULEMENT
# =====
lm_null_sel <- lm(score_sante ~ 1, data = esps)
lm_full_sel <- lm(score_sante ~ age + revenus_mensuels_euros +
  depenses_sante_annuelles_euros + nombre_consultations_annuelles +
  nombre_medicaments_reguliers + imc + nombre_enfants, data = esps)

# 4a. Tous sous-modeles (equiv. PROC REG / selection=ADJRSQ best=5)
reg_sub <- leaps::regsubsets(
  score_sante ~ age + revenus_mensuels_euros + depenses_sante_annuelles_euros
  + nombre_consultations_annuelles + nombre_medicaments_reguliers
  + imc + nombre_enfants, data = esps, nvmax = 7)
reg_sum <- summary(reg_sub)
cat("R2 ajuste :\n"); print(round(reg_sum$adjr2, 4))
print(reg_sum$which[order(reg_sum$adjr2, decreasing = TRUE)[1:5], ])

# 4b. Forward (equiv. PROC REG / selection=forward slentry=0.05)
lm_forward <- step(lm_null_sel, direction = "forward",
  scope = list(lower = lm_null_sel, upper = lm_full_sel), trace = 1)
print(summary(lm_forward))

# 4c. Backward (equiv. PROC REG / selection=backward slstay=0.05)
lm_backward <- step(lm_full_sel, direction = "backward", trace = 1)
print(summary(lm_backward))

# 4d. Stepwise -- VERIFICATION DE COHERENCE SEULEMENT
lm_stepwise <- step(lm_null_sel, direction = "both",
  scope = list(lower = lm_null_sel, upper = lm_full_sel), trace = 1)
print(summary(lm_stepwise))

# =====
# 5. VALIDATION DU MODELE LINEAIRE (robustesse)
# =====
resid_df <- data.frame(

```

```

    resid    = residuals(lm_reduit), yhat    = fitted(lm_reduit),
    rstud    = rstudent(lm_reduit),  cooks   = cooks.distance(lm_reduit),
    leverage = hatvalues(lm_reduit))

# 5b. Normalite (equiv. PROC UNIVARIATE normal qqplot)
qqnorm(resid_df$resid); qqline(resid_df$resid, col = "red")
print(shapiro.test(resid_df$resid))

# 5c. Histogramme
hist(resid_df$resid, breaks = 25, probability = TRUE, col = "steelblue")
curve(dnorm(x, 0, sd(resid_df$resid)), add = TRUE, col = "red", lwd = 2)

# 5d-5e. RStudent x Leverage + Cook
plot(resid_df$leverage, resid_df$rstud,
     xlab = "Leverage", ylab = "RStudent", pch = 19, cex = 0.7)
abline(h = c(-2, 2), lty = 2, col = "red")
threshold_cook <- 4 / nrow(esps) # 4/500 = 0.008
plot(resid_df$cooks, type = "h", ylab = "Cook's D")
abline(h = threshold_cook, col = "red", lty = 2)

# 5f. Durbin-Watson (equiv. PROC REG / dwprob)
print(lmtest::dwtest(lm_reduit))

# 5g. Test de White (equiv. PROC REG / spec)
print(lmtest::bptest(lm_reduit, studentize = FALSE))

# 5h. Residus partiels (equiv. PROC REG plots(partialplot))
car::avPlots(lm_reduit)

# 5i. LOESS (equiv. PROC SGPLOT loess)
for (v in c("age", "nombre_consultations_annuelles",
            "nombre_medicaments_reguliers")) {
  print(
    ggplot(esps, aes(x = .data[[v]], y = score_sante)) +
      geom_point(alpha = 0.3, size = 1) +
      geom_smooth(method = "loess", se = TRUE, color = "red") +
      labs(x = v, y = "score_sante") + theme_minimal()
  )
}

# 5j. Observations aberrantes
idx_out <- which(abs(resid_df$rstud) > 2 | resid_df$cooks > threshold_cook)
print(cbind(esps[idx_out, c("id", "age", "score_sante")],
            round(resid_df[idx_out, ], 4)))

# -----
# 5k. K-FOLD (k=10) -- modele ordinal (equiv. macro %kfold_ordinal)
# -----
set.seed(42); k <- 10L; n <- nrow(esps)
folds <- rep(NA_integer_, n)
for (lev in levels(esps$etat_sante_percu)) {
  idx <- which(as.character(esps$etat_sante_percu) == lev)
  idx_s <- sample(idx)
  folds[idx_s] <- (seq_along(idx_s) - 1L) %% k + 1L
}
concordance_folds <- numeric(k)
for (i in seq_len(k)) {
  fit_fold <- MASS::polr(
    etat_sante_percu ~ age + nombre_consultations_annuelles +
      nombre_medicaments_reguliers + sexe + hospitalisation_12_mois +
      activite_physique + handicap_declare,
    data = esps[folds != i, ], Hess = TRUE, method = "logistic")
  pred <- predict(fit_fold, newdata = esps[folds == i, ])
}

```

```

    concordance_folds[i] <- mean(pred == esps$etat_sante_percu[folds == i])
    cat(sprintf("  Fold %2d : %.4f\n", i, concordance_folds[i]))
  }
cat(sprintf("Concordance moy : %.4f  sd : %.4f\n",
            mean(concordance_folds), sd(concordance_folds)))

# =====
# 6. ROBUSTESSE -- ANCOVA (equiv. PROC GLM/ss3 + LSMEANS/tukey)
# =====
esps$sexe <- relevel(esps$sexe, ref = "Homme")
esps$hospitalisation_12_mois <- relevel(esps$hospitalisation_12_mois, ref="Non")
esps$tabagisme <- relevel(esps$tabagisme, ref = "Non-fumeur")
esps$activite_physique <- relevel(esps$activite_physique, ref = "Sedentaire")
esps$handicap_declare <- relevel(esps$handicap_declare, ref = "Non")
esps$couverture_complementaire <- relevel(esps$couverture_complementaire,
                                           ref = "Mutuelle privée")

# 6a. ANCOVA complete
lm_ancova_complet <- lm(score_sante ~ age + revenus_mensuels_euros + imc +
  depenses_sante_annuelles_euros + nombre_consultations_annuelles +
  nombre_medicaments_reguliers + sexe + profession + couverture_complementaire
  + hospitalisation_12_mois + tabagisme + activite_physique +
  handicap_declare + maladies_declarees, data = esps)
print(car::Anova(lm_ancova_complet, type = "III"))

# 6b. ANCOVA reduite
lm_ancova_reduit <- lm(score_sante ~ age + nombre_consultations_annuelles +
  nombre_medicaments_reguliers + sexe + hospitalisation_12_mois +
  activite_physique + handicap_declare, data = esps)
print(car::Anova(lm_ancova_reduit, type = "III"))
print(summary(lm_ancova_reduit))
for (fac in c("sexe", "hospitalisation_12_mois", "activite_physique",
              "handicap_declare")) {
  cat("\n---", fac, "---\n")
  print(pairs(emmeans::emmeans(lm_ancova_reduit, fac), adjust = "tukey"))
}

# 6c. Interaction Age x Sexe
lm_ia <- lm(score_sante ~ age + sexe + age:sexe, data = esps)
print(car::Anova(lm_ia, type = "III"))

# =====
# 7. MODELE PRINCIPAL -- REGRESSION LOGISTIQUE ORDINALE
# =====
# MASS::polr() = equiv. exact PROC LOGISTIC / link=cumlogit

# 7a. Modele complet
polr_complet <- MASS::polr(
  etat_sante_percu ~ age + revenus_mensuels_euros + imc +
  nombre_consultations_annuelles + nombre_medicaments_reguliers +
  depenses_sante_annuelles_euros + sexe + hospitalisation_12_mois +
  tabagisme + activite_physique + handicap_declare + couverture_complementaire,
  data = esps, Hess = TRUE, method = "logistic")
print(summary(polr_complet))
cat("OR :\n"); print(round(exp(coef(polr_complet)), 4))
print(round(exp(confint(polr_complet)), 4))

# Pseudo-R2 de Nagelkerke (equiv. option rsquare de SAS)
ll_null_p <- logLik(MASS::polr(etat_sante_percu ~ 1, data = esps,
                              method = "logistic", Hess = FALSE))
ll_model_p <- logLik(polr_complet); n_obs <- nrow(esps)
r2_nag <- (1 - exp((2/n_obs)*(as.numeric(ll_null_p)-as.numeric(ll_model_p)))) /
  (1 - exp((2/n_obs)*as.numeric(ll_null_p)))

```



```

cat(sprintf("Pseudo-R2 Nagelkerke : %.4f  AIC : %.2f  BIC : %.2f\n",
            r2_nag, AIC(polr_complet), BIC(polr_complet)))

# 7b. Test de proportionnalite des odds (equiv. Score Test de SAS)
if (requireNamespace("brant", quietly = TRUE)) {
  print(brant::brant(polr_complet))
} else cat("install.packages('brant') pour le test de proportionnalite\n")

# 7c. Modele reduit -- MODELE PRINCIPAL FINAL (base theorique)
polr_reduit <- MASS::polr(
  etat_sante_percu ~ age + nombre_consultations_annuelles +
  nombre_medicaments_reguliers + sexe + hospitalisation_12_mois +
  activite_physique + handicap_declare,
  data = esps, Hess = TRUE, method = "logistic")
print(summary(polr_reduit))
cat("OR :\n"); print(round(exp(coef(polr_reduit)), 4))
print(round(exp(confint(polr_reduit)), 4))
cat(sprintf("AIC=%.2f  BIC=%.2f\n", AIC(polr_reduit), BIC(polr_reduit)))

# 7d. Logistique binaire (robustesse)
logit_bin <- glm(sante_mauvaise ~ age + revenus_mensuels_euros + imc +
  nombre_consultations_annuelles + nombre_medicaments_reguliers +
  sexe + hospitalisation_12_mois + tabagisme + activite_physique +
  handicap_declare, data = esps, family = binomial)
print(summary(logit_bin))
cat("OR :\n"); print(round(exp(coef(logit_bin)), 4))
pred_bin <- ifelse(predict(logit_bin, type = "response") >= 0.5, 1, 0)
print(table(Observe = esps$sante_mauvaise, Predit = pred_bin))
cat(sprintf("Taux : %.1f%%\n", mean(pred_bin == esps$sante_mauvaise)*100))

# 7e. Coherence stepwise -- VERIFICATION SEULEMENT
polr_step <- MASS::stepAIC(polr_complet, direction = "both", trace = 1)
print(summary(polr_step))

# 7f. Courbe ROC (equiv. PROC LOGISTIC plots(roc))
logit_bin_red <- glm(sante_mauvaise ~ age + nombre_consultations_annuelles +
  nombre_medicaments_reguliers + sexe + hospitalisation_12_mois +
  activite_physique + handicap_declare, data = esps, family = binomial)
roc_obj <- pROC::roc(esps$sante_mauvaise,
  predict(logit_bin_red, type = "response"), quiet = TRUE)
cat(sprintf("AUC = %.4f\n", pROC::auc(roc_obj)))
plot(roc_obj, main = paste("Courbe ROC -- AUC =", round(pROC::auc(roc_obj),4)),
  col = "steelblue", lwd = 2)
abline(a = 0, b = 1, lty = 2, col = "grey")

# 7g. Matrice de confusion (equiv. ctable de SAS)
pred_r <- ifelse(predict(logit_bin_red, type = "response") >= 0.5, 1, 0)
cf <- table(Observe = esps$sante_mauvaise, Predit = pred_r)
print(cf)
cat(sprintf("Sensibilite : %.1f%%  Specificite : %.1f%%  Global : %.1f%%\n",
  cf[2,2]/(cf[2,2]+cf[2,1])*100,
  cf[1,1]/(cf[1,1]+cf[1,2])*100,
  (cf[2,2]+cf[1,1])/sum(cf)*100))

#####
# FIN DE L'ANNEXE C
#####

```

Bibliographie

- [1] Alan AGRESTI. *Analysis of Ordinal Categorical Data*. 2nd. Wiley, 2010.

- [2] Bruno ART et al. « Inégalités des chances en santé : influence de la profession et de l'assurance maladie complémentaire ». In : *Bulletin Épidémiologique Hebdomadaire* 2-3 (2006), p. 19-21.
- [3] Clare BAMBRA et al. « Gender, Health Inequalities and Welfare State Regimes : A Cross-National Study of 13 European Countries ». In : *Journal of Epidemiology and Community Health* 63.1 (2009), p. 38-44. DOI : [10.1136/jech.2007.070292](https://doi.org/10.1136/jech.2007.070292).
- [4] Stefan BOES et Rainer WINKELMANN. « Ordered Response Models ». In : *Allgemeines Statistisches Archiv* 90.1 (2006), p. 167-181. DOI : [10.1007/s10182-006-0228-y](https://doi.org/10.1007/s10182-006-0228-y).
- [5] Damien BRICARD et al. « Inequality of Opportunities in Health and the Principle of Natural Reward : Evidence from European Countries ». In : *Research on Economic Inequality* 23 (2015), p. 335-370.
- [6] Kenneth P. BURNHAM et David R. ANDERSON. *Model Selection and Multimodel Inference : A Practical Information-Theoretic Approach*. 2nd. Springer, 2002.
- [7] Emmanuelle CAMBOIS, Caroline LABORDE et Jean-Marie ROBINE. « La “double peine” des ouvriers : plus d’années d’incapacité au sein d’une vie plus courte ». In : *Population et Sociétés* 441 (2008).
- [8] COMMISSION ON SOCIAL DETERMINANTS OF HEALTH. *Closing the Gap in a Generation : Health Equity Through Action on the Social Determinants of Health*. Geneva : World Health Organization, 2008.
- [9] Göran DAHLGREN et Margaret WHITEHEAD. « Policies and Strategies to Promote Social Equity in Health ». In : *Institute for Futures Studies* (1991).
- [10] Karen B. DESALVO et al. « Mortality Prediction with a Single General Self-Rated Health Question : A Meta-Analysis ». In : *Journal of General Internal Medicine* 21.3 (2006), p. 267-275. DOI : [10.1111/j.1525-1497.2005.00291.x](https://doi.org/10.1111/j.1525-1497.2005.00291.x).
- [11] Caroline DESPRÈS et al. « Le renoncement aux soins : une approche socio-anthropologique ». In : *Questions d'Économie de la Santé* 169 (2011).
- [12] Marion DEVAUX et al. « La santé des seniors selon leur origine sociale ». In : *Économie et Statistique* 411 (2010), p. 25-46.
- [13] Eddy van DOORSLAER et Xander KOOLMAN. « Explaining the Differences in Income-Related Health Inequalities Across European Countries ». In : *Health Economics* 13.7 (2004), p. 609-628. DOI : [10.1002/hec.918](https://doi.org/10.1002/hec.918).
- [14] Paul DOURGNON, Florence JUSOT et Romain FANTIN. « Payer nuit gravement à la santé : une étude de l'impact du renoncement financier aux soins sur l'état de santé ». In : *Économie Publique* 28-29 (2012), p. 123-147.
- [15] Fabrice ETILÉ et Carine MILCENT. « Income-Related Reporting Heterogeneity in Self-Assessed Health : Evidence from France ». In : *Health Economics* 15.9 (2007), p. 965-981.
- [16] William H. GREENE. *Econometric Analysis*. 8th. New York : Pearson, 2018.
- [17] Michael GROSSMAN. « On the Concept of Health Capital and the Demand for Health ». In : *Journal of Political Economy* 80.2 (1972), p. 223-255. DOI : [10.1086/259880](https://doi.org/10.1086/259880).
- [18] David W. HOSMER, Stanley LEMESHOW et Rodney X. STURDIVANT. *Applied Logistic Regression*. 3rd. Wiley, 2013.
- [19] Ellen L. IDLER et Yael BENYAMINI. « Self-Rated Health and Mortality : A Review of Twenty-Seven Community Studies ». In : *Journal of Health and Social Behavior* 38.1 (1997), p. 21-37. DOI : [10.2307/2955359](https://doi.org/10.2307/2955359).
- [20] IRDES. *Enquête sur la Santé et la Protection Sociale (ESPS)*. Dernière édition : 2014. 2014. URL : <https://www.irdes.fr/recherche/enquetes/esps-enquete-sur-la-sante-et-la-protection-sociale/>.

- [21] Marja JYLHÄ. « What is Self-Rated Health and Why Does it Predict Mortality ? Towards a Unified Conceptual Model ». In : *Social Science & Medicine* 69.3 (2009), p. 307-316. DOI : [10.1016/j.socscimed.2009.05.013](https://doi.org/10.1016/j.socscimed.2009.05.013).
- [22] Bruce P. KENNEDY et al. « Income Distribution, Socioeconomic Status, and Self Rated Health in the United States : Multilevel Analysis ». In : *BMJ* 317.7163 (1998), p. 917-921. DOI : [10.1136/bmj.317.7163.917](https://doi.org/10.1136/bmj.317.7163.917).
- [23] Johan P. MACKENBACH et al. « Socioeconomic Inequalities in Morbidity and Mortality in Western Europe ». In : *The Lancet* 349.9066 (1999), p. 1655-1659.
- [24] Michael MARMOT. *The Status Syndrome : How Social Standing Affects Our Health and Longevity*. London : Bloomsbury Publishing, 2005.
- [25] Peter McCULLAGH. « Regression Models for Ordinal Data ». In : *Journal of the Royal Statistical Society. Series B (Methodological)* 42.2 (1980), p. 109-142.
- [26] Archana SINGH-MANOUX et al. « What Does Self Rated Health Measure ? Results from the British Whitehall II and French Gazel Cohort Studies ». In : *Journal of Epidemiology and Community Health* 60.4 (2006), p. 364-372. DOI : [10.1136/jech.2005.039883](https://doi.org/10.1136/jech.2005.039883).
- [27] S. V. SUBRAMANIAN, Daniel J. KIM et Ichiro KAWACHI. « Social Trust and Self-Rated Health in US Communities : A Multilevel Analysis ». In : *Journal of Urban Health* 79.Suppl 1 (2002), S21-S34. DOI : [10.1093/jurban/79.suppl_1.S21](https://doi.org/10.1093/jurban/79.suppl_1.S21).
- [28] Jeffrey M. WOOLDRIDGE. *Introductory Econometrics : A Modern Approach*. 6th. Cengage Learning, 2015.