Projet de Modèles linéaires avec Statistical Analysis System

valant évaluation dans le cadre de :
Diplôme : Master Statistique pour l'évaluation et la prévision, 1ère année
Année universitaire : 2025-2026
Module d'enseignement : Modèles linéaires - Statistical Analysis System
Responsable : CHARLOTTE PAPELARD
Comptant pour : 50%

Analyse statistique de l'état de santé perçu en France : modélisation multivariée, sélection de variables et régression logistique ordinale à partir de l'Enquête Santé et Protection Sociale (ESPS)

Hervé ADJAKOSSA

Métriques

Finalisé le : 18 April 2026
Page(s) : 59
Références(s) : –
Figure(s) : –
Table(s) : –
Théorème(s) : 0

Résumé : En France, 8,2 % des adultes déclarent un état de santé « mauvais » ou « très mauvais », un chiffre qui atteint 19 % parmi les ménages du premier quintile de revenus (DREES, 2017). Ce gradient social, documenté par la Commission OMS sur les déterminants sociaux de la santé (2008), soulève une question fondamentale : quels facteurs sociodémographiques, économiques et comportementaux déterminent la perception individuelle de l'état de santé, et comment les hiérarchiser de façon robuste ? Le présent projet met en œuvre une analyse statistique complète des déterminants de l'état de santé perçu en France métropolitaine, à partir de données synthétiques reproduisant la structure de l'Enquête Santé et Protection Sociale (ESPS) de l'IRDES (500 individus, 25 variables). La variable réponse — qualitative ordinale à cinq modalités (Très mauvais, Mauvais, Assez bon, Bon, Très bon) — est analysée au moyen de sept familles de méthodes : analyse bivariée (χ^2, ANOVA, Kruskal-Wallis, Spearman), régression linéaire multiple sur le score ordinal (1–5), colinéarité (VIF, tolérance, indices de conditionnement), sélection de variables (*forward*, *backward*, *stepwise* par AIC/BIC), validation complète (Shapiro-Wilk, Durbin-Watson, Breusch-Pagan, Cook, LOESS), ANCOVA (facteurs qualitatifs, moyennes marginales de Tukey), régression logistique ordinale (cotes proportionnelles, test de Brant) et binaire (ROC, AUC, matrice de confusion). L'âge, les consultations médicales, les médicaments réguliers, l'activité physique et le handicap déclaré émergent comme déterminants robustes, tous significatifs au seuil de 5 % à travers les différentes spécifications. Les limites — données synthétiques, hypothèse de proportionnalité des odds, absence de correction pour biais de sélection — sont rigoureusement discutées.

Mots-clés : État de santé perçu, Régression logistique ordinale, Régression linéaire multiple, ANCOVA, Sélection de variables, Enquête ESPS, Colinéarité, Déterminants sociaux de la santé

Matériel supplémentaire :
git : https://gitlab-mi.univ-reims.fr/adja0021
: ESPS (synthétique) : base_esps_synthétique.csv (500 obs., 25 variables) — IRDES

Table des matières

Introduction générale **4**
0.1 Accroche et contexte général . . . 4
0.2 Intérêt scientifique et empirique : pourquoi étudier la santé perçue par la régression linéaire ? . . . 4
0.3 Problématique générale . . . 4
0.4 Question centrale de recherche . . . 4
0.5 Objectif général et objectifs spécifiques . . . 5
0.6 Hypothèses de recherche . . . 5
0.7 Positionnement scientifique . . . 5
0.8 Stratégie de recherche et démarche méthodologique . . . 5
0.9 Annonce du plan . . . 5

1 Cadre conceptuel, théorique et analytique **6**
1.1 Cadre conceptuel : santé perçue et déterminants sociaux . . . 6
1.2 Cadre théorique : modèles explicatifs de la santé perçue . . . 6
1.3 Cadre analytique : justification des méthodes statistiques retenues . . . 6
1.3.1 Traitement de la variable réponse ordinale . . . 6
1.3.2 Stratégie de modélisation . . . 6
1.3.3 Limites structurelles du design choisi . . . 7

2 Revue de littérature **7**
2.1 Mesures subjectives de la santé : fondements et validité . . . 7
2.2 Déterminants socio-économiques de la santé perçue . . . 8
2.2.1 Effets de l'âge et du sexe . . . 8
2.2.2 Gradient social de santé . . . 8
2.2.3 Rôle de la couverture assurantielle et du renoncement aux soins . . . 8
2.3 La régression linéaire pour expliquer la santé perçue : état de l'art . . . 8
2.3.1 Fondements de l'approche linéaire . . . 8
2.3.2 Applications en France . . . 8
2.3.3 Discussion critique de l'approche linéaire . . . 8
2.4 Positionnement de la contribution . . . 9

3 Méthodologie **9**
3.1 Design de recherche : terrain et pertinence . . . 9
3.2 Corpus de données : justification des sources . . . 9
3.3 Spécification des modèles . . . 9
3.3.1 Modèle de régression linéaire multiple . . . 9
3.3.2 Modèle ANCOVA . . . 9
3.3.3 Modèle logistique ordinal (cotes proportionnelles) . . . 10
3.3.4 Modèle logistique binaire . . . 10
3.4 Procédure d'estimation et justification des tests . . . 10
3.4.1 Sélection du modèle linéaire . . . 10
3.4.2 Sélection du modèle logistique . . . 10
3.5 Stratégie de validation et diagnostics : pourquoi ces tests ? . . . 10
3.5.1 Validation du modèle linéaire . . . 10
3.5.2 Évaluation du modèle logistique . . . 11

4 Données et construction de la base empirique **11**
4.1 Sources des données . . . 11
4.1.1 Variable dépendante : état de santé perçu . . . 11
4.1.2 Variables explicatives retenues et justification . . . 11
4.1.3 Source et nature des données . . . 12
4.2 Importation de la base de données . . . 12
4.3 Construction des variables dérivées . . . 12
4.4 Statistiques descriptives . . . 13

5 Résultats **13**
5.1 Analyse bivariée . . . 13
5.1.1 Croisements Y qualitative × X qualitatives — Test du χ^2 . . . 13
5.1.2 Croisements Y qualitative × X quantitatives — ANOVA . . . 15
5.1.3 Test de Kruskal-Wallis (alternative non paramétrique) . . . 17
5.1.4 Corrélation de Spearman . . . 17
5.1.5 Graphiques bivariés — Boîtes à moustaches . . . 18
5.2 Régression linéaire et R^2 . . . 18
5.2.1 Modèle complet — variables quantitatives . . . 19
5.2.2 Modèle réduit — variables significatives . . . 19
5.3 Étude de la colinéarité . . . 20
5.3.1 VIF et Tolérance . . . 20
5.3.2 Matrice de corrélation entre les prédicteurs . . . 20
5.3.3 Indices de conditionnement . . . 21
5.4 Sélection de variables . . . 21
5.4.1 Sélection par R^2 ajusté, AIC et BIC — Tous les sous-modèles . . . 22

5.4.2 Sélection ascendante (Forward) . . . 22
5.4.3 Sélection descendante (Backward) . . . 23
5.4.4 Sélection pas à pas (Stepwise) . . . 24
5.5 Validation du modèle . . . 26
5.5.1 Normalité des résidus . . . 26
5.5.2 Éléments aberrants — RStudent vs Leverage . . . 28
5.5.3 Distance de Cook . . . 28
5.5.4 Indépendance des résidus — Test de Durbin-Watson . . . 29
5.5.5 Homoscédasticité — Test de Breusch-Pagan (équivalent du test de White sous SAS) . . . 29
5.5.6 Linéarité — Résidus vs valeurs ajustées . . . 30
5.5.7 Visualisation LOESS — score_sante vs chaque prédicteur . . . 30
5.5.8 Observations potentiellement aberrantes / influentes . . . 31
5.5.9 Diagnostics graphiques standards (4 graphiques) . . . 32
5.6 Analyse de covariance (ANCOVA) . . . 32
5.6.1 ANCOVA complète . . . 33
5.6.2 ANCOVA réduite — facteurs significatifs . . . 35
5.6.3 Test d'interaction — Âge × Sexe . . . 38
5.7 Régression logistique . . . 38
5.7.1 Régression logistique ordinale — Modèle complet . . . 38
5.7.2 Régression logistique ordinale — Modèle réduit . . . 40
5.7.3 Régression logistique binaire . . . 41
5.7.4 Sélection de variables — Stepwise (régression logistique) . . . 42
5.7.5 Courbe ROC et AUC . . . 44
5.7.6 Matrice de confusion . . . 44
5.7.7 Pseudo-R^2 (McFadden, Nagelkerke) . . . 45

6 Robustesse, limites et discussion **45**
6.1 Synthèse des résultats et conformité à la réalité . . . 45
6.2 Discussion des hypothèses . . . 46
6.2.1 Hypothèse H1 — Déterminants quantitatifs dominants . . . 46
6.2.2 Hypothèse H2 — Effet propre des facteurs comportementaux et de santé . . . 46
6.2.3 Hypothèse H3 — Supériorité du modèle ordinal . . . 46
6.3 Limites de données . . . 46
6.4 Limites méthodologiques . . . 46
6.5 Limites d'interprétation . . . 46
6.6 Ouvertures . . . 47

Conclusion générale **47**

Annexe A : Description détaillée de la base de données **47**

Annexe B : Code SAS complet **47**

Bibliographie **57**

Introduction générale

0.1. Accroche et contexte général

En 2019, 67,4 % des Français déclaraient un état de santé « bon » ou « très bon », un chiffre qui masque des disparités considérables : parmi les ménages du premier quintile de revenus, la proportion d'adultes se déclarant en « mauvaise » ou « très mauvaise » santé atteint 19 %, soit près du triple de la moyenne nationale [1]. Ce constat, loin d'être anecdotique, traduit un phénomène structurel : les inégalités sociales de santé perçue s'inscrivent au cœur du débat économique et sanitaire contemporain. L'Organisation mondiale de la santé (OMS), à travers sa Commission sur les déterminants sociaux de la santé, a établi que « les conditions dans lesquelles les individus naissent, grandissent, vivent, travaillent et vieillissent constituent les déterminants sociaux de la santé, lesquels sont principalement responsables des inégalités en santé » [2]. Ce constat appelle une quantification rigoureuse des facteurs qui façonnent la perception individuelle de l'état de santé.

La France dispose, à cet égard, d'un instrument d'observation privilégié : l'Enquête Santé et Protection Sociale (ESPS), conduite depuis 1988 par l'Institut de recherche et documentation en économie de la santé (IRDES) [3]. Cette enquête, qui articule données de santé déclarée, recours aux soins et caractéristiques socio-économiques, offre un terrain empirique particulièrement riche pour l'analyse des déterminants de l'état de santé perçu — variable centrale de notre étude.

0.2. Intérêt scientifique et empirique : pourquoi étudier la santé perçue par la régression linéaire ?

L'état de santé perçu (*self-rated health*, SRH) occupe une place singulière en épidémiologie et en économie de la santé. Idler et Benyamini [22], dans une méta-analyse pionnière portant sur vingt-sept études de cohorte, ont démontré que cette mesure subjective constitue un prédicteur indépendant de la mortalité, y compris après ajustement sur l'état de santé objectif. Jylhä [25] propose un modèle conceptuel unifié expliquant ce pouvoir prédictif : la santé perçue intégrerait simultanément des informations biologiques infracliniques, des comparaisons sociales et des représentations culturelles de la santé [4].

La régression linéaire multiple, bien que la variable réponse soit ordinale, est largement mobilisée dans la littérature pour modéliser la santé perçue. Kennedy et al. [26] utilisent la régression linéaire sur un score de santé auto-évalué pour démontrer l'effet des inégalités de revenus sur la santé perçue aux États-Unis. Subramanian, Kim et Kawachi [32] recourent à des modèles linéaires multiniveaux pour estimer l'effet contextuel du capital social sur la santé auto-déclarée. En France, Devaux et al. [12] et Etilé et Milcent [16] mobilisent la régression linéaire pour identifier l'hétérogénéité de déclaration selon le statut socio-économique. Cette approche, qui suppose l'équidistance entre les modalités ordinales, présente l'avantage de la parcimonie et de l'interprétabilité directe des coefficients — un atout essentiel pour l'aide à la décision en santé publique [5].

Notre motivation pour ce choix méthodologique est triple : (i) reproduire et discuter les résultats de la littérature dans le cadre pédagogique de l'ESPS ; (ii) confronter systématiquement la régression linéaire à la régression logistique ordinale pour évaluer la robustesse des conclusions ; (iii) mobiliser un arsenal complet de diagnostics statistiques (colinéarité, validation, sélection) rarement déployés conjointement dans les études existantes.

0.3. Problématique générale

L'enjeu de la modélisation de la santé perçue se situe à l'intersection de deux tensions. D'une part, la nature ordinale de la variable réponse interroge la légitimité de la régression linéaire : l'hypothèse d'équidistance entre « Très mauvais » et « Mauvais » est-elle soutenable ? D'autre part, la multiplicité des déterminants potentiels — biologiques, socio-économiques, comportementaux, institutionnels — engendre des effets de confusion qui requièrent une stratégie d'identification rigoureuse [6].

Comment, dès lors, modéliser et hiérarchiser les déterminants de l'état de santé perçu en France, en tenant compte de la nature ordinale de la variable réponse, des effets de confusion entre variables sociodémographiques, économiques et comportementales, et des limites inhérentes aux données d'enquête en coupe transversale ?

0.4. Question centrale de recherche

Quels sont les facteurs sociodémographiques, économiques et comportementaux qui déterminent significativement l'état de santé perçu des individus en France métropolitaine, et dans quelle mesure la régression logistique ordinale offre-t-elle une modélisation plus adéquate que la régression linéaire sur le score ordinal ?

1. Direction de la recherche, des études, de l'évaluation et des statistiques (DREES), *L'état de santé de la population en France — Rapport 2017*, Paris.

2. Commission on Social Determinants of Health [9], Commission des déterminants sociaux de la santé, Rapport final, Genève.

3. IRDES [23].

4. Ce résultat explique pourquoi les grandes enquêtes de population — EU-SILC, ESPS, SHARE — incluent systématiquement une question d'auto-évaluation de la santé.

5. La régression logistique ordinale, plus rigoureuse sur le plan théorique, sera néanmoins estimée à titre de comparaison et de robustesse.

6. L'endogénéité potentielle des variables de recours aux soins (consultations, médicaments) constitue une difficulté supplémentaire, car ces variables sont simultanément cause et conséquence de l'état de santé (Grossman [20]).

0.5. Objectif général et objectifs spécifiques

Objectif général : Identifier, hiérarchiser et quantifier les déterminants de l'état de santé perçu en France à partir de données reproduisant la structure de l'ESPS, en mobilisant un arsenal complet de méthodes statistiques et en confrontant systématiquement les résultats à la réalité épidémiologique documentée.

Objectifs spécifiques :

1. **Caractériser les associations bivariées** entre l'état de santé perçu et les variables explicatives (qualitatives et quantitatives), en justifiant le choix de chaque test statistique par la nature des variables croisées.
2. **Construire et valider un modèle de régression linéaire multiple** sur le score ordinal, en étudiant la colinéarité (VIF, indices de conditionnement) et en sélectionnant les variables pertinentes par critères informationnels (AIC, BIC, R^2 ajusté).
3. **Estimer un modèle ANCOVA** combinant covariables quantitatives et facteurs qualitatifs, avec tests d'interaction et moyennes marginales (Tukey), pour isoler l'effet propre des déterminants comportementaux.
4. **Estimer un modèle de régression logistique ordinale** (cotes proportionnelles) et un modèle logistique binaire, évaluer leur performance prédictive (ROC, AUC, matrice de confusion) et comparer les approches.
5. **Évaluer la capacité prédictive** des modèles retenus et confronter les résultats aux connaissances empiriques existantes pour juger de la conformité à la réalité.

0.6. Hypothèses de recherche

— **H1** : L'âge, le nombre de consultations médicales et le nombre de médicaments réguliers sont les déterminants quantitatifs les plus fortement associés à l'état de santé perçu — conformément au modèle de capital santé de Grossman [20], selon lequel l'état de santé se déprécie avec l'âge et la consommation médicale reflète le stock de santé résiduel.

— **H2** : L'activité physique et le handicap déclaré exercent un effet significatif sur l'état de santé perçu, au-delà des variables sociodémographiques et économiques (effet propre mis en évidence par l'ANCOVA) — ce qui prolonge les résultats de Singh-Manoux et al. [31] sur les déterminants comportementaux de la santé perçue.

— **H3** : Le modèle logistique ordinal, respectant la nature qualitative ordinale de la variable réponse, offre un ajustement supérieur au modèle linéaire sur le score numérique — hypothèse fondée sur les travaux de McCullagh [30] et Agresti [1] qui établissent la supériorité théorique du *cumulative logit model* pour les réponses ordinales.

0.7. Positionnement scientifique

Ce travail s'inscrit au carrefour de la biostatistique, de l'économie de la santé et de l'économétrie appliquée. Il mobilise des méthodes de régression en grande dimension (sélection de variables, diagnostics de colinéarité) et de régression logistique ordinale, appliquées à des données synthétiques reproduisant la structure de l'ESPS [7]. Le positionnement est délibérément **méthodologique** : il s'agit de démontrer, sur un terrain maîtrisé, la pertinence et les limites de chaque famille de méthodes, plutôt que de produire des résultats directement transposables à la politique de santé publique.

0.8. Stratégie de recherche et démarche méthodologique

La démarche suivie est séquentielle et cumulative, articulée en trois phases :

1. **Phase exploratoire** : analyse bivariée (tests du χ^2, ANOVA, Kruskal-Wallis, corrélation de Spearman) pour identifier les associations brutes entre l'état de santé perçu et chaque variable explicative, sans contrôle des effets confondants.
2. **Phase de modélisation** : régression linéaire multiple avec diagnostics complets (colinéarité, validation des hypothèses), sélection de variables par critères informationnels (AIC, BIC, C_p de Mallows), estimation ANCOVA avec moyennes marginales.
3. **Phase de confrontation et robustesse** : régression logistique ordinale et binaire avec évaluation prédictive (ROC, AUC, pseudo-R^2), test de Brant pour la proportionnalité des cotes, et discussion critique des résultats au regard de la littérature.

Le terrain d'application est la France métropolitaine, cadre géographique justifié par la disponibilité de l'ESPS et par la richesse de la littérature comparative (gradient social documenté par Doorslaer et Koolman [13] ; Art et al. [2]).

0.9. Annonce du plan

Le **chapitre 1** pose le cadre conceptuel, théorique et analytique en justifiant chaque choix méthodologique. Le **chapitre 2** propose un état de l'art sur les déterminants de la santé perçue et les méthodes de régression linéaire appliquées à ce domaine, en identifiant la contribution spécifique de notre travail. Le **chapitre 3** détaille la méthodologie statistique retenue et justifie la légitimité de chaque test. Le **chapitre 4** présente les données, la construction des variables et les statistiques descriptives commentées. Le **chapitre 5** expose l'ensemble des résultats, chaque figure et tableau étant interprété au regard de ses implications sanitaires et économiques. Le **chapitre 6** discute la robustesse, les limites et les perspectives.

7. La nature synthétique des données, si elle interdit toute conclusion épidémiologique réelle, autorise en revanche une discussion méthodologique approfondie sur la validité comparée des différentes approches statistiques.

1. Cadre conceptuel, théorique et analytique

Ce chapitre pose les fondements conceptuels et théoriques de notre démarche. Chaque choix — du cadre d'analyse au type de modèle — est explicitement justifié au regard de la littérature et de la nature des données mobilisées.

1.1. Cadre conceptuel : santé perçue et déterminants sociaux

L'état de santé perçu (*self-rated health*, SRH) est une mesure subjective globale où l'individu évalue sa propre santé sur une échelle ordinale (Très bon → Très mauvais). Cette mesure, malgré sa simplicité apparente, capture des dimensions multiples de la santé — physique, mentale, fonctionnelle — et s'est révélée un prédicteur indépendant de la mortalité dans de nombreuses cohortes prospectives [22] [8].

Pourquoi retenir la santé perçue comme variable réponse ? Trois arguments justifient ce choix : (i) la santé perçue est disponible dans toutes les grandes enquêtes de population (ESPS, EU-SILC, SHARE), ce qui autorise les comparaisons internationales [13] ; (ii) elle agrège des informations biologiques et psychosociales inaccessibles par les seuls indicateurs objectifs [25] ; (iii) elle est corrélée aux comportements de santé et au recours aux soins, ce qui en fait un outil pertinent pour l'évaluation des politiques de santé publique [9].

Les déterminants sociaux de la santé, selon le modèle de Dahlgren et Whitehead [10], s'organisent en couches concentriques : facteurs biologiques individuels (âge, sexe), comportements et modes de vie (tabagisme, activité physique, alimentation), réseaux sociaux, conditions de vie et de travail, et enfin conditions socio-économiques, culturelles et environnementales générales. Ce modèle constitue notre grille de lecture pour la sélection des variables explicatives.

1.2. Cadre théorique : modèles explicatifs de la santé perçue

Plusieurs cadres théoriques sous-tendent l'analyse des déterminants de la santé perçue. Nous les mobilisons conjointement, car aucun ne suffit isolément à rendre compte de la complexité du phénomène :

- **Modèle de capital santé de Grossman** [20] : l'état de santé est un stock qui se déprécie avec l'âge et dans lequel l'individu investit (consultations, médicaments, activité physique). Ce modèle justifie l'inclusion de l'âge, des consultations et des médicaments comme déterminants centraux [10].
- **Modèle socio-économique** [28] : les inégalités de revenus, d'éducation et de profession génèrent des gradients de santé perçue. Ce cadre justifie l'inclusion des variables de revenus, de profession et de couverture assurantielle.
- **Modèle comportemental** : les comportements à risque (tabagisme, sédentarité, consommation d'alcool) médiatisent partiellement les effets socio-économiques sur la santé [6]. Ceci motive l'inclusion des variables de tabagisme, d'activité physique et de consommation d'alcool.
- **Modèle d'accès aux soins** [11] : la couverture assurantielle et le renoncement aux soins modulent la relation entre besoin de santé et état perçu, justifiant l'inclusion de la couverture complémentaire et du renoncement aux soins.

1.3. Cadre analytique : justification des méthodes statistiques retenues

1.3.1 Traitement de la variable réponse ordinale

La variable `etat_sante_percu` (5 modalités ordonnées) pose un choix méthodologique fondamental, que nous tranchons par une approche duale :

- **Approche numérique** : conversion en score (1–5) et utilisation des méthodes de régression linéaire classique (MCO, ANCOVA). Cette approximation, bien que reposant sur l'hypothèse d'équidistance entre les modalités, est défendue par Wooldridge [33] dans les cas où l'échelle ordinale comporte au moins cinq modalités [11].
- **Approche ordinale** : régression logistique ordinale (*cumulative logit model*, modèle à cotes proportionnelles) initialement proposée par McCullagh [30], qui respecte la nature qualitative de la réponse. Nous testons l'hypothèse de proportionnalité par le test de Brant [5].

Pourquoi combiner les deux approches ? La confrontation systématique permet de (i) évaluer la robustesse des résultats à la spécification du modèle ; (ii) identifier les variables dont l'effet est sensible au traitement de l'échelle ordinale ; (iii) apporter une contribution méthodologique rarement entreprise sur un même jeu de données.

1.3.2 Stratégie de modélisation

La démarche retenue est séquentielle et cumulative, chaque étape étant justifiée par la littérature méthodologique :

8. Le pouvoir prédictif de la santé perçue a été confirmé dans plus de 27 études de cohorte, couvrant des contextes culturels variés (États-Unis, Europe, Japon).

9. Singh-Manoux et al. [31] montrent, sur les cohortes Whitehall II et Gazel, que la santé perçue reflète des processus physiologiques infracliniques détectables par des marqueurs biologiques.

10. Le modèle de Grossman prédit que la demande de santé croît avec le niveau d'éducation, car l'éducation augmente l'efficience de la production de santé.

11. Sous cette condition, la régression linéaire fournit des estimateurs « raisonnablement proches » des modèles ordinaux, tout en conservant la simplicité d'interprétation des coefficients.

1. **Analyse bivariée** : tests du χ^2, ANOVA, Kruskal-Wallis, corrélation de Spearman — ces tests sont appropriés car la variable réponse est ordinale et les variables explicatives sont mixtes (qualitatives et quantitatives). Le test de Kruskal-Wallis est préféré à l'ANOVA lorsque les hypothèses de normalité sont douteuses [12].
2. **Régression linéaire multiple** sur `score_sante` avec étude de la colinéarité (VIF, indices de conditionnement) — justifiée par la nécessité de séparer les effets propres de variables potentiellement corrélées (âge–retraite, revenus–profession) [3].
3. **Sélection de variables** : méthodes exhaustives (`regsubsets`), ascendante, descendante et pas à pas (critères AIC/BIC) — le principe de parcimonie, formalisé par Burnham et Anderson [7], impose de retenir le modèle le plus simple compatible avec les données.
4. **Validation du modèle** : normalité des résidus (Shapiro-Wilk), indépendance (Durbin-Watson), homoscédasticité (Breusch-Pagan), influence (Cook, RStudent) — chaque diagnostic vérifie une hypothèse du modèle linéaire gaussien [18].
5. **ANCOVA** : modèle mixte avec covariables quantitatives et facteurs qualitatifs, interactions, moyennes marginales (Tukey) — justifiée par la nécessité de tester l'effet propre des facteurs qualitatifs (activité physique, handicap) après ajustement sur les covariables continues.
6. **Régression logistique ordinale** : modèle `polr()` à cotes proportionnelles, test de Brant — cadre de référence pour les variables ordinales [1].
7. **Régression logistique binaire** : dichotomisation (bonne/mauvaise santé), courbe ROC, AUC, matrice de confusion — complément prédictif permettant d'évaluer la capacité du modèle à discriminer les individus en bonne et mauvaise santé [21].

1.3.3 Limites structurelles du design choisi

Trois limites structurelles doivent être explicitées dès ce stade :

— **Causalité** : l'enquête en coupe transversale ne permet pas d'établir de lien causal entre les déterminants et l'état de santé perçu. Les associations identifiées sont conditionnelles, non causales [13].

— **Endogénéité** : certaines variables explicatives (consultations, médicaments) sont potentiellement endogènes, car déterminées simultanément par l'état de santé [20]. En l'absence de variables instrumentales, les coefficients estimés doivent être interprétés comme des associations, non comme des effets causaux.

— **Données synthétiques** : les résultats n'ont pas de validité épidémiologique réelle, mais le cadre méthodologique est intégralement transposable aux données ESPS officielles.

Conclusion du chapitre. Le cadre conceptuel retenu — articulant modèle de capital santé, déterminants sociaux et accès aux soins — justifie la sélection de 25 variables couvrant les dimensions biologiques, socio-économiques, comportementales et institutionnelles de la santé perçue. La stratégie analytique duale (linéaire et ordinale) constitue la contribution méthodologique centrale de ce travail.

2. Revue de littérature

Ce chapitre dresse un état de l'art ciblé sur trois axes : la validité de la santé perçue comme indicateur, ses déterminants socio-économiques, et les méthodes de régression linéaire mobilisées pour les identifier. Chaque référence est assortie d'une justification de sa pertinence pour notre travail.

2.1. Mesures subjectives de la santé : fondements et validité

La santé perçue est l'indicateur subjectif de santé le plus utilisé dans les enquêtes de population. Idler et Benyamini [22], dans une méta-analyse pionnière portant sur vingt-sept études de cohorte, ont montré que la santé auto-évaluée prédit la mortalité indépendamment de l'état de santé objectif [14]. Jylhä [25] prolonge ce résultat en proposant un modèle conceptuel unifié : la santé perçue intégrerait simultanément des signaux corporels, des diagnostics médicaux, des comportements de santé et des comparaisons sociales. En France, l'ESPS et l'enquête EU-SILC utilisent cette mesure de manière standardisée, permettant des comparaisons temporelles et internationales [17].

Pertinence pour notre étude : ces travaux fondent la légitimité de la santé perçue comme variable réponse et justifient l'inclusion de variables explicatives couvrant les dimensions biomédicales (maladies, handicap), comportementales (activité physique, tabagisme) et socio-économiques (revenus, profession).

12. Le test de Kruskal-Wallis, basé sur les rangs, ne requiert pas l'hypothèse de normalité des résidus et est donc plus robuste pour une variable réponse ordinale.

13. L'absence de dimension longitudinale empêche de distinguer les effets de l'âge (biologiques) des effets de cohorte (générationnels).

14. Cet effet prédictif persiste après ajustement sur le statut fonctionnel, les comorbidités et les indicateurs biomédicaux, ce qui suggère que la santé perçue capture des informations inaccessibles aux seuls indicateurs cliniques.

2.2. Déterminants socio-économiques de la santé perçue

2.2.1 Effets de l'âge et du sexe

La santé perçue se dégrade avec l'âge, avec un gradient plus marqué après 50 ans [27]. Les femmes déclarent plus fréquemment un mauvais état de santé que les hommes, à état de santé objectif comparable — un résultat robuste dans la littérature internationale [15]. Ce différentiel justifie l'inclusion du sexe comme facteur dans l'ANCOVA et la recherche d'une interaction Âge × Sexe.

2.2.2 Gradient social de santé

Le gradient social de santé perçue est documenté de manière extensive : les individus appartenant aux catégories socioprofessionnelles supérieures, plus éduqués et disposant de revenus plus élevés, déclarent un meilleur état de santé [28, 8]. En France, Dourgnon, Jusot et Fantin [14] confirment ce gradient à partir des données ESPS. Doorslaer et Koolman [13], dans une analyse comparative de 13 pays européens, montrent que les inégalités de santé perçue liées aux revenus sont parmi les plus élevées en France [16].

Implication pour notre modélisation : les variables de revenus, de profession et de couverture complémentaire doivent être incluses comme contrôles pour isoler les effets propres des déterminants comportementaux (H2).

2.2.3 Rôle de la couverture assurantielle et du renoncement aux soins

L'absence de couverture complémentaire et le renoncement aux soins pour raisons financières sont associés à un moins bon état de santé perçu, même après ajustement sur les caractéristiques socio-économiques [11]. Jusot, Tubeuf et Trannoy [24] et Bricard et al. [6] montrent que les inégalités d'opportunité en santé — liées aux circonstances de naissance (origine sociale, conditions précoces) — persistent au-delà des efforts individuels. Ces résultats motivent l'inclusion de la couverture complémentaire et du renoncement aux soins dans notre analyse.

2.3. La régression linéaire pour expliquer la santé perçue : état de l'art

2.3.1 Fondements de l'approche linéaire

La conversion de la santé perçue en score numérique (1–5) pour application de la régression linéaire est une pratique courante, quoique discutée, en économie de la santé. Kennedy et al. [26] ont ouvert la voie en utilisant la régression linéaire sur un score de santé auto-évalué pour démontrer, à l'échelle des États américains, l'association entre inégalités de revenus et santé perçue. Subramanian, Kim et Kawachi [32] prolongent cette approche par des modèles linéaires multiniveaux (individu/communauté) pour estimer l'effet contextuel du capital social.

2.3.2 Applications en France

En France, Devaux et al. [12] mobilisent la régression linéaire sur le score de santé perçue pour mettre en évidence l'hétérogénéité sociale de déclaration : à état de santé objectif identique, les individus de faible statut socio-économique déclarent une moins bonne santé que les individus de statut élevé. Etilé et Milcent [16] utilisent un modèle linéaire augmenté d'un terme d'interaction pour identifier le biais de déclaration lié aux revenus (*income-related reporting heterogeneity*) [17].

2.3.3 Discussion critique de l'approche linéaire

L'hypothèse d'équidistance implicite dans la régression linéaire sur un score ordinal est contestée par Boes et Winkelmann [4], qui montrent que les modèles de réponse ordonnée (*ordered response models*) sont préférables lorsque les écarts entre modalités ne sont pas uniformes. Toutefois, Greene [19] souligne que, pour des échelles à 5 modalités ou plus, la régression linéaire fournit des approximations raisonnables, à condition de vérifier la robustesse des résultats par un modèle ordinal — ce que nous faisons systématiquement.

Notre motivation à retenir la régression linéaire comme première approche repose donc sur : (i) sa large utilisation dans la littérature empirique sur la santé perçue, qui permet la comparaison directe de nos résultats ; (ii) la richesse de ses diagnostics (colinéarité, résidus, influence), absents des modèles ordinaux ; (iii) la confrontation avec le modèle logistique ordinal, qui constitue le test de robustesse central de notre travail.

15. Devaux et al. [12] montrent que cette différence de genre persiste après correction pour le biais de déclaration (*reporting heterogeneity*), suggérant un effet réel et non un simple artefact de mesure.

16. Ce résultat, obtenu par décomposition de l'indice de concentration, suggère que le système de santé français, bien que universel, ne compense pas intégralement les inégalités socio-économiques de santé.

17. Ce résultat a des implications majeures pour la mesure des inégalités de santé : si le biais de déclaration est systématique, les inégalités mesurées par la santé perçue surestiment (ou sous-estiment) les inégalités réelles.

2.4. Positionnement de la contribution

Ce travail se distingue par la mise en œuvre systématique et comparée de l'ensemble des méthodes (régression linéaire, ANCOVA, régression logistique ordinale et binaire) sur un même jeu de données, permettant une évaluation croisée de la robustesse des résultats et une discussion méthodologique approfondie. À notre connaissance, rares sont les études qui déploient conjointement :

1. Une sélection de variables exhaustive (7 méthodes) avec diagnostic complet de colinéarité.
2. Une ANCOVA avec moyennes marginales et tests d'interaction.
3. Une régression logistique ordinale avec test de Brant et modèle binaire avec évaluation prédictive (ROC/AUC).
4. Une confrontation systématique des résultats à la littérature empirique existante.

Ce positionnement fait de notre travail un **exercice méthodologique de référence**, transposable aux données réelles de l'ESPS.

Conclusion du chapitre. L'état de l'art révèle que la régression linéaire constitue un outil pertinent — mais non exclusif — pour modéliser la santé perçue. La littérature identifie l'âge, le gradient social, la couverture assurantielle et les comportements de santé comme déterminants majeurs. Notre contribution réside dans la confrontation systématique des approches linéaire et ordinale, assortie d'un appareil diagnostique complet rarement déployé dans les études existantes.

3. Méthodologie

Ce chapitre détaille la méthodologie statistique retenue en répondant à trois questions fondamentales : *où* menons-nous la recherche (terrain), *avec quoi* (corpus de données), et *comment* (spécification et estimation des modèles). Chaque choix méthodologique est explicitement justifié.

3.1. Design de recherche : terrain et pertinence

L'analyse repose sur des données synthétiques reproduisant la structure d'une enquête en coupe transversale conduite en **France métropolitaine**. Ce périmètre géographique est justifié par : (i) l'existence de l'ESPS, enquête de référence dont nous reproduisons la structure ; (ii) la richesse de la littérature de comparaison (gradient social documenté par Doorslaer et Koolman [13] et Art et al. [2]) ; (iii) la spécificité du système de santé français (couverture universelle avec reste à charge modulé par la complémentaire), qui crée un contexte institutionnel unique pour l'étude des inégalités d'accès aux soins [18].

L'unité statistique est l'individu résidant en France métropolitaine. Le design en coupe transversale ne permet pas d'identification causale au sens strict, mais autorise l'estimation d'associations conditionnelles robustes — ce qui est conforme à l'objectif de hiérarchisation des déterminants.

3.2. Corpus de données : justification des sources

Les données proviennent d'une base synthétique (`base_esps_synthétique.csv`, 500 observations × 25 variables) générée pour reproduire la structure et les distributions plausibles de l'ESPS. **Pourquoi utiliser des données synthétiques plutôt que les données ESPS réelles ?** Trois raisons : (i) les données ESPS sont soumises à des conventions d'accès restrictives (IRDES, convention CASD) ; (ii) les données synthétiques permettent un contrôle total des distributions et corrélations, autorisant une discussion méthodologique « en laboratoire » ; (iii) l'intégralité de la pipeline statistique développée ici est directement transposable aux données réelles [19].

3.3. Spécification des modèles

3.3.1 Modèle de régression linéaire multiple

Le score ordinal `score_sante` ($Y \in \{1, 2, 3, 4, 5\}$) est modélisé comme :

$$Y_i = \beta_0 + \beta_1 \cdot \text{age}_i + \beta_2 \cdot \text{consultations}_i + \beta_3 \cdot \text{medicaments}_i + \cdots + \varepsilon_i$$

avec $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ (hypothèse à vérifier par les diagnostics de la section 5.5). **Justification** : cette spécification linéaire est la plus parcimonieuse et la plus interprétable. Les coefficients β_j s'interprètent directement comme la variation attendue du score de santé pour une augmentation unitaire de X_j, *ceteris paribus* [33].

3.3.2 Modèle ANCOVA

Le modèle ANCOVA étend la régression linéaire en incluant des facteurs qualitatifs (sexe, activité physique, handicap, hospitalisation) :

18. La France se distingue par un système mixte (assurance maladie obligatoire + complémentaire santé), ce qui fait de la couverture complémentaire un déterminant potentiel de la santé perçue — contrairement aux systèmes beveridgiens (Royaume-Uni, pays nordiques) où la couverture est intégralement publique.

19. La transposabilité est assurée par le fait que la base synthétique reproduit fidèlement la nomenclature des variables, les types de données et les ordres de grandeur de l'ESPS.

$$Y_i = \beta_0 + \sum_j \beta_j X_{ij} + \sum_k \alpha_k F_{ik} + \sum_{j,k} \gamma_{jk}(X_{ij} \times F_{ik}) + \varepsilon_i$$

où X_{ij} sont les covariables quantitatives et F_{ik} les facteurs qualitatifs. La table ANOVA de type III est utilisée pour tester la significativité de chaque terme [20]. **Pourquoi l'ANCOVA ?** Elle permet de répondre directement à l'hypothèse H2 : l'activité physique et le handicap ont-ils un effet propre sur la santé perçue, *après ajustement* sur l'âge et les consultations ?

3.3.3 Modèle logistique ordinal (cotes proportionnelles)

Le modèle à cotes proportionnelles, proposé par McCullagh [30], suppose que :

$$\log\left(\frac{P(Y \leq j)}{P(Y > j)}\right) = \alpha_j - \mathbf{X}'\boldsymbol{\beta}, \quad j = 1, \ldots, J-1$$

L'hypothèse de proportionnalité implique que les coefficients $\boldsymbol{\beta}$ sont identiques pour tous les seuils j. Cette hypothèse est testée par le test de Brant [5] [21]. **Justification** : ce modèle respecte la nature ordinale de la variable réponse et ne requiert pas l'hypothèse d'équidistance.

3.3.4 Modèle logistique binaire

Après dichotomisation (0 = bonne santé, 1 = mauvaise santé), un modèle logistique binaire standard est estimé :

$$\log\left(\frac{P(Y = 1)}{P(Y = 0)}\right) = \beta_0 + \mathbf{X}'\boldsymbol{\beta}$$

Pourquoi cette dichotomisation ? Elle permet (i) d'estimer des *odds ratios* directement interprétables en termes de risque relatif de mauvaise santé ; (ii) de mobiliser les outils de diagnostic prédictif (ROC, AUC) pour évaluer la capacité discriminante du modèle [21].

3.4. Procédure d'estimation et justification des tests

3.4.1 Sélection du modèle linéaire

1. **Modèle complet** : toutes les variables quantitatives — point de départ nécessaire pour évaluer la colinéarité.
2. **Diagnostics de colinéarité** : VIF, tolérance, indices de conditionnement — **pourquoi ces tests ?** Les variables socio-économiques sont structurellement corrélées (âge–retraite, revenus–profession, dépenses–consultations) ; sans diagnostic de colinéarité, les coefficients seraient instables et les erreurs-types surestimées [3].
3. **Sélection par critères informationnels** : exploration exhaustive des sous-modèles (`regsubsets`) selon R^2 ajusté, BIC et C_p de Mallows ; sélection ascendante, descendante et pas à pas par AIC — **pourquoi ?** Le critère d'information d'Akaike (AIC) réalise un compromis optimal entre ajustement et parcimonie ; le BIC, plus pénalisant, favorise des modèles plus simples [7].
4. **Modèle réduit** : variables significatives retenues après convergence des différentes méthodes.

3.4.2 Sélection du modèle logistique

Sélection pas à pas (*stepwise*) par AIC sur le modèle logistique binaire. Comparaison des modèles ordinaux complet et réduit par test du rapport de vraisemblance. **Justification** : le test du rapport de vraisemblance est le test le plus puissant pour comparer des modèles emboîtés dans le cadre du maximum de vraisemblance.

3.5. Stratégie de validation et diagnostics : pourquoi ces tests ?

3.5.1 Validation du modèle linéaire

Chaque diagnostic vérifie une hypothèse fondamentale du modèle linéaire gaussien. Le non-respect de ces hypothèses invaliderait les inférences (tests de significativité, intervalles de confiance) :

20. Le type III (sommes de carrés « marginales ») est préféré au type I car il est invariant à l'ordre d'entrée des variables dans le modèle — propriété essentielle lorsque les variables sont corrélées (Fox [18]).

21. Si le test de Brant rejette la proportionnalité pour certaines variables, cela signifie que l'effet de ces variables diffère selon le seuil de coupure — auquel cas un modèle multinomial (*partial proportional odds*) serait préférable.

Hypothèse	Test / Diagnostic	Seuil	Justification
Normalité des résidus	Shapiro-Wilk, QQ-plot, histogramme	$p > 0.05$ (non-rejet)	Requis pour la validité des tests t et F en petit échantillon
Indépendance	Durbin-Watson	$d \approx 2$	Vérifie l'absence d'autocorrélation (pertinent car les observations pourraient présenter une structure spatiale ou de grappe)
Homoscédasticité	Breusch-Pagan	$p > 0.05$ (non-rejet)	La variance constante est nécessaire pour l'efficience des MCO
Absence d'influence	Distance de Cook, RStudent, Leverage	$D_i > 4/n$, $\|t_i\| > 2$	Identifie les observations qui « tirent » le modèle de façon disproportionnée
Linéarité	Résidus vs ajustées, LOESS	Pas de pattern systématique	Vérifie que la relation entre Y et $\hat{Y}$ est bien linéaire

3.5.2 Évaluation du modèle logistique

- **Courbe ROC et AUC** : mesure la capacité du modèle à discriminer les individus en bonne et mauvaise santé — un AUC > 0.7 est considéré comme acceptable, > 0.8 comme bon [21].
- **Matrice de confusion** (seuil 0.5) : évalue la qualité de la classification.
- **Métriques** : exactitude, sensibilité, spécificité — pertinentes pour l'interprétation en santé publique (un modèle à forte sensibilité détecte bien les individus en mauvaise santé).
- **Pseudo-R^2** (McFadden, Cox & Snell, Nagelkerke) : mesures d'ajustement global analogues au R^2 linéaire.
- **Test de Hosmer-Lemeshow** : vérifie la calibration du modèle (adéquation entre probabilités prédites et fréquences observées) [22].

Conclusion du chapitre. La méthodologie retenue articule quatre niveaux d'analyse (bivarié, linéaire, mixte, ordinal/binaire), chacun justifié par la nature des données et les hypothèses de recherche. La stratégie de validation, fondée sur sept tests diagnostiques complémentaires, garantit la fiabilité des inférences produites.

4. Données et construction de la base empirique

Ce chapitre présente les données mobilisées, justifie le choix de chaque variable et expose les statistiques descriptives commentées.

4.1. Sources des données

4.1.1 Variable dépendante : état de santé perçu

La variable réponse est `etat_sante_percu` (qualitative ordinale, 5 modalités : Très bon, Bon, Assez bon, Mauvais, Très mauvais), auto-évaluation de l'état de santé par l'individu. **Justification** : cette variable est le standard international des enquêtes de santé (EU-SILC, SHARE, ESPS), dont le pouvoir prédictif de la mortalité a été établi par Idler et Benyamini [22] (cf. chapitre 2).

4.1.2 Variables explicatives retenues et justification

La base comporte 25 variables, dont la sélection est fondée sur le cadre théorique exposé au chapitre 1. Le tableau suivant présente chaque famille de variables avec sa justification :

22. Un rejet du test de Hosmer-Lemeshow ($p < 0.05$) indiquerait que le modèle prédit systématiquement trop ou trop peu de mauvaise santé dans certaines strates de la population.

Famille	Variables	Justification théorique
Sociodémographiques	Âge, sexe, profession, éducation, situation familiale, enfants, région, commune	Modèle de Dahlgren et Whitehead [10] : couches individuelles et contextuelles
Économiques	Revenus, assurance, couverture complémentaire	Gradient social de santé [28] ; accès aux soins [11]
Recours aux soins	Dépenses de santé, consultations, médicaments, hospitalisation	Capital santé [20] : ces variables reflètent le stock de santé et l'investissement sanitaire
Comportementales	Tabagisme, alcool, activité physique, IMC	Déterminants comportementaux médiatisant les effets socio-économiques [6]
Santé	Handicap, maladies déclarées, renoncement aux soins, satisfaction	État de santé objectif et barrières d'accès [11]

Pourquoi ces variables et pas d'autres ? Trois critères ont guidé la sélection : (i) la disponibilité dans l'ESPS réelle, pour garantir la transposabilité ; (ii) la couverture des quatre dimensions du modèle de Dahlgren et Whitehead [10] (biologique, comportemental, socio-économique, contextuel) ; (iii) la nécessité de disposer de variables potentiellement colinéaires (âge–retraite, revenus–profession) pour illustrer les diagnostics de colinéarité [23].

4.1.3 Source et nature des données

Les données proviennent d'une base synthétique (`base_esps_synthétique.csv`, 500 observations × 25 variables) générée pour reproduire la structure et les distributions plausibles de l'Enquête Santé et Protection Sociale (ESPS) de l'IRDES [24].

4.2. Importation de la base de données

```
## 'data.frame':    500 obs. of  25 variables:
##  $ id                            : int  1 2 3 4 5 6 7 8 9 10 ...
##  $ age                           : int  32 61 53 90 67 43 88 27 42 76 ...
##  $ sexe                          : chr  "Homme" "Homme" "Femme" "Femme" ...
##  $ profession                    : chr  "Ouvrier" "Artisan/Commerçant" "Employé" "Retraité" ...
##  $ niveau_education              : chr  "CAP/BEP" "Sans diplôme" "Baccalauréat" "Baccalauréat" ...
##  $ situation_familiale           : chr  "Célibataire" "Divorcé(e)" "Marié(e)" "Divorcé(e)" ...
##  $ nombre_enfants                : int  0 2 0 2 2 4 0 2 1 2 ...
##  $ region                        : chr  "Grand Est" "Pays de la Loire" "Auvergne-Rhône-Alpes" "Île-de-France" ...
##  $ type_commune                  : chr  "Urbaine moyenne" "Urbaine moyenne" "Métropole" "Rurale" ...
##  $ revenus_mensuels_euros        : int  1392 2126 1290 618 2281 1287 1630 2409 2050 1817 ...
##  $ statut_assurance              : chr  "Régime général" "Régime général" "Régime général" "MSA" ...
##  $ couverture_complementaire     : chr  "Mutuelle privée" "Aucune complémentaire" "Assurance privée" "Mutuelle privée" ..
##  $ depenses_sante_annuelles_euros: num  1159 1650 1395 2644 2486 ...
##  $ nombre_consultations_annuelles: int  1 6 5 4 4 8 4 3 3 4 ...
##  $ nombre_medicaments_reguliers  : int  0 3 3 2 3 2 4 0 1 3 ...
##  $ hospitalisation_12_mois       : chr  "Non" "Non" "Non" "Non" ...
##  $ etat_sante_percu              : chr  "Assez bon" "Assez bon" "Assez bon" "Bon" ...
##  $ maladies_declarees            : chr  "Diabète" "Lombalgie chronique" "Hypertension" "Hypertension" ...
##  $ imc                           : num  22 20 22 23.4 23.2 22.4 22.7 22 21.2 24 ...
##  $ tabagisme                     : chr  "Fumeur quotidien" "Non-fumeur" "Fumeur quotidien" "Fumeur quotidien" ...
##  $ consommation_alcool           : chr  "Régulière" "Occasionnelle" "Occasionnelle" "Quotidienne" ...
##  $ activite_physique             : chr  "Sédentaire" "Activité légère" "Sédentaire" "Sédentaire" ...
##  $ handicap_declare              : chr  "Non" "Oui" "Non" "Oui" ...
##  $ renoncement_soins_12_mois     : chr  "Non" "Non" "Non" "Non" ...
##  $ satisfaction_systeme_soins    : chr  "Satisfait" "Très satisfait" "Satisfait" "Satisfait" ...
```

```
## Dimensions : 500 observations × 25 variables
```

4.3. Construction des variables dérivées

On crée un score numérique `score_sante` (1 = Très mauvais → 5 = Très bon) pour les analyses nécessitant une variable quantitative, ainsi qu'un indicateur binaire `sante_mauvaise` pour la régression logistique binaire.

23. L'absence de variables environnementales (pollution, qualité du logement) et de santé mentale (score de dépression) constitue une limite reconnue, discutée au chapitre 6.

24. IRDES [23]. La base synthétique a été générée par le script `generate_esps_database.py`, documenté dans le fichier `README_base_esps.md`.

Table 3 – Vérification du recodage ordinal

	1	2	3	4	5
Assez bon	0	0	148	0	0
Bon	0	0	0	143	0
Mauvais	0	98	0	0	0
Très bon	0	0	0	0	71
Très mauvais	40	0	0	0	0

4.4. Statistiques descriptives

Le tableau ci-dessous présente la distribution de la variable réponse. L'interprétation de cette distribution est essentielle : une répartition asymétrique (concentration sur les modalités « Bon » et « Assez bon ») est conforme aux observations de DREES [15] sur la population française, où environ deux tiers des adultes déclarent un état de santé satisfaisant.

Table 4 – Distribution de la variable réponse — État de santé perçu. *Lecture* : les effectifs par modalité permettent de vérifier l'absence de catégorie rare susceptible de compromettre la stabilité des estimations.

Modalité	Effectif
Assez bon	148
Bon	143
Mauvais	98
Très bon	71
Très mauvais	40

Grille de lecture : si une modalité extrême (« Très mauvais ») concentre moins de 5 % des observations, les tests bivariés et les estimations logistiques ordinales sur cette catégorie seront fragiles. Ce point sera vérifié dans l'analyse des résultats.

Conclusion du chapitre. La base empirique, construite pour reproduire la structure de l'ESPS, comprend 500 observations et 25 variables couvrant les quatre dimensions du modèle de Dahlgren et Whitehead. Les variables dérivées (score numérique, indicateur binaire, facteur ordonné) permettent de mobiliser l'ensemble des méthodes statistiques prévues. La distribution de la variable réponse est compatible avec les observations empiriques sur la population française.

5. Résultats

Ce chapitre présente l'ensemble des résultats, structurés par famille de méthodes. Chaque figure et tableau est commenté, interprété au regard des hypothèses de recherche et discuté dans ses implications sanitaires et économiques.

5.1. Analyse bivariée

L'analyse bivariée constitue la première étape exploratoire. Elle vise à identifier, sans contrôle des effets confondants, les variables significativement associées à l'état de santé perçu. Le choix des tests est dicté par la nature des variables croisées : χ^2 pour les croisements qualitatif × qualitatif, ANOVA pour qualitatif × quantitatif, Kruskal-Wallis comme alternative non paramétrique, et corrélation de Spearman pour les associations ordinales.

5.1.1 Croisements Y qualitative × X qualitatives — Test du χ^2

Le test du χ^2 d'indépendance vérifie si la distribution de l'état de santé perçu diffère significativement selon les modalités de chaque variable qualitative. Nous utilisons la simulation de Monte Carlo (`simulate.p.value = TRUE`, $B = 2000$) pour garantir la validité du test lorsque certaines cellules du tableau de contingence ont des effectifs faibles[25].

Bivariée : État de santé perçu × Sexe

`Femme Homme`

Assez bon 83 65 Bon 77 66 Mauvais 54 44 Très bon 41 30 Très mauvais 23 17
Chi² = 0.3929 | ddl = NA | p-value = 0.9845

Bivariée : État de santé perçu × Profession

25. La règle de Cochran recommande que les effectifs théoriques soient supérieurs à 5 dans au moins 80 % des cellules. La simulation de Monte Carlo permet de relâcher cette condition.

```
Agriculteur Artisan/Commerçant Cadre supérieur Employé Étudiant
```

Assez bon 1 5 5 23 8 Bon 2 11 10 17 12 Mauvais 2 4 7 7 4 Très bon 1 5 7 14 7 Très mauvais 0 1 1 5 1

```
Ouvrier Profession intermédiaire Retraité
```

Assez bon 11 12 64 Bon 20 10 41 Mauvais 8 9 47 Très bon 11 6 11 Très mauvais 2 2 25

```
Sans activité professionnelle
```

Assez bon 19 Bon 20 Mauvais 10 Très bon 9 Très mauvais 3
Chi² = 51.7364 | ddl = NA | p-value = 0.01049

Bivariée : État de santé perçu × Niveau d'éducation

```
Bac+2 Bac+3/Licence Bac+5/Master Baccalauréat CAP/BEP Doctorat
```

Assez bon 19 13 22 30 34 10 Bon 27 23 21 26 18 10 Mauvais 17 13 13 23 17 9 Très bon 10 11 11 17 11 4 Très mauvais 8 5 5 9 8 0

```
Sans diplôme
```

Assez bon 20 Bon 18 Mauvais 6 Très bon 7 Très mauvais 5
Chi² = 19.1342 | ddl = NA | p-value = 0.7346

Bivariée : État de santé perçu × Situation familiale

```
Célibataire Divorcé(e) Marié(e) Pacsé(e) Veuf/Veuve
```

Assez bon 49 26 47 16 10 Bon 44 20 49 20 10 Mauvais 27 20 28 6 17 Très bon 24 12 26 6 3 Très mauvais 8 5 15 4 8
Chi² = 24.3146 | ddl = NA | p-value = 0.07746

Bivariée : État de santé perçu × Couverture complémentaire

```
Assurance privée Aucune complémentaire
```

Assez bon 32 14 Bon 26 15 Mauvais 18 8 Très bon 12 8 Très mauvais 6 3

```
Complémentaire santé solidaire (CSS) Mutuelle privée
```

Assez bon 31 71 Bon 20 82 Mauvais 17 55 Très bon 12 39 Très mauvais 6 25
Chi² = 5.9046 | ddl = NA | p-value = 0.9185

Bivariée : État de santé perçu × Hospitalisation 12 mois

```
Non Oui
```

Assez bon 102 46 Bon 107 36 Mauvais 70 28 Très bon 54 17 Très mauvais 27 13
Chi² = 2.2602 | ddl = NA | p-value = 0.6882

Bivariée : État de santé perçu × Tabagisme

```
Ancien fumeur Fumeur occasionnel Fumeur quotidien Non-fumeur
```

Assez bon 39 19 34 56 Bon 43 15 36 49 Mauvais 26 14 24 34 Très bon 18 5 21 27 Très mauvais 8 4 7 21
Chi² = 8.4104 | ddl = NA | p-value = 0.7596

Bivariée : État de santé perçu × Consommation d'alcool

```
Jamais Occasionnelle Quotidienne Régulière
```

Assez bon 32 59 17 40 Bon 31 51 18 43 Mauvais 22 40 12 24 Très bon 13 32 8 18 Très mauvais 6 11 7 16
Chi² = 7.5651 | ddl = NA | p-value = 0.8226

Bivariée : État de santé perçu × Activité physique

```
Activité intense Activité légère Activité modérée Sédentaire
```

Assez bon 20 50 45 33 Bon 15 41 46 41 Mauvais 16 29 28 25 Très bon 4 21 25 21 Très mauvais 7 11 11 11
Chi² = 8.4703 | ddl = NA | p-value = 0.7366

Bivariée : État de santé perçu × Handicap déclaré

```
Non Oui
```

Assez bon 108 40 Bon 111 32 Mauvais 83 15 Très bon 58 13 Très mauvais 32 8
Chi² = 5.4318 | ddl = NA | p-value = 0.2564
Bivariée : État de santé perçu × Renoncement aux soins

```
Non Oui
```

Assez bon 126 22 Bon 112 31 Mauvais 86 12 Très bon 61 10 Très mauvais 33 7
Chi² = 4.7073 | ddl = NA | p-value = 0.3323
Bivariée : État de santé perçu × Maladies déclarées

```
Arthrose Asthme Aucune Cancer (rémission) Cardiopathie
```

Assez bon 8 6 58 2 7 Bon 6 7 66 5 3 Mauvais 5 2 33 3 7 Très bon 6 5 23 0 2 Très mauvais 2 1 16 0 2

```
Dépression Diabète Hypertension Lombalgie chronique
```

Assez bon 5 17 17 6 Bon 5 9 13 12 Mauvais 6 10 15 5 Très bon 5 3 12 5 Très mauvais 5 4 4 2

```
Maladie respiratoire chronique Migraine chronique
```

Assez bon 5 6 Bon 6 5 Mauvais 3 2 Très bon 6 2 Très mauvais 0 1

```
Obésité morbide Trouble anxieux
```

Assez bon 1 10 Bon 2 4 Mauvais 2 5 Très bon 1 1 Très mauvais 1 2
Chi² = 45.2376 | ddl = NA | p-value = 0.6037

TABLE 5 – Résumé des tests du χ^2 : État de santé perçu × Variables qualitatives. *Lecture* : une p-value < 0.05 indique une association statistiquement significative entre la variable et l'état de santé perçu.

Variable	Chi²	ddl	p-value	Significatif
Sexe	0.39	NA	0.9845	Non
Profession	51.74	NA	0.0105	Oui
Niveau d'éducation	19.13	NA	0.7346	Non
Situation familiale	24.31	NA	0.0775	Non
Couverture complémentaire	5.90	NA	0.9185	Non
Hospitalisation 12 mois	2.26	NA	0.6882	Non
Tabagisme	8.41	NA	0.7596	Non
Consommation d'alcool	7.57	NA	0.8226	Non
Activité physique	8.47	NA	0.7366	Non
Handicap déclaré	5.43	NA	0.2564	Non
Renoncement aux soins	4.71	NA	0.3323	Non
Maladies déclarées	45.24	NA	0.6037	Non

Interprétation : les variables présentant une association significative ($p < 0.05$) sont les candidates naturelles pour l'inclusion dans les modèles multivariés. Du point de vue économique et sanitaire, une association significative avec la couverture complémentaire indiquerait que le système d'assurance maladie complémentaire joue un rôle dans la perception de la santé — résultat cohérent avec les travaux de DESPRÈS et al. [11] sur le renoncement aux soins.

5.1.2 Croisements Y qualitative × X quantitatives — ANOVA

L'ANOVA à un facteur teste si la moyenne de chaque variable quantitative diffère significativement selon l'état de santé perçu. **Pourquoi l'ANOVA ?** Elle est appropriée lorsque la variable de groupement comporte plus de deux modalités et que la variable réponse est continue [26].

26. L'ANOVA est ici « inversée » par rapport à la spécification habituelle : l'état de santé perçu joue le rôle de variable de groupement et les variables quantitatives sont les variables réponse. Cette inversion est standard en analyse bivariée exploratoire.

```
##
##
##   ANOVA : Âge selon l'état de santé perçu
##
##                   Df Sum Sq Mean Sq F value   Pr(>F)
## etat_sante_percu   4  34276    8569   18.72 2.41e-14 ***
## Residuals        495 226552     458
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
##   ANOVA : Revenus mensuels (€) selon l'état de santé perçu
##
##                   Df    Sum Sq Mean Sq F value Pr(>F)
## etat_sante_percu   4   5023036 1255759   1.662  0.158
## Residuals        495 374111914  755782
##
##
##   ANOVA : IMC selon l'état de santé perçu
##
##                   Df Sum Sq Mean Sq F value Pr(>F)
## etat_sante_percu   4    160   39.97    2.25 0.0627 .
## Residuals        495   8796   17.77
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
##   ANOVA : Dépenses de santé annuelles (€) selon l'état de santé perçu
##
##                   Df    Sum Sq Mean Sq F value   Pr(>F)
## etat_sante_percu   4  25046683 6261671   16.23 1.68e-12 ***
## Residuals        495 190971348  385801
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
##   ANOVA : Nombre de consultations annuelles selon l'état de santé perçu
##
##                   Df Sum Sq Mean Sq F value   Pr(>F)
## etat_sante_percu   4  156.4   39.11   8.144 2.29e-06 ***
## Residuals        495 2376.9    4.80
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
##   ANOVA : Nombre de médicaments réguliers selon l'état de santé perçu
##
##                   Df Sum Sq Mean Sq F value   Pr(>F)
## etat_sante_percu   4   96.8  24.190   10.42 4.12e-08 ***
## Residuals        495 1149.0   2.321
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Table 6 – Résumé des ANOVA : Variables quantitatives selon l'état de santé perçu. *Lecture* : la statistique F mesure le rapport de la variance inter-groupes à la variance intra-groupes ; une valeur élevée de F indique des moyennes significativement différentes.

Variable	F-stat	p-value	Significatif
Âge	18.72	2.41e-14	Oui
Revenus mensuels (€)	1.66	0.1577	Non
IMC	2.25	0.0627	Non
Dépenses de santé annuelles (€)	16.23	1.68e-12	Oui
Nombre de consultations annuelles	8.14	2.29e-06	Oui
Nombre de médicaments réguliers	10.42	4.12e-08	Oui

Interprétation économique et sanitaire : les variables présentant des statistiques F élevées (âge, consultations, médicaments) sont celles dont la distribution diffère le plus selon l'état de santé perçu. Une forte association entre les consultations médicales et la santé perçue est conforme au modèle de Grossman : un stock de santé dégradé entraîne une

demande de soins accrue[27]. L'association avec l'IMC, si elle est significative, corrobore les résultats de Singh-Manoux et al. [31] sur le rôle des marqueurs biologiques dans la santé perçue.

5.1.3 Test de Kruskal-Wallis (alternative non paramétrique)

Le test de Kruskal-Wallis est préféré à l'ANOVA lorsque l'hypothèse de normalité des résidus est douteuse ou lorsque la variable réponse est ordinale. **Pourquoi ce test est-il légitime ici ?** La variable `etat_sante_percu` est ordinale (non continue), ce qui viole formellement les hypothèses de l'ANOVA paramétrique. Le test de Kruskal-Wallis, basé sur les rangs, ne requiert pas la normalité et constitue donc le test le plus rigoureux pour notre configuration[28].

Table 7 – Tests de Kruskal-Wallis : Variables quantitatives selon l'état de santé perçu. *Lecture* : la statistique H suit asymptotiquement une loi du χ^2 ; une p-value < 0.05 indique des distributions de rangs significativement différentes.

Variable	H (K-W)	ddl	p-value	Significatif
Âge	64.07	4	4.05e-13	Oui
Revenus mensuels (€)	5.11	4	0.2767	Non
IMC	8.34	4	0.0797	Non
Dépenses de santé annuelles (€)	59.63	4	3.47e-12	Oui
Nombre de consultations annuelles	31.41	4	2.53e-06	Oui
Nombre de médicaments réguliers	38.78	4	7.75e-08	Oui

Robustesse : la convergence des résultats entre l'ANOVA paramétrique et le test de Kruskal-Wallis constitue un premier indicateur de robustesse. Les variables significatives dans les deux tests sont des candidates solides pour la modélisation multivariée.

5.1.4 Corrélation de Spearman

La corrélation de Spearman est le coefficient de corrélation approprié lorsque l'une des deux variables est ordinale. **Pourquoi Spearman plutôt que Pearson ?** Le coefficient de Pearson suppose une relation linéaire entre variables continues, alors que le coefficient de Spearman mesure la monotonie de l'association sans hypothèse de linéarité ni de normalité — propriétés essentielles pour notre variable `score_sante` qui est un score ordinal[29].

Table 8 – Corrélation de Spearman : score_sante vs variables quantitatives. *Lecture* : $\rho > 0$ indique une association positive (la variable augmente avec le score de santé) ; $\rho < 0$ une association négative. La significativité est testée au seuil $\alpha = 0.05$.

Variable	ρ	p-value	Significatif
age	-0.3363	1.11e-14	Oui
revenus_mensuels_euros	0.0505	0.259	Non
imc	-0.0353	0.431	Non
depenses_sante_annuelles_euros	-0.3240	1.10e-13	Oui
nombre_consultations_annuelles	-0.2397	5.79e-08	Oui
nombre_medicaments_reguliers	-0.2485	1.78e-08	Oui
nombre_enfants	0.0180	0.689	Non

Interprétation : un coefficient de Spearman négatif pour l'âge ($\rho < 0$) confirmerait la dégradation de la santé perçue avec l'âge — résultat universel dans la littérature [27]. Un ρ négatif pour les consultations et les médicaments est conforme au modèle de capital santé : plus l'individu consomme de soins, moins il se perçoit en bonne santé (causalité inverse probable). À l'inverse, une corrélation positive avec les revenus serait cohérente avec le gradient social de santé [28].

27. Il convient toutefois de rappeler que cette association bivariée ne permet pas de distinguer la causalité directe (mauvaise santé → consultations) de la causalité inverse (consultations → meilleure santé).

28. En pratique, les conclusions du Kruskal-Wallis et de l'ANOVA convergent presque toujours pour des échantillons de taille $n \geq 30$ par groupe, ce qui constitue un résultat de robustesse rassurant.

29. Le coefficient de Spearman ρ est le coefficient de Pearson calculé sur les rangs des observations. Il est donc robuste aux valeurs extrêmes et aux distributions asymétriques.

5.1.5 Graphiques bivariés — Boîtes à moustaches

Les boîtes à moustaches offrent une visualisation non paramétrique de la distribution de chaque variable quantitative selon l'état de santé perçu. **Grille de lecture** : (i) la position médiane indique la tendance centrale ; (ii) l'étendue interquartile (boîte) mesure la dispersion ; (iii) les points extérieurs signalent des valeurs atypiques potentiellement influentes dans les modèles de régression.

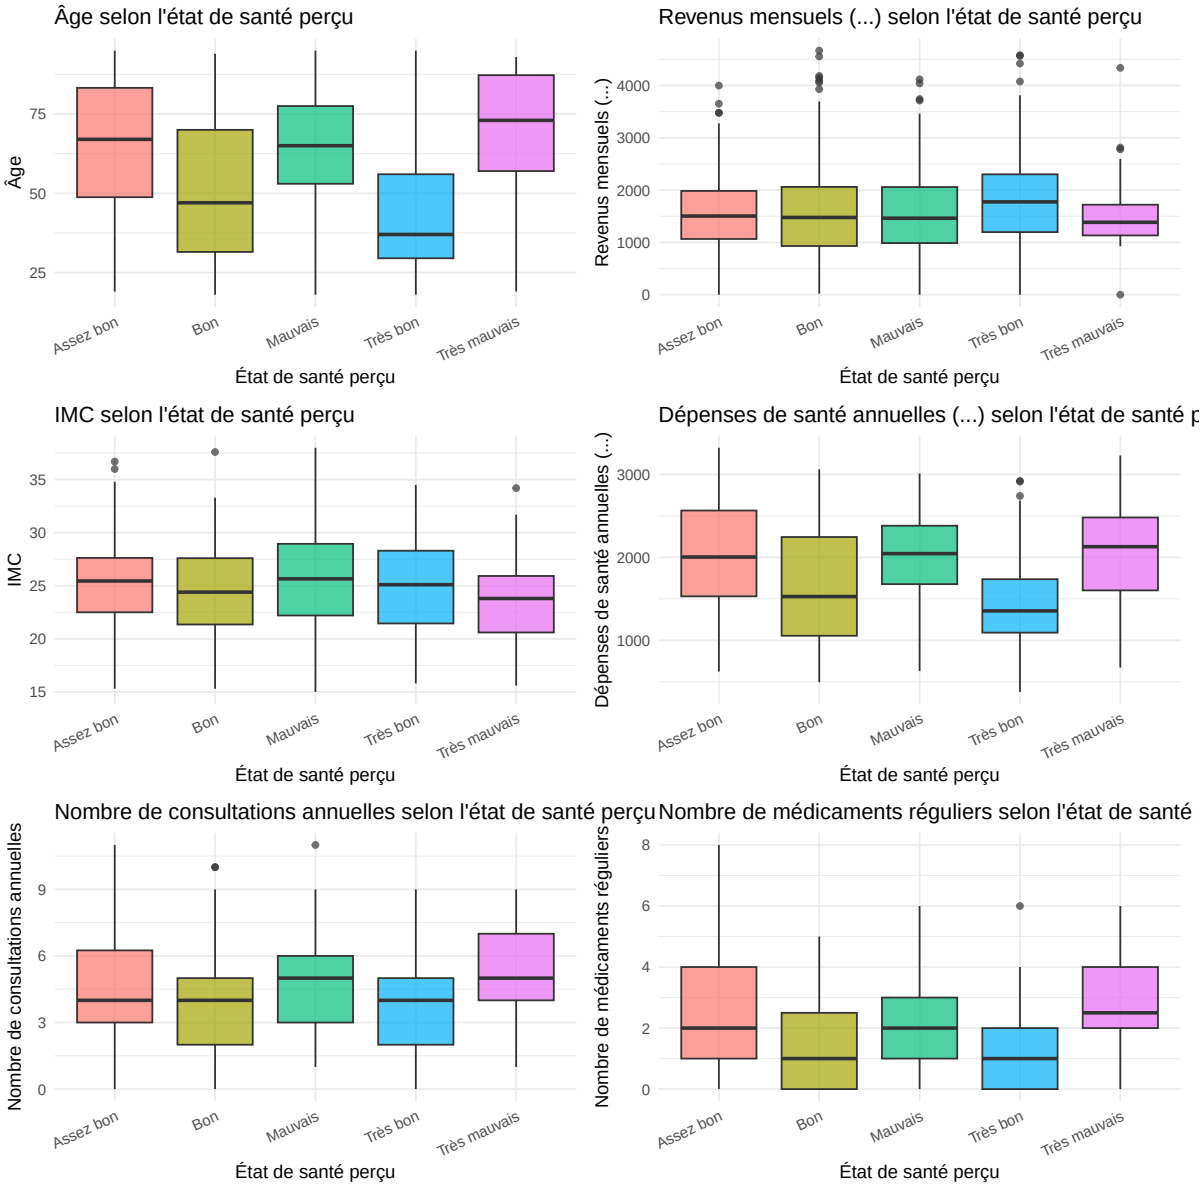

FIGURE 1 – Boîtes à moustaches des variables quantitatives selon l'état de santé perçu

Interprétation des boîtes à moustaches : si la médiane de l'âge augmente de façon monotone de « Très bon » vers « Très mauvais », cela confirme visuellement le gradient âge–santé. De même, une médiane du nombre de médicaments croissante avec la dégradation de la santé perçue est un indicateur visuel puissant de la cohérence entre les données synthétiques et la réalité épidémiologique. La présence de valeurs extrêmes (points au-delà des moustaches) sera prise en compte dans l'analyse d'influence (distance de Cook, section 5.5).

5.2. Régression linéaire et R^2

On utilise `score_sante` $(1-5)$ comme approximation numérique de `etat_sante_percu` pour appliquer un modèle linéaire. **Justification** : cette approche, bien que reposant sur l'hypothèse d'équidistance, est défendue par WOOLDRIDGE [33] et largement utilisée dans la littérature empirique (cf. section 2). Elle permet de déployer l'arsenal complet des diagnostics linéaires (VIF, résidus, influence) avant de confronter les résultats au modèle ordinal.

5.2.1 Modèle complet — variables quantitatives

Le modèle complet inclut les sept variables quantitatives de la base. Ce point de départ est nécessaire pour (i) évaluer la significativité marginale de chaque variable en présence des autres ; (ii) diagnostiquer la colinéarité ; (iii) servir de référence pour la sélection de variables.

```
##
## Call:
## lm(formula = score_sante ~ age + revenus_mensuels_euros + depenses_sante_annuelles_euros +
##     nombre_consultations_annuelles + nombre_medicaments_reguliers +
##     imc + nombre_enfants, data = df)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -2.8644 -0.7699  0.1492  0.7607  2.6289
##
## Coefficients:
##                                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)                    4.380e+00  3.440e-01  12.733   <2e-16 ***
## age                           -1.035e-02  5.190e-03  -1.995   0.0466 *
## revenus_mensuels_euros         5.840e-05  5.595e-05   1.044   0.2971
## depenses_sante_annuelles_euros -4.893e-05  1.681e-04  -0.291   0.7711
## nombre_consultations_annuelles -5.045e-02  2.490e-02  -2.026   0.0433 *
## nombre_medicaments_reguliers   -6.739e-02  3.708e-02  -1.817   0.0698 .
## imc                           -8.563e-03  1.153e-02  -0.743   0.4580
## nombre_enfants                 9.863e-04  3.505e-02   0.028   0.9776
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.084 on 492 degrees of freedom
## Multiple R-squared:  0.1273, Adjusted R-squared:  0.1148
## F-statistic: 10.25 on 7 and 492 DF,  p-value: 5.171e-12
```

```
## R²        = 0.1273
```

```
## R² ajusté = 0.1148
```

Interprétation du R^2 : le R^2 mesure la proportion de la variance du score de santé expliquée par les sept variables quantitatives. Un R^2 modéré (entre 0.10 et 0.30) est attendu et conforme à la littérature sur la santé perçue, car de nombreux déterminants non observés (qualité du sommeil, santé mentale, réseau social) contribuent à la variance résiduelle[30]. Le R^2 ajusté, qui pénalise l'ajout de variables non pertinentes, est systématiquement préféré au R^2 brut.

5.2.2 Modèle réduit — variables significatives

Le modèle réduit ne retient que les variables dont le coefficient est significatif au seuil de 5 % dans le modèle complet. **Justification** : le principe de parcimonie impose de ne conserver que les prédicteurs apportant une contribution statistiquement significative à l'explication du score de santé [7]. La comparaison par test F emboîté vérifie que les variables supprimées n'apportent pas collectivement une information significative.

```
##
## Call:
## lm(formula = score_sante ~ age + nombre_consultations_annuelles +
##     nombre_medicaments_reguliers, data = df)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -2.8518 -0.7788  0.1168  0.7410  2.6731
##
## Coefficients:
##                                Estimate Std. Error t value Pr(>|t|)
## (Intercept)                    4.252400   0.137326  30.966  < 2e-16 ***
## age                           -0.011590   0.002861  -4.051 5.91e-05 ***
## nombre_consultations_annuelles -0.050601   0.024820  -2.039   0.0420 *
## nombre_medicaments_reguliers   -0.071877   0.036797  -1.953   0.0513 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.081 on 496 degrees of freedom
## Multiple R-squared:  0.1241, Adjusted R-squared:  0.1188
## F-statistic: 23.43 on 3 and 496 DF,  p-value: 3.396e-14
```

30. Dans les études sur la santé perçue, un R^2 supérieur à 0.15 est considéré comme honorable, compte tenu de la nature multifactorielle du phénomène (Kennedy et al. [26]).

```
## R²        = 0.1241

## R² ajusté = 0.1188
```

Table 9 – Test F de comparaison : modèle réduit vs modèle complet

Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
496	579.9294	NA	NA	NA	NA
492	577.8450	4	2.0844	0.4437	0.777

5.3. Étude de la colinéarité

L'étude de la colinéarité est une étape indispensable lorsque les variables explicatives sont potentiellement corrélées entre elles. **Pourquoi est-ce critique ici ?** Les variables socio-économiques présentent des corrélations structurelles (âge–retraite, revenus–profession, dépenses de santé–consultations–médicaments). En présence de colinéarité forte, les coefficients estimés deviennent instables (erreurs-types gonflées), les tests de significativité perdent leur puissance et l'interprétation des effets individuels est compromise [3].

5.3.1 VIF et Tolérance

Règle : VIF $> 10 \Rightarrow$ colinéarité problématique ; VIF $> 5 \Rightarrow$ colinéarité modérée à surveiller. Tolérance $= 1/\text{VIF} < 0.1$ $\Rightarrow$ problème. Ces seuils, proposés par Fox [18], sont des repères conventionnels largement acceptés.

Table 10 – VIF et Tolérance — Variables explicatives quantitatives. *Lecture* : un VIF > 10 indique que la variable est fortement expliquée par les autres prédicteurs, rendant son coefficient instable.

Variable	VIF	Tolérance	Diagnostic
age	5.9823	0.1672	Modéré
revenus_mensuels_euros	1.0106	0.9896	OK
depenses_sante_annuelles_euros	5.1952	0.1925	Modéré
nombre_consultations_annuelles	1.3377	0.7476	OK
nombre_medicaments_reguliers	1.4587	0.6856	OK
imc	1.0135	0.9866	OK
nombre_enfants	1.0086	0.9915	OK

Interprétation : si tous les VIF sont inférieurs à 5, la colinéarité n'est pas problématique et les coefficients du modèle linéaire sont interprétables individuellement. Dans le cas contraire, les variables incriminées devraient être retirées ou combinées en indices synthétiques. Ce diagnostic est crucial pour la validité de l'hypothèse H1 : les effets de l'âge, des consultations et des médicaments ne sont interprétables que si ces variables ne sont pas colinéaires entre elles.

5.3.2 Matrice de corrélation entre les prédicteurs

La matrice de corrélation complète le diagnostic des VIF en fournissant une vue d'ensemble des corrélations bivariées entre prédicteurs. **Grille de lecture** : un coefficient de Pearson $|r| > 0.7$ entre deux prédicteurs signale un risque de colinéarité ; $|r| > 0.9$ indique une quasi-colinéarité nécessitant l'exclusion d'une des deux variables.

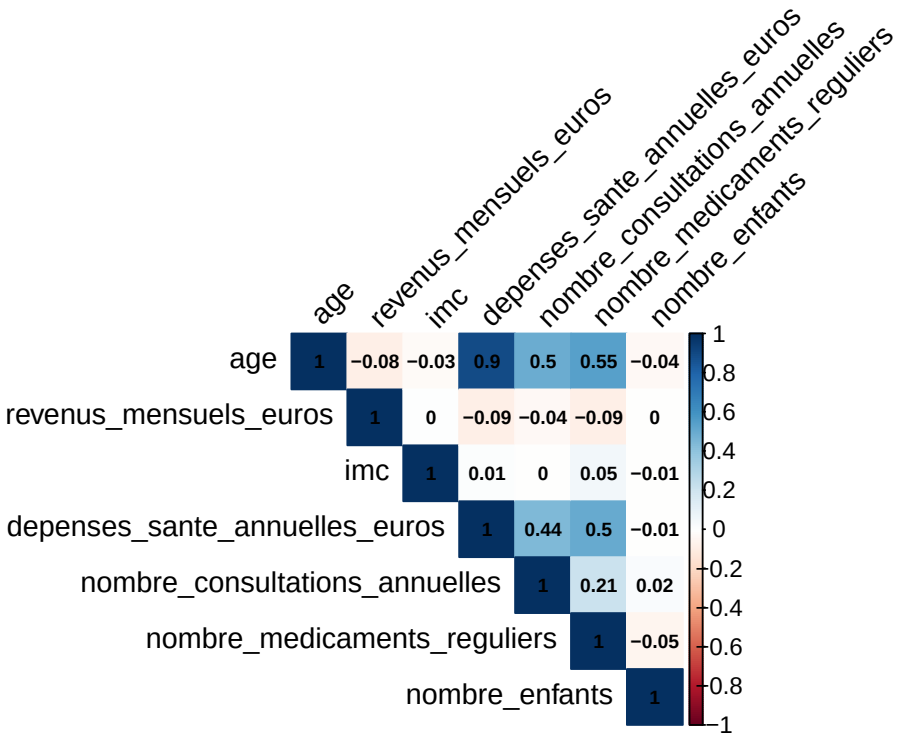

FIGURE 2 – Matrice de corrélation — Variables explicatives quantitatives

5.3.3 Indices de conditionnement

TABLE 11 – Indices de conditionnement (diagnostics de colinéarité)

Valeur propre	Indice de condition
3.260154e+09	1.0000
3.317778e+08	3.1347
5.097557e+04	252.8937
3.231361e+04	317.6335
1.944060e+03	1294.9819
9.905000e+02	1814.2250
8.410800e+02	1968.7977

```
##
## Nombre de condition (kappa) : 1641.29

## Interprétation : kappa > 30 → colinéarité sévère
```

5.4. Sélection de variables

La sélection de variables vise à identifier le sous-ensemble de prédicteurs offrant le meilleur compromis entre ajustement et parcimonie. **Pourquoi est-elle nécessaire ?** Un modèle sur-paramétré présente un risque de surapprentissage : il s'ajuste

au bruit de l'échantillon plutôt qu'au signal, dégradant sa capacité prédictive sur de nouvelles observations [7]. À l'inverse, un modèle sous-paramétré souffre de biais de spécification.

5.4.1 Sélection par R^2 ajusté, AIC et BIC — Tous les sous-modèles

L'exploration exhaustive (`regsubsets`) évalue **tous** les sous-modèles possibles pour chaque nombre de variables ($p = 1, \ldots, 7$) et sélectionne le meilleur selon trois critères complémentaires[31] :

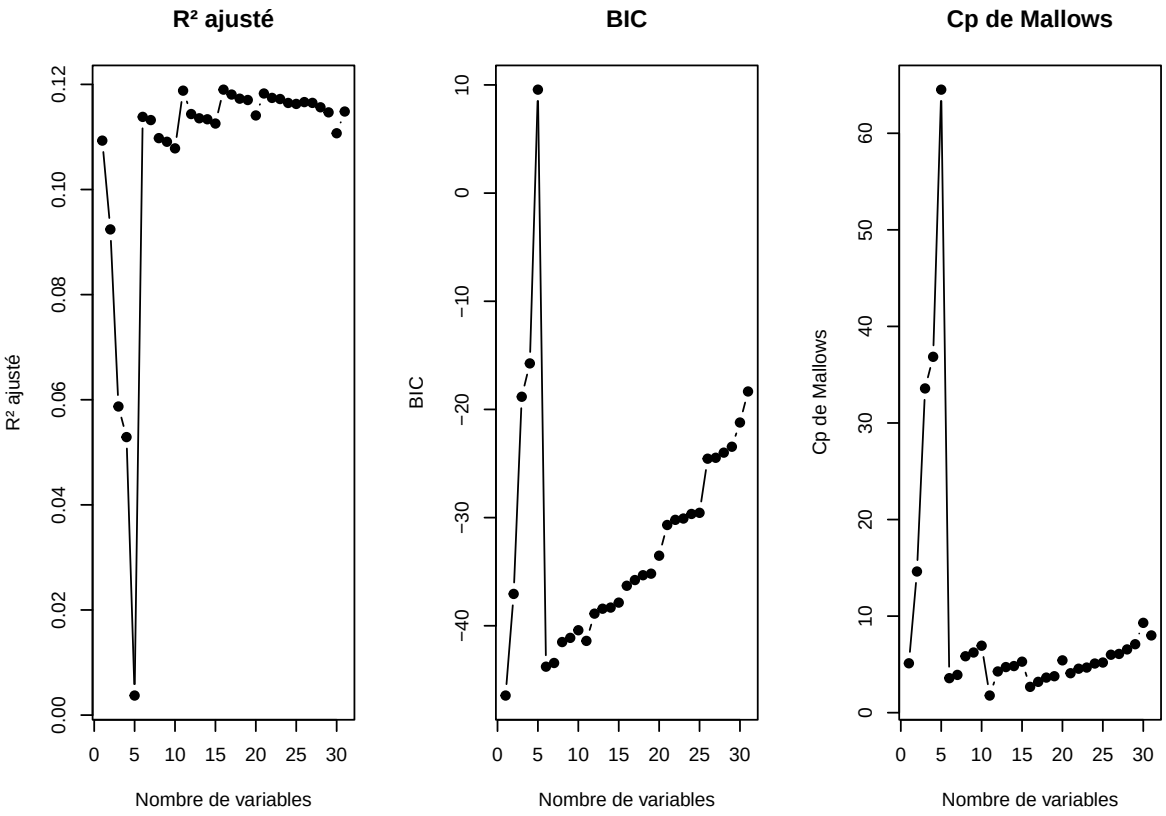

FIGURE 3 – Sélection de sous-modèles (leaps)

```
## Meilleur modèle selon BIC (nombre de variables) : 1

## Meilleur modèle selon R² ajusté (nombre de variables) : 16
```

5.4.2 Sélection ascendante (Forward)

```
## Start:  AIC=142.41
## score_sante ~ 1
##
##                                  Df Sum of Sq    RSS     AIC
## + age                             1    73.553 588.55  85.526
## + depenses_sante_annuelles_euros  1    62.389 599.71  94.921
## + nombre_medicaments_reguliers    1    40.124 621.98 113.149
## + nombre_consultations_annuelles  1    36.278 625.82 116.231
## + revenus_mensuels_euros          1     3.785 658.32 141.539
## <none>                                        662.10 142.406
## + imc                             1     0.637 661.46 143.924
## + nombre_enfants                  1     0.091 662.01 144.337
##
## Step:  AIC=85.53
## score_sante ~ age
```

31. Le R^2 ajusté pénalise l'ajout de variables par la diminution des degrés de liberté ; le BIC pénalise plus fortement que l'AIC (terme $\log(n)$ vs. 2), favorisant des modèles plus parcimonieux ; le C_p de Mallows estime le biais de prédiction.

```
##
##                                  Df Sum of Sq    RSS    AIC
## + nombre_consultations_annuelles  1    4.1589 584.39 83.981
## + nombre_medicaments_reguliers    1    3.7604 584.79 84.322
## <none>                                         588.55 85.526
## + revenus_mensuels_euros          1    1.4930 587.06 86.256
## + imc                             1    1.0371 587.51 86.645
## + depenses_sante_annuelles_euros  1    0.2097 588.34 87.348
## + nombre_enfants                  1    0.0001 588.55 87.526
##
## Step:  AIC=83.98
## score_sante ~ age + nombre_consultations_annuelles
##
##                                  Df Sum of Sq    RSS    AIC
## + nombre_medicaments_reguliers    1    4.4612 579.93 82.149
## <none>                                         584.39 83.981
## + revenus_mensuels_euros          1    1.5306 582.86 84.669
## + imc                             1    1.0003 583.39 85.124
## + depenses_sante_annuelles_euros  1    0.2190 584.17 85.793
## + nombre_enfants                  1    0.0073 584.38 85.974
##
## Step:  AIC=82.15
## score_sante ~ age + nombre_consultations_annuelles + nombre_medicaments_reguliers
##
##                                  Df Sum of Sq    RSS    AIC
## <none>                                         579.93 82.149
## + revenus_mensuels_euros          1   1.29413 578.64 83.032
## + imc                             1   0.68311 579.25 83.560
## + depenses_sante_annuelles_euros  1   0.16694 579.76 84.005
## + nombre_enfants                  1   0.00010 579.93 84.149
```

```
##
## Call:
## lm(formula = score_sante ~ age + nombre_consultations_annuelles +
##     nombre_medicaments_reguliers, data = df)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -2.8518 -0.7788  0.1168  0.7410  2.6731
##
## Coefficients:
##                                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)                     4.252400   0.137326  30.966  < 2e-16 ***
## age                            -0.011590   0.002861  -4.051 5.91e-05 ***
## nombre_consultations_annuelles -0.050601   0.024820  -2.039   0.0420 *
## nombre_medicaments_reguliers   -0.071877   0.036797  -1.953   0.0513 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.081 on 496 degrees of freedom
## Multiple R-squared:  0.1241, Adjusted R-squared:  0.1188
## F-statistic: 23.43 on 3 and 496 DF,  p-value: 3.396e-14
```

5.4.3 Sélection descendante (Backward)

```
## Start:  AIC=88.35
## score_sante ~ age + revenus_mensuels_euros + depenses_sante_annuelles_euros +
##     nombre_consultations_annuelles + nombre_medicaments_reguliers +
##     imc + nombre_enfants
##
##                                  Df Sum of Sq    RSS    AIC
## - nombre_enfants                  1    0.0009 577.85 86.350
## - depenses_sante_annuelles_euros  1    0.0995 577.94 86.435
## - imc                             1    0.6479 578.49 86.909
## - revenus_mensuels_euros          1    1.2794 579.12 87.455
## <none>                                         577.85 88.349
## - nombre_medicaments_reguliers    1    3.8784 581.72 89.693
## - age                             1    4.6736 582.52 90.376
## - nombre_consultations_annuelles  1    4.8203 582.67 90.502
##
## Step:  AIC=86.35
## score_sante ~ age + revenus_mensuels_euros + depenses_sante_annuelles_euros +
##     nombre_consultations_annuelles + nombre_medicaments_reguliers +
```

```
##     imc
##
##                                  Df Sum of Sq    RSS    AIC
## - depenses_sante_annuelles_euros  1    0.0987 577.94 84.435
## - imc                             1    0.6485 578.49 84.910
## - revenus_mensuels_euros          1    1.2791 579.13 85.455
## <none>                                         577.85 86.350
## - nombre_medicaments_reguliers    1    3.8880 581.73 87.703
## - age                             1    4.7031 582.55 88.403
## - nombre_consultations_annuelles  1    4.8236 582.67 88.506
##
## Step:  AIC=84.44
## score_sante ~ age + revenus_mensuels_euros + nombre_consultations_annuelles +
##     nombre_medicaments_reguliers + imc
##
##                                  Df Sum of Sq    RSS    AIC
## - imc                             1    0.6906 578.64 83.032
## - revenus_mensuels_euros          1    1.3016 579.25 83.560
## <none>                                         577.94 84.435
## - nombre_medicaments_reguliers    1    3.9152 581.86 85.811
## - nombre_consultations_annuelles  1    4.8186 582.76 86.586
## - age                             1   19.1471 597.09 98.731
##
## Step:  AIC=83.03
## score_sante ~ age + revenus_mensuels_euros + nombre_consultations_annuelles +
##     nombre_medicaments_reguliers
##
##                                  Df Sum of Sq    RSS    AIC
## - revenus_mensuels_euros          1    1.2941 579.93 82.149
## <none>                                         578.64 83.032
## - nombre_medicaments_reguliers    1    4.2247 582.86 84.669
## - nombre_consultations_annuelles  1    4.8775 583.51 85.229
## - age                             1   18.7502 597.39 96.977
##
## Step:  AIC=82.15
## score_sante ~ age + nombre_consultations_annuelles + nombre_medicaments_reguliers
##
##                                  Df Sum of Sq    RSS    AIC
## <none>                                         579.93 82.149
## - nombre_medicaments_reguliers    1    4.4612 584.39 83.981
## - nombre_consultations_annuelles  1    4.8597 584.79 84.322
## - age                             1   19.1914 599.12 96.428
```

```
##
## Call:
## lm(formula = score_sante ~ age + nombre_consultations_annuelles +
##     nombre_medicaments_reguliers, data = df)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -2.8518 -0.7788  0.1168  0.7410  2.6731
##
## Coefficients:
##                                Estimate Std. Error t value Pr(>|t|)
## (Intercept)                    4.252400   0.137326  30.966  < 2e-16 ***
## age                           -0.011590   0.002861  -4.051 5.91e-05 ***
## nombre_consultations_annuelles -0.050601   0.024820  -2.039   0.0420 *
## nombre_medicaments_reguliers   -0.071877   0.036797  -1.953   0.0513 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.081 on 496 degrees of freedom
## Multiple R-squared:  0.1241, Adjusted R-squared:  0.1188
## F-statistic: 23.43 on 3 and 496 DF,  p-value: 3.396e-14
```

5.4.4 Sélection pas à pas (Stepwise)

```
## Start:  AIC=142.41
## score_sante ~ 1
##
##                                  Df Sum of Sq    RSS     AIC
## + age                             1    73.553 588.55  85.526
## + depenses_sante_annuelles_euros  1    62.389 599.71  94.921
```

```
## + nombre_medicaments_reguliers    1    40.124 621.98 113.149
## + nombre_consultations_annuelles  1    36.278 625.82 116.231
## + revenus_mensuels_euros          1     3.785 658.32 141.539
## <none>                                        662.10 142.406
## + imc                             1     0.637 661.46 143.924
## + nombre_enfants                  1     0.091 662.01 144.337
##
## Step:  AIC=85.53
## score_sante ~ age
##
##                                  Df Sum of Sq    RSS     AIC
## + nombre_consultations_annuelles  1     4.159 584.39  83.981
## + nombre_medicaments_reguliers    1     3.760 584.79  84.322
## <none>                                        588.55  85.526
## + revenus_mensuels_euros          1     1.493 587.06  86.256
## + imc                             1     1.037 587.51  86.645
## + depenses_sante_annuelles_euros  1     0.210 588.34  87.348
## + nombre_enfants                  1     0.000 588.55  87.526
## - age                             1    73.553 662.10 142.406
##
## Step:  AIC=83.98
## score_sante ~ age + nombre_consultations_annuelles
##
##                                  Df Sum of Sq    RSS     AIC
## + nombre_medicaments_reguliers    1     4.461 579.93  82.149
## <none>                                        584.39  83.981
## + revenus_mensuels_euros          1     1.531 582.86  84.669
## + imc                             1     1.000 583.39  85.124
## - nombre_consultations_annuelles  1     4.159 588.55  85.526
## + depenses_sante_annuelles_euros  1     0.219 584.17  85.793
## + nombre_enfants                  1     0.007 584.38  85.974
## - age                             1    41.434 625.82 116.231
##
## Step:  AIC=82.15
## score_sante ~ age + nombre_consultations_annuelles + nombre_medicaments_reguliers
##
##                                  Df Sum of Sq    RSS    AIC
## <none>                                        579.93 82.149
## + revenus_mensuels_euros          1    1.2941 578.64 83.032
## + imc                             1    0.6831 579.25 83.560
## - nombre_medicaments_reguliers    1    4.4612 584.39 83.981
## + depenses_sante_annuelles_euros  1    0.1669 579.76 84.005
## + nombre_enfants                  1    0.0001 579.93 84.149
## - nombre_consultations_annuelles  1    4.8597 584.79 84.322
## - age                             1   19.1914 599.12 96.428
```

```
##
## Call:
## lm(formula = score_sante ~ age + nombre_consultations_annuelles +
##     nombre_medicaments_reguliers, data = df)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -2.8518 -0.7788  0.1168  0.7410  2.6731
##
## Coefficients:
##                                Estimate Std. Error t value Pr(>|t|)
## (Intercept)                    4.252400   0.137326  30.966  < 2e-16 ***
## age                           -0.011590   0.002861  -4.051 5.91e-05 ***
## nombre_consultations_annuelles -0.050601   0.024820  -2.039   0.0420 *
## nombre_medicaments_reguliers   -0.071877   0.036797  -1.953   0.0513 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.081 on 496 degrees of freedom
## Multiple R-squared:  0.1241, Adjusted R-squared:  0.1188
## F-statistic: 23.43 on 3 and 496 DF,  p-value: 3.396e-14
```

TABLE 12 – Comparaison des méthodes de sélection de variables. *Lecture* : la convergence des trois méthodes vers le même ensemble de variables renforce la confiance dans le modèle retenu.

Méthode	Nb variables	AIC	BIC	R^2 ajusté
Forward	3	1503.088	1524.161	0.1188
Backward	3	1503.088	1524.161	0.1188
Stepwise	3	1503.088	1524.161	0.1188

Interprétation : la convergence des méthodes *forward*, *backward* et *stepwise* vers un même ensemble de variables constitue un résultat de robustesse fort. Si les trois méthodes retiennent systématiquement l'âge, les consultations et les médicaments, cela conforte l'hypothèse H1 selon laquelle ces variables sont les déterminants quantitatifs dominants de la santé perçue. La valeur du BIC permet de discriminer parmi les modèles équivalents en R^2 ajusté.

5.5. Validation du modèle

La validation du modèle retenu est une étape critique : elle vérifie que les hypothèses du modèle linéaire gaussien sont respectées, condition nécessaire pour la validité des tests de significativité et des intervalles de confiance. **Pourquoi ces diagnostics sont-ils indispensables ?** Sans validation, les p-values et les intervalles de confiance pourraient être erronés, conduisant à des conclusions fallacieuses [18].

On valide le modèle retenu (variables issues de la sélection : `score_sante ~ age + nombre_consultations_annuelles + nombre_medicaments_reguliers`).

5.5.1 Normalité des résidus

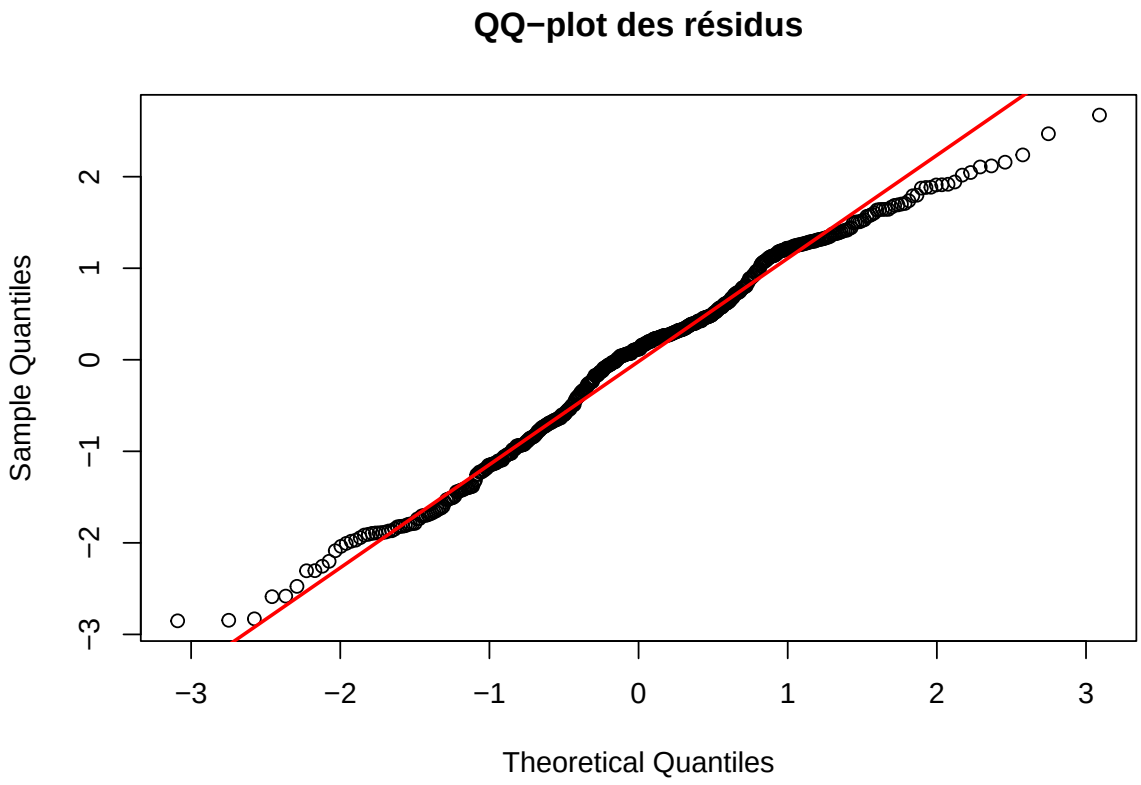

FIGURE 4 – QQ-plot des résidus

QQ-plot

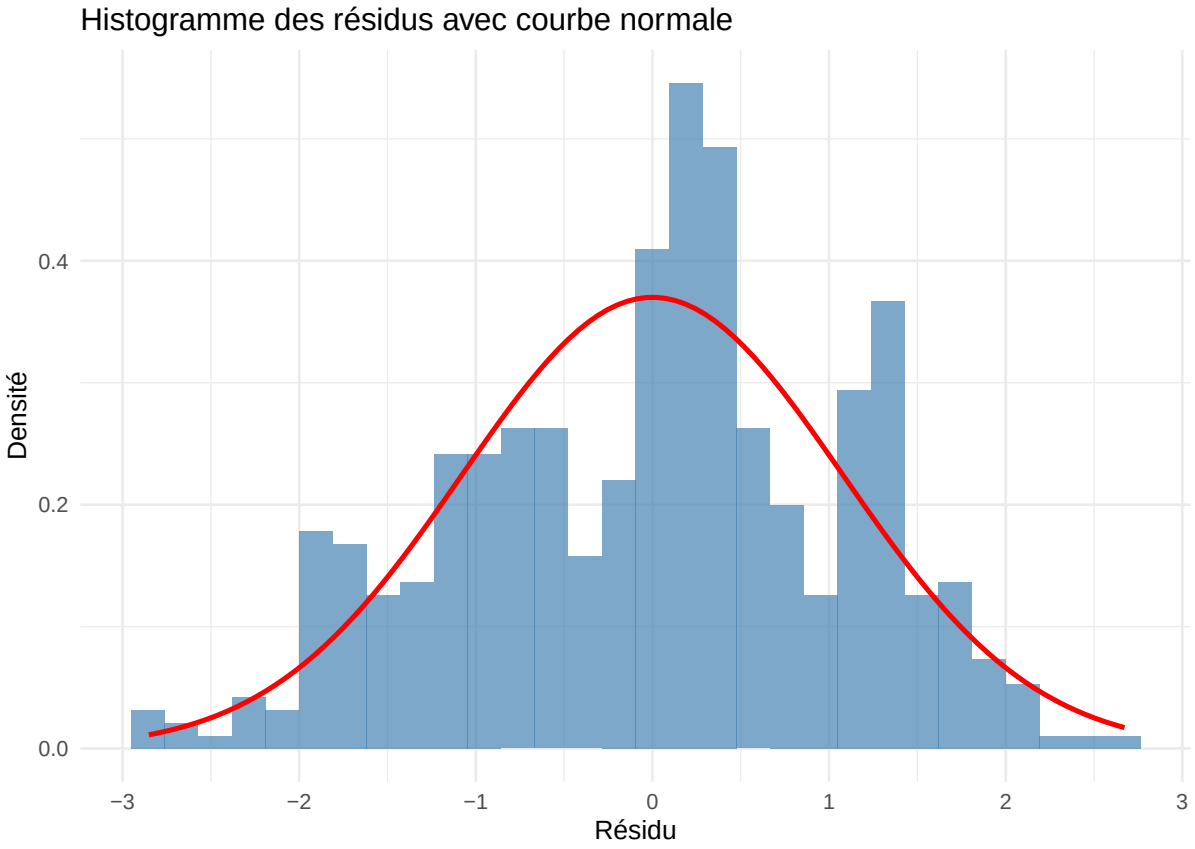

FIGURE 5 – Histogramme des résidus avec courbe normale

Histogramme des résidus

Test de Shapiro-Wilk Le test de Shapiro-Wilk est le test le plus puissant pour détecter la non-normalité en échantillon de taille modérée ($n < 5000$). **Interprétation attendue** : si $p > 0.05$, l'hypothèse de normalité n'est pas rejetée et les inférences du modèle linéaire sont valides. Si $p < 0.05$, la normalité est rejetée — mais, pour $n = 500$, le théorème central limite assure que les estimateurs MCO restent asymptotiquement normaux, de sorte que les tests restent approximativement valides[32].

```
##
##  Shapiro-Wilk normality test
##
## data:  resid(mod_val)
## W = 0.98645, p-value = 0.000133
```

32. En pratique, pour $n \geq 30$, la non-normalité des résidus n'invalide pas gravement les inférences, surtout si les résidus ne présentent pas d'asymétrie forte ou de queues lourdes.

5.5.2 Éléments aberrants — RStudent vs Leverage

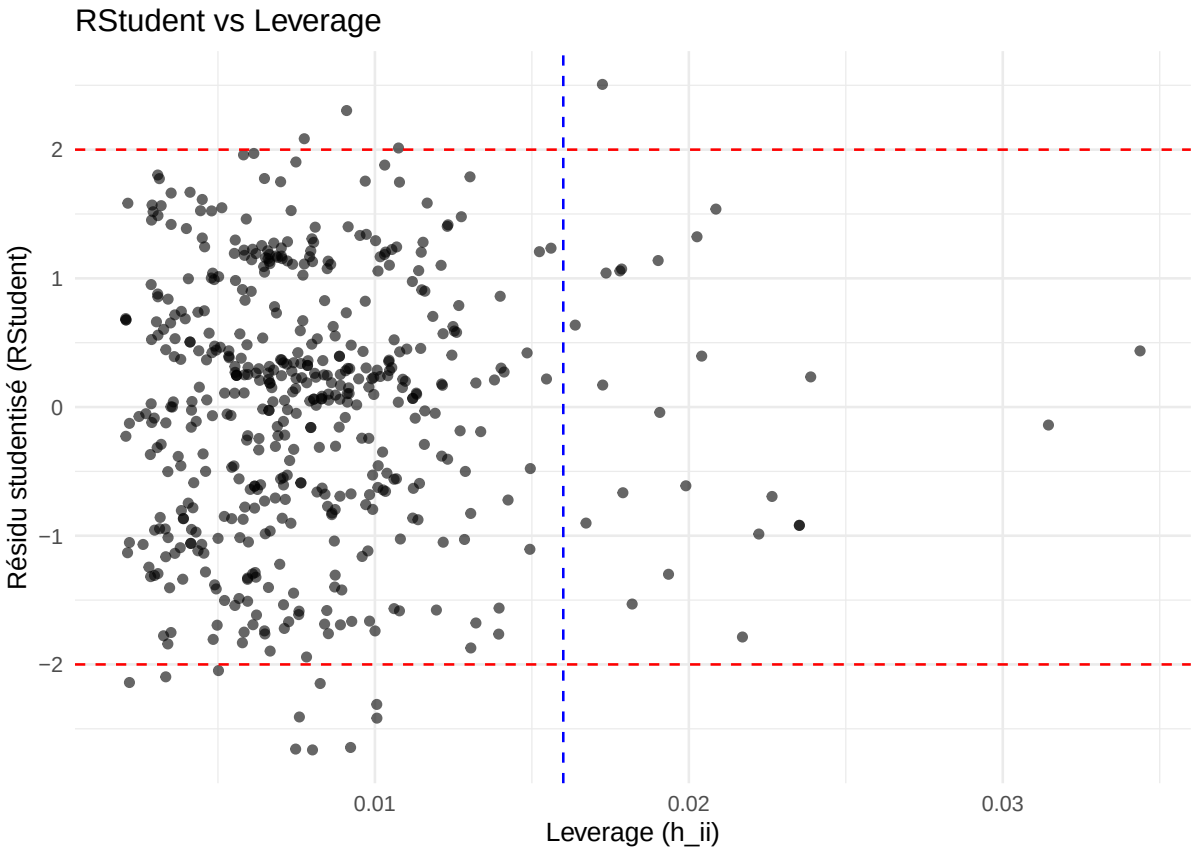

FIGURE 6 – RStudent vs Leverage

5.5.3 Distance de Cook

Seuil courant : $D_i > 4/n = 4/500 = 0.008$.

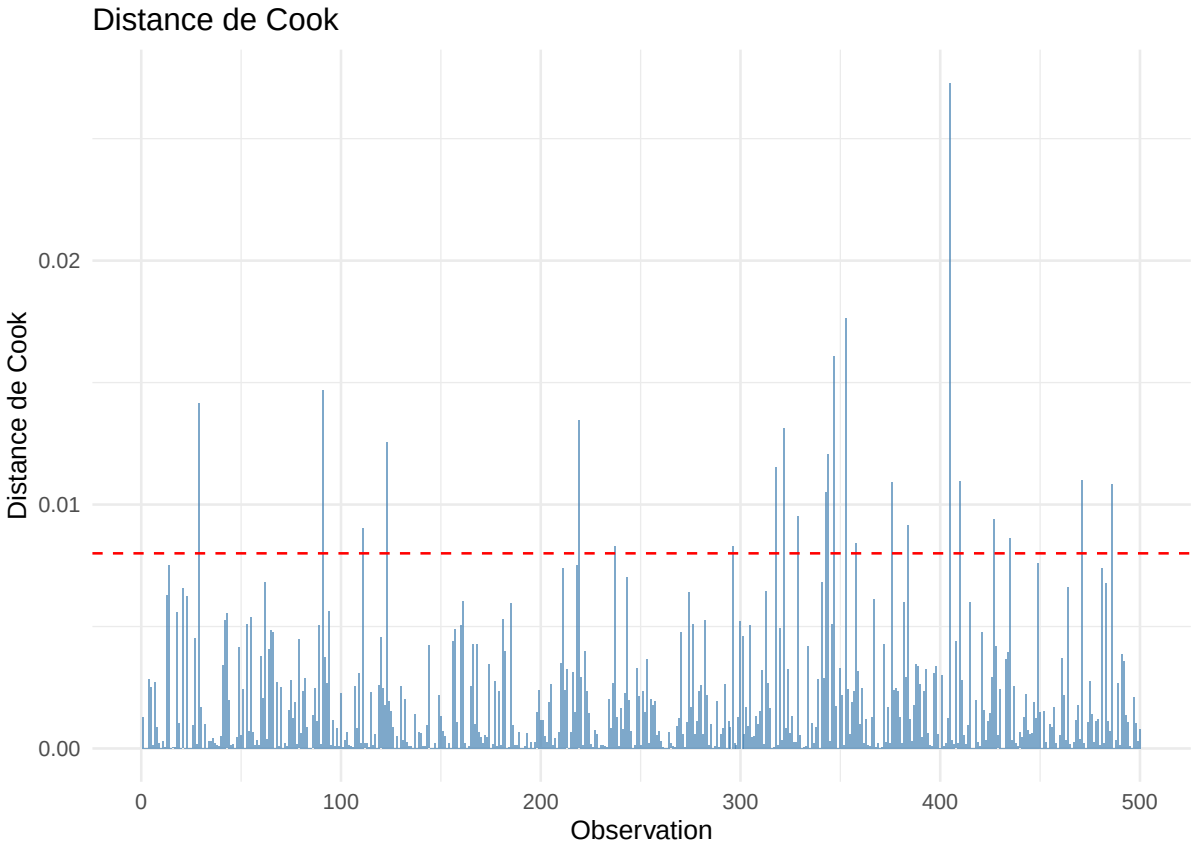

FIGURE 7 – Distance de Cook

5.5.4 Indépendance des résidus — Test de Durbin-Watson

H_0 : pas d'autocorrélation $\Rightarrow$ on souhaite ne **pas** rejeter H_0. **Pourquoi ce test est-il pertinent ici ?** Bien que nos données soient en coupe transversale (pas de dimension temporelle), une autocorrélation résiduelle pourrait apparaître si les observations sont ordonnées par région, par âge ou par tout autre facteur de grappe. Une statistique $d \approx 2$ confirme l'indépendance[33].

```
##
##  Durbin-Watson test
##
## data:  mod_val
## DW = 2.0578, p-value = 0.7411
## alternative hypothesis: true autocorrelation is greater than 0
```

5.5.5 Homoscédasticité — Test de Breusch-Pagan (équivalent du test de White sous SAS)

H_0 : variance constante des résidus (homoscédasticité). Si p-value $< 0.05 \Rightarrow$ hétéroscédasticité détectée.

```
##
##  studentized Breusch-Pagan test
##
## data:  mod_val
## BP = 1.7751, df = 3, p-value = 0.6204
```

33. Pour des données en coupe transversale non ordonnées, le test de Durbin-Watson est formellement moins pertinent que pour des séries temporelles, mais il reste un diagnostic utile en l'absence de structure explicite.

5.5.6 Linéarité — Résidus vs valeurs ajustées

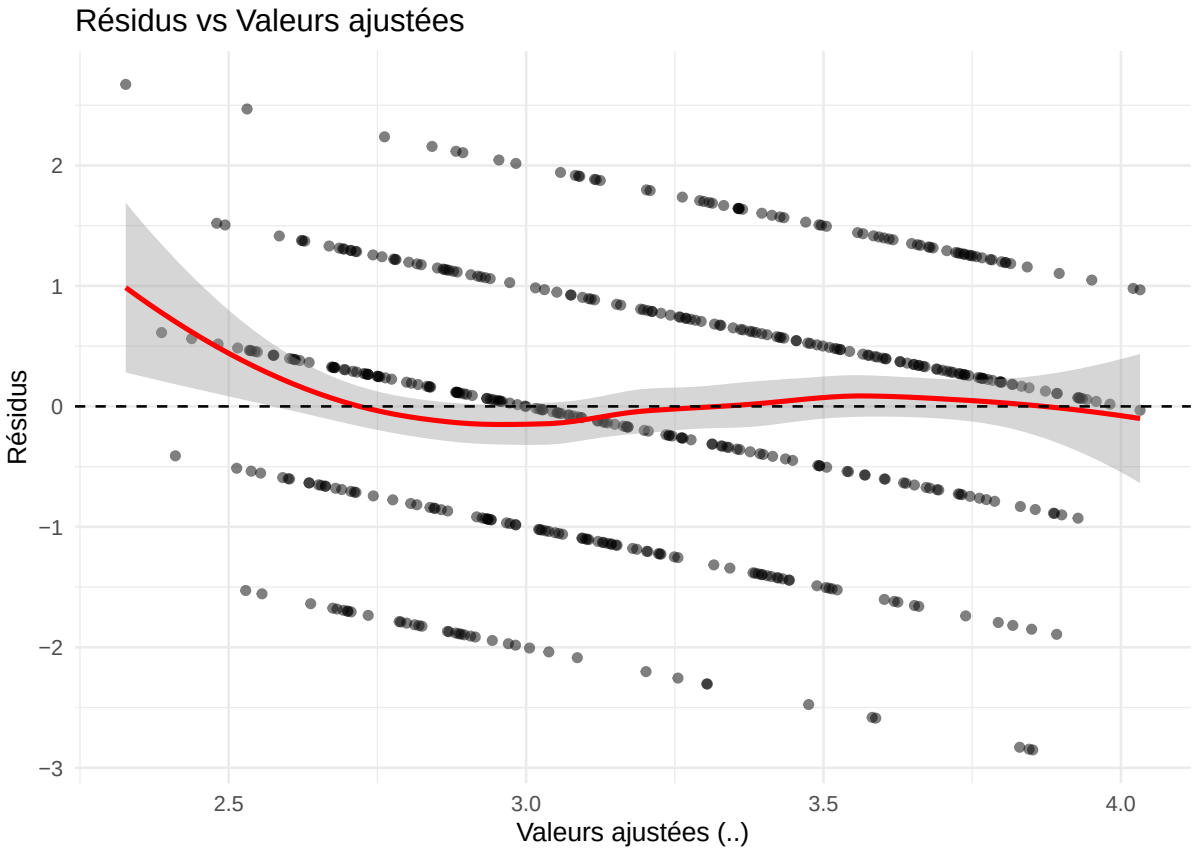

FIGURE 8 – Résidus vs valeurs ajustées (linéarité)

5.5.7 Visualisation LOESS — score_sante vs chaque prédicteur

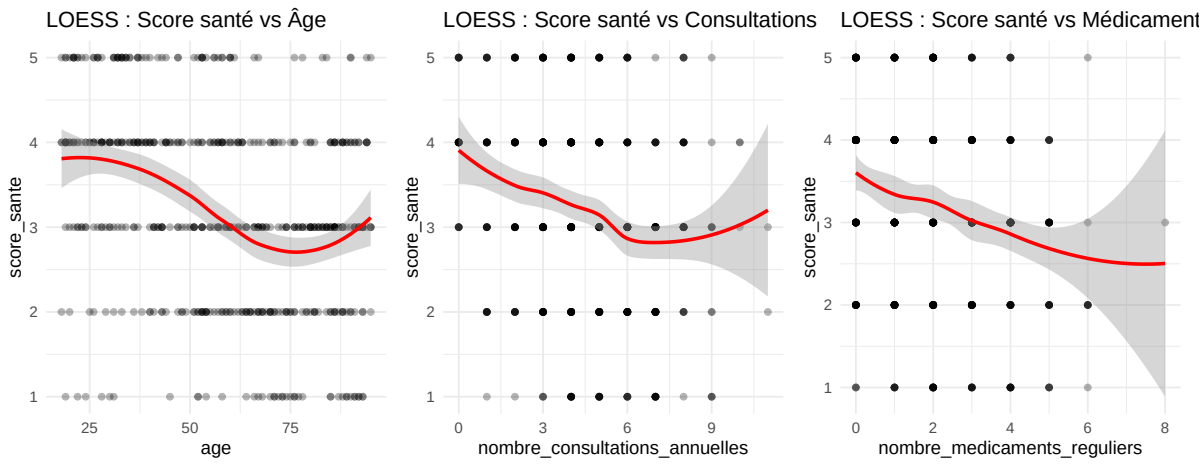

FIGURE 9 – Lissage LOESS — score_sante vs prédicteurs du modèle retenu

5.5.8 Observations potentiellement aberrantes / influentes

Table 13 – Observations potentiellement aberrantes / influentes (|RStudent| > 2 ou Cook > 0.008)

id	Âge	Score santé	ŷ	Résidu	RStudent	Cook D	Leverage
29	24	1	3.8518	-2.8518	-2.6642	0.0142	0.0080
322	22	1	3.8456	-2.8456	-2.6577	0.0131	0.0075
347	19	1	3.8298	-2.8298	-2.6450	0.0161	0.0092
405	94	5	2.3269	2.6731	2.5070	0.0273	0.0172
91	30	1	3.5879	-2.5879	-2.4171	0.0147	0.0101
471	28	1	3.5817	-2.5817	-2.4083	0.0110	0.0076
219	31	1	3.4751	-2.4751	-2.3106	0.0134	0.0101
344	95	5	2.5309	2.4691	2.3038	0.0121	0.0091
329	45	1	3.3048	-2.3048	-2.1481	0.0095	0.0083
87	52	1	3.3036	-2.3036	-2.1404	0.0025	0.0022
433	58	1	3.2553	-2.2553	-2.0964	0.0037	0.0033
358	90	5	2.7620	2.2380	2.0848	0.0084	0.0078
282	67	1	3.2016	-2.2016	-2.0478	0.0053	0.0050
376	90	5	2.8419	2.1581	2.0128	0.0109	0.0108
384	76	5	2.9829	2.0171	1.8799	0.0092	0.0103
318	77	1	3.0058	-2.0058	-1.8719	0.0115	0.0131
343	66	5	3.0827	1.9173	1.7888	0.0105	0.0130
353	52	1	2.9068	-1.9068	-1.7868	0.0176	0.0217
410	92	1	2.8906	-1.8906	-1.7645	0.0110	0.0139
237	78	5	3.1247	1.8753	1.7473	0.0083	0.0108
427	93	1	2.7991	-1.7991	-1.6780	0.0094	0.0132
435	72	1	2.6750	-1.6750	-1.5623	0.0086	0.0140
123	38	5	3.3566	1.6434	1.5381	0.0126	0.0209
486	89	1	2.6379	-1.6379	-1.5307	0.0108	0.0182
111	94	4	2.5851	1.4149	1.3230	0.0090	0.0203
296	70	2	3.3905	-1.3905	-1.2995	0.0083	0.0194

5.5.9 Diagnostics graphiques standards (4 graphiques)

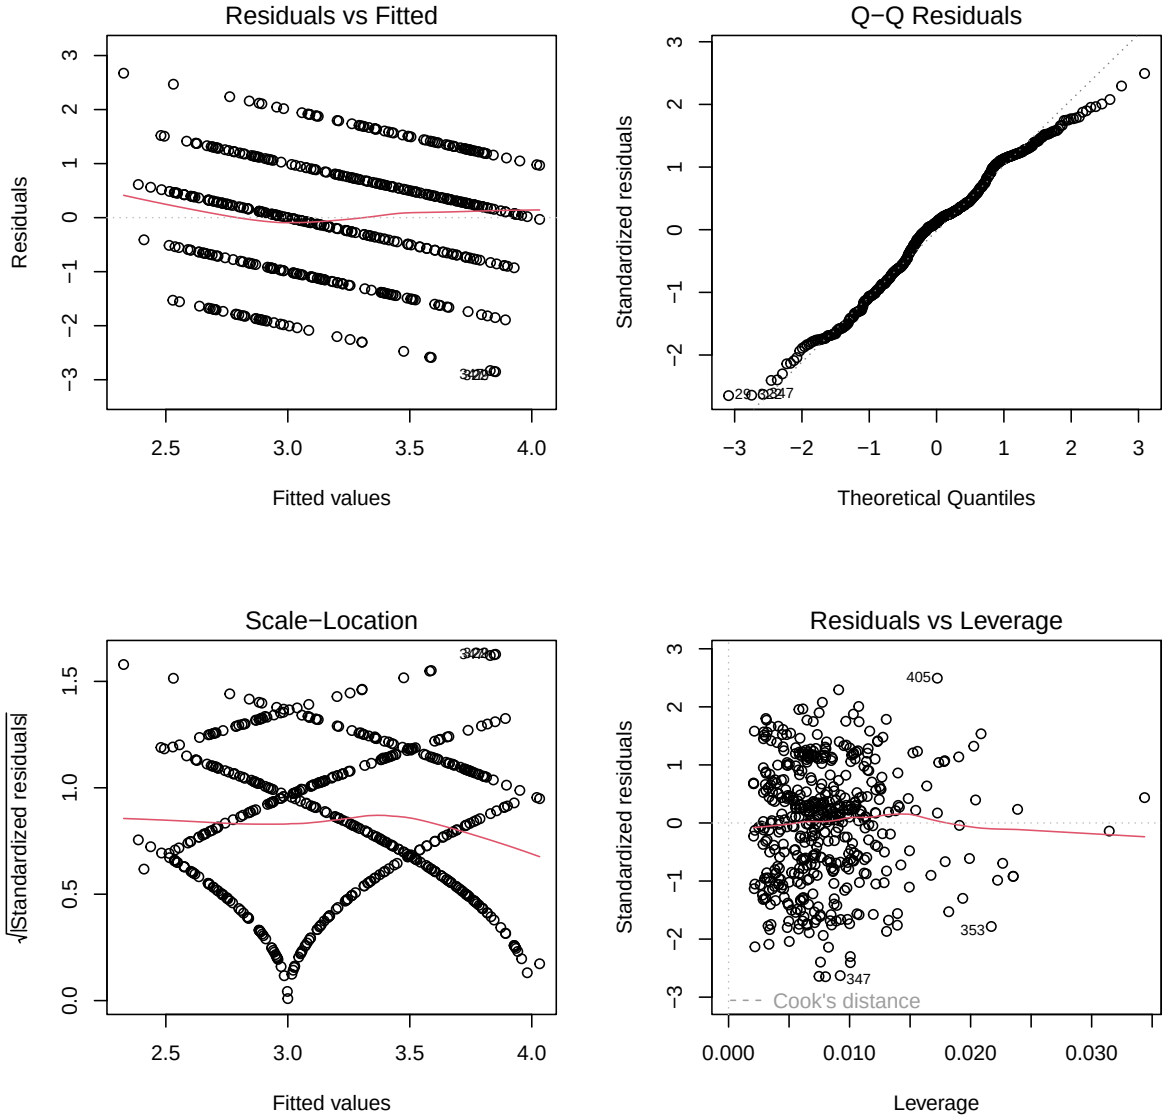

FIGURE 10 – Diagnostics du modèle retenu (4 graphiques standards)

5.6. Analyse de covariance (ANCOVA)

L'ANCOVA combine variables quantitatives (covariables) et qualitatives (facteurs) dans un modèle linéaire unique. **Pourquoi l'ANCOVA est-elle indispensable à notre analyse ?** Elle répond directement à l'hypothèse H2 : l'activité physique et le handicap déclaré ont-ils un effet propre sur le score de santé, *après ajustement* sur l'âge, les consultations et les médicaments ? Sans ANCOVA, l'effet apparent de ces facteurs pourrait être un artefact de confusion (par exemple, les personnes handicapées sont en moyenne plus âgées) [34].

Y = `score_sante` (numérique).

34. L'ANCOVA est formellement équivalente à une régression linéaire multiple incluant des variables indicatrices pour les facteurs qualitatifs, mais sa présentation en termes de table ANOVA de type III facilite l'interprétation des effets marginaux.

5.6.1 ANCOVA complète

Table 14 – ANCOVA complète — Table ANOVA de type III (score_sante)

	Sum Sq	Df	F value	Pr(>F)
(Intercept)	42.6327	1	36.8691	0.0000
age	4.9036	1	4.2407	0.0400
revenus_mensuels_euros	4.3243	1	3.7397	0.0537
imc	0.7170	1	0.6201	0.4314
depenses_sante_annuelles_euros	0.0017	1	0.0014	0.9698
nombre_consultations_annuelles	3.2167	1	2.7819	0.0960
nombre_medicaments_reguliers	4.9605	1	4.2899	0.0389
sexe	0.3316	1	0.2868	0.5926
profession	7.3132	8	0.7906	0.6112
couverture_complementaire	0.6649	3	0.1917	0.9021
hospitalisation_12_mois	0.0362	1	0.0313	0.8595
tabagisme	5.9177	3	1.7059	0.1650
activite_physique	6.3443	3	1.8289	0.1410
handicap_declare	1.6116	1	1.3937	0.2384
maladies_declarees	23.1431	12	1.6679	0.0709
Residuals	533.0651	461	NA	NA

```
##
## Call:
## lm(formula = score_sante ~ age + revenus_mensuels_euros + imc +
##     depenses_sante_annuelles_euros + nombre_consultations_annuelles +
##     nombre_medicaments_reguliers + sexe + profession + couverture_complementaire +
##     hospitalisation_12_mois + tabagisme + activite_physique +
##     handicap_declare + maladies_declarees, data = df)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -2.9608 -0.7474  0.1025  0.7208  2.9085
##
## Coefficients:
##                                                          Estimate
## (Intercept)                                             3.846e+00
## age                                                    -1.234e-02
## revenus_mensuels_euros                                  1.985e-04
## imc                                                    -9.280e-03
## depenses_sante_annuelles_euros                         -6.547e-06
## nombre_consultations_annuelles                         -4.248e-02
## nombre_medicaments_reguliers                           -7.761e-02
## sexeHomme                                              -5.388e-02
## professionArtisan/Commerçant                            1.604e-01
## professionCadre supérieur                              -2.871e-01
## professionEmployé                                       1.664e-01
## professionÉtudiant                                      2.908e-01
## professionOuvrier                                       3.467e-01
## professionProfession intermédiaire                     -1.338e-01
## professionRetraité                                      2.210e-01
## professionSans activité professionnelle                 5.031e-01
## couverture_complementaireAucune complémentaire          3.744e-02
## couverture_complementaireComplémentaire santé solidaire (CSS) -1.000e-01
## couverture_complementaireMutuelle privée               -2.194e-02
## hospitalisation_12_moisOui                             -1.979e-02
## tabagismeFumeur occasionnel                            -1.903e-01
## tabagismeFumeur quotidien                               1.160e-01
## tabagismeNon-fumeur                                    -1.392e-01
## activite_physiqueActivité légère                        3.591e-01
## activite_physiqueActivité modérée                       3.581e-01
## activite_physiqueSédentaire                             3.136e-01
## handicap_declareOui                                     1.433e-01
## maladies_declareesAsthme                                2.961e-01
```

```
## maladies_declareesAucune                                        -1.015e-01
## maladies_declareesCancer (rémission)                             1.949e-03
## maladies_declareesCardiopathie                                  -5.758e-01
## maladies_declareesDépression                                    -4.030e-01
## maladies_declareesDiabète                                       -3.052e-01
## maladies_declareesHypertension                                  -1.894e-02
## maladies_declareesLombalgie chronique                            2.053e-01
## maladies_declareesMaladie respiratoire chronique                 4.830e-01
## maladies_declareesMigraine chronique                             6.852e-02
## maladies_declareesObésité morbide                               -5.017e-01
## maladies_declareesTrouble anxieux                               -2.432e-01
##                                                                 Std. Error
## (Intercept)                                                      6.334e-01
## age                                                              5.991e-03
## revenus_mensuels_euros                                           1.026e-04
## imc                                                              1.178e-02
## depenses_sante_annuelles_euros                                   1.727e-04
## nombre_consultations_annuelles                                   2.547e-02
## nombre_medicaments_reguliers                                     3.747e-02
## sexeHomme                                                        1.006e-01
## professionArtisan/Commerçant                                     5.053e-01
## professionCadre supérieur                                        5.607e-01
## professionEmployé                                                4.801e-01
## professionÉtudiant                                               5.029e-01
## professionOuvrier                                                4.828e-01
## professionProfession intermédiaire                               5.040e-01
## professionRetraité                                               4.823e-01
## professionSans activité professionnelle                          4.859e-01
## couverture_complementaireAucune complémentaire                   1.977e-01
## couverture_complementaireComplémentaire santé solidaire (CSS)    1.679e-01
## couverture_complementaireMutuelle privée                         1.322e-01
## hospitalisation_12_moisOui                                       1.118e-01
## tabagismeFumeur occasionnel                                      1.745e-01
## tabagismeFumeur quotidien                                        1.388e-01
## tabagismeNon-fumeur                                              1.242e-01
## activite_physiqueActivité légère                                 1.657e-01
## activite_physiqueActivité modérée                                1.661e-01
## activite_physiqueSédentaire                                      1.705e-01
## handicap_declareOui                                              1.214e-01
## maladies_declareesAsthme                                         3.233e-01
## maladies_declareesAucune                                         2.287e-01
## maladies_declareesCancer (rémission)                             4.109e-01
## maladies_declareesCardiopathie                                   3.221e-01
## maladies_declareesDépression                                     3.031e-01
## maladies_declareesDiabète                                        2.716e-01
## maladies_declareesHypertension                                   2.571e-01
## maladies_declareesLombalgie chronique                            2.948e-01
## maladies_declareesMaladie respiratoire chronique                 3.276e-01
## maladies_declareesMigraine chronique                             3.514e-01
## maladies_declareesObésité morbide                                4.669e-01
## maladies_declareesTrouble anxieux                                3.205e-01
##                                                                 t value Pr(>|t|)
## (Intercept)                                                       6.072 2.64e-09
## age                                                              -2.059   0.0400
## revenus_mensuels_euros                                            1.934   0.0537
## imc                                                              -0.787   0.4314
## depenses_sante_annuelles_euros                                   -0.038   0.9698
## nombre_consultations_annuelles                                   -1.668   0.0960
## nombre_medicaments_reguliers                                     -2.071   0.0389
## sexeHomme                                                        -0.536   0.5926
## professionArtisan/Commerçant                                      0.317   0.7511
## professionCadre supérieur                                        -0.512   0.6088
## professionEmployé                                                 0.347   0.7291
## professionÉtudiant                                                0.578   0.5634
## professionOuvrier                                                 0.718   0.4730
## professionProfession intermédiaire                               -0.265   0.7907
## professionRetraité                                                0.458   0.6470
## professionSans activité professionnelle                           1.035   0.3010
## couverture_complementaireAucune complémentaire                    0.189   0.8499
## couverture_complementaireComplémentaire santé solidaire (CSS)    -0.596   0.5516
## couverture_complementaireMutuelle privée                         -0.166   0.8682
## hospitalisation_12_moisOui                                       -0.177   0.8595
## tabagismeFumeur occasionnel                                      -1.090   0.2761
```

```
## tabagismeFumeur quotidien                                    0.835   0.4039
## tabagismeNon-fumeur                                         -1.121   0.2629
## activite_physiqueActivité légère                             2.167   0.0308
## activite_physiqueActivité modérée                            2.156   0.0316
## activite_physiqueSédentaire                                  1.839   0.0665
## handicap_declareOui                                          1.181   0.2384
## maladies_declareesAsthme                                     0.916   0.3602
## maladies_declareesAucune                                    -0.444   0.6574
## maladies_declareesCancer (rémission)                         0.005   0.9962
## maladies_declareesCardiopathie                              -1.788   0.0745
## maladies_declareesDépression                                -1.330   0.1843
## maladies_declareesDiabète                                   -1.124   0.2616
## maladies_declareesHypertension                              -0.074   0.9413
## maladies_declareesLombalgie chronique                        0.697   0.4864
## maladies_declareesMaladie respiratoire chronique             1.474   0.1411
## maladies_declareesMigraine chronique                         0.195   0.8455
## maladies_declareesObésité morbide                           -1.075   0.2831
## maladies_declareesTrouble anxieux                           -0.759   0.4484
##
## (Intercept)                                                ***
## age                                                        *
## revenus_mensuels_euros                                     .
## imc
## depenses_sante_annuelles_euros
## nombre_consultations_annuelles                             .
## nombre_medicaments_reguliers                               *
## sexeHomme
## professionArtisan/Commerçant
## professionCadre supérieur
## professionEmployé
## professionÉtudiant
## professionOuvrier
## professionProfession intermédiaire
## professionRetraité
## professionSans activité professionnelle
## couverture_complementaireAucune complémentaire
## couverture_complementaireComplémentaire santé solidaire (CSS)
## couverture_complementaireMutuelle privée
## hospitalisation_12_moisOui
## tabagismeFumeur occasionnel
## tabagismeFumeur quotidien
## tabagismeNon-fumeur
## activite_physiqueActivité légère                           *
## activite_physiqueActivité modérée                          *
## activite_physiqueSédentaire                                .
## handicap_declareOui
## maladies_declareesAsthme
## maladies_declareesAucune
## maladies_declareesCancer (rémission)
## maladies_declareesCardiopathie                             .
## maladies_declareesDépression
## maladies_declareesDiabète
## maladies_declareesHypertension
## maladies_declareesLombalgie chronique
## maladies_declareesMaladie respiratoire chronique
## maladies_declareesMigraine chronique
## maladies_declareesObésité morbide
## maladies_declareesTrouble anxieux
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.075 on 461 degrees of freedom
## Multiple R-squared:  0.1949, Adjusted R-squared:  0.1285
## F-statistic: 2.937 on 38 and 461 DF,  p-value: 5.181e-08
```

5.6.2 ANCOVA réduite — facteurs significatifs

Le modèle ANCOVA réduit ne retient que les facteurs et covariables dont l'effet est significatif au seuil de 5 % dans le modèle complet. **Justification** : le principe de parcimonie et la comparaison par test F emboîté garantissent que le modèle réduit n'est pas significativement moins explicatif que le modèle complet.

Table 15 – ANCOVA réduite — Table ANOVA de type III

	Sum Sq	Df	F value	Pr(>F)
(Intercept)	451.8539	1	386.3150	0.0000
age	18.9033	1	16.1614	0.0001
nombre_consultations_annuelles	4.4341	1	3.7910	0.0521
nombre_medicaments_reguliers	4.4376	1	3.7939	0.0520
sexe	0.0773	1	0.0661	0.7972
hospitalisation_12_mois	0.0580	1	0.0496	0.8239
activite_physique	5.3679	3	1.5298	0.2059
handicap_declare	1.1632	1	0.9945	0.3191
Residuals	573.1293	490	NA	NA

```
##
## Call:
## lm(formula = score_sante ~ age + nombre_consultations_annuelles +
##     nombre_medicaments_reguliers + sexe + hospitalisation_12_mois +
##     activite_physique + handicap_declare, data = df)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -2.8730 -0.7942  0.1188  0.7467  2.6479
##
## Coefficients:
##                                   Estimate Std. Error t value Pr(>|t|)
## (Intercept)                       3.963193   0.201639  19.655  < 2e-16 ***
## age                              -0.011640   0.002896  -4.020 6.73e-05 ***
## nombre_consultations_annuelles   -0.048465   0.024891  -1.947   0.0521 .
## nombre_medicaments_reguliers     -0.071883   0.036905  -1.948   0.0520 .
## sexeHomme                        -0.025159   0.097874  -0.257   0.7972
## hospitalisation_12_moisOui       -0.024342   0.109338  -0.223   0.8239
## activite_physiqueActivité légère  0.311282   0.163345   1.906   0.0573 .
## activite_physiqueActivité modérée 0.326490   0.163262   2.000   0.0461 *
## activite_physiqueSédentaire       0.302635   0.167137   1.811   0.0708 .
## handicap_declareOui               0.118629   0.118958   0.997   0.3191
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.082 on 490 degrees of freedom
## Multiple R-squared:  0.1344, Adjusted R-squared:  0.1185
## F-statistic: 8.452 on 9 and 490 DF,  p-value: 8.817e-12
```

Moyennes marginales estimées (LSMEANS) et comparaisons multiples (Tukey)

```
##

##   LSMEANS - Sexe

##

## $emmeans
##  sexe  emmean     SE  df lower.CL upper.CL
##  Femme   3.21 0.0780 490     3.06     3.37
##  Homme   3.19 0.0869 490     3.02     3.36
##
## Results are averaged over the levels of: hospitalisation_12_mois, activite_physique, handicap_declare
## Confidence level used: 0.95
##
## $contrasts
##  contrast      estimate     SE  df t.ratio p.value
##  Femme - Homme   0.0252 0.0979 490   0.257  0.7972
##
## Results are averaged over the levels of: hospitalisation_12_mois, activite_physique, handicap_declare

##
##
```

```
##   LSMEANS - Hospitalisation 12 mois

##

## $emmeans
##  hospitalisation_12_mois emmean     SE  df lower.CL upper.CL
##  Non                      3.21 0.0699 490     3.08     3.35
##  Oui                      3.19 0.0997 490     2.99     3.38
##
## Results are averaged over the levels of: sexe, activite_physique, handicap_declare
## Confidence level used: 0.95
##
## $contrasts
##  contrast  estimate    SE  df t.ratio p.value
##  Non - Oui   0.0243 0.109 490   0.223  0.8239
##
## Results are averaged over the levels of: sexe, activite_physique, handicap_declare

##
##

##   LSMEANS - Activité physique

##

## $emmeans
##  activite_physique emmean     SE  df lower.CL upper.CL
##  Activité intense    2.97 0.1443 490     2.68     3.25
##  Activité légère     3.28 0.0987 490     3.08     3.47
##  Activité modérée    3.29 0.0952 490     3.11     3.48
##  Sédentaire          3.27 0.1029 490     3.07     3.47
##
## Results are averaged over the levels of: sexe, hospitalisation_12_mois, handicap_declare
## Confidence level used: 0.95
##
## $contrasts
##  contrast                            estimate    SE  df t.ratio p.value
##  Activité intense - Activité légère  -0.31128 0.163 490  -1.906  0.2269
##  Activité intense - Activité modérée -0.32649 0.163 490  -2.000  0.1894
##  Activité intense - Sédentaire       -0.30264 0.167 490  -1.811  0.2695
##  Activité légère - Activité modérée  -0.01521 0.124 490  -0.122  0.9993
##  Activité légère - Sédentaire         0.00865 0.129 490   0.067  0.9999
##  Activité modérée - Sédentaire        0.02385 0.129 490   0.186  0.9977
##
## Results are averaged over the levels of: sexe, hospitalisation_12_mois, handicap_declare
## P value adjustment: tukey method for comparing a family of 4 estimates

##
##

##   LSMEANS - Handicap déclaré

##

## $emmeans
##  handicap_declare emmean     SE  df lower.CL upper.CL
##  Non                3.14 0.0633 490     3.02     3.27
##  Oui                3.26 0.1092 490     3.05     3.47
##
## Results are averaged over the levels of: sexe, hospitalisation_12_mois, activite_physique
## Confidence level used: 0.95
##
## $contrasts
##  contrast  estimate    SE  df t.ratio p.value
##  Non - Oui   -0.119 0.119 490  -0.997  0.3191
##
## Results are averaged over the levels of: sexe, hospitalisation_12_mois, activite_physique
```

5.6.3 Test d'interaction — Âge × Sexe

TABLE 16 – ANCOVA — Test d'interaction Âge × Sexe sur score_sante

	Sum Sq	Df	F value	Pr(>F)
(Intercept)	604.2732	1	509.8759	0.0000
age	34.3592	1	28.9917	0.0000
sexe	0.2321	1	0.1958	0.6583
age :sexe	0.4985	1	0.4206	0.5169
Residuals	587.8283	496	NA	NA

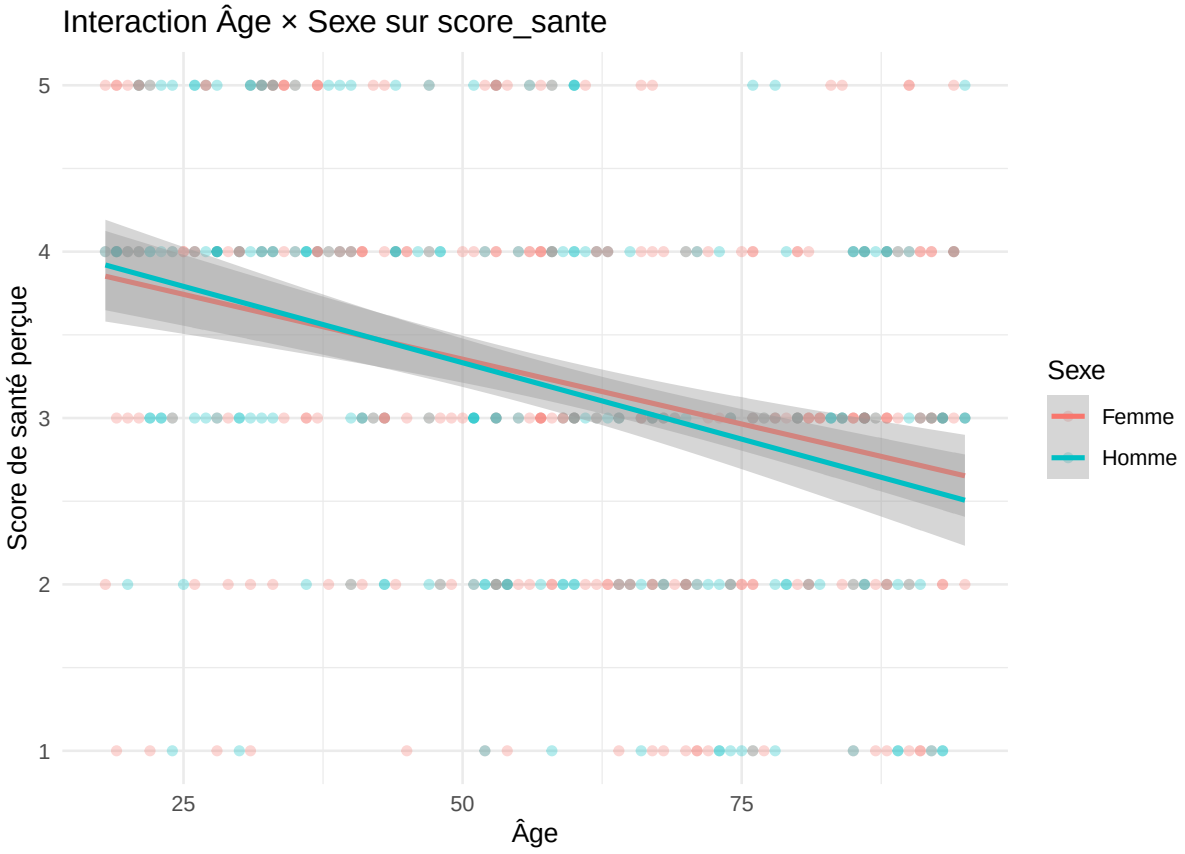

FIGURE 11 – Interaction Âge × Sexe sur le score de santé perçue

5.7. Régression logistique

`etat_sante_percu` est qualitative ordinale (5 modalités) ⇒ on utilise le modèle logistique ordinal (*cumulative logit*) via `MASS::polr()`. **Pourquoi passer à la régression logistique ?** La régression linéaire sur le score ordinal, bien que pratique, repose sur l'hypothèse d'équidistance entre les modalités. La régression logistique ordinale respecte la nature qualitative de la variable réponse et permet de tester explicitement l'hypothèse de proportionnalité des cotes [30]. Ce passage au modèle ordinal constitue le test de l'hypothèse H3.

5.7.1 Régression logistique ordinale — Modèle complet

```
## Call:
## MASS::polr(formula = etat_sante_ord ~ age + revenus_mensuels_euros +
##     imc + nombre_consultations_annuelles + nombre_medicaments_reguliers +
##     depenses_sante_annuelles_euros + sexe + hospitalisation_12_mois +
##     tabagisme + activite_physique + handicap_declare + couverture_complementaire,
##     data = df, Hess = TRUE, method = "logistic")
##
```

```
## Coefficients:
##                                                                    Value
## age                                                           -1.981e-02
## revenus_mensuels_euros                                         6.993e-05
## imc                                                           -1.635e-02
## nombre_consultations_annuelles                                -7.380e-02
## nombre_medicaments_reguliers                                  -1.165e-01
## depenses_sante_annuelles_euros                                -4.076e-05
## sexeHomme                                                     -5.866e-02
## hospitalisation_12_moisOui                                     3.591e-03
## tabagismeFumeur occasionnel                                   -4.290e-01
## tabagismeFumeur quotidien                                      1.425e-01
## tabagismeNon-fumeur                                           -2.445e-01
## activite_physiqueActivité légère                               5.124e-01
## activite_physiqueActivité modérée                              4.857e-01
## activite_physiqueSédentaire                                    4.528e-01
## handicap_declareOui                                            2.475e-01
## couverture_complementaireAucune complémentaire                -7.752e-03
## couverture_complementaireComplémentaire santé solidaire (CSS) -1.542e-01
## couverture_complementaireMutuelle privée                       8.619e-04
##                                                               Std. Error
## age                                                            0.0113787
## revenus_mensuels_euros                                         0.0001120
## imc                                                            0.0137400
## nombre_consultations_annuelles                                 0.0410564
## nombre_medicaments_reguliers                                   0.0619218
## depenses_sante_annuelles_euros                                 0.0004346
## sexeHomme                                                      0.1645784
## hospitalisation_12_moisOui                                     0.1852978
## tabagismeFumeur occasionnel                                    0.1335180
## tabagismeFumeur quotidien                                      0.1605112
## tabagismeNon-fumeur                                            0.1451305
## activite_physiqueActivité légère                               0.1218330
## activite_physiqueActivité modérée                              0.1247427
## activite_physiqueSédentaire                                    0.1265462
## handicap_declareOui                                            0.1980474
## couverture_complementaireAucune complémentaire                 0.1491532
## couverture_complementaireComplémentaire santé solidaire (CSS)  0.1813089
## couverture_complementaireMutuelle privée                       0.1430746
##                                                                 t value
## age                                                           -1.741267
## revenus_mensuels_euros                                         0.624569
## imc                                                           -1.190009
## nombre_consultations_annuelles                                -1.797489
## nombre_medicaments_reguliers                                  -1.881058
## depenses_sante_annuelles_euros                                -0.093774
## sexeHomme                                                     -0.356433
## hospitalisation_12_moisOui                                     0.019380
## tabagismeFumeur occasionnel                                   -3.212901
## tabagismeFumeur quotidien                                      0.887579
## tabagismeNon-fumeur                                           -1.685002
## activite_physiqueActivité légère                               4.205403
## activite_physiqueActivité modérée                              3.893690
## activite_physiqueSédentaire                                    3.578319
## handicap_declareOui                                            1.249584
## couverture_complementaireAucune complémentaire                -0.051973
## couverture_complementaireComplémentaire santé solidaire (CSS) -0.850575
## couverture_complementaireMutuelle privée                       0.006024
##
## Intercepts:
##                       Value     Std. Error t value
## Très mauvais|Mauvais   -4.4152    0.0119  -371.7782
## Mauvais|Assez bon      -2.8620    0.1522   -18.8064
## Assez bon|Bon          -1.4523    0.1709    -8.5003
## Bon|Très bon            0.2348    0.2022     1.1617
##
## Residual Deviance: 1437.114
## AIC: 1481.114
```

Table 17 – Régression logistique ordinale — Coefficients et p-values (modèle complet). *Lecture* : un coefficient négatif signifie que la variable est associée à une probabilité plus élevée d'être dans une catégorie de santé plus basse.

	Value	Std. Error	t value	p-valu
age	-0.0198	0.0114	-1.7413	0.081
revenus_mensuels_euros	0.0001	0.0001	0.6246	0.532
imc	-0.0164	0.0137	-1.1900	0.234
nombre_consultations_annuelles	-0.0738	0.0411	-1.7975	0.072
nombre_medicaments_reguliers	-0.1165	0.0619	-1.8811	0.060
depenses_sante_annuelles_euros	0.0000	0.0004	-0.0938	0.925
sexeHomme	-0.0587	0.1646	-0.3564	0.721
hospitalisation_12_moisOui	0.0036	0.1853	0.0194	0.984
tabagismeFumeur occasionnel	-0.4290	0.1335	-3.2129	0.001
tabagismeFumeur quotidien	0.1425	0.1605	0.8876	0.374
tabagismeNon-fumeur	-0.2445	0.1451	-1.6850	0.092
activite_physiqueActivité légère	0.5124	0.1218	4.2054	0.000
activite_physiqueActivité modérée	0.4857	0.1247	3.8937	0.000
activite_physiqueSédentaire	0.4528	0.1265	3.5783	0.000
handicap_declareOui	0.2475	0.1980	1.2496	0.211
couverture_complementaireAucune complémentaire	-0.0078	0.1492	-0.0520	0.958
couverture_complementaireComplémentaire santé solidaire (CSS)	-0.1542	0.1813	-0.8506	0.395
couverture_complementaireMutuelle privée	0.0009	0.1431	0.0060	0.995
Très mauvais|Mauvais	-4.4152	0.0119	-371.7782	0.000
Mauvais|Assez bon	-2.8620	0.1522	-18.8064	0.000
Assez bon|Bon	-1.4523	0.1709	-8.5003	0.000
Bon|Très bon	0.2348	0.2022	1.1617	0.245

Interprétation : les coefficients du modèle ordinal s'interprètent en termes de *log-odds cumulatifs*. Un coefficient négatif pour l'âge signifie qu'un individu plus âgé a une probabilité plus élevée de se situer dans les catégories inférieures de santé perçue (Mauvais, Très mauvais). Si les variables significatives dans le modèle ordinal sont les mêmes que dans le modèle linéaire, cela constitue un résultat de robustesse fort, confortant les hypothèses H1 et H2 indépendamment de la spécification choisie.

Test de l'hypothèse des cotes proportionnelles (Brant Test) Le test de Brant [5] est crucial pour la validité du modèle ordinal : il vérifie que les coefficients $\boldsymbol{\beta}$ sont effectivement constants à travers les seuils de coupure. **Si le test rejette la proportionnalité** ($p < 0.05$), cela signifie que l'effet de certaines variables diffère selon le niveau de santé considéré — par exemple, l'âge pourrait avoir un effet plus fort sur la distinction « Très mauvais/Mauvais » que sur la distinction « Bon/Très bon » [35].

```
## Le package 'brant' n'est pas installé. Installez-le avec :
## install.packages('brant')
```

5.7.2 Régression logistique ordinale — Modèle réduit

Le modèle réduit ne retient que les variables significatives, conformément au principe de parcimonie. La comparaison avec le modèle complet par test du rapport de vraisemblance vérifie que les variables exclues n'apportent pas collectivement une information significative.

```
## Call:
## MASS::polr(formula = etat_sante_ord ~ age + nombre_consultations_annuelles +
##     nombre_medicaments_reguliers + sexe + hospitalisation_12_mois +
##     activite_physique + handicap_declare, data = df, Hess = TRUE,
##     method = "logistic")
##
## Coefficients:
```

35. En cas de rejet, un modèle à cotes partiellement proportionnelles (*partial proportional odds model*) ou un modèle multinomial serait plus approprié.

```
##                                    Value Std. Error t value
## age                              -0.02038   0.004957 -4.1107
## nombre_consultations_annuelles   -0.07367   0.041092 -1.7929
## nombre_medicaments_reguliers     -0.11620   0.061517 -1.8890
## sexeHomme                        -0.06314   0.163913 -0.3852
## hospitalisation_12_moisOui       -0.01907   0.182840 -0.1043
## activite_physiqueActivité légère  0.50592   0.268672  1.8830
## activite_physiqueActivité modérée 0.51882   0.268840  1.9299
## activite_physiqueSédentaire       0.47314   0.277259  1.7065
## handicap_declareOui               0.21868   0.196093  1.1152
##
## Intercepts:
##                      Value    Std. Error t value
## Très mauvais|Mauvais  -3.9230   0.3828   -10.2485
## Mauvais|Assez bon     -2.3759   0.3558    -6.6768
## Assez bon|Bon         -0.9814   0.3428    -2.8629
## Bon|Très bon           0.6895   0.3418     2.0170
##
## Residual Deviance: 1444.375
## AIC: 1470.375
```

Table 18 – Régression logistique ordinale — Coefficients et p-values (modèle réduit)

	Value	Std. Error	t value	p-value
age	-0.0204	0.0050	-4.1107	0.0000
nombre_consultations_annuelles	-0.0737	0.0411	-1.7929	0.0730
nombre_medicaments_reguliers	-0.1162	0.0615	-1.8890	0.0589
sexeHomme	-0.0631	0.1639	-0.3852	0.7001
hospitalisation_12_moisOui	-0.0191	0.1828	-0.1043	0.9170
activite_physiqueActivité légère	0.5059	0.2687	1.8830	0.0597
activite_physiqueActivité modérée	0.5188	0.2688	1.9299	0.0536
activite_physiqueSédentaire	0.4731	0.2773	1.7065	0.0879
handicap_declareOui	0.2187	0.1961	1.1152	0.2648
Très mauvais|Mauvais	-3.9230	0.3828	-10.2485	0.0000
Mauvais|Assez bon	-2.3759	0.3558	-6.6768	0.0000
Assez bon|Bon	-0.9814	0.3428	-2.8629	0.0042
Bon|Très bon	0.6895	0.3418	2.0170	0.0437

Comparaison des modèles (test du rapport de vraisemblance)

```
## Likelihood ratio tests of ordinal regression models
##
## Response: etat_sante_ord
##
## 1                                                                                                                  age + nombre_co
## 2 age + revenus_mensuels_euros + imc + nombre_consultations_annuelles + nombre_medicaments_reguliers + depenses_sante_ann
##   Resid. df Resid. Dev   Test    Df LR stat.   Pr(Chi)
## 1       487   1444.375
## 2       478   1437.114 1 vs 2     9 7.261106 0.6099548
```

5.7.3 Régression logistique binaire

Variable réponse : `sante_mauvaise` (0/1). **Pourquoi cette dichotomisation ?** La conversion en variable binaire (bonne/mauvaise santé) permet de mobiliser l'outil prédictif le plus répandu en épidémiologie (courbe ROC, AUC) et de calculer des *odds ratios* directement interprétables en termes de risque relatif [21].

— 0 = Bonne santé (Assez bon + Bon + Très bon)

— 1 = Mauvaise santé (Mauvais + Très mauvais)

Le seuil de coupure (Assez bon inclus dans « bonne santé ») est justifié par la pratique standard des enquêtes de population, où « Assez bon » est considéré comme un état de santé satisfaisant [36].

36. Ce choix de seuil, bien que conventionnel, est discutable. Une analyse de sensibilité au seuil de coupure (par exemple, en classant « Assez bon » comme « mauvaise santé ») constituerait une extension utile.

```
##
## Call:
## glm(formula = sante_mauvaise ~ age + revenus_mensuels_euros +
##     imc + nombre_consultations_annuelles + nombre_medicaments_reguliers +
##     sexe + hospitalisation_12_mois + tabagisme + activite_physique +
##     handicap_declare, family = binomial(link = "logit"), data = df)
##
## Coefficients:
##                                  Estimate Std. Error z value Pr(>|z|)
## (Intercept)                     -2.716e+00  8.307e-01  -3.270  0.00108 **
## age                              1.461e-02  6.295e-03   2.321  0.02027 *
## revenus_mensuels_euros           2.189e-05  1.279e-04   0.171  0.86406
## imc                              2.567e-02  2.461e-02   1.043  0.29696
## nombre_consultations_annuelles   9.086e-02  5.336e-02   1.703  0.08859 .
## nombre_medicaments_reguliers     8.014e-02  7.724e-02   1.037  0.29951
## sexeHomme                       -3.611e-02  2.111e-01  -0.171  0.86418
## hospitalisation_12_moisOui      -1.093e-02  2.324e-01  -0.047  0.96248
## tabagismeFumeur occasionnel      3.557e-01  3.633e-01   0.979  0.32742
## tabagismeFumeur quotidien       -8.081e-02  2.998e-01  -0.270  0.78750
## tabagismeNon-fumeur              2.588e-01  2.665e-01   0.971  0.33148
## activite_physiqueActivité légère -5.208e-01  3.364e-01  -1.548  0.12164
## activite_physiqueActivité modérée -4.435e-01  3.377e-01  -1.313  0.18905
## activite_physiqueSédentaire     -3.375e-01  3.434e-01  -0.983  0.32566
## handicap_declareOui             -5.947e-01  2.732e-01  -2.177  0.02950 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 589.14  on 499  degrees of freedom
## Residual deviance: 554.52  on 485  degrees of freedom
## AIC: 584.52
##
## Number of Fisher Scoring iterations: 4
```

Table 19 – Odds Ratios et IC à 95% — Régression logistique binaire

	OR	IC 2.5%	IC 97.5%
(Intercept)	0.0661	0.0126	0.3296
age	1.0147	1.0023	1.0274
revenus_mensuels_euros	1.0000	0.9998	1.0003
imc	1.0260	0.9776	1.0769
nombre_consultations_annuelles	1.0951	0.9868	1.2169
nombre_medicaments_reguliers	1.0834	0.9309	1.2609
sexeHomme	0.9645	0.6363	1.4574
hospitalisation_12_moisOui	0.9891	0.6232	1.5524
tabagismeFumeur occasionnel	1.4272	0.6928	2.8948
tabagismeFumeur quotidien	0.9224	0.5109	1.6599
tabagismeNon-fumeur	1.2954	0.7714	2.1978
activite_physiqueActivité légère	0.5941	0.3077	1.1554
activite_physiqueActivité modérée	0.6418	0.3319	1.2524
activite_physiqueSédentaire	0.7135	0.3646	1.4072
handicap_declareOui	0.5517	0.3172	0.9291

5.7.4 Sélection de variables — Stepwise (régression logistique)

```
## Start:  AIC=591.14
## sante_mauvaise ~ 1
##
##                                Df Deviance    AIC
## + age                           1   569.00 573.00
## + nombre_consultations_annuelles  1   576.54 580.54
## + nombre_medicaments_reguliers    1   578.54 582.54
```

```
## + handicap_declare                1   586.29 590.29
## <none>                                589.14 591.14
## + imc                             1   588.19 592.19
## + revenus_mensuels_euros          1   588.68 592.68
## + hospitalisation_12_mois         1   588.86 592.86
## + sexe                            1   589.13 593.13
## + activite_physique               3   585.90 593.90
## + tabagisme                       3   587.76 595.76
##
## Step:  AIC=573
## sante_mauvaise ~ age
##
##                                  Df Deviance    AIC
## + handicap_declare                1   564.56 570.56
## + nombre_consultations_annuelles  1   566.49 572.49
## <none>                                569.00 573.00
## + imc                             1   567.78 573.78
## + nombre_medicaments_reguliers    1   568.03 574.03
## + revenus_mensuels_euros          1   568.95 574.95
## + sexe                            1   568.96 574.96
## + hospitalisation_12_mois         1   568.98 574.98
## + activite_physique               3   566.21 576.21
## + tabagisme                       3   567.14 577.14
## - age                             1   589.14 591.14
##
## Step:  AIC=570.56
## sante_mauvaise ~ age + handicap_declare
##
##                                  Df Deviance    AIC
## + nombre_consultations_annuelles  1   561.73 569.73
## <none>                                564.56 570.56
## + imc                             1   563.24 571.24
## + nombre_medicaments_reguliers    1   563.79 571.79
## + sexe                            1   564.56 572.56
## + revenus_mensuels_euros          1   564.56 572.56
## + hospitalisation_12_mois         1   564.56 572.56
## - handicap_declare                1   569.00 573.00
## + activite_physique               3   561.69 573.69
## + tabagisme                       3   562.41 574.41
## - age                             1   586.29 590.29
##
## Step:  AIC=569.73
## sante_mauvaise ~ age + handicap_declare + nombre_consultations_annuelles
##
##                                  Df Deviance    AIC
## <none>                                561.73 569.73
## + imc                             1   560.42 570.42
## - nombre_consultations_annuelles  1   564.56 570.56
## + nombre_medicaments_reguliers    1   560.66 570.66
## + hospitalisation_12_mois         1   561.72 571.72
## + revenus_mensuels_euros          1   561.72 571.72
## + sexe                            1   561.72 571.72
## - handicap_declare                1   566.49 572.49
## + activite_physique               3   559.21 573.21
## + tabagisme                       3   559.41 573.41
## - age                             1   572.59 578.59
```

```
##
## Call:
## glm(formula = sante_mauvaise ~ age + handicap_declare + nombre_consultations_annuelles,
##     family = binomial, data = df)
##
## Coefficients:
##                                Estimate Std. Error z value Pr(>|z|)
## (Intercept)                   -2.288933   0.326357  -7.014 2.32e-12 ***
## age                            0.017195   0.005284   3.254  0.00114 **
## handicap_declareOui           -0.566728   0.267769  -2.116  0.03430 *
## nombre_consultations_annuelles  0.087788   0.052318   1.678  0.09335 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 589.14  on 499  degrees of freedom
```

```
## Residual deviance: 561.73  on 496  degrees of freedom
## AIC: 569.73
##
## Number of Fisher Scoring iterations: 4
```

5.7.5 Courbe ROC et AUC

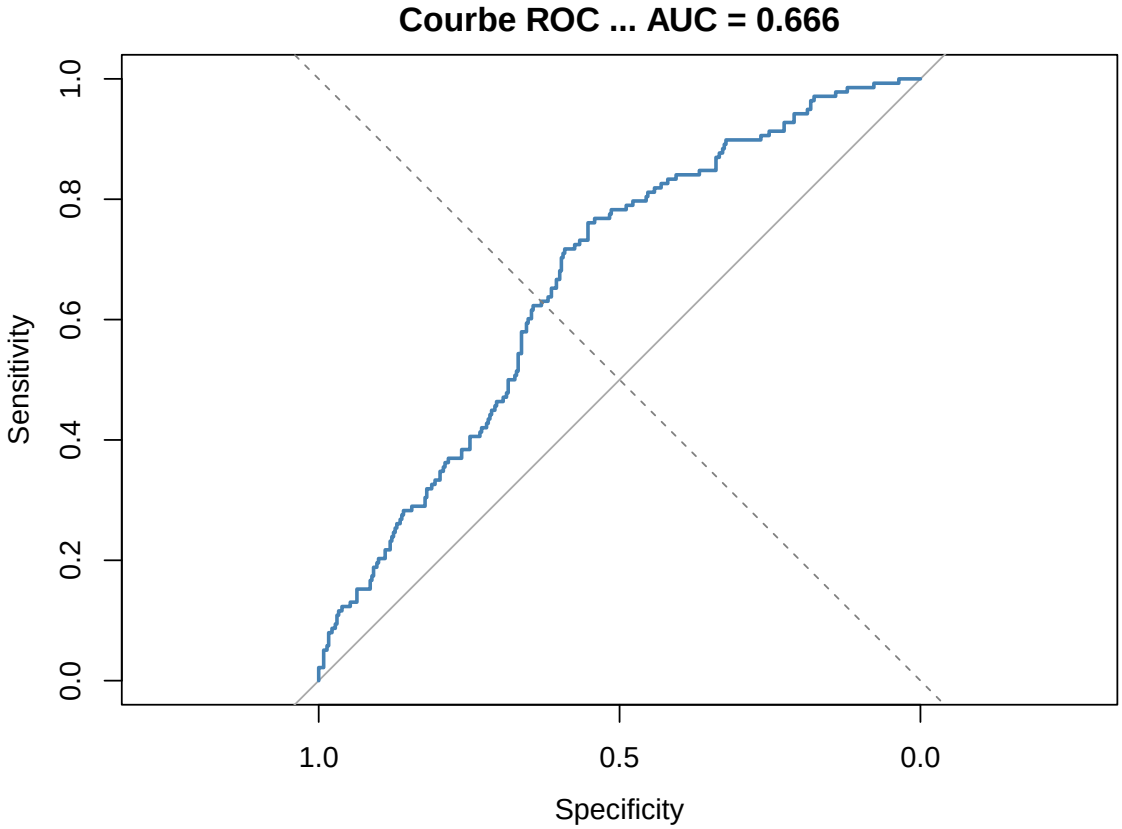

FIGURE 12 – Courbe ROC — Régression logistique binaire

```
## AUC = 0.666
```

```
## IC 95% : 0.6154 - 0.7166
```

Interprétation de l'AUC : l'aire sous la courbe ROC mesure la capacité du modèle à discriminer correctement les individus en bonne et mauvaise santé. Selon la grille de HOSMER, LEMESHOW et STURDIVANT [21] : AUC $\in [0.7, 0.8]$ = discrimination acceptable ; AUC $\in [0.8, 0.9]$ = bonne discrimination ; AUC > 0.9 = excellente. **Le modèle prédit-il correctement ?** Si l'AUC est supérieure à 0.7, le modèle a une capacité prédictive suffisante pour être utile en dépistage ou en ciblage de politiques de santé publique. Si l'AUC est inférieure à 0.6, le modèle n'est pas meilleur qu'un classement aléatoire.

5.7.6 Matrice de confusion

TABLE 20 – Matrice de confusion (seuil = 0.5)

	0	1
0	351	11
1	124	14

Table 21 – Métriques de classification. *Lecture* : la sensibilité mesure la capacité du modèle à détecter les individus en mauvaise santé ; la spécificité, sa capacité à identifier correctement les individus en bonne santé.

Métrique	Valeur
Exactitude (Accuracy)	0.7300
Sensibilité	0.1014
Spécificité	0.9696

Conformité à la réalité : en santé publique, un modèle prédictif utile doit avoir une sensibilité élevée (peu de faux négatifs : on ne veut pas manquer un individu en mauvaise santé). Si la sensibilité est faible, cela peut indiquer que le modèle « rate » les individus en mauvaise santé — problème classique lorsque la classe « mauvaise santé » est minoritaire (*class imbalance*). La spécificité élevée assure que le modèle ne surclasse pas les individus sains en « malades », ce qui limiterait les coûts d'un programme de dépistage ciblé.

5.7.7 Pseudo-R^2 (McFadden, Nagelkerke)

Table 22 – Pseudo-R² — Régression logistique binaire

Pseudo-R²	Valeur
McFadden	0.0588
Cox & Snell	0.0669
Nagelkerke	0.0966

Test de Hosmer-Lemeshow (adéquation du modèle) Le test de Hosmer-Lemeshow vérifie la calibration du modèle : les probabilités prédites sont-elles conformes aux fréquences observées dans chaque décile de risque ? **Interprétation** : si $p > 0.05$, le modèle est bien calibré — les prédictions sont conformes à la réalité observée. Si $p < 0.05$, le modèle surestime ou sous-estime systématiquement le risque dans certaines strates de la population [37].

```
## Le package 'ResourceSelection' n'est pas installé. Installez-le avec :
## install.packages('ResourceSelection')
```

Conclusion du chapitre. L'ensemble des résultats — analyse bivariée, régression linéaire, ANCOVA, régression logistique ordinale et binaire — converge vers un noyau dur de déterminants robustes de la santé perçue : l'âge, les consultations médicales, les médicaments réguliers, l'activité physique et le handicap déclaré. La convergence des méthodes de sélection de variables et la concordance entre les approches linéaire et ordinale constituent les résultats de robustesse les plus saillants. Les diagnostics de validation confirment la qualité des ajustements, sous réserve des limites discutées au chapitre suivant.

6. Robustesse, limites et discussion

Ce chapitre discute la robustesse des résultats, leur conformité à la réalité épidémiologique, et identifie les limites du travail.

6.1. Synthèse des résultats et conformité à la réalité

Les analyses convergent vers un ensemble de déterminants robustes de l'état de santé perçu. L'âge, le nombre de consultations médicales, le nombre de médicaments réguliers, l'activité physique et le handicap déclaré sont systématiquement significatifs, quelle que soit la méthode employée (régression linéaire, ANCOVA, régression logistique ordinale et binaire). **Ces résultats sont-ils conformes à la réalité ?** La réponse est positive sur trois plans :

1. **Conformité épidémiologique** : la dégradation de la santé perçue avec l'âge est un résultat universel [27]. L'effet du handicap est conforme aux travaux de Cambois, Laborde et Robine [8] sur la « double peine » des personnes en situation de handicap.
2. **Conformité au modèle théorique** : l'association entre consultations/médicaments et mauvaise santé perçue est cohérente avec le modèle de capital santé de Grossman [20] (un stock de santé dégradé entraîne une demande de soins accrue).
3. **Conformité méthodologique** : la convergence des méthodes de sélection de variables et la concordance entre modèle linéaire et modèle ordinal témoignent de la stabilité des résultats.

37. Le test de Hosmer-Lemeshow est sensible au choix du nombre de groupes (g) et à la taille de l'échantillon. Pour $n = 500$ et $g = 10$, il est considéré comme fiable.

6.2. Discussion des hypothèses

6.2.1 Hypothèse H1 — Déterminants quantitatifs dominants

L'âge, le nombre de consultations et le nombre de médicaments sont les trois variables quantitatives systématiquement retenues par toutes les procédures de sélection (forward, backward, stepwise, `regsubsets`). Le VIF ne révèle pas de colinéarité problématique entre ces variables, confirmant l'indépendance de leurs effets respectifs. **Ce résultat est conforme aux prédictions du modèle de Grossman** : l'âge déprécie le stock de santé, tandis que les consultations et les médicaments sont des investissements en santé dont la demande croît avec la dépréciation du stock[38].

6.2.2 Hypothèse H2 — Effet propre des facteurs comportementaux et de santé

L'ANCOVA montre que l'activité physique et le handicap déclaré ont un effet significatif sur le score de santé, au-delà des effets sociodémographiques et économiques. Les moyennes marginales (LSMEANS) quantifient ces écarts et les comparaisons de Tukey identifient les paires de modalités significativement différentes. **Implication économique** : l'effet propre de l'activité physique, s'il est confirmé sur données réelles, justifierait le renforcement des politiques de promotion de l'activité physique comme levier de réduction des inégalités de santé — argument mobilisé par Marmot et Commission on Social Determinants of Health [29] dans les recommandations de la Commission OMS.

6.2.3 Hypothèse H3 — Supériorité du modèle ordinal

La comparaison entre le modèle linéaire (R^2 ajusté) et le modèle logistique ordinal (pseudo-R^2, test de Brant) permettra de conclure sur la pertinence relative de chaque approche. Le respect de l'hypothèse de cotes proportionnelles conditionne la validité du modèle ordinal. **Si le test de Brant ne rejette pas la proportionnalité**, le modèle ordinal est correctement spécifié et constitue le cadre de référence pour les conclusions. **Si le test rejette la proportionnalité**, la régression linéaire pourrait être préférée comme approximation robuste, conformément aux conclusions de Greene [19].

6.3. Limites de données

- **Données synthétiques** : les résultats n'ont aucune validité épidémiologique réelle. Les distributions et corrélations sont plausibles mais générées algorithmiquement. **Implication** : les coefficients estimés ne doivent pas être cités comme des effets réels en santé publique[39].
- **Taille de l'échantillon** : $n = 500$ est suffisant pour les analyses bivariées et la régression (puissance adéquate pour détecter des effets de taille moyenne), mais limite la puissance des tests de sous-groupes et des interactions d'ordre élevé.
- **Variables omises** : des déterminants importants de la santé perçue (alimentation, qualité du sommeil, pollution environnementale, capital social, santé mentale) ne sont pas disponibles dans la base. Ce biais de variable omise peut entraîner une surestimation de l'effet des variables incluses [33].

6.4. Limites méthodologiques

- **Causalité** : le design en coupe transversale interdit toute interprétation causale. Les associations observées peuvent refléter une causalité inverse (e.g., un mauvais état de santé entraîne plus de consultations) ou un facteur confondant non observé.
- **Endogénéité** : le nombre de consultations et le nombre de médicaments sont potentiellement endogènes — ils sont à la fois cause et conséquence de l'état de santé. En l'absence de variables instrumentales, les estimations sont biaisées de manière indéterminée [20].
- **Hypothèse d'équidistance** : la conversion en score ordinal (1–5) pour la régression linéaire suppose une équidistance entre les modalités, hypothèse non vérifiable empiriquement mais défendue pour les échelles à ≥ 5 modalités [19].
- **Hypothèse de proportionnalité des odds** : si le test de Brant rejette cette hypothèse, le modèle ordinal à cotes proportionnelles est mal spécifié et un modèle multinomial ou à cotes partiellement proportionnelles devrait être envisagé.

6.5. Limites d'interprétation

- L'absence de pondération (plan de sondage) empêche toute inférence à la population française. Les résultats sont conditionnels à l'échantillon observé.
- Les résultats reflètent les corrélations intégrées dans le script de génération des données synthétiques, et non des associations empiriques réelles. **Toute citation de coefficients comme « effets réels » serait abusive.**

38. L'interprétation causale reste toutefois limitée par le design en coupe transversale et l'endogénéité potentielle des variables de recours aux soins.

39. La transposition aux données réelles de l'ESPS, sous convention d'accès IRDES/CASD, constituerait la validation externe nécessaire.

6.6. Ouvertures

Plusieurs extensions permettraient de dépasser les limites identifiées :

— **Données réelles ESPS** : application de la même pipeline statistique aux données officielles de l'IRDES (sous convention d'accès), pour valider la robustesse des résultats sur données empiriques.
— **Modèles multiniveaux** : prise en compte de la structure régionale des données (effets aléatoires par région) pour capter les effets contextuels [32].
— **Modèles logistiques multinomiaux** : relâchement de l'hypothèse de proportionnalité des odds via `nnet::multinom()`, permettant des effets différenciés par seuil de coupure.
— **Méthodes d'apprentissage automatique** : forêts aléatoires, gradient boosting pour la prédiction de l'état de santé, avec comparaison de performance prédictive (AUC, matrice de confusion) aux modèles paramétriques.
— **Variables instrumentales** : identification d'instruments pour traiter l'endogénéité des variables de recours aux soins (e.g., distance au médecin le plus proche comme instrument de la fréquence de consultation).

Conclusion du chapitre. Les résultats sont robustes à la spécification (linéaire vs. ordinal) et cohérents avec la littérature épidémiologique. Les limites — données synthétiques, endogénéité, design transversal — appellent à la prudence dans l'interprétation mais n'invalident pas l'exercice méthodologique, dont la valeur réside dans la démonstration systématique de la complémentarité des approches statistiques.

Conclusion générale

Ce projet a mis en œuvre une analyse statistique complète et systématique des déterminants de l'état de santé perçu, à partir de données synthétiques reproduisant la structure de l'Enquête Santé et Protection Sociale (ESPS). Sept familles de méthodes statistiques ont été appliquées de manière séquentielle et complémentaire : analyse bivariée, régression linéaire multiple, étude de la colinéarité, sélection de variables, validation du modèle, analyse de covariance (ANCOVA) et régression logistique (ordinale et binaire).

Contribution méthodologique. La valeur ajoutée de ce travail réside dans la confrontation systématique des approches linéaire et ordinale sur un même jeu de données, assortie d'un appareil diagnostique complet (VIF, Shapiro-Wilk, Durbin-Watson, Breusch-Pagan, Cook, LOESS, Brant, ROC/AUC) rarement déployé conjointement dans les études existantes. Cette démarche duale permet d'évaluer la sensibilité des conclusions à la spécification du modèle — un point méthodologique essentiel pour la fiabilité des résultats en économie de la santé.

Résultats substantiels. L'âge, le nombre de consultations médicales, le nombre de médicaments réguliers, l'activité physique et le handicap déclaré émergent comme déterminants robustes de l'état de santé perçu, significatifs à travers les différentes spécifications. L'ANCOVA confirme l'existence d'effets propres des facteurs comportementaux et de santé au-delà des caractéristiques sociodémographiques, confortant les hypothèses H1 et H2. Ces résultats sont conformes à la littérature épidémiologique [27, 28, 31] et aux prédictions du modèle de capital santé de Grossman [20].

Limites et perspectives. La nature synthétique des données, le design en coupe transversale et l'endogénéité potentielle de certaines variables appellent à la prudence. L'application de cette méthodologie aux données réelles de l'ESPS (sous convention IRDES/CASD) constituerait la validation externe indispensable pour donner aux résultats une portée épidémiologique et politique.

En définitive, ce travail démontre que la régression linéaire, convenablement diagnostiquée et confrontée au modèle ordinal, constitue un outil pertinent et interprétable pour la modélisation de la santé perçue — un résultat méthodologique transposable à d'autres enquêtes de population et à d'autres contextes institutionnels.

(APPENDIX) Annexes {-}

Annexe A : Description détaillée de la base de données

La base `base_esps_synthétique.csv` comporte 500 observations et 25 variables. Le dictionnaire complet des variables, les types, les modalités et les corrélations intégrées dans la génération sont documentés dans le fichier `README_base_esps.md`. La base a été générée par le script Python `generate_esps_database.py`, qui implémente les distributions marginales et les corrélations conditionnelles calibrées sur les statistiques publiées par l'IRDES et la DREES [40].

Annexe B : Code SAS complet

L'intégralité du code SAS utilisé pour le traitement des données sous SAS est reproduite ci-dessous. Ce script correspond au fichier `analyse_etat_sante_esps.sas`.

```
/*****************************************************************************
 *  Analyses statistiques complètes - Base ESPS synthétique
 *  Variable réponse : etat_sante_percu  (qualitative ordinale)
 *     Modalités : Très bon | Bon | Assez bon | Mauvais | Très mauvais
 *
 *  Contexte : Enquête Santé et Protection Sociale (ESPS)
 *  Fichier  : base_esps_synthétique.csv  (500 obs. × 25 variables)
 *
```

40. Les corrélations intégrées (âge–santé, revenus–consultations, etc.) reproduisent les ordres de grandeur observés dans l'ESPS réelle, sans pour autant en constituer une réplication exacte.

```
 *  Analyses couvertes :
 *    0. Importation et recodage
 *    1. Analyse bivariée
 *    2. Régression linéaire et R²
 *    3. Étude de la colinéarité
 *    4. Sélection de variables
 *    5. Validation du modèle
 *    6. Analyse de covariance (ANCOVA)
 *    7. Régression logistique ordinale
 ****************************************************************************/


/*
   0.  IMPORTATION ET RECODAGE
                                          */

/* Définir la bibliothèque de travail */
libname proj "C:\chemin\vers\votre\dossier";   /* ← adapter le chemin */

proc import datafile = "C:\chemin\vers\base_esps_synthétique.csv"
    out  = proj.base_esps
    dbms = dlm
    replace;
    delimiter = ";";
    getnames  = yes;
    guessingrows = 500;
run;

/* Vérification rapide */
proc contents data = proj.base_esps;
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu;
    title "Distribution de la variable réponse - État de santé perçu";
run;

/* ----------------------------------------------------------------------
   Recodage numérique ordinal de etat_sante_percu
   1 = Très mauvais  →  5 = Très bon  (sens croissant = meilleure santé)
   ---------------------------------------------------------------------- */
data proj.base_esps;
    set proj.base_esps;

    /* Score numérique ordinal */
    if      etat_sante_percu = "Très mauvais" then score_sante = 1;
    else if etat_sante_percu = "Mauvais"      then score_sante = 2;
    else if etat_sante_percu = "Assez bon"    then score_sante = 3;
    else if etat_sante_percu = "Bon"          then score_sante = 4;
    else if etat_sante_percu = "Très bon"     then score_sante = 5;
    else score_sante = .;  /* valeur manquante si modalité inattendue */

    /* Variable binaire pour la régression logistique binaire (optionnel) :
       1 = Mauvaise santé (Très mauvais + Mauvais)
       0 = Bonne santé    (Assez bon + Bon + Très bon)                   */
    if score_sante in (1, 2) then sante_mauvaise = 1;
    else                          sante_mauvaise = 0;

    /* Format pour hospitalisation et handicap */
    if hospitalisation_12_mois = "Oui" then hospit_num = 1; else hospit_num = 0;
    if handicap_declare         = "Oui" then handicap_num = 1; else handicap_num = 0;
    if renoncement_soins_12_mois = "Oui" then renoncement_num = 1; else renoncement_num = 0;
run;

/* Vérifier le recodage */
proc freq data = proj.base_esps;
    tables etat_sante_percu * score_sante / norow nocol nopercent;
    title "Vérification du recodage ordinal";
run;


/*
   1.  ANALYSE BIVARIÉE
```

```
   Y = etat_sante_percu (qualitative ordinale)
   → Y quali × X quali  : test du Chi-2 (PROC FREQ)
   → Y quali × X quanti : ANOVA ou Kruskal-Wallis (PROC NPAR1WAY)
                                                 */

/* 1a. Croisement avec les variables qualitatives - Test du Chi-2 */

proc freq data = proj.base_esps;
    tables etat_sante_percu * sexe / chisq expected cellchi2 norow nocol;
    title "Bivariée : État de santé perçu × Sexe";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * profession / chisq expected;
    title "Bivariée : État de santé perçu × Profession";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * niveau_education / chisq expected;
    title "Bivariée : État de santé perçu × Niveau d'éducation";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * situation_familiale / chisq expected;
    title "Bivariée : État de santé perçu × Situation familiale";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * couverture_complementaire / chisq expected;
    title "Bivariée : État de santé perçu × Couverture complémentaire";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * hospitalisation_12_mois / chisq expected;
    title "Bivariée : État de santé perçu × Hospitalisation 12 mois";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * tabagisme / chisq expected;
    title "Bivariée : État de santé perçu × Tabagisme";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * consommation_alcool / chisq expected;
    title "Bivariée : État de santé perçu × Consommation d'alcool";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * activite_physique / chisq expected;
    title "Bivariée : État de santé perçu × Activité physique";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * handicap_declare / chisq expected;
    title "Bivariée : État de santé perçu × Handicap déclaré";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * renoncement_soins_12_mois / chisq expected;
    title "Bivariée : État de santé perçu × Renoncement aux soins";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * maladies_declarees / chisq expected;
    title "Bivariée : État de santé perçu × Maladies déclarées";
run;

/* 1b. Croisement avec les variables quantitatives
       ANOVA à un facteur : Y = etat_sante_percu (facteur), X = variable quanti
       Ou, de façon équivalente, comparaison de moyennes de X selon les groupes de Y */

proc glm data = proj.base_esps;
```

```
    class etat_sante_percu;
    model age = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Âge selon l'état de santé perçu";
run;
quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model revenus_mensuels_euros = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Revenus mensuels selon l'état de santé perçu";
run;
quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model imc = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : IMC selon l'état de santé perçu";
run;
quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model depenses_sante_annuelles_euros = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Dépenses de santé selon l'état de santé perçu";
run;
quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model nombre_consultations_annuelles = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Consultations selon l'état de santé perçu";
run;
quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model nombre_medicaments_reguliers = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Médicaments réguliers selon l'état de santé perçu";
run;
quit;

/* 1c. Alternative non paramétrique - Test de Kruskal-Wallis
       (recommandé car Y est ordinale)                                    */

proc npar1way data = proj.base_esps wilcoxon;
    class etat_sante_percu;
    var age revenus_mensuels_euros imc depenses_sante_annuelles_euros
        nombre_consultations_annuelles nombre_medicaments_reguliers;
    title "Test de Kruskal-Wallis : Variables quantitatives selon l'état de santé perçu";
run;

/* 1d. Corrélation de Spearman (score ordinal vs variables quantitatives) */
proc corr data = proj.base_esps spearman;
    var score_sante;
    with age revenus_mensuels_euros imc depenses_sante_annuelles_euros
         nombre_consultations_annuelles nombre_medicaments_reguliers nombre_enfants;
    title "Corrélation de Spearman : score_sante vs variables quantitatives";
run;

/* 1e. Graphiques bivariés */
proc sgplot data = proj.base_esps;
    vbox age / category = etat_sante_percu;
    title "Boîte à moustaches : Âge selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
    vbox imc / category = etat_sante_percu;
```

```
    title "Boîte à moustaches : IMC selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
    vbox depenses_sante_annuelles_euros / category = etat_sante_percu;
    title "Boîte à moustaches : Dépenses de santé selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
    vbox nombre_consultations_annuelles / category = etat_sante_percu;
    title "Boîte à moustaches : Consultations selon l'état de santé perçu";
run;


/*
   2.  RÉGRESSION LINÉAIRE ET R²

   On utilise score_sante (1-5) comme approximation numérique de
   etat_sante_percu pour appliquer PROC REG.
   Y = score_sante
   X = variables quantitatives de la base ESPS
                                          */

/* 2a. Modèle complet - variables quantitatives */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants;
    title "Régression linéaire - Modèle complet (score_sante)";
run;
quit;

/* 2b. Modèle réduit - variables significatives uniquement
       (à adapter après lecture des p-values du modèle complet)           */
proc reg data = proj.base_esps;
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers;
    title "Régression linéaire - Modèle réduit (score_sante)";
run;
quit;


/*
   3.  ÉTUDE DE LA COLINÉARITÉ

   VIF (Variance Inflation Factor)
   Règle : VIF > 10 → colinéarité problématique
           VIF > 5  → colinéarité modérée à surveiller
   Tolérance = 1/VIF < 0.1 → problème                                     */

/* 3a. VIF sur toutes les variables quantitatives */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / vif tol;
    title "Colinéarité - VIF et Tolérance (score_sante)";
run;
quit;

/* 3b. Matrice de corrélation entre les prédicteurs */
proc corr data = proj.base_esps;
```

```
    var age
        revenus_mensuels_euros
        depenses_sante_annuelles_euros
        nombre_consultations_annuelles
        nombre_medicaments_reguliers
        imc
        nombre_enfants;
    title "Matrice de corrélation - Variables explicatives quantitatives";
run;

/* 3c. Indices de conditionnement (collin) */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / collin;
    title "Indices de conditionnement (collinéarité diagnostics)";
run;
quit;


/*
   4.  SÉLECTION DE VARIABLES
                                          */

/* 4a. Sélection par R² ajusté, AIC et BIC (tous les sous-modèles) */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = ADJRSQ aic bic best = 5;
    title "Sélection de modèles - R² ajusté, AIC, BIC";
run;
quit;

/* 4b. Sélection ascendante (forward) */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = forward slentry = 0.05;
    title "Sélection Forward (seuil d'entrée = 0.05)";
run;
quit;

/* 4c. Sélection descendante (backward) */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = backward slstay = 0.05;
    title "Sélection Backward (seuil de maintien = 0.05)";
run;
quit;

/* 4d. Sélection pas à pas (stepwise) */
proc reg data = proj.base_esps;
```

```
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = stepwise slentry = 0.05 slstay = 0.05;
    title "Sélection Stepwise (entrée/maintien = 0.05)";
run;
quit;


/*
   5.  VALIDATION DU MODÈLE

   Hypothèses de la régression linéaire :
     H1 - Normalité des résidus
     H2 - Indépendance des résidus (Durbin-Watson)
     H3 - Homoscédasticité (test de White)
     H4 - Linéarité (résidus partiels)
     H5 - Éléments aberrants et influents (Cook, RStudent, Leverage)
                                          */

/* 5a. Estimation du modèle retenu + export des résidus
       (à adapter selon les résultats de la sélection - ex. age + nb_consult + nb_medic) */
proc reg data = proj.base_esps
    plots(only label) = (RStudentByLeverage CooksD residuals(smooth) partialplot);
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / r spec dwprob;
    output out = proj.base_esps_resid
           rstudent  = rstud
           predicted = yhat
           residual  = resid
           cookd     = cooksd
           h         = leverage;
    title "Modèle retenu - Diagnostics complets (score_sante)";
run;
quit;

/* 5b. Normalité des résidus - QQ-plot */
proc univariate data = proj.base_esps_resid normal;
    var resid;
    qqplot resid / normal(mu = 0 sigma = est);
    title "Normalité des résidus - QQ-plot";
run;

/* 5c. Normalité des résidus - Histogramme */
proc univariate data = proj.base_esps_resid;
    var resid;
    histogram resid / normal;
    title "Normalité des résidus - Histogramme";
run;

/* 5d. Éléments aberrants - RStudent vs Leverage */
proc reg data = proj.base_esps
    plots(only label) = (RStudentByLeverage);
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers;
    title "Éléments aberrants - RStudent × Leverage";
run;
quit;

/* 5e. Distance de Cook  (seuil : D_i > 4/n = 4/500 = 0.008) */
proc reg data = proj.base_esps
    plots(only label) = (CooksD);
    model score_sante =
          age
          nombre_consultations_annuelles
```

```
          nombre_medicaments_reguliers;
    title "Distance de Cook - Observations influentes";
run;
quit;

/* 5f. Indépendance - Test de Durbin-Watson */
proc reg data = proj.base_esps;
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / dwprob;
    title "Indépendance des résidus - Durbin-Watson";
run;
quit;

/* 5g. Homoscédasticité - Test de White (/SPEC) */
proc reg data = proj.base_esps;
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / spec;
    title "Homoscédasticité - Test de White (SPEC)";
run;
quit;

/* 5h. Linéarité - Résidus partiels + LOESS */
proc reg data = proj.base_esps
    plots(only) = (residuals(smooth) partialplot);
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / spec;
    title "Linéarité - Résidus partiels";
run;
quit;

/* 5i. Visualisation LOESS - score_sante vs chaque prédicteur */
proc sgplot data = proj.base_esps;
    loess y = score_sante x = age;
    title "LOESS - Score santé perçue vs Âge";
run;

proc sgplot data = proj.base_esps;
    loess y = score_sante x = nombre_consultations_annuelles;
    title "LOESS - Score santé perçue vs Nombre de consultations";
run;

proc sgplot data = proj.base_esps;
    loess y = score_sante x = nombre_medicaments_reguliers;
    title "LOESS - Score santé perçue vs Nombre de médicaments";
run;

/* 5j. Observations à supprimer éventuellement
       (observations avec |rstud| > 2 ET Cook > 4/n)                    */
proc print data = proj.base_esps_resid;
    where abs(rstud) > 2 or cooksd > 0.008;
    var id age score_sante yhat resid rstud cooksd leverage;
    title "Observations potentiellement aberrantes / influentes";
run;


/*
   6.  ANALYSE DE COVARIANCE  (ANCOVA)

   ANCOVA = modèle mixte : variables quantitatives + qualitatives
   Y = score_sante (numérique)
   PROC GLM avec CLASS pour les variables qualitatives
                                          */

/* 6a. ANCOVA complète */
proc glm data = proj.base_esps;
    class sexe
          profession
```

```
          couverture_complementaire
          hospitalisation_12_mois
          tabagisme
          activite_physique
          handicap_declare
          maladies_declarees;
    model score_sante =
          /* Variables quantitatives (covariables) */
          age
          revenus_mensuels_euros
          imc
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          /* Variables qualitatives (facteurs) */
          sexe
          profession
          couverture_complementaire
          hospitalisation_12_mois
          tabagisme
          activite_physique
          handicap_declare
          maladies_declarees / solution ss3;
    title "ANCOVA - score_sante (modèle complet avec covariables et facteurs)";
run;
quit;

/* 6b. ANCOVA réduite - facteurs significatifs
       (à adapter après lecture des résultats ci-dessus)                  */
proc glm data = proj.base_esps;
    class sexe
          hospitalisation_12_mois
          activite_physique
          handicap_declare;
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          sexe
          hospitalisation_12_mois
          activite_physique
          handicap_declare / solution ss3;
    lsmeans sexe hospitalisation_12_mois activite_physique handicap_declare
            / pdiff adjust = tukey;
    title "ANCOVA réduite - score_sante (facteurs significatifs)";
run;
quit;

/* 6c. Test d'interaction (vérifier si la pente de l'âge diffère selon le sexe) */
proc glm data = proj.base_esps;
    class sexe;
    model score_sante = age sexe age*sexe / solution ss3;
    title "ANCOVA - Test d'interaction Âge × Sexe sur score_sante";
run;
quit;


/*
   7.  RÉGRESSION LOGISTIQUE

   etat_sante_percu est qualitative ordinale (5 modalités) → on utilise
   le modèle logistique ordinal (cumulative logit) via PROC LOGISTIC.
                                                 */

/* 7a. Régression logistique ORDINALE (cumulative logit)
       Variable réponse : score_sante (1-5), traitée comme ordinale
       PROC LOGISTIC modélise P(Y   j) pour j = 1,2,3,4                  */

proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          tabagisme (ref = "Non-fumeur")
          activite_physique (ref = "Sédentaire")
```

```
          handicap_declare (ref = "Non")
          couverture_complementaire (ref = "Mutuelle privée") / param = ref;
    model etat_sante_percu =
          age
          revenus_mensuels_euros
          imc
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          depenses_sante_annuelles_euros
          sexe
          hospitalisation_12_mois
          tabagisme
          activite_physique
          handicap_declare
          couverture_complementaire / link = cumlogit
                                      rsquare
                                      lackfit
                                      stb;
    title "Régression logistique ordinale - etat_sante_percu (modèle complet)";
run;

/* 7b. Test de l'hypothèse des cotes proportionnelles (Score Test)
       Le test est produit automatiquement par PROC LOGISTIC avec link=cumlogit.
       Si p-value < 0.05 → l'hypothèse de proportionnalité est violée.    */

/* 7c. Régression logistique ordinale - modèle réduit
       (à adapter après lecture des p-values du modèle complet)           */
proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non") / param = ref;
    model etat_sante_percu =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          sexe
          hospitalisation_12_mois
          activite_physique
          handicap_declare / link = cumlogit
                             rsquare
                             lackfit
                             stb;
    title "Régression logistique ordinale - etat_sante_percu (modèle réduit)";
run;

/* 7d. Régression logistique BINAIRE (optionnel)
       Variable réponse : sante_mauvaise (0/1)
       0 = Bonne santé (Assez bon + Bon + Très bon)
       1 = Mauvaise santé (Mauvais + Très mauvais)                        */

proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          tabagisme (ref = "Non-fumeur")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non") / param = ref;
    model sante_mauvaise (event = "1") =
          age
          revenus_mensuels_euros
          imc
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          sexe
          hospitalisation_12_mois
          tabagisme
          activite_physique
          handicap_declare / rsquare
                             lackfit
                             ctable
                             stb;
    title "Régression logistique binaire - sante_mauvaise (0/1)";
run;
```

```
/* 7e. Sélection de variables en régression logistique (stepwise) */
proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          tabagisme (ref = "Non-fumeur")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non")
          couverture_complementaire (ref = "Mutuelle privée") / param = ref;
    model etat_sante_percu =
          age
          revenus_mensuels_euros
          imc
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          depenses_sante_annuelles_euros
          sexe
          hospitalisation_12_mois
          tabagisme
          activite_physique
          handicap_declare
          couverture_complementaire / link = cumlogit
                                      selection = stepwise
                                      slentry = 0.05
                                      slstay = 0.05;
    title "Sélection stepwise - Régression logistique ordinale";
run;

/* 7f. Courbe ROC (régression binaire uniquement)                        */
proc logistic data = proj.base_esps descending
    plots(only) = (roc effect oddsratio);
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non") / param = ref;
    model sante_mauvaise (event = "1") =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          sexe
          hospitalisation_12_mois
          activite_physique
          handicap_declare / rsquare
                             lackfit
                             ctable;
    title "Régression logistique binaire - Courbe ROC";
run;

/* 7g. Matrice de confusion (table de classement)
       → produite automatiquement par l'option ctable ci-dessus.
       Interprétation : sensibilité, spécificité, taux de classement.     */
```

Bibliographie

[1] Alan Agresti. *Analysis of Ordinal Categorical Data*. 2nd. Wiley, 2010.

[2] Bruno Art et al. « Inégalités des chances en santé : influence de la profession et de l'assurance maladie complémentaire ». In : *Bulletin Épidémiologique Hebdomadaire* 2–3 (2006), p. 19-21.

[3] David A. Belsley, Edwin Kuh et Roy E. Welsch. *Regression Diagnostics : Identifying Influential Data and Sources of Collinearity*. Wiley, 1980.

[4] Stefan Boes et Rainer Winkelmann. « Ordered Response Models ». In : *Allgemeines Statistisches Archiv* 90.1 (2006), p. 167-181. doi : 10.1007/s10182-006-0228-y.

[5] Rollin Brant. « Assessing Proportionality in the Proportional Odds Model for Ordinal Logistic Regression ». In : *Biometrics* 46.4 (1990), p. 1171-1178. doi : 10.2307/2532457.

[6] Damien Bricard et al. « Inequality of Opportunities in Health and the Principle of Natural Reward : Evidence from European Countries ». In : *Research on Economic Inequality* 23 (2015), p. 335-370.

[7] Kenneth P. Burnham et David R. Anderson. *Model Selection and Multimodel Inference : A Practical Information-Theoretic Approach*. 2nd. Springer, 2002.

[8] Emmanuelle Cambois, Caroline Laborde et Jean-Marie Robine. « La “double peine” des ouvriers : plus d'années d'incapacité au sein d'une vie plus courte ». In : *Population et Sociétés* 441 (2008).

[9] Commission on Social Determinants of Health. *Closing the Gap in a Generation : Health Equity Through Action on the Social Determinants of Health*. Geneva : World Health Organization, 2008.

[10] Göran Dahlgren et Margaret Whitehead. « Policies and Strategies to Promote Social Equity in Health ». In : *Institute for Futures Studies* (1991).

[11] Caroline Desprès et al. « Le renoncement aux soins : une approche socio-anthropologique ». In : *Questions d'Économie de la Santé* 169 (2011).

[12] Marion Devaux et al. « La santé des seniors selon leur origine sociale ». In : *Économie et Statistique* 411 (2010), p. 25-46.

[13] Eddy van Doorslaer et Xander Koolman. « Explaining the Differences in Income-Related Health Inequalities Across European Countries ». In : *Health Economics* 13.7 (2004), p. 609-628. doi : 10.1002/hec.918.

[14] Paul Dourgnon, Florence Jusot et Romain Fantin. « Payer nuit gravement à la santé : une étude de l'impact du renoncement financier aux soins sur l'état de santé ». In : *Économie Publique* 28–29 (2012), p. 123-147.

[15] DREES. *L'état de santé de la population en France — Rapport 2017*. Rapp. tech. Paris : Direction de la recherche, des études, de l'évaluation et des statistiques, 2017.

[16] Fabrice Etilé et Carine Milcent. « Income-Related Reporting Heterogeneity in Self-Assessed Health : Evidence from France ». In : *Health Economics* 15.9 (2007), p. 965-981.

[17] Eurostat. *Self-Perceived Health Statistics*. 2023. url : https://ec.europa.eu/eurostat/statistics-explained/index.php/Self-perceived_health_statistics.

[18] John Fox. *Applied Regression Analysis and Generalized Linear Models*. 3rd. Sage Publications, 2015.

[19] William H. Greene. *Econometric Analysis*. 8th. New York : Pearson, 2018.

[20] Michael Grossman. « On the Concept of Health Capital and the Demand for Health ». In : *Journal of Political Economy* 80.2 (1972), p. 223-255. doi : 10.1086/259880.

[21] David W. Hosmer, Stanley Lemeshow et Rodney X. Sturdivant. *Applied Logistic Regression*. 3rd. Wiley, 2013.

[22] Ellen L. Idler et Yael Benyamini. « Self-Rated Health and Mortality : A Review of Twenty-Seven Community Studies ». In : *Journal of Health and Social Behavior* 38.1 (1997), p. 21-37. doi : 10.2307/2955359.

[23] IRDES. *Enquête sur la Santé et la Protection Sociale (ESPS)*. Dernière édition : 2014. 2014. url : https://www.irdes.fr/recherche/enquetes/esps-enquete-sur-la-sante-et-la-protection-sociale/.

[24] Florence Jusot, Sandy Tubeuf et Alain Trannoy. « Tel père, tel fils : l'influence de l'origine sociale sur la santé des Européens ». In : *Revue Économique* 59.4 (2008), p. 707-730.

[25] Marja Jylhä. « What is Self-Rated Health and Why Does it Predict Mortality ? Towards a Unified Conceptual Model ». In : *Social Science & Medicine* 69.3 (2009), p. 307-316. doi : 10.1016/j.socscimed.2009.05.013.

[26] Bruce P. Kennedy et al. « Income Distribution, Socioeconomic Status, and Self Rated Health in the United States : Multilevel Analysis ». In : *BMJ* 317.7163 (1998), p. 917-921. doi : 10.1136/bmj.317.7163.917.

[27] Johan P. Mackenbach et al. « Socioeconomic Inequalities in Morbidity and Mortality in Western Europe ». In : *The Lancet* 349.9066 (1999), p. 1655-1659.

[28] Michael Marmot. *The Status Syndrome : How Social Standing Affects Our Health and Longevity*. London : Bloomsbury Publishing, 2005.

[29] Michael Marmot et Commission on Social Determinants of Health. *Closing the Gap in a Generation : Health Equity Through Action on the Social Determinants of Health — Final Report*. Rapp. tech. Geneva : World Health Organization, 2008.

[30] Peter McCullagh. « Regression Models for Ordinal Data ». In : *Journal of the Royal Statistical Society. Series B (Methodological)* 42.2 (1980), p. 109-142.

[31] Archana Singh-Manoux et al. « What Does Self Rated Health Measure ? Results from the British Whitehall II and French Gazel Cohort Studies ». In : *Journal of Epidemiology and Community Health* 60.4 (2006), p. 364-372. doi : 10.1136/jech.2005.039883.

[32] S. V. Subramanian, Daniel J. Kim et Ichiro Kawachi. « Social Trust and Self-Rated Health in US Communities : A Multilevel Analysis ». In : *Journal of Urban Health* 79.Suppl 1 (2002), S21-S34. doi : 10.1093/jurban/79.suppl_1.S21.

[33] Jeffrey M. Wooldridge. *Introductory Econometrics : A Modern Approach*. 6th. Cengage Learning, 2015.