Projet de Modèles linéaires avec Statistical Analysis System

valant évaluation dans le cadre de :
Diplôme : Master Statistique pour l'évaluation et la prévision, 1ère année
Année universitaire : 2025-2026
Module d'enseignement : Modèles linéaires - Statistical Analysis System
Responsable : CHARLOTTE PAPELARD
Comptant pour : 50%

Analyse statistique de l'état de santé perçu en France : modélisation multivariée, sélection de variables et régression logistique ordinale à partir de l'Enquête Santé et Protection Sociale (ESPS)

Hervé ADJAKOSSA

Métriques

Finalisé le : 18 April 2026
Page(s) : 35
Références(s) : –
Figure(s) : –
Table(s) : –
Théorème(s) : 0

Résumé : En France, 8,2 % des adultes déclarent un état de santé « mauvais » ou « très mauvais », un chiffre qui atteint 19 % parmi les ménages du premier quintile de revenus (DREES, 2017). Ce gradient social, documenté par la Commission OMS sur les déterminants sociaux de la santé (2008), soulève une question fondamentale : quels facteurs sociodémographiques, économiques et comportementaux déterminent la perception individuelle de l'état de santé, et comment les hiérarchiser de façon robuste ? Le présent projet met en œuvre une analyse statistique complète des déterminants de l'état de santé perçu en France métropolitaine, à partir de données synthétiques reproduisant la structure de l'Enquête Santé et Protection Sociale (ESPS) de l'IRDES (500 individus, 25 variables). La variable réponse — qualitative ordinale à cinq modalités (Très mauvais, Mauvais, Assez bon, Bon, Très bon) — est analysée au moyen de sept familles de méthodes : analyse bivariée (χ^2, ANOVA, Kruskal-Wallis, Spearman), régression linéaire multiple sur le score ordinal (1–5), colinéarité (VIF, tolérance, indices de conditionnement), sélection de variables (*forward*, *backward*, *stepwise*), validation complète (Shapiro-Wilk, Durbin-Watson, test de White, Cook, LOESS), ANCOVA (facteurs qualitatifs, moyennes marginales de Tukey), régression logistique ordinale (cotes proportionnelles, test du Score) et binaire (ROC, AUC, matrice de confusion). L'âge, les consultations médicales, les médicaments réguliers, l'activité physique et le handicap déclaré émergent comme déterminants robustes, tous significatifs au seuil de 5 % à travers les différentes spécifications. Les limites — données synthétiques, hypothèse de proportionnalité des odds, absence de correction pour biais de sélection — sont rigoureusement discutées.

Mots-clés : État de santé perçu, Régression logistique ordinale, Régression linéaire multiple, ANCOVA, Sélection de variables, Enquête ESPS, Colinéarité, Déterminants sociaux de la santé

Matériel supplémentaire :
git : https://gitlab-mi.univ-reims.fr/adja0021
: ESPS (synthétique) : base_esps_synthétique.csv (500 obs., 25 variables) — IRDES

Table des matières

Introduction générale **4**
0.1 Accroche et contexte général . . . 4
0.2 Intérêt scientifique et empirique : pourquoi étudier la santé perçue par la régression linéaire ? . . . 4
0.3 Problématique générale . . . 4
0.4 Question centrale de recherche . . . 4
0.5 Objectif général et objectifs spécifiques . . . 5
0.6 Hypothèses de recherche . . . 5
0.7 Positionnement scientifique . . . 5
0.8 Stratégie de recherche et démarche méthodologique . . . 5
0.9 Annonce du plan . . . 5

1 Cadre conceptuel, théorique et analytique **6**
1.1 Cadre conceptuel : santé perçue et déterminants sociaux . . . 6
1.2 Cadre théorique : modèles explicatifs de la santé perçue . . . 6
1.3 Cadre analytique : justification des méthodes statistiques retenues . . . 6
1.3.1 Traitement de la variable réponse ordinale . . . 6
1.3.2 Stratégie de modélisation . . . 7
1.3.3 Limites structurelles du design choisi . . . 7

2 Revue de littérature **7**
2.1 Mesures subjectives de la santé : fondements et validité . . . 7
2.2 Déterminants socio-économiques de la santé perçue . . . 8
2.2.1 Effets de l'âge et du sexe . . . 8
2.2.2 Gradient social de santé . . . 8
2.2.3 Rôle de la couverture assurantielle et du renoncement aux soins . . . 8
2.3 La régression linéaire pour expliquer la santé perçue : état de l'art . . . 8
2.3.1 Fondements de l'approche linéaire . . . 8
2.3.2 Applications en France . . . 8
2.3.3 Discussion critique de l'approche linéaire . . . 8
2.4 Positionnement de la contribution . . . 8

3 Méthodologie **9**
3.1 Design de recherche : terrain et pertinence . . . 9
3.2 Corpus de données : justification des sources . . . 9
3.3 Spécification des modèles . . . 9
3.3.1 Modèle de régression linéaire multiple . . . 9
3.3.2 Modèle ANCOVA . . . 9
3.3.3 Modèle logistique ordinal (cotes proportionnelles) . . . 10
3.3.4 Modèle logistique binaire . . . 10
3.4 Procédure d'estimation et justification des tests . . . 10
3.4.1 Sélection du modèle linéaire . . . 10
3.4.2 Sélection du modèle logistique . . . 10
3.5 Stratégie de validation et diagnostics : pourquoi ces tests ? . . . 10
3.5.1 Validation du modèle linéaire . . . 10
3.5.2 Évaluation du modèle logistique . . . 11

4 Données et construction de la base empirique **11**
4.1 Sources des données . . . 11
4.1.1 Variable dépendante : état de santé perçu . . . 11
4.1.2 Variables explicatives retenues et justification . . . 11
4.1.3 Source et nature des données . . . 12
4.2 Importation et recodage sous SAS . . . 12
4.3 Statistiques descriptives . . . 12

5 Résultats **13**
5.1 Analyse bivariée . . . 13
5.1.1 Croisements Y qualitative × X qualitatives — Test du χ^2 (PROC FREQ) . . . 13
5.1.2 Croisements Y qualitative × X quantitatives — ANOVA (PROC GLM) . . . 14
5.1.3 Test de Kruskal-Wallis — Alternative non paramétrique (PROC NPAR1WAY) . . . 14
5.1.4 Corrélation de Spearman (PROC CORR) . . . 15
5.1.5 Graphiques bivariés — Boîtes à moustaches (PROC SGPLOT) . . . 15
5.2 Régression linéaire et R^2 — PROC REG . . . 15
5.2.1 Modèle complet — variables quantitatives . . . 15
5.2.2 Modèle réduit — variables significatives . . . 16
5.3 Étude de la colinéarité . . . 16
5.3.1 VIF et Tolérance . . . 16
5.3.2 Matrice de corrélation entre les prédicteurs (PROC CORR) . . . 16
5.3.3 Indices de conditionnement . . . 16
5.4 Sélection de variables . . . 17
5.4.1 Sélection par R^2 ajusté, AIC et BIC — Tous les sous-modèles . . . 17
5.4.2 Sélection ascendante (Forward) . . . 17

5.4.3 Sélection descendante (Backward) . . . 17
5.4.4 Sélection pas à pas (Stepwise) . . . 17
5.5 Validation du modèle . . . 18
5.5.1 Estimation du modèle retenu et export des résidus . . . 18
5.5.2 Normalité des résidus — QQ-plot et histogramme (PROC UNIVARIATE) . . . 18
5.5.3 Éléments aberrants — RStudent vs Leverage . . . 18
5.5.4 Distance de Cook . . . 18
5.5.5 Indépendance des résidus — Test de Durbin-Watson . . . 19
5.5.6 Homoscédasticité — Test de White (option SPEC) . . . 19
5.5.7 Linéarité — Résidus partiels et LOESS . . . 19
5.5.8 Visualisation LOESS — score_sante vs chaque prédicteur (PROC SGPLOT) . . . 19
5.5.9 Observations potentiellement aberrantes / influentes . . . 19
5.6 Analyse de covariance (ANCOVA) — PROC GLM . . . 19
5.6.1 ANCOVA complète . . . 20
5.6.2 ANCOVA réduite — facteurs significatifs . . . 20
5.6.3 Test d'interaction — Âge × Sexe . . . 20
5.7 Régression logistique — PROC LOGISTIC . . . 20
5.7.1 Régression logistique ordinale — Modèle complet . . . 20
5.7.2 Régression logistique ordinale — Modèle réduit . . . 21
5.7.3 Régression logistique binaire . . . 21
5.7.4 Sélection de variables — Stepwise (régression logistique) . . . 21
5.7.5 Courbe ROC et AUC . . . 22
5.7.6 Matrice de confusion et métriques . . . 22

6 Robustesse, limites et discussion **22**
6.1 Synthèse des résultats et conformité à la réalité . . . 22
6.2 Discussion des hypothèses . . . 22
6.2.1 Hypothèse H1 — Déterminants quantitatifs dominants . . . 22
6.2.2 Hypothèse H2 — Effet propre des facteurs comportementaux et de santé . . . 23
6.2.3 Hypothèse H3 — Supériorité du modèle ordinal . . . 23
6.3 Limites de données . . . 23
6.4 Limites méthodologiques . . . 23
6.5 Limites d'interprétation . . . 23
6.6 Ouvertures . . . 23

Conclusion générale **23**

Annexe A : Description détaillée de la base de données **24**

Annexe B : Code SAS complet **24**

Bibliographie **34**

Introduction générale

0.1. Accroche et contexte général

En 2019, 67,4 % des Français déclaraient un état de santé « bon » ou « très bon », un chiffre qui masque des disparités considérables : parmi les ménages du premier quintile de revenus, la proportion d'adultes se déclarant en « mauvaise » ou « très mauvaise » santé atteint 19 %, soit près du triple de la moyenne nationale [1]. Ce constat, loin d'être anecdotique, traduit un phénomène structurel : les inégalités sociales de santé perçue s'inscrivent au cœur du débat économique et sanitaire contemporain. L'Organisation mondiale de la santé (OMS), à travers sa Commission sur les déterminants sociaux de la santé, a établi que « les conditions dans lesquelles les individus naissent, grandissent, vivent, travaillent et vieillissent constituent les déterminants sociaux de la santé, lesquels sont principalement responsables des inégalités en santé » [2]. Ce constat appelle une quantification rigoureuse des facteurs qui façonnent la perception individuelle de l'état de santé.

La France dispose, à cet égard, d'un instrument d'observation privilégié : l'Enquête Santé et Protection Sociale (ESPS), conduite depuis 1988 par l'Institut de recherche et documentation en économie de la santé (IRDES) [3]. Cette enquête, qui articule données de santé déclarée, recours aux soins et caractéristiques socio-économiques, offre un terrain empirique particulièrement riche pour l'analyse des déterminants de l'état de santé perçu — variable centrale de notre étude.

0.2. Intérêt scientifique et empirique : pourquoi étudier la santé perçue par la régression linéaire ?

L'état de santé perçu (*self-rated health*, SRH) occupe une place singulière en épidémiologie et en économie de la santé. Idler et Benyamini [22], dans une méta-analyse pionnière portant sur vingt-sept études de cohorte, ont démontré que cette mesure subjective constitue un prédicteur indépendant de la mortalité, y compris après ajustement sur l'état de santé objectif. Jylhä [24] propose un modèle conceptuel unifié expliquant ce pouvoir prédictif : la santé perçue intégrerait simultanément des informations biologiques infracliniques, des comparaisons sociales et des représentations culturelles de la santé [4].

La régression linéaire multiple, bien que la variable réponse soit ordinale, est largement mobilisée dans la littérature pour modéliser la santé perçue. Kennedy et al. [25] utilisent la régression linéaire sur un score de santé auto-évalué pour démontrer l'effet des inégalités de revenus sur la santé perçue aux États-Unis. Subramanian, Kim et Kawachi [30] recourent à des modèles linéaires multiniveaux pour estimer l'effet contextuel du capital social sur la santé auto-déclarée. En France, Devaux et al. [13] et Etilé et Milcent [17] mobilisent la régression linéaire pour identifier l'hétérogénéité de déclaration selon le statut socio-économique. Cette approche, qui suppose l'équidistance entre les modalités ordinales, présente l'avantage de la parcimonie et de l'interprétabilité directe des coefficients — un atout essentiel pour l'aide à la décision en santé publique [5].

Notre motivation pour ce choix méthodologique est triple : (i) reproduire et discuter les résultats de la littérature dans le cadre pédagogique de l'ESPS ; (ii) confronter systématiquement la régression linéaire à la régression logistique ordinale pour évaluer la robustesse des conclusions ; (iii) mobiliser un arsenal complet de diagnostics statistiques (colinéarité, validation, sélection) rarement déployés conjointement dans les études existantes.

0.3. Problématique générale

L'enjeu de la modélisation de la santé perçue se situe à l'intersection de deux tensions. D'une part, la nature ordinale de la variable réponse interroge la légitimité de la régression linéaire : l'hypothèse d'équidistance entre « Très mauvais » et « Mauvais » est-elle soutenable ? D'autre part, la multiplicité des déterminants potentiels — biologiques, socio-économiques, comportementaux, institutionnels — engendre des effets de confusion qui requièrent une stratégie d'identification rigoureuse [6].

Comment, dès lors, modéliser et hiérarchiser les déterminants de l'état de santé perçu en France, en tenant compte de la nature ordinale de la variable réponse, des effets de confusion entre variables sociodémographiques, économiques et comportementales, et des limites inhérentes aux données d'enquête en coupe transversale ?

0.4. Question centrale de recherche

Quels sont les facteurs sociodémographiques, économiques et comportementaux qui déterminent significativement l'état de santé perçu des individus en France métropolitaine, et dans quelle mesure la régression logistique ordinale offre-t-elle une modélisation plus adéquate que la régression linéaire sur le score ordinal ?

1. Direction de la recherche, des études, de l'évaluation et des statistiques (DREES), *L'état de santé de la population en France — Rapport 2017*, Paris.

2. Commission on Social Determinants of Health [9], Commission des déterminants sociaux de la santé, Rapport final, Genève.

3. IRDES [23].

4. Ce résultat explique pourquoi les grandes enquêtes de population — EU-SILC, ESPS, SHARE — incluent systématiquement une question d'auto-évaluation de la santé.

5. La régression logistique ordinale, plus rigoureuse sur le plan théorique, sera néanmoins estimée à titre de comparaison et de robustesse.

6. L'endogénéité potentielle des variables de recours aux soins (consultations, médicaments) constitue une difficulté supplémentaire, car ces variables sont simultanément cause et conséquence de l'état de santé (Grossman [20]).

0.5. Objectif général et objectifs spécifiques

Objectif général : Identifier, hiérarchiser et quantifier les déterminants de l'état de santé perçu en France à partir de données reproduisant la structure de l'ESPS, en mobilisant un arsenal complet de méthodes statistiques sous SAS et en confrontant systématiquement les résultats à la réalité épidémiologique documentée.

Objectifs spécifiques :

1. **Caractériser les associations bivariées** entre l'état de santé perçu et les variables explicatives (qualitatives et quantitatives), en justifiant le choix de chaque test statistique par la nature des variables croisées.
2. **Construire et valider un modèle de régression linéaire multiple** sur le score ordinal via `PROC REG`, en étudiant la colinéarité (VIF, indices de conditionnement) et en sélectionnant les variables pertinentes par critères informationnels.
3. **Estimer un modèle ANCOVA** via `PROC GLM` combinant covariables quantitatives et facteurs qualitatifs, avec tests d'interaction et moyennes marginales (Tukey/LSMEANS), pour isoler l'effet propre des déterminants comportementaux.
4. **Estimer un modèle de régression logistique ordinale** via `PROC LOGISTIC` (cotes proportionnelles) et un modèle logistique binaire, évaluer leur performance prédictive (ROC, AUC, matrice de confusion) et comparer les approches.
5. **Évaluer la capacité prédictive** des modèles retenus et confronter les résultats aux connaissances empiriques existantes pour juger de la conformité à la réalité.

0.6. Hypothèses de recherche

— **H1** : L'âge, le nombre de consultations médicales et le nombre de médicaments réguliers sont les déterminants quantitatifs les plus fortement associés à l'état de santé perçu — conformément au modèle de capital santé de Grossman [20], selon lequel l'état de santé se déprécie avec l'âge et la consommation médicale reflète le stock de santé résiduel.

— **H2** : L'activité physique et le handicap déclaré exercent un effet significatif sur l'état de santé perçu, au-delà des variables sociodémographiques et économiques (effet propre mis en évidence par l'ANCOVA) — ce qui prolonge les résultats de Singh-Manoux et al. [29] sur les déterminants comportementaux de la santé perçue.

— **H3** : Le modèle logistique ordinal, respectant la nature qualitative ordinale de la variable réponse, offre un ajustement supérieur au modèle linéaire sur le score numérique — hypothèse fondée sur les travaux de McCullagh [28] et Agresti [1] qui établissent la supériorité théorique du *cumulative logit model* pour les réponses ordinales.

0.7. Positionnement scientifique

Ce travail s'inscrit au carrefour de la biostatistique, de l'économie de la santé et de l'économétrie appliquée. Il mobilise des méthodes de régression en grande dimension (sélection de variables, diagnostics de colinéarité) et de régression logistique ordinale, appliquées à des données synthétiques reproduisant la structure de l'ESPS [7]. Le positionnement est délibérément **méthodologique** : il s'agit de démontrer, sur un terrain maîtrisé, la pertinence et les limites de chaque famille de méthodes, plutôt que de produire des résultats directement transposables à la politique de santé publique.

0.8. Stratégie de recherche et démarche méthodologique

La démarche suivie est séquentielle et cumulative, articulée en trois phases :

1. **Phase exploratoire** : analyse bivariée (`PROC FREQ` pour les tests du χ^2, `PROC GLM` pour l'ANOVA, `PROC NPAR1WAY` pour le test de Kruskal-Wallis, `PROC CORR` pour la corrélation de Spearman) pour identifier les associations brutes entre l'état de santé perçu et chaque variable explicative, sans contrôle des effets confondants.
2. **Phase de modélisation** : régression linéaire multiple via `PROC REG` avec diagnostics complets (colinéarité via options VIF/TOL/COLLIN, validation des hypothèses via SPEC/DWPROB), sélection de variables par critères informationnels (sélection ADJRSQ, Forward, Backward, Stepwise), estimation ANCOVA via `PROC GLM` avec LSMEANS.
3. **Phase de confrontation et robustesse** : régression logistique ordinale et binaire via `PROC LOGISTIC` avec évaluation prédictive (courbe ROC, AUC, table de classement CTABLE), test du Score pour la proportionnalité des cotes, et discussion critique des résultats au regard de la littérature.

Le terrain d'application est la France métropolitaine, cadre géographique justifié par la disponibilité de l'ESPS et par la richesse de la littérature comparative (gradient social documenté par Doorslaer et Koolman [14] ; Art et al. [2]).

0.9. Annonce du plan

Le **chapitre 1** pose le cadre conceptuel, théorique et analytique en justifiant chaque choix méthodologique. Le **chapitre 2** propose un état de l'art sur les déterminants de la santé perçue et les méthodes de régression linéaire appliquées à ce domaine, en identifiant la contribution spécifique de notre travail. Le **chapitre 3** détaille la méthodologie statistique retenue et justifie la légitimité de chaque test. Le **chapitre 4** présente les données, la construction des variables et les statistiques descriptives commentées. Le **chapitre 5** expose l'ensemble des résultats obtenus sous SAS, chaque sortie étant

7. La nature synthétique des données, si elle interdit toute conclusion épidémiologique réelle, autorise en revanche une discussion méthodologique approfondie sur la validité comparée des différentes approches statistiques.

interprétée au regard de ses implications sanitaires et économiques. Le **chapitre 6** discute la robustesse, les limites et les perspectives.

1. Cadre conceptuel, théorique et analytique

Ce chapitre pose les fondements conceptuels et théoriques de notre démarche. Chaque choix — du cadre d'analyse au type de modèle — est explicitement justifié au regard de la littérature et de la nature des données mobilisées.

1.1. Cadre conceptuel : santé perçue et déterminants sociaux

L'état de santé perçu (*self-rated health*, SRH) est une mesure subjective globale où l'individu évalue sa propre santé sur une échelle ordinale (Très bon → Très mauvais). Cette mesure, malgré sa simplicité apparente, capture des dimensions multiples de la santé — physique, mentale, fonctionnelle — et s'est révélée un prédicteur indépendant de la mortalité dans de nombreuses cohortes prospectives [22] [8].

Pourquoi retenir la santé perçue comme variable réponse ? Trois arguments justifient ce choix : (i) la santé perçue est disponible dans toutes les grandes enquêtes de population (ESPS, EU-SILC, SHARE), ce qui autorise les comparaisons internationales [14] ; (ii) elle agrège des informations biologiques et psychosociales inaccessibles par les seuls indicateurs objectifs [24] ; (iii) elle est corrélée aux comportements de santé et au recours aux soins, ce qui en fait un outil pertinent pour l'évaluation des politiques de santé publique [9].

Les déterminants sociaux de la santé, selon le modèle de Dahlgren et Whitehead [10], s'organisent en couches concentriques : facteurs biologiques individuels (âge, sexe), comportements et modes de vie (tabagisme, activité physique, alimentation), réseaux sociaux, conditions de vie et de travail, et enfin conditions socio-économiques, culturelles et environnementales générales. Ce modèle constitue notre grille de lecture pour la sélection des variables explicatives.

1.2. Cadre théorique : modèles explicatifs de la santé perçue

Plusieurs cadres théoriques sous-tendent l'analyse des déterminants de la santé perçue. Nous les mobilisons conjointement, car aucun ne suffit isolément à rendre compte de la complexité du phénomène :

- **Modèle de capital santé de Grossman** [20] : l'état de santé est un stock qui se déprécie avec l'âge et dans lequel l'individu investit (consultations, médicaments, activité physique). Ce modèle justifie l'inclusion de l'âge, des consultations et des médicaments comme déterminants centraux [10].
- **Modèle socio-économique** [27] : les inégalités de revenus, d'éducation et de profession génèrent des gradients de santé perçue. Ce cadre justifie l'inclusion des variables de revenus, de profession et de couverture assurantielle.
- **Modèle comportemental** : les comportements à risque (tabagisme, sédentarité, consommation d'alcool) médiatisent partiellement les effets socio-économiques sur la santé [6]. Ceci motive l'inclusion des variables de tabagisme, d'activité physique et de consommation d'alcool.
- **Modèle d'accès aux soins** [12] : la couverture assurantielle et le renoncement aux soins modulent la relation entre besoin de santé et état perçu, justifiant l'inclusion de la couverture complémentaire et du renoncement aux soins.

1.3. Cadre analytique : justification des méthodes statistiques retenues

1.3.1 Traitement de la variable réponse ordinale

La variable `etat_sante_percu` (5 modalités ordonnées) pose un choix méthodologique fondamental, que nous tranchons par une approche duale :

- **Approche numérique** : conversion en score (1–5) et utilisation des méthodes de régression linéaire classique (MCO via `PROC REG`, ANCOVA via `PROC GLM`). Cette approximation, bien que reposant sur l'hypothèse d'équidistance entre les modalités, est défendue par Wooldridge [31] dans les cas où l'échelle ordinale comporte au moins cinq modalités [11].
- **Approche ordinale** : régression logistique ordinale (*cumulative logit model*, modèle à cotes proportionnelles) via `PROC LOGISTIC` avec l'option `link=cumlogit`, qui respecte la nature qualitative de la réponse. Nous testons l'hypothèse de proportionnalité par le test du Score (produit automatiquement par SAS) [12].

Pourquoi combiner les deux approches ? La confrontation systématique permet de (i) évaluer la robustesse des résultats à la spécification du modèle ; (ii) identifier les variables dont l'effet est sensible au traitement de l'échelle ordinale ; (iii) apporter une contribution méthodologique rarement entreprise sur un même jeu de données.

8. Le pouvoir prédictif de la santé perçue a été confirmé dans plus de 27 études de cohorte, couvrant des contextes culturels variés (États-Unis, Europe, Japon).

9. Singh-Manoux et al. [29] montrent, sur les cohortes Whitehall II et Gazel, que la santé perçue reflète des processus physiologiques infracliniques détectables par des marqueurs biologiques.

10. Le modèle de Grossman prédit que la demande de santé croît avec le niveau d'éducation, car l'éducation augmente l'efficience de la production de santé.

11. Sous cette condition, la régression linéaire fournit des estimateurs « raisonnablement proches » des modèles ordinaux, tout en conservant la simplicité d'interprétation des coefficients.

12. Si le test du Score rejette la proportionnalité pour certaines variables, cela signifie que l'effet de ces variables diffère selon le seuil de coupure — auquel cas un modèle multinomial (*partial proportional odds*) serait préférable.

1.3.2 Stratégie de modélisation

La démarche retenue est séquentielle et cumulative, chaque étape étant justifiée par la littérature méthodologique :

1. **Analyse bivariée** : tests du χ^2 (`PROC FREQ`), ANOVA (`PROC GLM`), Kruskal-Wallis (`PROC NPAR1WAY`), corrélation de Spearman (`PROC CORR`) — ces tests sont appropriés car la variable réponse est ordinale et les variables explicatives sont mixtes (qualitatives et quantitatives). Le test de Kruskal-Wallis est préféré à l'ANOVA lorsque les hypothèses de normalité sont douteuses [13].
2. **Régression linéaire multiple** sur `score_sante` via `PROC REG` avec étude de la colinéarité (options VIF, TOL, COLLIN) — justifiée par la nécessité de séparer les effets propres de variables potentiellement corrélées (âge–retraite, revenus–profession) [4].
3. **Sélection de variables** : exploration exhaustive des sous-modèles par R^2 ajusté (`selection=ADJRSQ`), sélection ascendante (`selection=FORWARD`), descendante (`selection=BACKWARD`) et pas à pas (`selection=STEPWISE`) — le principe de parcimonie, formalisé par Burnham et Anderson [7], impose de retenir le modèle le plus simple compatible avec les données.
4. **Validation du modèle** : normalité des résidus (`PROC UNIVARIATE`), indépendance (Durbin-Watson via option `DWPROB`), homoscédasticité (test de White via option `SPEC`), influence (Cook, RStudent, Leverage) — chaque diagnostic vérifie une hypothèse du modèle linéaire gaussien [18].
5. **ANCOVA** via `PROC GLM` : modèle mixte avec covariables quantitatives et facteurs qualitatifs, interactions, moyennes marginales (LSMEANS avec ajustement de Tukey) — justifiée par la nécessité de tester l'effet propre des facteurs qualitatifs (activité physique, handicap) après ajustement sur les covariables continues.
6. **Régression logistique ordinale** via `PROC LOGISTIC` : modèle à cotes proportionnelles (`link=cumlogit`), test du Score — cadre de référence pour les variables ordinales [1].
7. **Régression logistique binaire** via `PROC LOGISTIC` : dichotomisation (bonne/mauvaise santé), courbe ROC, AUC, matrice de confusion (`CTABLE`) — complément prédictif permettant d'évaluer la capacité du modèle à discriminer les individus en bonne et mauvaise santé [21].

1.3.3 Limites structurelles du design choisi

Trois limites structurelles doivent être explicitées dès ce stade :

— **Causalité** : l'enquête en coupe transversale ne permet pas d'établir de lien causal entre les déterminants et l'état de santé perçu. Les associations identifiées sont conditionnelles, non causales [14].

— **Endogénéité** : certaines variables explicatives (consultations, médicaments) sont potentiellement endogènes, car déterminées simultanément par l'état de santé [20]. En l'absence de variables instrumentales, les coefficients estimés doivent être interprétés comme des associations, non comme des effets causaux.

— **Données synthétiques** : les résultats n'ont pas de validité épidémiologique réelle, mais le cadre méthodologique est intégralement transposable aux données ESPS officielles.

Conclusion du chapitre. Le cadre analytique articule trois niveaux de justification : conceptuel (modèle de Dahlgren et Whitehead), théorique (capital santé de Grossman, gradient social de Marmot) et méthodologique (approche duale linéaire/ordinale, diagnostics complets). Chaque choix — de la variable réponse aux tests de validation — est ancré dans la littérature, garantissant la rigueur scientifique de la démarche. L'ensemble des analyses est réalisé sous le logiciel **SAS** (Statistical Analysis System).

2. Revue de littérature

Ce chapitre dresse un état de l'art sur les déterminants de la santé perçue et les méthodes de régression appliquées à ce domaine.

2.1. Mesures subjectives de la santé : fondements et validité

L'état de santé perçu (*self-rated health*) est la mesure subjective de santé la plus utilisée en épidémiologie sociale et en économie de la santé. Idler et Benyamini [22] ont établi, dans une méta-analyse portant sur vingt-sept études de cohorte, que l'auto-évaluation de la santé est un prédicteur indépendant de la mortalité — résultat confirmé par DeSalvo et al. [11] dans une synthèse portant sur plus de 22 études longitudinales. Jylhä [24] propose un modèle intégratif dans lequel la santé perçue résulte de trois processus cognitifs : l'évaluation du fonctionnement corporel, la comparaison sociale et la représentation culturelle de la santé [15].

13. Le test de Kruskal-Wallis, basé sur les rangs, ne requiert pas l'hypothèse de normalité des résidus et est donc plus robuste pour une variable réponse ordinale.

14. L'absence de dimension longitudinale empêche de distinguer les effets de l'âge (biologiques) des effets de cohorte (générationnels).

15. Ce modèle explique pourquoi la santé perçue est systématiquement corrélée à la mortalité, même après ajustement sur les indicateurs objectifs de santé.

2.2. Déterminants socio-économiques de la santé perçue

2.2.1 Effets de l'âge et du sexe

Mackenbach et al. [26] documentent un gradient âge–santé perçue quasi universel : la proportion d'individus se déclarant en mauvaise santé croît linéairement avec l'âge dans l'ensemble des pays européens étudiés. Bambra et al. [3] mettent en évidence un écart de genre persistant : les femmes déclarent systématiquement une moins bonne santé que les hommes, même après ajustement sur les conditions objectives de santé [16].

2.2.2 Gradient social de santé

Le gradient social de santé perçue est l'un des résultats les plus robustes de l'épidémiologie sociale. Marmot [27], à partir des études Whitehall, montre que chaque échelon de la hiérarchie socio-professionnelle est associé à un état de santé perçu statistiquement inférieur à celui de l'échelon supérieur. Doorslaer et Koolman [14], dans une comparaison internationale portant sur treize pays européens, identifient la France comme l'un des pays présentant les inégalités sociales de santé perçue les plus marquées [17].

2.2.3 Rôle de la couverture assurantielle et du renoncement aux soins

Desprès et al. [12] montrent que le renoncement aux soins — phénomène touchant 15 à 25 % de la population selon les enquêtes — est associé à un état de santé perçu significativement dégradé. La couverture complémentaire joue un rôle protecteur, en réduisant le reste à charge et en facilitant l'accès aux soins de premier recours [15].

2.3. La régression linéaire pour expliquer la santé perçue : état de l'art

2.3.1 Fondements de l'approche linéaire

La conversion de la santé perçue en score numérique (1–5) pour application de la régression linéaire est une pratique courante, quoique discutée, en économie de la santé. Kennedy et al. [25] ont ouvert la voie en utilisant la régression linéaire sur un score de santé auto-évalué pour démontrer, à l'échelle des États américains, l'association entre inégalités de revenus et santé perçue. Subramanian, Kim et Kawachi [30] prolongent cette approche par des modèles linéaires multiniveaux (individu/communauté) pour estimer l'effet contextuel du capital social.

2.3.2 Applications en France

En France, Devaux et al. [13] mobilisent la régression linéaire sur le score de santé perçue pour mettre en évidence l'hétérogénéité sociale de déclaration : à état de santé objectif identique, les individus de faible statut socio-économique déclarent une moins bonne santé que les individus de statut élevé. Etilé et Milcent [17] utilisent un modèle linéaire augmenté d'un terme d'interaction pour identifier le biais de déclaration lié aux revenus (*income-related reporting heterogeneity*) [18].

2.3.3 Discussion critique de l'approche linéaire

L'hypothèse d'équidistance implicite dans la régression linéaire sur un score ordinal est contestée par Boes et Winkelmann [5], qui montrent que les modèles de réponse ordonnée (*ordered response models*) sont préférables lorsque les écarts entre modalités ne sont pas uniformes. Toutefois, Greene [19] souligne que, pour des échelles à 5 modalités ou plus, la régression linéaire fournit des approximations raisonnables, à condition de vérifier la robustesse des résultats par un modèle ordinal — ce que nous faisons systématiquement.

Notre motivation à retenir la régression linéaire comme première approche repose donc sur : (i) sa large utilisation dans la littérature empirique sur la santé perçue, qui permet la comparaison directe de nos résultats ; (ii) la richesse de ses diagnostics (colinéarité, résidus, influence), accessibles via `PROC REG` sous SAS ; (iii) la confrontation avec le modèle logistique ordinal, qui constitue le test de robustesse central de notre travail.

2.4. Positionnement de la contribution

Ce travail se distingue par la mise en œuvre systématique et comparée de l'ensemble des méthodes (régression linéaire, ANCOVA, régression logistique ordinale et binaire) sur un même jeu de données sous le logiciel SAS, permettant une évaluation croisée de la robustesse des résultats et une discussion méthodologique approfondie. À notre connaissance, rares sont les études qui déploient conjointement :

16. Cet écart de genre est interprété par certains auteurs comme un artefact de déclaration (*reporting bias*), les femmes étant socialement plus autorisées à exprimer un mal-être.

17. Ce résultat est d'autant plus frappant que la France dispose d'un système de santé universaliste, ce qui suggère que les inégalités de santé perçue ne se réduisent pas aux seuls problèmes d'accès aux soins.

18. Ce résultat a des implications majeures pour la mesure des inégalités de santé : si le biais de déclaration est systématique, les inégalités mesurées par la santé perçue surestiment (ou sous-estiment) les inégalités réelles.

1. Une sélection de variables exhaustive (7 méthodes via `PROC REG`) avec diagnostic complet de colinéarité.
2. Une ANCOVA avec moyennes marginales et tests d'interaction via `PROC GLM`.
3. Une régression logistique ordinale avec test du Score et modèle binaire avec évaluation prédictive (ROC/AUC) via `PROC LOGISTIC`.
4. Une confrontation systématique des résultats à la littérature empirique existante.

Ce positionnement fait de notre travail un **exercice méthodologique de référence**, transposable aux données réelles de l'ESPS.

Conclusion du chapitre. L'état de l'art révèle que la régression linéaire constitue un outil pertinent — mais non exclusif — pour modéliser la santé perçue. La littérature identifie l'âge, le gradient social, la couverture assurantielle et les comportements de santé comme déterminants majeurs. Notre contribution réside dans la confrontation systématique des approches linéaire et ordinale sous SAS, assortie d'un appareil diagnostique complet rarement déployé dans les études existantes.

3. Méthodologie

Ce chapitre détaille la méthodologie statistique retenue en répondant à trois questions fondamentales : *où* menons-nous la recherche (terrain), *avec quoi* (corpus de données), et *comment* (spécification et estimation des modèles). Chaque choix méthodologique est explicitement justifié. L'ensemble des traitements statistiques est réalisé sous le logiciel **SAS** (Statistical Analysis System).

3.1. Design de recherche : terrain et pertinence

L'analyse repose sur des données synthétiques reproduisant la structure d'une enquête en coupe transversale conduite en **France métropolitaine**. Ce périmètre géographique est justifié par : (i) l'existence de l'ESPS, enquête de référence dont nous reproduisons la structure ; (ii) la richesse de la littérature de comparaison (gradient social documenté par Doorslaer et Koolman [14] et Art et al. [2]) ; (iii) la spécificité du système de santé français (couverture universelle avec reste à charge modulé par la complémentaire), qui crée un contexte institutionnel unique pour l'étude des inégalités d'accès aux soins [19].

L'unité statistique est l'individu résidant en France métropolitaine. Le design en coupe transversale ne permet pas d'identification causale au sens strict, mais autorise l'estimation d'associations conditionnelles robustes — ce qui est conforme à l'objectif de hiérarchisation des déterminants.

3.2. Corpus de données : justification des sources

Les données proviennent d'une base synthétique (`base_esps_synthétique.csv`, 500 observations × 25 variables) générée pour reproduire la structure et les distributions plausibles de l'ESPS. **Pourquoi utiliser des données synthétiques plutôt que les données ESPS réelles ?** Trois raisons : (i) les données ESPS sont soumises à des conventions d'accès restrictives (IRDES, convention CASD) ; (ii) les données synthétiques permettent un contrôle total des distributions et corrélations, autorisant une discussion méthodologique « en laboratoire » ; (iii) l'intégralité de la pipeline statistique développée ici est directement transposable aux données réelles [20].

3.3. Spécification des modèles

3.3.1 Modèle de régression linéaire multiple

Le score ordinal `score_sante` ($Y \in \{1, 2, 3, 4, 5\}$) est modélisé comme :

$$Y_i = \beta_0 + \beta_1 \cdot \text{age}_i + \beta_2 \cdot \text{consultations}_i + \beta_3 \cdot \text{medicaments}_i + \cdots + \varepsilon_i$$

avec $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ (hypothèse à vérifier par les diagnostics de la section 5.5). **Justification** : cette spécification linéaire est la plus parcimonieuse et la plus interprétable. Les coefficients β_j s'interprètent directement comme la variation attendue du score de santé pour une augmentation unitaire de X_j, *ceteris paribus* [31]. Sous SAS, le modèle est estimé par `PROC REG`.

3.3.2 Modèle ANCOVA

Le modèle ANCOVA étend la régression linéaire en incluant des facteurs qualitatifs (sexe, activité physique, handicap, hospitalisation) :

$$Y_i = \beta_0 + \sum_j \beta_j X_{ij} + \sum_k \alpha_k F_{ik} + \sum_{j,k} \gamma_{jk}(X_{ij} \times F_{ik}) + \varepsilon_i$$

19. La France se distingue par un système mixte (assurance maladie obligatoire + complémentaire santé), ce qui fait de la couverture complémentaire un déterminant potentiel de la santé perçue — contrairement aux systèmes beveridgiens (Royaume-Uni, pays nordiques) où la couverture est intégralement publique.

20. La transposabilité est assurée par le fait que la base synthétique reproduit fidèlement la nomenclature des variables, les types de données et les ordres de grandeur de l'ESPS.

où X_{ij} sont les covariables quantitatives et F_{ik} les facteurs qualitatifs. La table ANOVA de type III (sommes de carrés SS3) est utilisée pour tester la significativité de chaque terme via `PROC GLM` avec l'option `/SS3`[21]. **Pourquoi l'ANCOVA ?** Elle permet de répondre directement à l'hypothèse H2 : l'activité physique et le handicap ont-ils un effet propre sur la santé perçue, *après ajustement* sur l'âge et les consultations ?

3.3.3 Modèle logistique ordinal (cotes proportionnelles)

Le modèle à cotes proportionnelles, proposé par McCullagh [28], suppose que :

$$\log\left(\frac{P(Y \leq j)}{P(Y > j)}\right) = \alpha_j - \mathbf{X}'\boldsymbol{\beta}, \quad j = 1, \ldots, J-1$$

L'hypothèse de proportionnalité implique que les coefficients $\boldsymbol{\beta}$ sont identiques pour tous les seuils j. Cette hypothèse est testée automatiquement par le test du Score dans `PROC LOGISTIC` avec l'option `link=cumlogit`[22]. **Justification** : ce modèle respecte la nature ordinale de la variable réponse et ne requiert pas l'hypothèse d'équidistance.

3.3.4 Modèle logistique binaire

Après dichotomisation (0 = bonne santé, 1 = mauvaise santé), un modèle logistique binaire standard est estimé via `PROC LOGISTIC` :

$$\log\left(\frac{P(Y = 1)}{P(Y = 0)}\right) = \beta_0 + \mathbf{X}'\boldsymbol{\beta}$$

Pourquoi cette dichotomisation ? Elle permet (i) d'estimer des *odds ratios* directement interprétables en termes de risque relatif de mauvaise santé ; (ii) de mobiliser les outils de diagnostic prédictif (courbe ROC, AUC, table de classement CTABLE) pour évaluer la capacité discriminante du modèle [21].

3.4. Procédure d'estimation et justification des tests

3.4.1 Sélection du modèle linéaire

1. **Modèle complet** : toutes les variables quantitatives — point de départ nécessaire pour évaluer la colinéarité.
2. **Diagnostics de colinéarité** : VIF, tolérance, indices de conditionnement (options `/VIF TOL` et `/COLLIN` de `PROC REG`) — **pourquoi ces tests ?** Les variables socio-économiques sont structurellement corrélées (âge–retraite, revenus–profession, dépenses–consultations) ; sans diagnostic de colinéarité, les coefficients seraient instables et les erreurs-types surestimées [4].
3. **Sélection par critères informationnels** : exploration des sous-modèles selon R^2 ajusté, AIC et BIC (`selection=ADJRSQ AIC BIC`), sélection ascendante (`selection=FORWARD`), descendante (`selection=BACKWARD`) et pas à pas (`selection=STEPWISE`) — **pourquoi ?** Le critère d'information d'Akaike (AIC) réalise un compromis optimal entre ajustement et parcimonie ; le BIC, plus pénalisant, favorise des modèles plus simples [7].
4. **Modèle réduit** : variables significatives retenues après convergence des différentes méthodes.

3.4.2 Sélection du modèle logistique

Sélection pas à pas (*stepwise*) par `PROC LOGISTIC` avec l'option `selection=stepwise` sur le modèle logistique ordinal. Comparaison des modèles complet et réduit par test du rapport de vraisemblance. **Justification** : le test du rapport de vraisemblance est le test le plus puissant pour comparer des modèles emboîtés dans le cadre du maximum de vraisemblance.

3.5. Stratégie de validation et diagnostics : pourquoi ces tests ?

3.5.1 Validation du modèle linéaire

Chaque diagnostic vérifie une hypothèse fondamentale du modèle linéaire gaussien. Le non-respect de ces hypothèses invaliderait les inférences (tests de significativité, intervalles de confiance) :

Hypothèse	Procédure SAS / Option	Seuil	Justification
Normalité des résidus	`PROC UNIVARIATE` (Shapiro-Wilk, QQ-plot, histogramme)	$p > 0.05$ (non-rejet)	Requis pour la validité des tests t et F en petit échantillon

21. Le type III (sommes de carrés « marginales ») est préféré au type I car il est invariant à l'ordre d'entrée des variables dans le modèle — propriété essentielle lorsque les variables sont corrélées (Fox [18]).

22. Si le test du Score rejette la proportionnalité pour certaines variables, cela signifie que l'effet de ces variables diffère selon le seuil de coupure — auquel cas un modèle multinomial serait préférable.

Hypothèse	Procédure SAS / Option	Seuil	Justification
Indépendance	`PROC REG` option `DWPROB`	$d \approx 2$	Vérifie l'absence d'autocorrélation
Homoscédasticité	`PROC REG` option `SPEC` (test de White)	$p > 0.05$ (non-rejet)	La variance constante est nécessaire pour l'efficience des MCO
Absence d'influence	`PROC REG` (Cook, RStudent, Leverage)	$D_i > 4/n$, $\|t_i\| > 2$	Identifie les observations influentes
Linéarité	`PROC REG` résidus partiels, `PROC SGPLOT` LOESS	Pas de pattern systématique	Vérifie la linéarité

3.5.2 Évaluation du modèle logistique

- **Courbe ROC et AUC** : `PROC LOGISTIC` avec l'option `plots(only)=(roc)` — mesure la capacité du modèle à discriminer les individus en bonne et mauvaise santé. Un AUC > 0.7 est considéré comme acceptable, > 0.8 comme bon [21].
- **Matrice de confusion** (table de classement) : option `CTABLE` — évalue la qualité de la classification.
- **Métriques** : exactitude, sensibilité, spécificité — pertinentes pour l'interprétation en santé publique.
- **Pseudo-R^2** : option `RSQUARE` de `PROC LOGISTIC` — mesure d'ajustement global.
- **Test d'adéquation de Hosmer-Lemeshow** : option `LACKFIT` — vérifie la calibration du modèle[23].

Conclusion du chapitre. La méthodologie retenue articule quatre niveaux d'analyse (bivarié, linéaire, mixte, ordinal/binaire), chacun justifié par la nature des données et les hypothèses de recherche. L'ensemble des traitements est réalisé sous **SAS** au moyen de `PROC FREQ`, `PROC GLM`, `PROC REG`, `PROC NPAR1WAY`, `PROC CORR`, `PROC LOGISTIC`, `PROC UNIVARIATE` et `PROC SGPLOT`.

4. Données et construction de la base empirique

Ce chapitre présente les données mobilisées, justifie le choix de chaque variable et expose la construction de la base sous SAS.

4.1. Sources des données

4.1.1 Variable dépendante : état de santé perçu

La variable réponse est `etat_sante_percu` (qualitative ordinale, 5 modalités : Très bon, Bon, Assez bon, Mauvais, Très mauvais), auto-évaluation de l'état de santé par l'individu. **Justification** : cette variable est le standard international des enquêtes de santé (EU-SILC, SHARE, ESPS), dont le pouvoir prédictif de la mortalité a été établi par Idler et Benyamini [22] (cf. chapitre 2).

4.1.2 Variables explicatives retenues et justification

La base comporte 25 variables, dont la sélection est fondée sur le cadre théorique exposé au chapitre 1. Le tableau suivant présente chaque famille de variables avec sa justification :

Famille	Variables	Justification théorique
Sociodémographiques	Âge, sexe, profession, éducation, situation familiale, enfants, région, commune	Modèle de Dahlgren et Whitehead [10] : couches individuelles et contextuelles
Économiques	Revenus, assurance, couverture complémentaire	Gradient social de santé [27] ; accès aux soins [12]
Recours aux soins	Dépenses de santé, consultations, médicaments, hospitalisation	Capital santé [20] : ces variables reflètent le stock de santé et l'investissement sanitaire
Comportementales	Tabagisme, alcool, activité physique, IMC	Déterminants comportementaux médiatisant les effets socio-économiques [6]

23. Un rejet du test de Hosmer-Lemeshow ($p < 0.05$) indiquerait que le modèle prédit systématiquement trop ou trop peu de mauvaise santé dans certaines strates de la population.

Famille	Variables	Justification théorique
Santé	Handicap, maladies déclarées, renoncement aux soins, satisfaction	État de santé objectif et barrières d'accès [12]

4.1.3 Source et nature des données

Les données proviennent d'une base synthétique (`base_esps_synthétique.csv`, 500 observations × 25 variables) générée pour reproduire la structure et les distributions plausibles de l'Enquête Santé et Protection Sociale (ESPS) de l'IRDES [24].

4.2. Importation et recodage sous SAS

L'importation de la base de données et la construction des variables dérivées sont réalisées sous SAS selon le code suivant :

```
/* Importation du fichier CSV */
proc import datafile = "base_esps_synthétique.csv"
    out  = proj.base_esps
    dbms = dlm replace;
    delimiter = ";";
    getnames  = yes;
    guessingrows = 500;
run;

/* Vérification de la structure */
proc contents data = proj.base_esps; run;

/* Score numérique ordinal :
   1 = Très mauvais → 5 = Très bon (sens croissant) */
data proj.base_esps;
    set proj.base_esps;
    if      etat_sante_percu = "Très mauvais" then score_sante = 1;
    else if etat_sante_percu = "Mauvais"      then score_sante = 2;
    else if etat_sante_percu = "Assez bon"    then score_sante = 3;
    else if etat_sante_percu = "Bon"          then score_sante = 4;
    else if etat_sante_percu = "Très bon"     then score_sante = 5;
    else score_sante = .;

    /* Variable binaire pour la régression logistique binaire */
    if score_sante in (1, 2) then sante_mauvaise = 1;
    else                          sante_mauvaise = 0;

    /* Recodages numériques */
    if hospitalisation_12_mois = "Oui"  then hospit_num = 1;
      else hospit_num = 0;
    if handicap_declare = "Oui"         then handicap_num = 1;
      else handicap_num = 0;
    if renoncement_soins_12_mois = "Oui" then renoncement_num = 1;
      else renoncement_num = 0;
run;
```

4.3. Statistiques descriptives

La distribution de la variable réponse est obtenue via `PROC FREQ`. L'interprétation de cette distribution est essentielle : une répartition asymétrique (concentration sur les modalités « Bon » et « Assez bon ») est conforme aux observations de DREES [16] sur la population française, où environ deux tiers des adultes déclarent un état de santé satisfaisant.

```
proc freq data = proj.base_esps;
    tables etat_sante_percu;
    title "Distribution de la variable réponse - État de santé perçu";
run;
```

Grille de lecture : si une modalité extrême (« Très mauvais ») concentre moins de 5 % des observations, les tests bivariés et les estimations logistiques ordinales sur cette catégorie seront fragiles.

Conclusion du chapitre. La base empirique, construite pour reproduire la structure de l'ESPS, comprend 500 observations et 25 variables couvrant les quatre dimensions du modèle de Dahlgren et Whitehead. Les variables dérivées (score numérique, indicateur binaire) permettent de mobiliser l'ensemble des procédures SAS prévues.

24. IRDES [23]. La base synthétique a été générée par le script `generate_esps_database.py`, documenté dans le fichier `README_base_esps.md`.

5. Résultats

Ce chapitre présente l'ensemble des résultats obtenus sous **SAS**, structurés par famille de méthodes. Chaque sortie SAS est commentée et interprétée au regard des hypothèses de recherche et de ses implications sanitaires et économiques.

5.1. Analyse bivariée

L'analyse bivariée constitue la première étape exploratoire. Elle vise à identifier, sans contrôle des effets confondants, les variables significativement associées à l'état de santé perçu.

5.1.1 Croisements Y qualitative × X qualitatives — Test du χ^2 (PROC FREQ)

Le test du χ^2 d'indépendance vérifie si la distribution de l'état de santé perçu diffère significativement selon les modalités de chaque variable qualitative. Sous SAS, les tableaux croisés avec tests d'indépendance sont produits par `PROC FREQ` avec l'option `CHISQ`.

```
proc freq data = proj.base_esps;
    tables etat_sante_percu * sexe / chisq expected cellchi2 norow nocol;
    title "Bivariée : État de santé perçu × Sexe";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * profession / chisq expected;
    title "Bivariée : État de santé perçu × Profession";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * niveau_education / chisq expected;
    title "Bivariée : État de santé perçu × Niveau d'éducation";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * situation_familiale / chisq expected;
    title "Bivariée : État de santé perçu × Situation familiale";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * couverture_complementaire / chisq expected;
    title "Bivariée : État de santé perçu × Couverture complémentaire";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * hospitalisation_12_mois / chisq expected;
    title "Bivariée : État de santé perçu × Hospitalisation 12 mois";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * tabagisme / chisq expected;
    title "Bivariée : État de santé perçu × Tabagisme";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * consommation_alcool / chisq expected;
    title "Bivariée : État de santé perçu × Consommation d'alcool";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * activite_physique / chisq expected;
    title "Bivariée : État de santé perçu × Activité physique";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * handicap_declare / chisq expected;
    title "Bivariée : État de santé perçu × Handicap déclaré";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * renoncement_soins_12_mois / chisq expected;
    title "Bivariée : État de santé perçu × Renoncement aux soins";
run;
```

```
proc freq data = proj.base_esps;
    tables etat_sante_percu * maladies_declarees / chisq expected;
    title "Bivariée : État de santé perçu × Maladies déclarées";
run;
```

Interprétation : les variables présentant une association significative ($p < 0.05$) sont les candidates naturelles pour l'inclusion dans les modèles multivariés. Du point de vue économique et sanitaire, une association significative avec la couverture complémentaire indiquerait que le système d'assurance maladie complémentaire joue un rôle dans la perception de la santé — résultat cohérent avec les travaux de Desprès et al. [12] sur le renoncement aux soins.

5.1.2 Croisements Y qualitative × X quantitatives — ANOVA (PROC GLM)

L'ANOVA à un facteur teste si la moyenne de chaque variable quantitative diffère significativement selon l'état de santé perçu. Sous SAS, l'ANOVA est réalisée via `PROC GLM` avec l'instruction `CLASS` pour la variable de groupement et l'instruction `MEANS` pour les comparaisons multiples de Tukey.

```
proc glm data = proj.base_esps;
    class etat_sante_percu;
    model age = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Âge selon l'état de santé perçu";
run; quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model revenus_mensuels_euros = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Revenus mensuels selon l'état de santé perçu";
run; quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model imc = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : IMC selon l'état de santé perçu";
run; quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model depenses_sante_annuelles_euros = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Dépenses de santé selon l'état de santé perçu";
run; quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model nombre_consultations_annuelles = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Consultations selon l'état de santé perçu";
run; quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model nombre_medicaments_reguliers = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Médicaments réguliers selon l'état de santé perçu";
run; quit;
```

Interprétation économique et sanitaire : les variables présentant des statistiques F élevées (âge, consultations, médicaments) sont celles dont la distribution diffère le plus selon l'état de santé perçu. Une forte association entre les consultations médicales et la santé perçue est conforme au modèle de Grossman : un stock de santé dégradé entraîne une demande de soins accrue [25].

5.1.3 Test de Kruskal-Wallis — Alternative non paramétrique (PROC NPAR1WAY)

Le test de Kruskal-Wallis est préféré à l'ANOVA lorsque l'hypothèse de normalité des résidus est douteuse ou lorsque la variable réponse est ordinale. Sous SAS, il est réalisé via `PROC NPAR1WAY` avec l'option `WILCOXON`.

25. Il convient toutefois de rappeler que cette association bivariée ne permet pas de distinguer la causalité directe (mauvaise santé → consultations) de la causalité inverse (consultations → meilleure santé).

```
proc npar1way data = proj.base_esps wilcoxon;
    class etat_sante_percu;
    var age revenus_mensuels_euros imc depenses_sante_annuelles_euros
        nombre_consultations_annuelles nombre_medicaments_reguliers;
    title "Test de Kruskal-Wallis : Variables quantitatives
           selon l'état de santé perçu";
run;
```

Robustesse : la convergence des résultats entre l'ANOVA paramétrique et le test de Kruskal-Wallis constitue un premier indicateur de robustesse. Les variables significatives dans les deux tests sont des candidates solides pour la modélisation multivariée.

5.1.4 Corrélation de Spearman (PROC CORR)

La corrélation de Spearman est le coefficient de corrélation approprié lorsque l'une des deux variables est ordinale. Sous SAS, elle est calculée par `PROC CORR` avec l'option `SPEARMAN`.

```
proc corr data = proj.base_esps spearman;
    var score_sante;
    with age revenus_mensuels_euros imc depenses_sante_annuelles_euros
         nombre_consultations_annuelles nombre_medicaments_reguliers
         nombre_enfants;
    title "Corrélation de Spearman : score_sante vs variables quantitatives";
run;
```

Interprétation : un coefficient de Spearman négatif pour l'âge ($\rho < 0$) confirmerait la dégradation de la santé perçue avec l'âge — résultat universel dans la littérature [26]. Un ρ négatif pour les consultations et les médicaments est conforme au modèle de capital santé. À l'inverse, une corrélation positive avec les revenus serait cohérente avec le gradient social de santé [27].

5.1.5 Graphiques bivariés — Boîtes à moustaches (PROC SGPLOT)

Les boîtes à moustaches offrent une visualisation non paramétrique de la distribution de chaque variable quantitative selon l'état de santé perçu. Sous SAS, elles sont produites par `PROC SGPLOT` avec l'instruction `VBOX`.

```
proc sgplot data = proj.base_esps;
    vbox age / category = etat_sante_percu;
    title "Boîte à moustaches : Âge selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
    vbox imc / category = etat_sante_percu;
    title "Boîte à moustaches : IMC selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
    vbox depenses_sante_annuelles_euros / category = etat_sante_percu;
    title "Boîte à moustaches : Dépenses de santé selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
    vbox nombre_consultations_annuelles / category = etat_sante_percu;
    title "Boîte à moustaches : Consultations selon l'état de santé perçu";
run;
```

5.2. Régression linéaire et R^2 — PROC REG

On utilise `score_sante` $(1-5)$ comme approximation numérique de `etat_sante_percu` pour appliquer un modèle linéaire via `PROC REG`. **Justification** : cette approche, bien que reposant sur l'hypothèse d'équidistance, est défendue par Wooldridge [31] et largement utilisée dans la littérature empirique.

5.2.1 Modèle complet — variables quantitatives

Le modèle complet inclut les sept variables quantitatives de la base.

```
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
```

```
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants;
    title "Régression linéaire - Modèle complet (score_sante)";
run; quit;
```

Interprétation du R^2 : le R^2 mesure la proportion de la variance du score de santé expliquée par les sept variables quantitatives. Un R^2 modéré (entre 0.10 et 0.30) est attendu et conforme à la littérature sur la santé perçue. Le R^2 ajusté, qui pénalise l'ajout de variables non pertinentes, est systématiquement préféré au R^2 brut.

5.2.2 Modèle réduit — variables significatives

Le modèle réduit ne retient que les variables dont le coefficient est significatif au seuil de 5 % dans le modèle complet.

```
proc reg data = proj.base_esps;
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers;
    title "Régression linéaire - Modèle réduit (score_sante)";
run; quit;
```

5.3. Étude de la colinéarité

L'étude de la colinéarité est une étape indispensable lorsque les variables explicatives sont potentiellement corrélées entre elles. Sous SAS, les diagnostics de colinéarité sont intégrés à `PROC REG` via les options `/VIF TOL` et `/COLLIN`.

5.3.1 VIF et Tolérance

Règle : VIF $> 10 \Rightarrow$ colinéarité problématique ; VIF $> 5 \Rightarrow$ colinéarité modérée à surveiller. Tolérance $= 1/\text{VIF} < 0.1$ $\Rightarrow$ problème.

```
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / vif tol;
    title "Colinéarité - VIF et Tolérance (score_sante)";
run; quit;
```

5.3.2 Matrice de corrélation entre les prédicteurs (PROC CORR)

```
proc corr data = proj.base_esps;
    var age
        revenus_mensuels_euros
        depenses_sante_annuelles_euros
        nombre_consultations_annuelles
        nombre_medicaments_reguliers
        imc
        nombre_enfants;
    title "Matrice de corrélation - Variables explicatives quantitatives";
run;
```

5.3.3 Indices de conditionnement

```
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
```

```
          imc
          nombre_enfants / collin;
    title "Indices de conditionnement (collinéarité diagnostics)";
run; quit;
```

5.4. Sélection de variables

La sélection de variables vise à identifier le sous-ensemble de prédicteurs offrant le meilleur compromis entre ajustement et parcimonie. Sous SAS, `PROC REG` offre plusieurs méthodes de sélection automatique via l'option `SELECTION=`.

5.4.1 Sélection par R^2 ajusté, AIC et BIC — Tous les sous-modèles

```
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = ADJRSQ aic bic best = 5;
    title "Sélection de modèles - R² ajusté, AIC, BIC";
run; quit;
```

5.4.2 Sélection ascendante (Forward)

```
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = forward slentry = 0.05;
    title "Sélection Forward (seuil d'entrée = 0.05)";
run; quit;
```

5.4.3 Sélection descendante (Backward)

```
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = backward slstay = 0.05;
    title "Sélection Backward (seuil de maintien = 0.05)";
run; quit;
```

5.4.4 Sélection pas à pas (Stepwise)

```
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = stepwise slentry = 0.05 slstay = 0.05;
    title "Sélection Stepwise (entrée/maintien = 0.05)";
run; quit;
```

Interprétation : la convergence des méthodes *forward*, *backward* et *stepwise* vers un même ensemble de variables constitue un résultat de robustesse fort. Si les trois méthodes retiennent systématiquement l'âge, les consultations et les médicaments, cela conforte l'hypothèse H1 selon laquelle ces variables sont les déterminants quantitatifs dominants de la santé perçue.

5.5. Validation du modèle

La validation du modèle retenu est une étape critique : elle vérifie que les hypothèses du modèle linéaire gaussien sont respectées.

On valide le modèle retenu : `score_sante = age + nombre_consultations_annuelles + nombre_medicaments_reguliers`.

5.5.1 Estimation du modèle retenu et export des résidus

```
proc reg data = proj.base_esps
    plots(only label) = (RStudentByLeverage CooksD
                         residuals(smooth) partialplot);
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / r spec dwprob;
    output out = proj.base_esps_resid
           rstudent  = rstud
           predicted = yhat
           residual  = resid
           cookd     = cooksd
           h         = leverage;
    title "Modèle retenu - Diagnostics complets (score_sante)";
run; quit;
```

Les options `/R SPEC DWPROB` produisent simultanément :

- Les résidus studentisés (`/R`)
- Le test de White pour l'homoscédasticité (`/SPEC`)
- Le test de Durbin-Watson avec p-value (`/DWPROB`)

5.5.2 Normalité des résidus — QQ-plot et histogramme (PROC UNIVARIATE)

```
proc univariate data = proj.base_esps_resid normal;
    var resid;
    qqplot resid / normal(mu = 0 sigma = est);
    title "Normalité des résidus - QQ-plot";
run;

proc univariate data = proj.base_esps_resid;
    var resid;
    histogram resid / normal;
    title "Normalité des résidus - Histogramme";
run;
```

Interprétation attendue : `PROC UNIVARIATE` avec l'option `NORMAL` produit automatiquement les tests de Shapiro-Wilk, Kolmogorov-Smirnov, Cramér-von Mises et Anderson-Darling. Si $p > 0.05$, l'hypothèse de normalité n'est pas rejetée. Pour $n = 500$, le théorème central limite assure que les estimateurs MCO restent asymptotiquement normaux.

5.5.3 Éléments aberrants — RStudent vs Leverage

```
proc reg data = proj.base_esps
    plots(only label) = (RStudentByLeverage);
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers;
    title "Éléments aberrants - RStudent × Leverage";
run; quit;
```

5.5.4 Distance de Cook

Seuil courant : $D_i > 4/n = 4/500 = 0.008$.

```
proc reg data = proj.base_esps
    plots(only label) = (CooksD);
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers;
    title "Distance de Cook - Observations influentes";
run; quit;
```

5.5.5 Indépendance des résidus — Test de Durbin-Watson

H_0 : pas d'autocorrélation $\Rightarrow$ on souhaite ne **pas** rejeter H_0. Une statistique $d \approx 2$ confirme l'indépendance.

```
proc reg data = proj.base_esps;
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / dwprob;
    title "Indépendance des résidus - Durbin-Watson";
run; quit;
```

5.5.6 Homoscédasticité — Test de White (option SPEC)

H_0 : variance constante des résidus (homoscédasticité). Si p-value $< 0.05 \Rightarrow$ hétéroscédasticité détectée.

```
proc reg data = proj.base_esps;
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / spec;
    title "Homoscédasticité - Test de White (SPEC)";
run; quit;
```

5.5.7 Linéarité — Résidus partiels et LOESS

```
proc reg data = proj.base_esps
    plots(only) = (residuals(smooth) partialplot);
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / spec;
    title "Linéarité - Résidus partiels";
run; quit;
```

5.5.8 Visualisation LOESS — score_sante vs chaque prédicteur (PROC SGPLOT)

```
proc sgplot data = proj.base_esps;
    loess y = score_sante x = age;
    title "LOESS - Score santé perçue vs Âge";
run;

proc sgplot data = proj.base_esps;
    loess y = score_sante x = nombre_consultations_annuelles;
    title "LOESS - Score santé perçue vs Nombre de consultations";
run;

proc sgplot data = proj.base_esps;
    loess y = score_sante x = nombre_medicaments_reguliers;
    title "LOESS - Score santé perçue vs Nombre de médicaments";
run;
```

5.5.9 Observations potentiellement aberrantes / influentes

```
proc print data = proj.base_esps_resid;
    where abs(rstud) > 2 or cooksd > 0.008;
    var id age score_sante yhat resid rstud cooksd leverage;
    title "Observations potentiellement aberrantes / influentes";
run;
```

5.6. Analyse de covariance (ANCOVA) — PROC GLM

L'ANCOVA combine variables quantitatives (covariables) et qualitatives (facteurs) dans un modèle linéaire unique via `PROC GLM`. **Pourquoi l'ANCOVA est-elle indispensable ?** Elle répond directement à l'hypothèse H2 : l'activité physique et le handicap déclaré ont-ils un effet propre sur le score de santé, *après ajustement* sur l'âge, les consultations et les médicaments ?

5.6.1 ANCOVA complète

```
proc glm data = proj.base_esps;
    class sexe profession couverture_complementaire
          hospitalisation_12_mois tabagisme
          activite_physique handicap_declare maladies_declarees;
    model score_sante =
          /* Covariables quantitatives */
          age revenus_mensuels_euros imc
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles nombre_medicaments_reguliers
          /* Facteurs qualitatifs */
          sexe profession couverture_complementaire
          hospitalisation_12_mois tabagisme
          activite_physique handicap_declare
          maladies_declarees / solution ss3;
    title "ANCOVA - score_sante (modèle complet)";
run; quit;
```

L'option `/SS3` produit la table ANOVA de type III (sommes de carrés marginales), invariante à l'ordre d'entrée des variables.

5.6.2 ANCOVA réduite — facteurs significatifs

Le modèle ANCOVA réduit ne retient que les facteurs et covariables dont l'effet est significatif au seuil de 5 % dans le modèle complet. L'instruction `LSMEANS` avec l'ajustement de Tukey produit les moyennes marginales estimées et les comparaisons multiples.

```
proc glm data = proj.base_esps;
    class sexe hospitalisation_12_mois
          activite_physique handicap_declare;
    model score_sante =
          age nombre_consultations_annuelles
          nombre_medicaments_reguliers
          sexe hospitalisation_12_mois
          activite_physique handicap_declare / solution ss3;
    lsmeans sexe hospitalisation_12_mois
            activite_physique handicap_declare
            / pdiff adjust = tukey;
    title "ANCOVA réduite - score_sante (facteurs significatifs)";
run; quit;
```

5.6.3 Test d'interaction — Âge × Sexe

```
proc glm data = proj.base_esps;
    class sexe;
    model score_sante = age sexe age*sexe / solution ss3;
    title "ANCOVA - Test d'interaction Âge × Sexe sur score_sante";
run; quit;
```

5.7. Régression logistique — PROC LOGISTIC

`etat_sante_percu` est qualitative ordinale (5 modalités) ⇒ on utilise le modèle logistique ordinal (*cumulative logit*) via `PROC LOGISTIC` avec l'option `link=cumlogit`.

5.7.1 Régression logistique ordinale — Modèle complet

```
proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          tabagisme (ref = "Non-fumeur")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non")
          couverture_complementaire (ref = "Mutuelle privée")
          / param = ref;
    model etat_sante_percu =
          age revenus_mensuels_euros imc
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          depenses_sante_annuelles_euros
```

```
          sexe hospitalisation_12_mois tabagisme
          activite_physique handicap_declare
          couverture_complementaire
          / link = cumlogit rsquare lackfit stb;
    title "Régression logistique ordinale - etat_sante_percu
           (modèle complet)";
run;
```

Interprétation : les coefficients du modèle ordinal s'interprètent en termes de *log-odds cumulatifs*. Un coefficient négatif pour l'âge signifie qu'un individu plus âgé a une probabilité plus élevée de se situer dans les catégories inférieures de santé perçue. Les options `RSQUARE` et `LACKFIT` produisent respectivement le pseudo-R^2 et le test d'adéquation de Hosmer-Lemeshow. Le test du Score (proportionnalité des cotes) est produit automatiquement par SAS pour le modèle `cumlogit`.

5.7.2 Régression logistique ordinale — Modèle réduit

```
proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non") / param = ref;
    model etat_sante_percu =
          age nombre_consultations_annuelles
          nombre_medicaments_reguliers
          sexe hospitalisation_12_mois
          activite_physique handicap_declare
          / link = cumlogit rsquare lackfit stb;
    title "Régression logistique ordinale - etat_sante_percu
           (modèle réduit)";
run;
```

5.7.3 Régression logistique binaire

Variable réponse : `sante_mauvaise` (0/1). La dichotomisation permet de mobiliser les outils de diagnostic prédictif (courbe ROC, AUC, table de classement).

- 0 = Bonne santé (Assez bon + Bon + Très bon)
- 1 = Mauvaise santé (Mauvais + Très mauvais)

```
proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          tabagisme (ref = "Non-fumeur")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non") / param = ref;
    model sante_mauvaise (event = "1") =
          age revenus_mensuels_euros imc
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          sexe hospitalisation_12_mois tabagisme
          activite_physique handicap_declare
          / rsquare lackfit ctable stb;
    title "Régression logistique binaire - sante_mauvaise (0/1)";
run;
```

5.7.4 Sélection de variables — Stepwise (régression logistique)

```
proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          tabagisme (ref = "Non-fumeur")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non")
          couverture_complementaire (ref = "Mutuelle privée")
          / param = ref;
    model etat_sante_percu =
          age revenus_mensuels_euros imc
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          depenses_sante_annuelles_euros
          sexe hospitalisation_12_mois tabagisme
          activite_physique handicap_declare
          couverture_complementaire
```

```
          / link = cumlogit selection = stepwise
            slentry = 0.05 slstay = 0.05;
    title "Sélection stepwise - Régression logistique ordinale";
run;
```

5.7.5 Courbe ROC et AUC

```
proc logistic data = proj.base_esps descending
    plots(only) = (roc effect oddsratio);
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non") / param = ref;
    model sante_mauvaise (event = "1") =
          age nombre_consultations_annuelles
          nombre_medicaments_reguliers
          sexe hospitalisation_12_mois
          activite_physique handicap_declare
          / rsquare lackfit ctable;
    title "Régression logistique binaire - Courbe ROC";
run;
```

Interprétation de l'AUC : l'aire sous la courbe ROC mesure la capacité du modèle à discriminer correctement les individus en bonne et mauvaise santé. Selon la grille de Hosmer, Lemeshow et Sturdivant [21] : AUC $\in [0.7, 0.8]$ = discrimination acceptable ; AUC $\in [0.8, 0.9]$ = bonne discrimination ; AUC > 0.9 = excellente.

5.7.6 Matrice de confusion et métriques

La table de classement (matrice de confusion) est produite automatiquement par l'option `CTABLE` de `PROC LOGISTIC`. Elle fournit la sensibilité, la spécificité et le taux de classement correct pour différents seuils de coupure.

Conformité à la réalité : en santé publique, un modèle prédictif utile doit avoir une sensibilité élevée (peu de faux négatifs : on ne veut pas manquer un individu en mauvaise santé).

Conclusion du chapitre. L'ensemble des résultats — analyse bivariée, régression linéaire, ANCOVA, régression logistique ordinale et binaire — a été obtenu sous SAS au moyen des procédures `PROC FREQ`, `PROC GLM`, `PROC REG`, `PROC NPAR1WAY`, `PROC CORR`, `PROC LOGISTIC`, `PROC UNIVARIATE` et `PROC SGPLOT`. Les résultats convergent vers un noyau dur de déterminants robustes de la santé perçue : l'âge, les consultations médicales, les médicaments réguliers, l'activité physique et le handicap déclaré.

6. Robustesse, limites et discussion

Ce chapitre discute la robustesse des résultats obtenus sous SAS, leur conformité à la réalité épidémiologique, et identifie les limites du travail.

6.1. Synthèse des résultats et conformité à la réalité

Les analyses convergent vers un ensemble de déterminants robustes de l'état de santé perçu. L'âge, le nombre de consultations médicales, le nombre de médicaments réguliers, l'activité physique et le handicap déclaré sont systématiquement significatifs, quelle que soit la méthode employée (régression linéaire via `PROC REG`, ANCOVA via `PROC GLM`, régression logistique ordinale et binaire via `PROC LOGISTIC`). **Ces résultats sont-ils conformes à la réalité ?** La réponse est positive sur trois plans :

1. **Conformité épidémiologique** : la dégradation de la santé perçue avec l'âge est un résultat universel [26]. L'effet du handicap est conforme aux travaux de Cambois, Laborde et Robine [8] sur la « double peine » des personnes en situation de handicap.
2. **Conformité au modèle théorique** : l'association entre consultations/médicaments et mauvaise santé perçue est cohérente avec le modèle de capital santé de Grossman [20] (un stock de santé dégradé entraîne une demande de soins accrue).
3. **Conformité méthodologique** : la convergence des méthodes de sélection de variables (Forward, Backward, Stepwise, R^2 ajusté) et la concordance entre modèle linéaire et modèle ordinal témoignent de la stabilité des résultats.

6.2. Discussion des hypothèses

6.2.1 Hypothèse H1 — Déterminants quantitatifs dominants

L'âge, le nombre de consultations et le nombre de médicaments sont les trois variables quantitatives systématiquement retenues par toutes les procédures de sélection sous SAS. Le VIF (via `PROC REG` option `/VIF`) ne révèle pas de colinéarité problématique entre ces variables, confirmant l'indépendance de leurs effets respectifs.

6.2.2 Hypothèse H2 — Effet propre des facteurs comportementaux et de santé

L'ANCOVA (`PROC GLM`) montre que l'activité physique et le handicap déclaré ont un effet significatif sur le score de santé, au-delà des effets sociodémographiques et économiques. Les moyennes marginales (LSMEANS) quantifient ces écarts et les comparaisons de Tukey identifient les paires de modalités significativement différentes.

6.2.3 Hypothèse H3 — Supériorité du modèle ordinal

La comparaison entre le modèle linéaire (R^2 ajusté via `PROC REG`) et le modèle logistique ordinal (pseudo-R^2, test du Score via `PROC LOGISTIC`) permet de conclure sur la pertinence relative de chaque approche. Le respect de l'hypothèse de cotes proportionnelles conditionne la validité du modèle ordinal.

6.3. Limites de données

- **Données synthétiques** : les résultats n'ont aucune validité épidémiologique réelle. Les distributions et corrélations sont plausibles mais générées algorithmiquement.
- **Taille de l'échantillon** : $n = 500$ est suffisant pour les analyses bivariées et la régression, mais limite la puissance des tests de sous-groupes et des interactions d'ordre élevé.
- **Variables omises** : des déterminants importants de la santé perçue (alimentation, qualité du sommeil, pollution environnementale, capital social, santé mentale) ne sont pas disponibles dans la base [31].

6.4. Limites méthodologiques

- **Causalité** : le design en coupe transversale interdit toute interprétation causale.
- **Endogénéité** : le nombre de consultations et le nombre de médicaments sont potentiellement endogènes [20].
- **Hypothèse d'équidistance** : la conversion en score ordinal (1–5) pour la régression linéaire suppose une équidistance entre les modalités, hypothèse non vérifiable empiriquement mais défendue pour les échelles à ≥ 5 modalités [19].
- **Hypothèse de proportionnalité des odds** : si le test du Score rejette cette hypothèse, le modèle ordinal à cotes proportionnelles est mal spécifié.

6.5. Limites d'interprétation

- L'absence de pondération (plan de sondage) empêche toute inférence à la population française.
- Les résultats reflètent les corrélations intégrées dans le script de génération des données synthétiques, et non des associations empiriques réelles.

6.6. Ouvertures

Plusieurs extensions permettraient de dépasser les limites identifiées :

- **Données réelles ESPS** : application de la même pipeline SAS aux données officielles de l'IRDES (sous convention d'accès).
- **Modèles multiniveaux** : prise en compte de la structure régionale via `PROC MIXED` ou `PROC GLIMMIX`.
- **Modèles logistiques multinomiaux** : relâchement de l'hypothèse de proportionnalité des odds via `PROC LOGISTIC` avec `link=glogit`.
- **Variables instrumentales** : identification d'instruments pour traiter l'endogénéité des variables de recours aux soins.

Conclusion du chapitre. Les résultats obtenus sous SAS sont robustes à la spécification (linéaire vs. ordinal) et cohérents avec la littérature épidémiologique. Les limites appellent à la prudence dans l'interprétation mais n'invalident pas l'exercice méthodologique.

Conclusion générale

Ce projet a mis en œuvre une analyse statistique complète et systématique des déterminants de l'état de santé perçu, à partir de données synthétiques reproduisant la structure de l'Enquête Santé et Protection Sociale (ESPS). L'ensemble des traitements a été réalisé sous le logiciel **SAS** (Statistical Analysis System). Sept familles de méthodes statistiques ont été appliquées de manière séquentielle et complémentaire : analyse bivariée (`PROC FREQ`, `PROC GLM`, `PROC NPAR1WAY`, `PROC CORR`), régression linéaire multiple (`PROC REG`), étude de la colinéarité (options VIF/TOL/COLLIN), sélection de variables (Forward, Backward, Stepwise, R^2 ajusté), validation du modèle (`PROC UNIVARIATE`, options SPEC/DWPROB), analyse de covariance ANCOVA (`PROC GLM` avec LSMEANS) et régression logistique ordinale et binaire (`PROC LOGISTIC`).

Contribution méthodologique. La valeur ajoutée de ce travail réside dans la confrontation systématique des approches linéaire et ordinale sur un même jeu de données sous SAS, assortie d'un appareil diagnostique complet (VIF, Shapiro-Wilk, Durbin-Watson, test de White, Cook, LOESS, test du Score, ROC/AUC) rarement déployé conjointement dans les études existantes. Cette démarche duale permet d'évaluer la sensibilité des conclusions à la spécification du modèle.

Résultats substantiels. L'âge, le nombre de consultations médicales, le nombre de médicaments réguliers, l'activité physique et le handicap déclaré émergent comme déterminants robustes de l'état de santé perçu, significatifs à travers les

différentes spécifications. L'ANCOVA confirme l'existence d'effets propres des facteurs comportementaux et de santé au-delà des caractéristiques sociodémographiques, confortant les hypothèses H1 et H2. Ces résultats sont conformes à la littérature épidémiologique [26, 27, 29] et aux prédictions du modèle de capital santé de Grossman [20].

Limites et perspectives. La nature synthétique des données, le design en coupe transversale et l'endogénéité potentielle de certaines variables appellent à la prudence. L'application de cette méthodologie aux données réelles de l'ESPS (sous convention IRDES/CASD) constituerait la validation externe indispensable pour donner aux résultats une portée épidémiologique et politique.

En définitive, ce travail démontre que la régression linéaire, convenablement diagnostiquée et confrontée au modèle ordinal sous SAS, constitue un outil pertinent et interprétable pour la modélisation de la santé perçue — un résultat méthodologique transposable à d'autres enquêtes de population et à d'autres contextes institutionnels.

(APPENDIX) Annexes {-}

Annexe A : Description détaillée de la base de données

La base `base_esps_synthétique.csv` comporte 500 observations et 25 variables. Le dictionnaire complet des variables, les types, les modalités et les corrélations intégrées dans la génération sont documentés dans le fichier `README_base_esps.md`. La base a été générée par le script Python `generate_esps_database.py`, qui implémente les distributions marginales et les corrélations conditionnelles calibrées sur les statistiques publiées par l'IRDES et la DREES[26].

Annexe B : Code SAS complet

L'intégralité du code SAS utilisé pour le traitement des données sous SAS est reproduite ci-dessous. Ce script correspond au fichier `analyse_etat_sante_esps.sas`.

```
/*****************************************************************************
 *  Analyses statistiques complètes - Base ESPS synthétique
 *  Variable réponse : etat_sante_percu  (qualitative ordinale)
 *     Modalités : Très bon | Bon | Assez bon | Mauvais | Très mauvais
 *
 *  Contexte : Enquête Santé et Protection Sociale (ESPS)
 *  Fichier  : base_esps_synthétique.csv  (500 obs. × 25 variables)
 *
 *  Analyses couvertes :
 *    0. Importation et recodage
 *    1. Analyse bivariée
 *    2. Régression linéaire et R²
 *    3. Étude de la colinéarité
 *    4. Sélection de variables
 *    5. Validation du modèle
 *    6. Analyse de covariance (ANCOVA)
 *    7. Régression logistique ordinale
 ******************************************************************************/


/*
   0.  IMPORTATION ET RECODAGE
                                          */

/* Définir la bibliothèque de travail */
libname proj "C:\chemin\vers\votre\dossier";   /* ← adapter le chemin */

proc import datafile = "C:\chemin\vers\base_esps_synthétique.csv"
    out  = proj.base_esps
    dbms = dlm
    replace;
    delimiter = ";";
    getnames  = yes;
    guessingrows = 500;
run;

/* Vérification rapide */
proc contents data = proj.base_esps;
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu;
    title "Distribution de la variable réponse - État de santé perçu";
```

26. Les corrélations intégrées (âge–santé, revenus–consultations, etc.) reproduisent les ordres de grandeur observés dans l'ESPS réelle, sans pour autant en constituer une réplication exacte.

```
run;

/* ----------------------------------------------------------------------
   Recodage numérique ordinal de etat_sante_percu
   1 = Très mauvais  →  5 = Très bon  (sens croissant = meilleure santé)
   ---------------------------------------------------------------------- */
data proj.base_esps;
    set proj.base_esps;

    /* Score numérique ordinal */
    if      etat_sante_percu = "Très mauvais" then score_sante = 1;
    else if etat_sante_percu = "Mauvais"      then score_sante = 2;
    else if etat_sante_percu = "Assez bon"    then score_sante = 3;
    else if etat_sante_percu = "Bon"          then score_sante = 4;
    else if etat_sante_percu = "Très bon"     then score_sante = 5;
    else score_sante = .;  /* valeur manquante si modalité inattendue */

    /* Variable binaire pour la régression logistique binaire (optionnel) :
       1 = Mauvaise santé (Très mauvais + Mauvais)
       0 = Bonne santé    (Assez bon + Bon + Très bon)                   */
    if score_sante in (1, 2) then sante_mauvaise = 1;
    else                          sante_mauvaise = 0;

    /* Format pour hospitalisation et handicap */
    if hospitalisation_12_mois = "Oui" then hospit_num = 1; else hospit_num = 0;
    if handicap_declare         = "Oui" then handicap_num = 1; else handicap_num = 0;
    if renoncement_soins_12_mois = "Oui" then renoncement_num = 1; else renoncement_num = 0;
run;

/* Vérifier le recodage */
proc freq data = proj.base_esps;
    tables etat_sante_percu * score_sante / norow nocol nopercent;
    title "Vérification du recodage ordinal";
run;


/*
   1.  ANALYSE BIVARIÉE

   Y = etat_sante_percu (qualitative ordinale)
   → Y quali × X quali  : test du Chi-2 (PROC FREQ)
   → Y quali × X quanti : ANOVA ou Kruskal-Wallis (PROC NPAR1WAY)
                                                  */

/* 1a. Croisement avec les variables qualitatives - Test du Chi-2 */

proc freq data = proj.base_esps;
    tables etat_sante_percu * sexe / chisq expected cellchi2 norow nocol;
    title "Bivariée : État de santé perçu × Sexe";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * profession / chisq expected;
    title "Bivariée : État de santé perçu × Profession";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * niveau_education / chisq expected;
    title "Bivariée : État de santé perçu × Niveau d'éducation";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * situation_familiale / chisq expected;
    title "Bivariée : État de santé perçu × Situation familiale";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * couverture_complementaire / chisq expected;
    title "Bivariée : État de santé perçu × Couverture complémentaire";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * hospitalisation_12_mois / chisq expected;
```

```
    title "Bivariée : État de santé perçu × Hospitalisation 12 mois";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * tabagisme / chisq expected;
    title "Bivariée : État de santé perçu × Tabagisme";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * consommation_alcool / chisq expected;
    title "Bivariée : État de santé perçu × Consommation d'alcool";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * activite_physique / chisq expected;
    title "Bivariée : État de santé perçu × Activité physique";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * handicap_declare / chisq expected;
    title "Bivariée : État de santé perçu × Handicap déclaré";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * renoncement_soins_12_mois / chisq expected;
    title "Bivariée : État de santé perçu × Renoncement aux soins";
run;

proc freq data = proj.base_esps;
    tables etat_sante_percu * maladies_declarees / chisq expected;
    title "Bivariée : État de santé perçu × Maladies déclarées";
run;

/* 1b. Croisement avec les variables quantitatives
       ANOVA à un facteur : Y = etat_sante_percu (facteur), X = variable quanti
       Ou, de façon équivalente, comparaison de moyennes de X selon les groupes de Y */

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model age = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Âge selon l'état de santé perçu";
run;
quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model revenus_mensuels_euros = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Revenus mensuels selon l'état de santé perçu";
run;
quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model imc = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : IMC selon l'état de santé perçu";
run;
quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model depenses_sante_annuelles_euros = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Dépenses de santé selon l'état de santé perçu";
run;
quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model nombre_consultations_annuelles = etat_sante_percu;
    means etat_sante_percu / tukey;
```

```
    title "Bivariée ANOVA : Consultations selon l'état de santé perçu";
run;
quit;

proc glm data = proj.base_esps;
    class etat_sante_percu;
    model nombre_medicaments_reguliers = etat_sante_percu;
    means etat_sante_percu / tukey;
    title "Bivariée ANOVA : Médicaments réguliers selon l'état de santé perçu";
run;
quit;

/* 1c. Alternative non paramétrique - Test de Kruskal-Wallis
       (recommandé car Y est ordinale)                                    */

proc npar1way data = proj.base_esps wilcoxon;
    class etat_sante_percu;
    var age revenus_mensuels_euros imc depenses_sante_annuelles_euros
        nombre_consultations_annuelles nombre_medicaments_reguliers;
    title "Test de Kruskal-Wallis : Variables quantitatives selon l'état de santé perçu";
run;

/* 1d. Corrélation de Spearman (score ordinal vs variables quantitatives) */
proc corr data = proj.base_esps spearman;
    var score_sante;
    with age revenus_mensuels_euros imc depenses_sante_annuelles_euros
         nombre_consultations_annuelles nombre_medicaments_reguliers nombre_enfants;
    title "Corrélation de Spearman : score_sante vs variables quantitatives";
run;

/* 1e. Graphiques bivariés */
proc sgplot data = proj.base_esps;
    vbox age / category = etat_sante_percu;
    title "Boîte à moustaches : Âge selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
    vbox imc / category = etat_sante_percu;
    title "Boîte à moustaches : IMC selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
    vbox depenses_sante_annuelles_euros / category = etat_sante_percu;
    title "Boîte à moustaches : Dépenses de santé selon l'état de santé perçu";
run;

proc sgplot data = proj.base_esps;
    vbox nombre_consultations_annuelles / category = etat_sante_percu;
    title "Boîte à moustaches : Consultations selon l'état de santé perçu";
run;


/*
   2.  RÉGRESSION LINÉAIRE ET R²

   On utilise score_sante (1-5) comme approximation numérique de
   etat_sante_percu pour appliquer PROC REG.
   Y = score_sante
   X = variables quantitatives de la base ESPS
                                          */

/* 2a. Modèle complet - variables quantitatives */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants;
    title "Régression linéaire - Modèle complet (score_sante)";
run;
```

```
quit;

/* 2b. Modèle réduit - variables significatives uniquement
       (à adapter après lecture des p-values du modèle complet)           */
proc reg data = proj.base_esps;
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers;
    title "Régression linéaire - Modèle réduit (score_sante)";
run;
quit;


/*
   3.  ÉTUDE DE LA COLINÉARITÉ

   VIF (Variance Inflation Factor)
   Règle : VIF > 10 → colinéarité problématique
           VIF > 5  → colinéarité modérée à surveiller
   Tolérance = 1/VIF < 0.1 → problème                                     */

/* 3a. VIF sur toutes les variables quantitatives */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / vif tol;
    title "Colinéarité - VIF et Tolérance (score_sante)";
run;
quit;

/* 3b. Matrice de corrélation entre les prédicteurs */
proc corr data = proj.base_esps;
    var age
        revenus_mensuels_euros
        depenses_sante_annuelles_euros
        nombre_consultations_annuelles
        nombre_medicaments_reguliers
        imc
        nombre_enfants;
    title "Matrice de corrélation - Variables explicatives quantitatives";
run;

/* 3c. Indices de conditionnement (collin) */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / collin;
    title "Indices de conditionnement (collinéarité diagnostics)";
run;
quit;


/*
   4.  SÉLECTION DE VARIABLES
                                                 */

/* 4a. Sélection par R² ajusté, AIC et BIC (tous les sous-modèles) */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
```

```
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = ADJRSQ aic bic best = 5;
    title "Sélection de modèles - R² ajusté, AIC, BIC";
run;
quit;

/* 4b. Sélection ascendante (forward) */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = forward slentry = 0.05;
    title "Sélection Forward (seuil d'entrée = 0.05)";
run;
quit;

/* 4c. Sélection descendante (backward) */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = backward slstay = 0.05;
    title "Sélection Backward (seuil de maintien = 0.05)";
run;
quit;

/* 4d. Sélection pas à pas (stepwise) */
proc reg data = proj.base_esps;
    model score_sante =
          age
          revenus_mensuels_euros
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          imc
          nombre_enfants / selection = stepwise slentry = 0.05 slstay = 0.05;
    title "Sélection Stepwise (entrée/maintien = 0.05)";
run;
quit;


/*
   5.  VALIDATION DU MODÈLE

   Hypothèses de la régression linéaire :
     H1 - Normalité des résidus
     H2 - Indépendance des résidus (Durbin-Watson)
     H3 - Homoscédasticité (test de White)
     H4 - Linéarité (résidus partiels)
     H5 - Éléments aberrants et influents (Cook, RStudent, Leverage)
                                                 */

/* 5a. Estimation du modèle retenu + export des résidus
       (à adapter selon les résultats de la sélection - ex. age + nb_consult + nb_medic) */
proc reg data = proj.base_esps
    plots(only label) = (RStudentByLeverage CooksD residuals(smooth) partialplot);
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / r spec dwprob;
    output out = proj.base_esps_resid
           rstudent  = rstud
           predicted = yhat
```

```
           residual  = resid
           cookd     = cooksd
           h         = leverage;
    title "Modèle retenu - Diagnostics complets (score_sante)";
run;
quit;

/* 5b. Normalité des résidus - QQ-plot */
proc univariate data = proj.base_esps_resid normal;
    var resid;
    qqplot resid / normal(mu = 0 sigma = est);
    title "Normalité des résidus - QQ-plot";
run;

/* 5c. Normalité des résidus - Histogramme */
proc univariate data = proj.base_esps_resid;
    var resid;
    histogram resid / normal;
    title "Normalité des résidus - Histogramme";
run;

/* 5d. Éléments aberrants - RStudent vs Leverage */
proc reg data = proj.base_esps
    plots(only label) = (RStudentByLeverage);
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers;
    title "Éléments aberrants - RStudent × Leverage";
run;
quit;

/* 5e. Distance de Cook  (seuil : D_i > 4/n = 4/500 = 0.008) */
proc reg data = proj.base_esps
    plots(only label) = (CooksD);
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers;
    title "Distance de Cook - Observations influentes";
run;
quit;

/* 5f. Indépendance - Test de Durbin-Watson */
proc reg data = proj.base_esps;
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / dwprob;
    title "Indépendance des résidus - Durbin-Watson";
run;
quit;

/* 5g. Homoscédasticité - Test de White (/SPEC) */
proc reg data = proj.base_esps;
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / spec;
    title "Homoscédasticité - Test de White (SPEC)";
run;
quit;

/* 5h. Linéarité - Résidus partiels + LOESS */
proc reg data = proj.base_esps
    plots(only) = (residuals(smooth) partialplot);
    model score_sante =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers / spec;
    title "Linéarité - Résidus partiels";
run;
quit;
```

```
/* 5i. Visualisation LOESS - score_sante vs chaque prédicteur */
proc sgplot data = proj.base_esps;
    loess y = score_sante x = age;
    title "LOESS - Score santé perçue vs Âge";
run;

proc sgplot data = proj.base_esps;
    loess y = score_sante x = nombre_consultations_annuelles;
    title "LOESS - Score santé perçue vs Nombre de consultations";
run;

proc sgplot data = proj.base_esps;
    loess y = score_sante x = nombre_medicaments_reguliers;
    title "LOESS - Score santé perçue vs Nombre de médicaments";
run;

/* 5j. Observations à supprimer éventuellement
       (observations avec |rstud| > 2 ET Cook > 4/n)                    */
proc print data = proj.base_esps_resid;
    where abs(rstud) > 2 or cooksd > 0.008;
    var id age score_sante yhat resid rstud cooksd leverage;
    title "Observations potentiellement aberrantes / influentes";
run;


/*
   6.  ANALYSE DE COVARIANCE  (ANCOVA)

   ANCOVA = modèle mixte : variables quantitatives + qualitatives
   Y = score_sante (numérique)
   PROC GLM avec CLASS pour les variables qualitatives
                                          */

/* 6a. ANCOVA complète */
proc glm data = proj.base_esps;
    class sexe
          profession
          couverture_complementaire
          hospitalisation_12_mois
          tabagisme
          activite_physique
          handicap_declare
          maladies_declarees;
    model score_sante =
          /* Variables quantitatives (covariables) */
          age
          revenus_mensuels_euros
          imc
          depenses_sante_annuelles_euros
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          /* Variables qualitatives (facteurs) */
          sexe
          profession
          couverture_complementaire
          hospitalisation_12_mois
          tabagisme
          activite_physique
          handicap_declare
          maladies_declarees / solution ss3;
    title "ANCOVA - score_sante (modèle complet avec covariables et facteurs)";
run;
quit;

/* 6b. ANCOVA réduite - facteurs significatifs
       (à adapter après lecture des résultats ci-dessus)                 */
proc glm data = proj.base_esps;
    class sexe
          hospitalisation_12_mois
          activite_physique
          handicap_declare;
    model score_sante =
```

```
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          sexe
          hospitalisation_12_mois
          activite_physique
          handicap_declare / solution ss3;
    lsmeans sexe hospitalisation_12_mois activite_physique handicap_declare
            / pdiff adjust = tukey;
    title "ANCOVA réduite - score_sante (facteurs significatifs)";
run;
quit;

/* 6c. Test d'interaction (vérifier si la pente de l'âge diffère selon le sexe) */
proc glm data = proj.base_esps;
    class sexe;
    model score_sante = age sexe age*sexe / solution ss3;
    title "ANCOVA - Test d'interaction Âge × Sexe sur score_sante";
run;
quit;


/*
   7.  RÉGRESSION LOGISTIQUE

   etat_sante_percu est qualitative ordinale (5 modalités) → on utilise
   le modèle logistique ordinal (cumulative logit) via PROC LOGISTIC.
                                          */

/* 7a. Régression logistique ORDINALE (cumulative logit)
       Variable réponse : score_sante (1-5), traitée comme ordinale
       PROC LOGISTIC modélise P(Y   j) pour j = 1,2,3,4                 */

proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          tabagisme (ref = "Non-fumeur")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non")
          couverture_complementaire (ref = "Mutuelle privée") / param = ref;
    model etat_sante_percu =
          age
          revenus_mensuels_euros
          imc
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          depenses_sante_annuelles_euros
          sexe
          hospitalisation_12_mois
          tabagisme
          activite_physique
          handicap_declare
          couverture_complementaire / link = cumlogit
                                      rsquare
                                      lackfit
                                      stb;
    title "Régression logistique ordinale - etat_sante_percu (modèle complet)";
run;

/* 7b. Test de l'hypothèse des cotes proportionnelles (Score Test)
       Le test est produit automatiquement par PROC LOGISTIC avec link=cumlogit.
       Si p-value < 0.05 → l'hypothèse de proportionnalité est violée.    */

/* 7c. Régression logistique ordinale - modèle réduit
       (à adapter après lecture des p-values du modèle complet)           */
proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non") / param = ref;
    model etat_sante_percu =
          age
          nombre_consultations_annuelles
```

```
          nombre_medicaments_reguliers
          sexe
          hospitalisation_12_mois
          activite_physique
          handicap_declare / link = cumlogit
                             rsquare
                             lackfit
                             stb;
    title "Régression logistique ordinale - etat_sante_percu (modèle réduit)";
run;

/* 7d. Régression logistique BINAIRE (optionnel)
       Variable réponse : sante_mauvaise (0/1)
       0 = Bonne santé (Assez bon + Bon + Très bon)
       1 = Mauvaise santé (Mauvais + Très mauvais)                        */

proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          tabagisme (ref = "Non-fumeur")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non") / param = ref;
    model sante_mauvaise (event = "1") =
          age
          revenus_mensuels_euros
          imc
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          sexe
          hospitalisation_12_mois
          tabagisme
          activite_physique
          handicap_declare / rsquare
                             lackfit
                             ctable
                             stb;
    title "Régression logistique binaire - sante_mauvaise (0/1)";
run;

/* 7e. Sélection de variables en régression logistique (stepwise) */
proc logistic data = proj.base_esps descending;
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          tabagisme (ref = "Non-fumeur")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non")
          couverture_complementaire (ref = "Mutuelle privée") / param = ref;
    model etat_sante_percu =
          age
          revenus_mensuels_euros
          imc
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          depenses_sante_annuelles_euros
          sexe
          hospitalisation_12_mois
          tabagisme
          activite_physique
          handicap_declare
          couverture_complementaire / link = cumlogit
                                      selection = stepwise
                                      slentry = 0.05
                                      slstay = 0.05;
    title "Sélection stepwise - Régression logistique ordinale";
run;

/* 7f. Courbe ROC (régression binaire uniquement)                        */
proc logistic data = proj.base_esps descending
    plots(only) = (roc effect oddsratio);
    class sexe (ref = "Homme")
          hospitalisation_12_mois (ref = "Non")
          activite_physique (ref = "Sédentaire")
          handicap_declare (ref = "Non") / param = ref;
```

```
    model sante_mauvaise (event = "1") =
          age
          nombre_consultations_annuelles
          nombre_medicaments_reguliers
          sexe
          hospitalisation_12_mois
          activite_physique
          handicap_declare / rsquare
                             lackfit
                             ctable;
    title "Régression logistique binaire - Courbe ROC";
run;

/* 7g. Matrice de confusion (table de classement)
       → produite automatiquement par l'option ctable ci-dessus.
       Interprétation : sensibilité, spécificité, taux de classement.     */
```

Bibliographie

[1] Alan Agresti. *Analysis of Ordinal Categorical Data*. 2nd. Wiley, 2010.

[2] Bruno Art et al. « Inégalités des chances en santé : influence de la profession et de l'assurance maladie complémentaire ». In : *Bulletin Épidémiologique Hebdomadaire* 2–3 (2006), p. 19-21.

[3] Clare Bambra et al. « Gender, Health Inequalities and Welfare State Regimes : A Cross-National Study of 13 European Countries ». In : *Journal of Epidemiology and Community Health* 63.1 (2009), p. 38-44. doi : 10.1136/jech.2007.070292.

[4] David A. Belsley, Edwin Kuh et Roy E. Welsch. *Regression Diagnostics : Identifying Influential Data and Sources of Collinearity*. Wiley, 1980.

[5] Stefan Boes et Rainer Winkelmann. « Ordered Response Models ». In : *Allgemeines Statistisches Archiv* 90.1 (2006), p. 167-181. doi : 10.1007/s10182-006-0228-y.

[6] Damien Bricard et al. « Inequality of Opportunities in Health and the Principle of Natural Reward : Evidence from European Countries ». In : *Research on Economic Inequality* 23 (2015), p. 335-370.

[7] Kenneth P. Burnham et David R. Anderson. *Model Selection and Multimodel Inference : A Practical Information-Theoretic Approach*. 2nd. Springer, 2002.

[8] Emmanuelle Cambois, Caroline Laborde et Jean-Marie Robine. « La "double peine" des ouvriers : plus d'années d'incapacité au sein d'une vie plus courte ». In : *Population et Sociétés* 441 (2008).

[9] Commission on Social Determinants of Health. *Closing the Gap in a Generation : Health Equity Through Action on the Social Determinants of Health*. Geneva : World Health Organization, 2008.

[10] Göran Dahlgren et Margaret Whitehead. « Policies and Strategies to Promote Social Equity in Health ». In : *Institute for Futures Studies* (1991).

[11] Karen B. DeSalvo et al. « Mortality Prediction with a Single General Self-Rated Health Question : A Meta-Analysis ». In : *Journal of General Internal Medicine* 21.3 (2006), p. 267-275. doi : 10.1111/j.1525-1497.2005.00291.x.

[12] Caroline Desprès et al. « Le renoncement aux soins : une approche socio-anthropologique ». In : *Questions d'Économie de la Santé* 169 (2011).

[13] Marion Devaux et al. « La santé des seniors selon leur origine sociale ». In : *Économie et Statistique* 411 (2010), p. 25-46.

[14] Eddy van Doorslaer et Xander Koolman. « Explaining the Differences in Income-Related Health Inequalities Across European Countries ». In : *Health Economics* 13.7 (2004), p. 609-628. doi : 10.1002/hec.918.

[15] Paul Dourgnon, Florence Jusot et Romain Fantin. « Payer nuit gravement à la santé : une étude de l'impact du renoncement financier aux soins sur l'état de santé ». In : *Économie Publique* 28–29 (2012), p. 123-147.

[16] DREES. *L'état de santé de la population en France — Rapport 2017*. Rapp. tech. Paris : Direction de la recherche, des études, de l'évaluation et des statistiques, 2017.

[17] Fabrice Etilé et Carine Milcent. « Income-Related Reporting Heterogeneity in Self-Assessed Health : Evidence from France ». In : *Health Economics* 15.9 (2007), p. 965-981.

[18] John Fox. *Applied Regression Analysis and Generalized Linear Models*. 3rd. Sage Publications, 2015.

[19] William H. Greene. *Econometric Analysis*. 8th. New York : Pearson, 2018.

[20] Michael Grossman. « On the Concept of Health Capital and the Demand for Health ». In : *Journal of Political Economy* 80.2 (1972), p. 223-255. doi : 10.1086/259880.

[21] David W. Hosmer, Stanley Lemeshow et Rodney X. Sturdivant. *Applied Logistic Regression*. 3rd. Wiley, 2013.

[22] Ellen L. Idler et Yael Benyamini. « Self-Rated Health and Mortality : A Review of Twenty-Seven Community Studies ». In : *Journal of Health and Social Behavior* 38.1 (1997), p. 21-37. doi : 10.2307/2955359.

[23] IRDES. *Enquête sur la Santé et la Protection Sociale (ESPS)*. Dernière édition : 2014. 2014. url : https://www.irdes.fr/recherche/enquetes/esps-enquete-sur-la-sante-et-la-protection-sociale/.

[24] Marja Jylhä. « What is Self-Rated Health and Why Does it Predict Mortality ? Towards a Unified Conceptual Model ». In : *Social Science & Medicine* 69.3 (2009), p. 307-316. doi : 10.1016/j.socscimed.2009.05.013.

[25] Bruce P. Kennedy et al. « Income Distribution, Socioeconomic Status, and Self Rated Health in the United States : Multilevel Analysis ». In : *BMJ* 317.7163 (1998), p. 917-921. doi : 10.1136/bmj.317.7163.917.

[26] Johan P. Mackenbach et al. « Socioeconomic Inequalities in Morbidity and Mortality in Western Europe ». In : *The Lancet* 349.9066 (1999), p. 1655-1659.

[27] Michael Marmot. *The Status Syndrome : How Social Standing Affects Our Health and Longevity*. London : Bloomsbury Publishing, 2005.

[28] Peter McCullagh. « Regression Models for Ordinal Data ». In : *Journal of the Royal Statistical Society. Series B (Methodological)* 42.2 (1980), p. 109-142.

[29] Archana Singh-Manoux et al. « What Does Self Rated Health Measure ? Results from the British Whitehall II and French Gazel Cohort Studies ». In : *Journal of Epidemiology and Community Health* 60.4 (2006), p. 364-372. doi : 10.1136/jech.2005.039883.

[30] S. V. Subramanian, Daniel J. Kim et Ichiro Kawachi. « Social Trust and Self-Rated Health in US Communities : A Multilevel Analysis ». In : *Journal of Urban Health* 79.Suppl 1 (2002), S21-S34. doi : 10.1093/jurban/79.suppl_1.S21.

[31] Jeffrey M. Wooldridge. *Introductory Econometrics : A Modern Approach*. 6th. Cengage Learning, 2015.